Appunti di Probabilità

Carbone Davide [1]

A.A. 2026/2027

[1]Lezioni della prof.ssa P. Siri.

Indice

1 Complementi all'esame di Metodi Matematici per l'Ingegneria **2**
1.1 Funzione Gamma di Eulero . . . 2
1.2 Variabile aleatoria Gamma . . . 2

2 Spazi prodotto e misura prodotto **6**

3 Vettori aleatori **15**
3.1 Vettori aleatori discreti . . . 18
3.2 Vettori aleatori assolutamente continui . . . 23
3.3 Variabili aleatorie indipendenti . . . 28
3.4 Valori attesi . . . 40
3.5 Covarianza e correlazione . . . 41

4 Trasformazioni di variabili e vettori aleatori **50**
4.1 Trasformazioni di variabili aleatorie . . . 50
4.1.1 Caso discreto . . . 50
4.1.2 Caso assolutamente continuo . . . 51
4.2 Trasformazioni di vettori aleatori . . . 56
4.2.1 Caso discreto . . . 56
4.2.2 Caso assolutamente continuo . . . 58
4.3 Variabile aleatoria Beta . . . 65

5 Funzioni Caratteristiche **69**
5.1 Proprietà delle funzioni caratteristiche . . . 71

6 Condizionamento **76**
6.1 Condizionamento di variabili aleatorie discrete . . . 76
6.1.1 Proprietà caratterizzanti dell'attesa condizionata $\mathbb{E}[X|Y]$ nel caso discreto . . . 78
6.2 Attesa condizionata rispetto ad una σ-algebra . . . 81
6.2.1 Proprietà dell'attesa condizionata rispetto ad una σ-algebra . . . 87
6.3 Varianza condizionata . . . 93

7 Convergenza di sucessioni di variabili aleatorie **96**
7.1 Convergenza q.c., $\mathbb{P}$ e in L^p . . . 96
7.2 Legge dei grandi numeri . . . 106
7.2.1 Applicazione: Metodo Montecarlo . . . 108
7.3 Convergenza in legge . . . 109
7.3.1 Criteri di convergenza in legge . . . 111
7.3.2 Proprietà della convergenza in legge . . . 113
7.4 Teorema del limite centrale . . . 115

Capitolo 1

Complementi all'esame di Metodi Matematici per l'Ingegneria

1.1 Funzione Gamma di Eulero

Definizione 1.1.1. Definiamo la funzione Gamma di Eulero come $\Gamma : (0, +\infty) \to (0, +\infty)$

$$\alpha \mapsto \Gamma(\alpha) = \int_0^{+\infty} y^{\alpha-1} e^{-y}\, dy$$

Calcoliamo alcuni valori della funzione Gamma.

- $$\Gamma(1) = \int_0^{+\infty} y^{1-1} e^{-y}\, dy = \int_0^{+\infty} e^{-y}\, dy = \int_{-\infty}^{+\infty} f_Y(y)\, dy = 1,$$

  dove

  $$f_Y(y) = e^{-y} \mathbb{1}_{(0,+\infty)}(y),$$

  cioè

  $$Y \sim \text{Exp}(1).$$

- Per $\alpha > 0$,

$$\Gamma(\alpha+1) = \int_0^{+\infty} y^{\alpha} e^{-y}\, dy \overset{\text{I.P.P.}}{=} \underbrace{\left(-y^{\alpha} e^{-y}\right)\Big|_0^{+\infty}}_{=0} + \int_0^{+\infty} \alpha y^{\alpha-1} e^{-y}\, dy$$

$$= \alpha \int_0^{+\infty} y^{\alpha-1} e^{-y}\, dy = \alpha\Gamma(\alpha).$$

- $$\Gamma(n) = (n-1)\Gamma(n-1) = (n-1)(n-2)\Gamma(n-2) = \dots$$
$$= (n-1)(n-2)\cdots 1 \underbrace{\Gamma(1)}_{=1} = (n-1)!, \qquad \forall\, n \in \mathbb{N}^* = \mathbb{N} \setminus \{0\}.$$

1.2 Variabile aleatoria Gamma

Definizione 1.2.1. Diciamo che la variabile aleatoria assolutamente continua X ha legge gamma di parametri $\alpha > 0$ (parametro di forma) e $\lambda > 0$ (parametro di scala) e denotiamo con

$$X \sim \Gamma(\alpha, \lambda) \qquad \text{oppure} \qquad X \sim \text{Gamma}(\alpha, \lambda)$$

se ha funzione di densità

$$f_X(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} \mathbb{1}_{(0,+\infty)}(x)$$

Osservazione: f_X è una funzione di densità:

- f_X è misurabile
- $f_X \geq 0$
- $$\int_{-\infty}^{+\infty} f_X(x)\,dx = \int_0^{+\infty} \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}\,dx \overset{y=\lambda x}{=} \frac{1}{\Gamma(\alpha)} \int_0^{+\infty} y^{\alpha-1} e^{-y}\,dy = \frac{1}{\Gamma(\alpha)} \cdot \Gamma(\alpha) = 1$$

Osservazione:

$$\mathbb{P}(X \geq 0) = \int_{(0,+\infty)} f_X(x)\,dx = 1 \qquad \Rightarrow \qquad X \geq 0 \text{ q.o.}$$

Vediamo i seguenti casi particolari

- Se $\alpha = 1$

  $$X \sim \Gamma(1, \lambda)$$

  $$f_X(x) = \frac{\lambda^1}{\Gamma(1)} x^{1-1} e^{-\lambda x} \mathbb{1}_{(0,+\infty)}(x) = \lambda e^{-\lambda x} \mathbb{1}_{(0,+\infty)}(x)$$

  ovvero X è un'esponenziale di parametro λ

  $$X \sim \text{Exp}(\lambda).$$

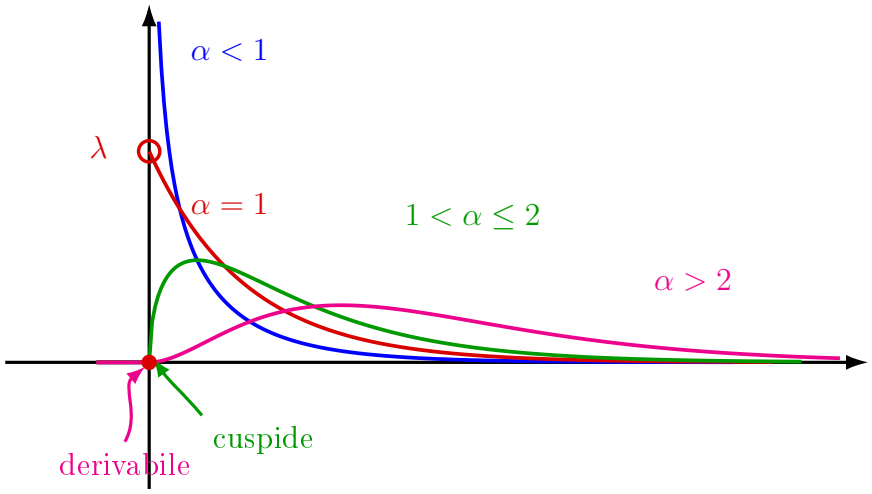
- Se $\alpha = n \in \mathbb{N}^*$

  $$X \sim \Gamma(n, \lambda)$$

  $$f_X(x) = \frac{\lambda^n}{(n-1)!} x^{n-1} e^{-\lambda x} \mathbb{1}_{(0,+\infty)}(x)$$

  Chiamiamo la variabile Gamma ristretta ai parametri interi positivi variabile Erlang e indichiamo

  $$X \sim \text{Erlang}(n, \lambda).$$



Calcoliamo ora media e varianza di $X \sim \Gamma(\alpha, \lambda)$.

- $$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x f_X(x)\,dx = \int_0^{+\infty} x \cdot \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}\,dx$$
$$= \frac{\lambda^\alpha}{\Gamma(\alpha)} \frac{\Gamma(\alpha+1)}{\lambda^{\alpha+1}} \underbrace{\int_0^{+\infty} \frac{\lambda^{\alpha+1}}{\Gamma(\alpha+1)} x^\alpha e^{-\lambda x}\,dx}_{\substack{\text{densità di } \Gamma(\alpha+1,\lambda) \\ =1}}$$
$$= \frac{\lambda^\alpha}{\Gamma(\alpha)} \cdot \frac{\Gamma(\alpha+1)}{\lambda^{\alpha+1}} = \frac{\lambda^\alpha}{\Gamma(\alpha)} \cdot \frac{\alpha\Gamma(\alpha)}{\lambda^{\alpha+1}} = \frac{\alpha}{\lambda} \qquad \Rightarrow \qquad \mathbb{E}[X] = \frac{\alpha}{\lambda}.$$

- $$\mathbb{E}[X^2] = \int_{-\infty}^{+\infty} x^2 f_X(x)\,dx = \int_0^{+\infty} x^2 \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}\,dx$$
$$= \frac{\lambda^\alpha}{\Gamma(\alpha)} \frac{\Gamma(\alpha+2)}{\lambda^{\alpha+2}} \underbrace{\int_0^{+\infty} \frac{\lambda^{\alpha+2}}{\Gamma(\alpha+2)} x^{\alpha+1} e^{-\lambda x}\,dx}_{\substack{\text{densità di } \Gamma(\alpha+2,\lambda) \\ =1}}$$
$$= \frac{\lambda^\alpha}{\Gamma(\alpha)} \cdot \frac{\alpha(\alpha+1)\Gamma(\alpha)}{\lambda^{\alpha+2}} = \frac{\alpha(\alpha+1)}{\lambda^2}$$

$$\Rightarrow \quad \operatorname{var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \frac{\alpha(\alpha+1)}{\lambda^2} - \frac{\alpha^2}{\lambda^2} \Rightarrow \operatorname{var}(X) = \frac{\alpha}{\lambda^2}.$$

Sia $T_n \sim \text{Erlang}(n, \lambda)$ ($T_n \sim \Gamma(n, \lambda)$).

$$\forall\, t \leq 0 \qquad F_{T_n}(t) = 0.$$

$$\forall\, t > 0 \qquad F_{T_n}(t) = \int_0^t \frac{\lambda^n}{(n-1)!} x^{n-1} e^{-\lambda x}\,dx \overset{\text{IPA}}{=}$$
$$= \frac{\lambda^n}{(n-1)!} \left[x^{n-1} \left(-\frac{1}{\lambda} e^{-\lambda x} \right) \right]_0^t + \int_0^t \frac{\lambda^n}{(n-1)!} (n-1) x^{n-2} \frac{1}{\lambda} e^{-\lambda x}\,dx$$

$$= -\frac{\lambda^{n-1}}{(n-1)!}t^{n-1}e^{-\lambda t} + \underbrace{\int_0^t \frac{\lambda^{n-1}}{(n-2)!}x^{n-2}e^{-\lambda x}\,dx}_{F_{T_{n-1}}(t) \text{ con } T_{n-1}\sim\Gamma(n-1,\lambda)}$$

$$= -\frac{\lambda^{n-1}}{(n-1)!}t^{n-1}e^{-\lambda t} - \frac{\lambda^{n-2}}{(n-2)!}t^{n-2}e^{-\lambda t} + \underbrace{\int_0^t \frac{\lambda^{n-2}}{(n-3)!}x^{n-3}e^{-\lambda x}\,dx}_{F_{T_{n-2}}(t) \text{ con } T_{n-2}\sim\Gamma(n-2,\lambda)}$$

$$= -\frac{\lambda^{n-1}}{(n-1)!}t^{n-1}e^{-\lambda t} - \frac{\lambda^{n-2}}{(n-2)!}t^{n-2}e^{-\lambda t} - \dots$$

$$\dots - \frac{\lambda^1}{1!}t^1e^{-\lambda t} + F_{T_1}(t)$$

con $T_1 \sim \Gamma(1,\lambda)$ cioè $T_1 \sim \text{Exp}(\lambda)$

$$\Rightarrow F_{T_1}(t) = 1 - e^{-\lambda t} = 1 - \frac{\lambda^0}{0!}t^0e^{-\lambda t} \qquad (\text{se } t > 0)$$

$$\Rightarrow F_{T_n}(t) = 1 - \sum_{k=0}^{n-1}\frac{\lambda^k}{k!}t^ke^{-\lambda t} = 1 - \sum_{k=0}^{n-1}\frac{(\lambda t)^k}{k!}e^{-\lambda t} \text{ se } t > 0.$$

Poniamo $N_t \sim P(\lambda t) \Rightarrow \mathbb{P}(N_t = k) = e^{-(\lambda t)}\frac{(\lambda t)^k}{k!} \quad \forall k \in \mathbb{N}$. Otteniamo quindi che

- $$F_{T_n}(t) = \mathbb{P}(T_n \le t) = 1 - \sum_{k=0}^{n-1}\mathbb{P}(N_t = k)$$
$$= 1 - \mathbb{P}(N_t \le n-1) = \mathbb{P}(N_t > n-1) = S_{N_t}(n-1)$$
$$= \mathbb{P}(N_t \ge n) \qquad \forall\, t > 0.$$

- $$S_{T_n}(t) = \mathbb{P}(T_n > t) = \mathbb{P}(N_t < n) = F_{N_t}(n-1) \qquad \forall\, t > 0.$$

Considerando anche il fatto che il numero medio di eventi in $[0,t]$ è λt e che $N_1 \sim P(\lambda)$ rappresnta il numero di eventi in $[0,1]$ possiamo concludere che $N_t \sim P(\lambda t)$ rappresenta il numero di eventi in $[0,t]$. Sappiamo quindi che la probabilià che in $[0,t]$ ci siano stati più di $n-1$ eventi è $S_{N_t}(n-1) = F_{T_n}(t) = \mathbb{P}(T_n \le t)$ ovvero è uguale alla probabilità che T_n sia minore o uguale a t. T_n deve quindi rappresentare l'istante in cui succede l'n-esimo evento. In particolare $T_1 \sim \text{Exp}(\lambda)$ rappresenta l'istante in cui accade il primo evento. Ancora una volta identifichiamo quindi l'esponenziale come un analogo continuo della geometrica.

Capitolo 2

Spazi prodotto e misura prodotto

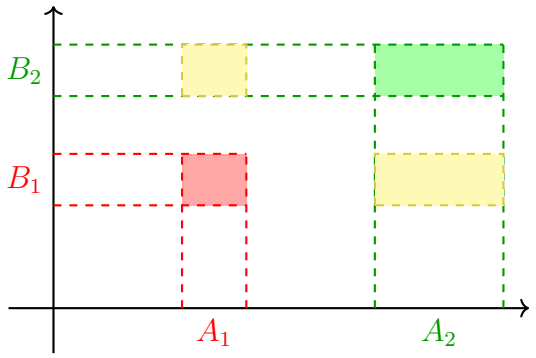
Siano $(X_1, \mathcal{A}_1, \mu_1)$ e $(X_2, \mathcal{A}_2, \mu_2)$ spazi di misura.
Vogliamo dotare l'insieme $X_1 \times X_2$ di una struttura di spazio di misura che sia in un certo senso indotta dalla struttura di spazio di misura delle componenti.

Definizione 2.0.1. Si dice rettangolo misurabile un insieme del tipo $A \times B$ con $A \in \mathcal{A}_1$ e $B \in \mathcal{A}_2$.

L'insieme dei rettangoli misurabili non è una σ-algebra, perché in generale

$$(A_1 \times B_1) \cup (A_2 \times B_2)$$

non è un rettangolo misurabile:



Definizione 2.0.2. Si definisce σ-algebra prodotto la σ-algebra generata dai rettangoli misurabili

$$\mathcal{A}_1 \otimes \mathcal{A}_2 = \sigma\left(\{A \times B : A \in \mathcal{A}_1,\, B \in \mathcal{A}_2\}\right).$$

Siano π_1 e π_2 le proiezioni canoniche:

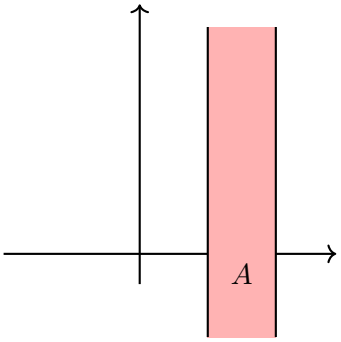
$$\begin{aligned} \pi_1 : X_1 \times X_2 &\longrightarrow X_1 \\ (x, y) &\longmapsto x \end{aligned} \qquad \begin{aligned} \pi_2 : X_1 \times X_2 &\longrightarrow X_2 \\ (x, y) &\longmapsto y \end{aligned}$$

Proposizione 2.0.3.

$$\mathcal{A}_1 \otimes \mathcal{A}_2 = \sigma(\pi_1, \pi_2) = \sigma\left(\left\{\pi_1^{-1}(A), \pi_2^{-1}(B) : A \in \mathcal{A}_1,\ B \in \mathcal{A}_2\right\}\right)$$
$$= \left\{\pi_1^{-1}(A) : A \in \mathcal{A}_1\right\} \vee \left\{\pi_2^{-1}(B) : B \in \mathcal{A}_2\right\}.$$

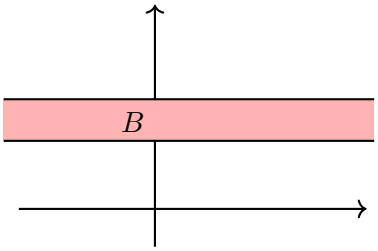
Dimostrazione. "$\supset$": Sia

$$\pi_1^{-1}(A) = A \times X_2, \qquad A \in \mathcal{A}_1,$$
$$\Rightarrow \pi_1^{-1}(A) \in \mathcal{A}_1 \otimes \mathcal{A}_2.$$



Sia

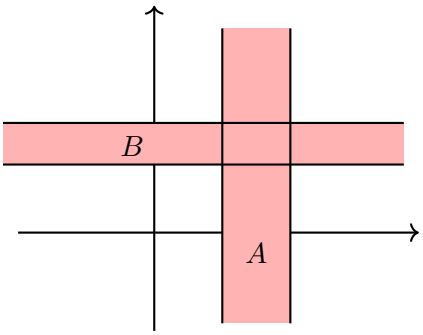
$$\pi_2^{-1}(B) = X_1 \times B, \qquad B \in \mathcal{A}_2,$$
$$\Rightarrow \pi_2^{-1}(B) \in \mathcal{A}_1 \otimes \mathcal{A}_2.$$



"$\subset$": Sia $A \times B$ rettangolo misurabile,

$$A \in \mathcal{A}_1, \qquad B \in \mathcal{A}_2.$$

$$A \times B = \pi_1^{-1}(A) \cap \pi_2^{-1}(B)$$



$$\Rightarrow A \times B \in \sigma(\pi_1, \pi_2).$$

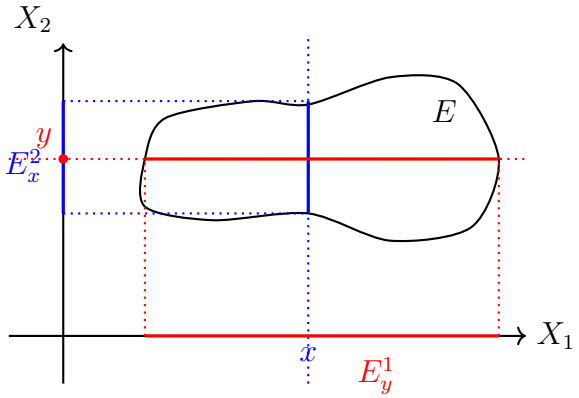
□

Per costruzione $(X_1 \times X_2, \mathcal{A}_1 \otimes \mathcal{A}_2)$ è uno spazio misurabile. Costruiamo una misura su di esso.

Definizione 2.0.4. Sia $E \in \mathcal{A}_1 \otimes \mathcal{A}_2$. Definiamo le sezioni di E come

$$E_x^2 = \{y \in X_2 : (x, y) \in E\} \quad \forall\, x \in X_1$$

$$E_y^1 = \{x \in X_1 : (x, y) \in E\} \quad \forall\, y \in X_2$$



Proposizione 2.0.5. Siano $(X_1, \mathcal{A}_1, \mu_1)$ e $(X_2, \mathcal{A}_2, \mu_2)$ spazi di misura e siano μ_1 e μ_2 misure σ-finite.
Sia $E \in \mathcal{A}_1 \otimes \mathcal{A}_2$. Allora:

1. $$\forall\, x \in X_1 \qquad E_x^2 \in \mathcal{A}_2 \qquad \text{e} \qquad \forall\, y \in X_2 \qquad E_y^1 \in \mathcal{A}_1.$$

2. Le funzioni
$$\begin{array}{ccc} X_1 & \longrightarrow & [0, +\infty] \\ x & \longmapsto & \mu_2(E_x^2) \end{array}$$
$$\begin{array}{ccc} X_2 & \longrightarrow & [0, +\infty] \\ y & \longmapsto & \mu_1(E_y^1) \end{array}$$
sono misurabili e ≥ 0.

3. $$\int_{X_1} \mu_2(E_x^2)\, d\mu_1(x) = \int_{X_2} \mu_1(E_y^1)\, d\mu_2(y).$$

Dimostrazione. Verifichiamolo nel caso in cui

$$E = A \times B, \qquad A \in \mathcal{A}_1, \qquad B \in \mathcal{A}_2.$$

1.
$$E_x^2 = \begin{cases} B & \text{se } x \in A, \\ \varnothing & \text{se } x \notin A, \end{cases}$$
$$E_y^1 = \begin{cases} A & \text{se } y \in B, \\ \varnothing & \text{se } y \notin B. \end{cases}$$
$$\Rightarrow \quad \forall\, x \in X_1 \qquad E_x^2 \in \mathcal{A}_2 \qquad \text{e} \qquad \forall\, y \in X_2 \qquad E_y^1 \in \mathcal{A}_1.$$

2.
$$\forall\, x \in X_1 \qquad \mu_2(E_x^2) = \mu_2(B)\mathbb{1}_A(x),$$
$$\forall\, y \in X_2 \qquad \mu_1(E_y^1) = \mu_1(A)\mathbb{1}_B(y),$$
misurabili ≥ 0.

3.
$$\int_{X_1} \mu_2(E_x^2)\, d\mu_1(x) = \int_{X_1} \mu_2(B)\mathbb{1}_A(x)\, d\mu_1(x)$$
$$= \mu_2(B) \int_{X_1} \mathbb{1}_A(x)\, d\mu_1(x) = \mu_2(B)\mu_1(A).$$
$$\int_{X_2} \mu_1(E_y^1)\, d\mu_2(y) = \int_{X_2} \mu_1(A)\mathbb{1}_B(y)\, d\mu_2(y)$$
$$= \mu_1(A) \int_{X_2} \mathbb{1}_B(y)\, d\mu_2(y) = \mu_1(A)\mu_2(B) \Rightarrow \underline{\text{ok}}$$

□

Teorema 2.0.6. $(X_1, \mathcal{A}_1, \mu_1)$, $(X_2, \mathcal{A}_2, \mu_2)$ spazi di misura e siano μ_1 e μ_2 misure σ-finite. Allora

1.
$$\mu_1 \otimes \mu_2 : \mathcal{A}_1 \otimes \mathcal{A}_2 \longrightarrow [0, +\infty] \qquad \text{tale che } \forall E \in \mathcal{A}_1 \otimes \mathcal{A}_2$$
$$\mu_1 \otimes \mu_2(E) = \int_{X_1} \mu_2(E_x^2)\, d\mu_1(x) = \int_{X_2} \mu_1(E_y^1)\, d\mu_2(y)$$
è una misura σ-finita definita su
$$(X_1 \times X_2, \mathcal{A}_1 \otimes \mathcal{A}_2)$$
ed è detta misura prodotto.

2. Inoltre se $E = A \times B$ con $A \in \mathcal{A}_1$ e $B \in \mathcal{A}_2$ allora
$$\mu_1 \otimes \mu_2(E) = \mu_1 \otimes \mu_2(A \times B) = \mu_1(A)\mu_2(B).$$

3. Infine se
$$\lambda : \mathcal{A}_1 \otimes \mathcal{A}_2 \longrightarrow [0, +\infty]$$

è una misura σ-finita definita su

$$(X_1 \times X_2, \mathcal{A}_1 \otimes \mathcal{A}_2)$$

tale che

$$\forall A \in \mathcal{A}_1,\ B \in \mathcal{A}_2 \qquad \lambda(A \times B) = \mu_1(A)\mu_2(B)$$

allora

$$\lambda = \mu_1 \otimes \mu_2.$$

Osservazione:

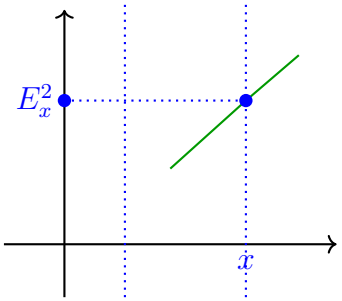
1. Se

$$X_1 = X_2 = \mathbb{R}, \qquad \mathcal{A}_1 = \mathcal{A}_2 = \mathcal{B}(\mathbb{R}),$$
$$X_1 \times X_2 = \mathbb{R}^2.$$

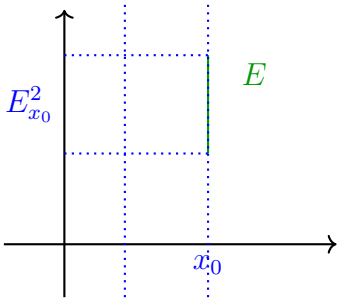
   - Si può provare che
   $$\mathcal{A}_1 \otimes \mathcal{A}_2 = \mathcal{B}(\mathbb{R}) \otimes \mathcal{B}(\mathbb{R}) = \mathcal{B}(\mathbb{R}^2)$$
   ed è generata da rettangoli misurabili del tipo
   $$(a,b) \times (c,d), \qquad [a,b] \times (c,d], \ldots$$
   $$(-\infty, a] \times (b, +\infty), \ldots$$
   - Su $\mathcal{B}(\mathbb{R}^2)$ possiamo definire la misura prodotto
   $$\underline{m} = m \otimes m \qquad \text{tale che} \qquad \underline{m}(A \times B) = m(A)m(B).$$
   $\underline{m}$ è detta misura di Borel-Lebesgue.

2. Se

$$E \in \mathcal{A}_1 \otimes \mathcal{A}_2 \qquad \text{tale che} \qquad \mu_1 \otimes \mu_2(E) = 0,$$
$$\Rightarrow \qquad \mu_2(E_x^2) = 0 \quad \text{per quasi ogni } x \in X_1 \qquad (\mu_1 \text{ q.o.})$$
$$\mu_1(E_y^1) = 0 \quad \text{per quasi ovunque } y \in X_2 \qquad (\mu_2 \text{ q.o.}).$$



$\mu_2(E_x^2) = 0$
$\forall x \in X_1$



$\mu_2(E_x^2) = 0$
$\forall x \neq x_0$

$\mu_2(E_{x_0}^2) \neq 0$ ma $\{x_0\}$ è trascurabile

Teorema 2.0.7 (di Tonelli)**.** Siano $(X_1, \mathcal{A}_1, \mu_1)$, $(X_2, \mathcal{A}_2, \mu_2)$ spazi di misura e siano μ_1 e μ_2 misure σ-finite.
Sia

$$f : X_1 \times X_2 \longrightarrow \overline{\mathbb{R}}$$

f misurabile e $f \geq 0$. Allora

1. $\forall\, x \in X_1$

$$\begin{aligned} f(x,\cdot) : X_2 &\longrightarrow \overline{\mathbb{R}} \\ y &\longmapsto f(x,y) \end{aligned}$$

   $\forall\, y \in X_2$

$$\begin{aligned} f(\cdot,y) : X_1 &\longrightarrow \overline{\mathbb{R}} \\ x &\longmapsto f(x,y) \end{aligned}$$

   sono misurabili e ≥ 0.

2. Le funzioni

$$\begin{aligned} X_1 &\longrightarrow \overline{\mathbb{R}} \\ x &\longmapsto \int_{X_2} f(x,y)\, d\mu_2(y) \end{aligned}$$

$$\begin{aligned} X_2 &\longrightarrow \overline{\mathbb{R}} \\ y &\longmapsto \int_{X_1} f(x,y)\, d\mu_1(x) \end{aligned}$$

   sono misurabili e ≥ 0.

3. $$\int_{X_1} \left(\int_{X_2} f(x,y)\, d\mu_2(y) \right) d\mu_1(x) =$$
$$\int_{X_2} \left(\int_{X_1} f(x,y)\, d\mu_1(x) \right) d\mu_2(y)$$
$$= \int_{X_1 \times X_2} f(x,y)\, d(\mu_1 \otimes \mu_2)(x,y).$$

Teorema 2.0.8 (di Fubini)**.** Siano $(X_1, \mathcal{A}_1, \mu_1)$, $(X_2, \mathcal{A}_2, \mu_2)$ spazi di misura e siano μ_1 e μ_2 misure σ-finite.
Sia

$$f : X_1 \times X_2 \longrightarrow \overline{\mathbb{R}}$$

f integrabile rispetto a $\mu_1 \otimes \mu_2$. Allora

1. $\forall\, x \in X_1$

$$\begin{aligned} f(x,\cdot) : X_2 &\longrightarrow \overline{\mathbb{R}} \\ y &\longmapsto f(x,y) \end{aligned}$$

   $\forall\, y \in X_2$

$$\begin{aligned} f(\cdot,y) : X_1 &\longrightarrow \overline{\mathbb{R}} \\ x &\longmapsto f(x,y) \end{aligned}$$

   integrabili rispetto a μ_2 e μ_1 rispettivamente.

2. Le funzioni

$$\begin{aligned} X_1 &\longrightarrow \overline{\mathbb{R}} \\ x &\longmapsto \int_{X_2} f(x,y)\, d\mu_2(y) \\ X_2 &\longrightarrow \overline{\mathbb{R}} \\ y &\longmapsto \int_{X_1} f(x,y)\, d\mu_1(x) \end{aligned}$$

integrabili rispetto a μ_1 e μ_2 rispettivamente.

3.

$$\int_{X_1} \left(\int_{X_2} f(x,y)\, d\mu_2(y) \right) d\mu_1(x) = \int_{X_2} \left(\int_{X_1} f(x,y)\, d\mu_1(x) \right) d\mu_2(y) = \int_{X_1 \times X_2} f(x,y)\, d(\mu_1 \otimes \mu_2)(x,y).$$

Diamo ora un'applicazione dei teoremi di Fubini-Tonelli nel calcolo delle probabilità. In particolare siamo interessati nel calcolare la media di una variabile aleatoria come intergrale della sua funzione di sopravvivenza.

Proposizione 2.0.9. Sia $X \geq 0$ q.o. tale che

$$X \in L^1(\Omega, \mathcal{F}, \mathbb{P}).$$

Allora

$$\mathbb{E}[X] = \int_0^{+\infty} S_X(x)\, dx = \int_0^{+\infty} \mathbb{P}(X > x)\, dx.$$

ricordando che

$$\mathbb{E}[X] = \int_\Omega X\, d\mathbb{P} = \int_{\mathbb{R}} x\, d\mathbb{P}_X(x).$$

Dimostrazione. Consideriamo la misura prodotto su

$$\left(\mathbb{R}^2, \mathcal{B}(\mathbb{R}^2)\right)$$

data da

$$\mathbb{P}_X \otimes m = \mu.$$

$\forall\, E \in \mathcal{B}(\mathbb{R}^2)$ le sue sezioni sono

$$\forall\, x \in \mathbb{R} \qquad E_x^2 = \{y \in \mathbb{R} : (x,y) \in E\},$$

$$\forall\, y \in \mathbb{R} \qquad E_y^1 = \{x \in \mathbb{R} : (x,y) \in E\}.$$

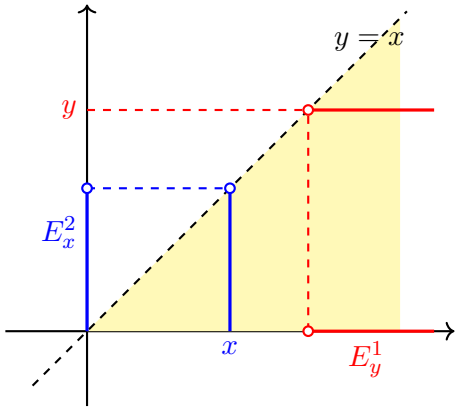
$$\mu(E) = (\mathbb{P}_X \otimes m)(E) = \int_{\mathbb{R}} m(E_x^2)\, d\mathbb{P}_X(x) = \int_{\mathbb{R}} \mathbb{P}_X(E_y^1)\, dm(y).$$

Sia

$$E = \left\{(x,) \in \mathbb{R}^2 : 0 \leq y < x\right\}.$$

- $$\forall\, x \le 0 \qquad E_x^2 = \varnothing \qquad m(E_x^2) = 0.$$

$$\forall\, x > 0 \qquad E_x^2 = [0, x) \qquad m(E_x^2) = x.$$



$$\mu(E) = \int_{\mathbb{R}} m(E_x^2)\, d\mathbb{P}_X(x) = \int_0^{+\infty} x\, d\mathbb{P}_X(x) =$$

dal momento che

$$X \ge 0 \text{ q.o.}, \qquad \mathbb{P}_X((-\infty, 0)) = 0.$$

si ottiene

$$\int_{-\infty}^{+\infty} x\, d\mathbb{P}_X(x). = \int_\Omega X\, d\mathbb{P} = \mathbb{E}[X].$$

- $$\forall\, y \le 0 \qquad E_y^1 = \varnothing \qquad \mathbb{P}_X(E_y^1) = 0.$$

$$\forall\, y > 0 \qquad E_y^1 = (y, +\infty) \qquad \mathbb{P}_X(E_y^1) = \mathbb{P}_X((y, +\infty)) = \mathbb{P}(X > y).$$

$$\mu(E) = \int_{\mathbb{R}} \mathbb{P}_X(E_y^1)\, dm(y) = \int_0^{+\infty} \mathbb{P}(X > y)\, dy = \int_0^{+\infty} S_X(y)\, dy.$$

da cui la tesi. □

Osservazione:

- Vale anche
$$\mathbb{E}[X] = \int_0^{+\infty} \mathbb{P}(X \ge x)\, dx.$$
- Se X ha segno qualsiasi
$$\mathbb{E}[X] = \int_0^{+\infty} S_X(x)\, dx - \int_{-\infty}^0 F_X(x)\, dx.$$
- Se X è una variabile aleatoria discreta con $X(\Omega) \subseteq \mathbb{N}$
$$\mathbb{E}[X] = \sum_{k=0}^{\infty} S_X(k).$$

Esempio 2.0.10. 1. Sia $X \sim \text{Exp}(\lambda)$ $\quad S_X(x) = e^{-\lambda x} \quad \forall\, x > 0.$

$$\mathbb{E}[X] = \int_0^{+\infty} S_X(x)\, dx = \frac{1}{\lambda} \underbrace{\int_0^{+\infty} \lambda e^{-\lambda x}\, dx}_{1 \text{ perché è la densità di } X} = \frac{1}{\lambda}.$$

2. Sia $X \sim \text{Geo}(p)$ $\quad S_X(k) = (1-p)^k \quad \forall\, k \in \mathbb{N}.$

$$\mathbb{E}[X] = \sum_{k=0}^{\infty} S_X(k) = \sum_{k=0}^{\infty} (1-p)^k = \frac{1}{1-(1-p)} = \frac{1}{p}.$$

dal momento che $0 \leq 1-p < 1$ la serie geometrica di ragione geometrica $(1-p)$ converge.

Capitolo 3

Vettori aleatori

Definizione 3.0.1. Sia $(\Omega, \mathcal{F}, \mathbb{P})$ spazio di probabilità.
Un vettore aleatorio o variabile aleatoria vettoriale a valori in $\mathbb{R}^N$ è una funzione misurabile

$$\underline{X} : (\Omega, \mathcal{F}) \longrightarrow \left(\mathbb{R}^N, \mathcal{B}(\mathbb{R}^N)\right)$$

Possiamo indicare un vettore aleatori con

$$\underline{X} = (X_1, \dots, X_N).$$

dove $X_i = \pi_i \circ X$ e le π_i sono le proiezioni canoniche del prodotto cartesiano.

Esempio 3.0.2. Estraggo n palline da un'urna che contiene palline di 4 colori: Bianco, Giallo, Verde, Rosso.
Mi interessa il numero di palline Bianche e Gialle che sono state estratte. Posso usare il vettore aleatorio

$$\underline{X} = (X_1, X_2)$$

con

$$X_1 = n^\circ \text{ palline Bianche}, X_2 = n^\circ \text{ palline Gialle}.$$

Esempio 3.0.3. Immaginiamo di tirare ad un bersaglio circolare. Ci interessa il punto colpito. Possiamo usare il vettore aleatorio $\underline{X} = (X_1, X_2)$ dove

$$X_i,\ i = 1, 2 \qquad \text{coordinate del punto (cartesiane e polare)}$$

Osservazione: Le proiezione canoniche viste come funzioni tra spazi misurabili

$$\forall\, i = 1, \dots, N \quad \pi_i : \left(\mathbb{R}^N, \mathcal{B}(\mathbb{R}^N)\right) \longrightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R})) \quad \underline{x} = (x_1, \dots, x_N) \longmapsto x_i$$

sono funzioni misurabili.
Consideriamo

$$X_i : \Omega \longrightarrow \mathbb{R} \qquad : \qquad X_i = \pi_i \circ \underline{X}$$

$$\Omega \xrightarrow{\underline{X}} \mathbb{R}^N \xrightarrow{\pi_i} \mathbb{R}$$

Otteniamo che le X_i sono misurabi perché composizione di misurabili. In particolare sono variabilili aleatorie.
Viceversa $X_1, \dots, X_N$ siano variabili aleatorie.Sia

$$A = A_1 \times \cdots \times A_N$$

un rettangolo misurabile ovvero

$$A_i \in \mathcal{B}(\mathbb{R}) \qquad \forall\, i = 1, \dots, N.$$

Allora

$$\underline{X}^{-1}(A) = \underline{X}^{-1}(A_1 \times \cdots \times A_N) = (\underline{X} \in A_1 \times \cdots \times A_N) =$$

$$= (X_1 \in A_1) \cap \cdots \cap (X_N \in A_N) = (X_1 \in A_1, \dots, X_N \in A_N) =$$

$$= \underbrace{X_1^{-1}(A_1)}_{\in \mathcal{F}} \cap \cdots \cap \underbrace{X_N^{-1}(A_N)}_{\in \mathcal{F}} \in \mathcal{F}$$

$$\Rightarrow \underline{X}^{-1}(A) \in \mathcal{F}.$$

Ma i rettangoli misurabili generano $\mathcal{B}(\mathbb{R}^N)$

$$\Rightarrow \quad \forall\, A \in \mathcal{B}(\mathbb{R}^N) \qquad \underline{X}^{-1}(A) \in \mathcal{F}$$

$$\Rightarrow \quad \underline{X} \text{ è misurabile e quindi un vettore aleatorio}$$

Possiamo quindi dare una definizione equivalente di variabile aleatoria.

Definizione 3.0.4. Dato $(\Omega, \mathcal{F}, \mathbb{P})$ spazio di probabilità. Un vettore aleatorio a valori in $\mathbb{R}^N$ è una funzione vettoriale

$$\underline{X} = (X_1, \dots, X_N), \qquad \underline{X} : \Omega \to \mathbb{R}^N$$

le cui componenti sono variabili aleatorie reali.

Definizione 3.0.5. Sia

$$\underline{X} = (X_1, \dots, X_N)$$

un vettore aleatorio.
Si dice legge congiunta di $\underline{X}$ (legge congiunta delle variabili $X_1, \dots, X_N$) la misura immagine di $\mathbb{P}$ mediante $\underline{X}$ ovvero la misura di probabilità $\mathbb{P}_{\underline{X}}$ tale che

$$\forall\, A \in \mathcal{B}(\mathbb{R}^N) \qquad \mathbb{P}_{\underline{X}}(A) = \mathbb{P}\left(\underline{X}^{-1}(A)\right) = \mathbb{P}(\underline{X} \in A).$$

Si dicono invece leggi marginali le leggi delle componenti ovvero $\mathbb{P}_{X_i}$ tale che

$$\forall\, B \in \mathcal{B}(\mathbb{R}) \qquad \mathbb{P}_{X_i}(B) = \mathbb{P}\left(X_i^{-1}(B)\right) = \mathbb{P}(X_i \in B).$$

Per semplicità da qui alla fine della lezione consideriamo $N = 2$ e scriviamo $Z = (X, Y)$.

Definizione 3.0.6. Sia

$$\underline{Z} = (X, Y)$$

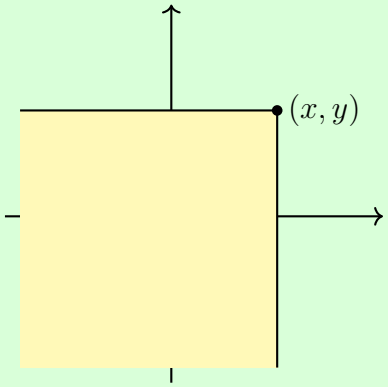
un vettore aleatorio.
Si dice funzione di ripartizione (o di distribuzione cumulata) congiunta di $\underline{Z}$ la funzione

$$F_{\underline{Z}} = F_{(X,Y)} : \mathbb{R}^2 \longrightarrow [0,1]$$

$$z = (x, y) \longmapsto F_{\underline{Z}}(z) = F_{\underline{Z}}(x, y)$$

dove

$$\begin{aligned} F_{\underline{Z}}(z) = F_{\underline{Z}}(x, y) &= \mathbb{P}\big((X \leq x) \cap (Y \leq y)\big) \\ &= \mathbb{P}(X \leq x, Y \leq y) \\ &= \mathbb{P}\left(X^{-1}((-\infty, x]) \cap Y^{-1}((-\infty, y])\right) \\ &= \mathbb{P}\left(\underline{Z}^{-1}\left((-\infty, x] \times (-\infty, y]\right)\right) = \mathbb{P}_{\underline{Z}}\left((-\infty, x] \times (-\infty, y]\right). \end{aligned}$$



Le funzioni di ripartizione marginali sono le funzioni di ripartizioni delle componenti ovvero

$$F_X, F_Y : \mathbb{R} \longrightarrow [0,1] \qquad \text{tale che}$$

$$F_X(x) = \mathbb{P}_X((-\infty, x]) = \mathbb{P}\left(X^{-1}((-\infty, x])\right) = \mathbb{P}(X \leq x) \qquad \forall x \in \mathbb{R}.$$

$$F_Y(y) = \mathbb{P}_Y((-\infty, y]) = \mathbb{P}\left(Y^{-1}((-\infty, y])\right) = \mathbb{P}(Y \leq y) \qquad \forall y \in \mathbb{R}.$$

Proposizione 3.0.7. 1.

$$\forall\, x \in \mathbb{R} \qquad F_X(x) = \lim_{y \to +\infty} F_{\underline{Z}}((x, y)).$$

2.

$$\forall\, y \in \mathbb{R} \qquad F_Y(y) = \lim_{x \to +\infty} F_{\underline{Z}}((x, y)).$$

Dimostrazione. Sia

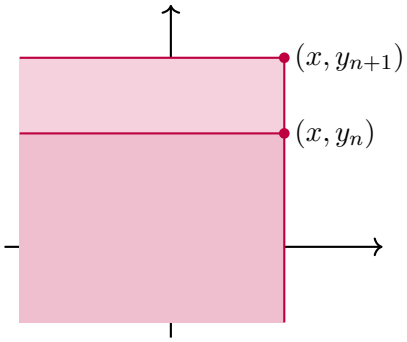
$$y_n \to +\infty$$

e sia

$$A_n = (-\infty, x] \times (-\infty, y_n].$$

$$y_n \leq y_{n+1} \qquad \Rightarrow \qquad A_n \subseteq A_{n+1}.$$

$$A = \bigcup_{n \geq 1} A_n = (-\infty, x] \times \mathbb{R}.$$



$$\Rightarrow \lim_{n\to\infty} F_{\underline{Z}}(x, y_n) = \lim_{n\to\infty} \mathbb{P}_{\underline{Z}}\left((-\infty, x] \times (-\infty, y_n]\right) =$$

$$= \lim_{n\to\infty} \mathbb{P}_{\underline{Z}}(A_n) = \mathbb{P}_{\underline{Z}}(A) = \mathbb{P}_{\underline{Z}}\left((-\infty, x] \times \mathbb{R}\right)$$

$$= \mathbb{P}(X \leq x) = F_X(x) \qquad \Rightarrow \qquad \lim_{y\to+\infty} F_{\underline{Z}}(x, y) = F_X(x).$$

analogo per F_Y. □

Osservazione: In generale F_X e F_Y non si può ricavare $F_{\underline{Z}}$.

3.1 Vettori aleatori discreti

Definizione 3.1.1. Un vettore aleatorio

$$\underline{Z} = (X, Y)$$

si dice discreto se l'insieme dei valori assunti da $\underline{Z}$, $\underline{Z}(\Omega)$, è un insieme discreto.
Questo succede se e solo se sono discrete le componenti X e Y.
In particolare

$$\underline{Z}(\Omega) \subseteq X(\Omega) \times Y(\Omega) = \{(x_i, y_j) : i \in I,\ j \in J\}$$

con I e J al più numerabili.

- La legge di $\underline{Z}$, $\mathbb{P}_{\underline{Z}}$, è una misura discreta concentrata su $\underline{Z}(\Omega)$
  è definita su $\{(x_i, y_j)\}$ con $(x_i, y_j) \in \underline{Z}(\Omega)$
  e poi estesa ai Boreliani:

$$\forall\, B \in \mathcal{B}(\mathbb{R}^2) \qquad \mathbb{P}_{\underline{Z}}(B) = \mathbb{P}(\underline{Z} \in B) = \sum_{(x_i,y_j) \in B \cap \underline{Z}(\Omega)} \mathbb{P}_{\underline{Z}}\big(\{(x_i, y_j)\}\big)$$

$$= \sum_{(x_i,y_j)\in B\cap \underline{Z}(\Omega)} \mathbb{P}\big(\underline{Z} = (x_i, y_j)\big) = \sum_{(x_i,y_j)\in B\cap \underline{Z}(\Omega)} \mathbb{P}(X = x_i, Y = y_j).$$

La funzione di densità discreta congiunta di $\underline{Z}$ è la funzione

$$p_{\underline{Z}} = p_{(X,Y)} : \mathbb{R}^2 \longrightarrow [0,1]$$

tale che

$$p_{\underline{Z}}(z) = p_{\underline{Z}}((x,y)) = \mathbb{P}\big(\underline{Z} = (x,y)\big) = \mathbb{P}(X = x, Y = y)$$

$$= \begin{cases} \mathbb{P}(X = x_i, Y = y_j) & \text{se } (x,y) = (x_i, y_j) \in \underline{Z}(\Omega), \\ 0 & \text{altrimenti.} \end{cases}$$

Le funzioni di densità discrete delle componenti X e Y sono dette marginali e si possono ricavare dalla densità discreta congiunta (non viceversa).

Osservazione: Fissiamo $x_i \in X(\Omega)$, $i \in I$.
Osserviamo che

$$\{(Y = y_j) : j \in J\}$$

è una partizione dell'evento certo $\Rightarrow$ possiamo utilizzare la formula della probabilità totale, ovvero

$$\forall B \in \mathcal{B}(\mathbb{R}) \qquad \mathbb{P}(B) = \sum_{j\in J} \mathbb{P}\big(B \cap (Y = y_j)\big).$$

$$p_X(x_i) = \mathbb{P}(X = x_i) = \mathbb{P}(B) = \sum_{j\in J} \mathbb{P}\big(B \cap (Y = y_j)\big)$$

$$= \sum_{j\in J} \mathbb{P}(X = x_i, Y = y_j) = \sum_{j\in J} p_{(X,Y)}(x_i, y_j).$$

$$\Downarrow$$

$$\forall x_i \in X(\Omega) \qquad p_X(x_i) = \sum_{j\in J} p_{(X,Y)}(x_i, y_j)$$

$$\forall y_j \in Y(\Omega) \qquad p_Y(y_j) = \sum_{i\in I} p_{(X,Y)}(x_i, y_j).$$

Variabile aleatoria multinomiale

Come primo vettore aleatorio discreto presentiamo una diretta estensione della variabile discreta binomiale.

Definizione 3.1.2. Consideriamo n prove ripetute e indipendenti dello stesso esperimento aleatorio, ciascuna delle quali può produrre $N + 1$ possibili risultati.
Indichiamo con

$$p_i, \qquad i = 1, \ldots, N,$$

la probabilità di ottenere il risultato di tipo i. La probabilità di ottenere il risultato di tipo

$N+1$ è quindi

$$p_{N+1} = 1 - \sum_{i=1}^{N} p_i.$$

Definiamo il vettore aleatorio

$$\underline{X} = (X_1, \dots, X_N),$$

dove

$$X_i = \text{n° di risultati di tipo } i, \qquad i = 1, \dots, N.$$

Il numero di risultati di tipo $N+1$ non deve essere incluso esplicitamente nel vettore, poiché è determinato dagli altri:

$$X_{N+1} = n - \sum_{i=1}^{N} X_i.$$

Si scrive

$$\underline{X} \sim M(n, p_1, \dots, p_N),$$

e si dice che $\underline{X}$ è una variabile aleatoria multinomiale di parametri

$$n, p_1, \dots, p_N.$$

Lo spazio dei valori assunti da $\underline{X}$ è

$$\underline{X}(\Omega) = \left\{ (n_1, \dots, n_N) : n_i \in \{0, \dots, n\}, \quad \sum_{i=1}^{N} n_i \leq n \right\}.$$

Infatti, fissato

$$(n_1, \dots, n_N) \in \underline{X}(\Omega),$$

il numero di risultati di tipo $N+1$ è

$$n_{N+1} = n - \sum_{i=1}^{N} n_i.$$

La funzione di densità discreta congiunta è quindi

$$\begin{aligned} p_{\underline{X}}(n_1, \dots, n_N) &= \mathbb{P}\left(X_1 = n_1, \dots, X_N = n_N\right) \\ &= \mathbb{P}\left(\underline{X} = (n_1, \dots, n_N)\right) \\ &= \frac{n!}{n_1! \cdots n_N! \left(n - \sum_{i=1}^{N} n_i\right)!} p_1^{n_1} \cdots p_N^{n_N} \left(1 - \sum_{i=1}^{N} p_i\right)^{n - \sum_{i=1}^{N} n_i}. \end{aligned}$$

Il coefficiente

$$\binom{n}{n_1, \dots, n_{N+1}} = \frac{n!}{n_1! \cdots n_N! n_{N+1}!}$$

è detto coefficiente multinomiale.

Osservazione: Possiamo ricavare le distribuzioni marginali delle componenti X_i.

Fissato $i \in \{1, \dots, N\}$ e $n_i \in \{0, \dots, n\}$,

$$p_{X_i}(n_i) = \mathbb{P}(X_i = n_i) = \sum_{\substack{n_j,\, j \neq i \\ (n_1,\dots,n_N) \in \underline{X}(\Omega)}} p_{\underline{X}}(n_1, \dots, n_N).$$

Sommando rispetto a tutti i possibili valori delle altre componenti si ottiene

$$p_{X_i}(n_i) = \binom{n}{n_i} p_i^{n_i} (1 - p_i)^{n - n_i}.$$

Quindi

$$X_i \sim B(n, p_i).$$

Ogni componente X_i può dunque essere vista come una variabile aleatoria binomiale associata allo schema di Bernoulli in cui il "successo" consiste nell'ottenere un risultato di tipo i, evento che in ogni prova ha probabilità p_i.

Esempio 3.1.3. Facciamo 10 estrazioni con reinserimento da un'urna con 100 palline di cui 50 nere, 20 rosse, 20 bianche e 10 verdi.

a) Con quale probabilità ottengo 5 nere, 3 rosse e 1 bianca?

$$N = 3 \qquad \underline{X} = (X_N, X_R, X_B) \qquad X_V = n - (X_N + X_R + X_B)$$

$$n = 10$$

$$p_N = \frac{1}{2} \qquad p_R = \frac{1}{5} \qquad p_B = \frac{1}{5} \qquad p_V = 1 - (p_N + p_R + p_B) = \frac{1}{10}$$

$$p_{\underline{X}}((5,3,1)) = \mathbb{P}(\underline{X} = (5,3,1)) = \mathbb{P}(X_N = 5, X_R = 3, X_B = 1)$$

$$= \frac{10!}{5!\,3!\,1!\,1!} \left(\frac{1}{2}\right)^5 \left(\frac{1}{5}\right)^3 \left(\frac{1}{5}\right)^1 \left(\frac{1}{10}\right)^1 = 0.0252$$

b) Con quale probabilità ottengo 5 nere e 3 rosse?
Due possibili strade:

1) $$\mathbb{P}\big((\underline{X} = (5,3,0)) \cup (\underline{X} = (5,3,1)) \cup (\underline{X} = (5,3,2))\big)$$

$$= p_{\underline{X}}((5,3,0)) + p_{\underline{X}}((5,3,1)) + p_{\underline{X}}((5,3,2)) = 0.056$$

2) $$\widetilde{N} = 2 \qquad \underline{\widetilde{X}} = (X_N, X_R) \qquad X_{BV} = n - (X_N + X_R)$$

$$n = 10$$

$$p_N = \frac{1}{2} \qquad p_R = \frac{1}{5} \qquad p_{BV} = 1 - (p_N + p_R) = \frac{3}{10}$$

$$\mathbb{P}\left(\underline{\widetilde{X}} = (5,3)\right) = p_{\underline{\widetilde{X}}}((5,3)) = \mathbb{P}(X_N = 5, X_R = 3)$$

$$= \frac{10!}{5!\,3!\,2!}\left(\frac{1}{2}\right)^5\left(\frac{1}{5}\right)^3\left(\frac{3}{10}\right)^2 = 0.056$$

c) Con quale probabilità ottengo 5 palline nere?

$$X_N \sim B(n, p_N) \qquad n = 10 \qquad p_N = \frac{1}{2}$$

$$\mathbb{P}(X_N = 5) = p_{X_N}(5) = \frac{10!}{5!\,5!}\left(\frac{1}{2}\right)^5\left(\frac{1}{2}\right)^5 = 0.2461$$

Esempio 3.1.4. Da un'urna contenente 3 palline bianche, 4 palline nere e 5 palline rosse vengono estratte $n = 3$ palline senza reinserimento. Si definiscono X e Y come il numero di palline bianche e nere ottenute nelle tre estrazioni, rispettivamente.

a) Determinare la densità discreta congiunta della coppia (X, Y).

b) Determinare le densità discrete marginali delle variabili aleatorie X e Y.

c) Calcolare la probabilità che il numero di palline bianche estratte sia minore del numero di palline nere estratte.

Soluzione

$$X = \text{n° di palline bianche estratte} \qquad X(\Omega) = \{0,1,2,3\}$$

$$Y = \text{n° di palline nere estratte} \qquad Y(\Omega) = \{0,1,2,3\}$$

a)

$$Z = (X, Y) \qquad Z(\Omega) \subseteq X(\Omega) \times Y(\Omega)$$

$$\forall (i,j) \in Z(\Omega)$$

$$\begin{aligned} p_Z((i,j)) &= \mathbb{P}(Z = (i,j)) \\ &= \mathbb{P}(X = i, Y = j) \\ &= \frac{\binom{3}{i}\binom{4}{j}\binom{5}{3-i-j}}{\binom{12}{3}}. \end{aligned}$$

$X(\Omega)$ \ $Y(\Omega)$

$i\backslash j$	0	1	2	3	p_X
0					
1					
2					
3					
p_Y					1

b)

$$\forall i \in X(\Omega)$$

$$p_X(i) = \mathbb{P}(X = i) = \sum_{j=0}^{3} p_Z((i,j)) = \ldots = \frac{\binom{3}{i}\binom{9}{3-i}}{\binom{12}{3}}.$$

$$X \sim \text{Ipergeometrica}(12, 3, 3)$$

Analogamente

$$\forall j \in Y(\Omega)$$

$$p_Y(j) = \mathbb{P}(Y = j) = \sum_{i=0}^{3} p_Z((i,j)) = \ldots = \frac{\binom{4}{j}\binom{8}{3-j}}{\binom{12}{3}}.$$

$$Y \sim \text{Ipergeometrica}(12, 4, 3)$$

c)

$$\mathbb{P}(X < Y) = \mathbb{P}((X,Y) \in C) = \mathbb{P}_Z(C) = *$$

dove

$$C = \{(x,y) \in \mathbb{R}^2 : x < y\} \in \mathcal{B}(\mathbb{R}^2)$$

$$\begin{aligned} * &= \sum_{(i,j)\in C} p_Z((i,j)) \\ &= p_Z((0,1)) + p_Z((0,2)) + p_Z((0,3)) \\ &\quad + p_Z((1,2)) + \cancel{p_Z((1,3))} \\ &\quad + \cancel{p_Z((2,3))} \end{aligned}$$

3.2 Vettori aleatori assolutamente continui

Definizione 3.2.1. Un vettore aleatorio $Z = (X,Y)$ si dice assolutamente continuo se la sua legge $\mathbb{P}_Z$ è una misura assolutamente continua rispetto alla misura di Lebesgue su

$$\left(\mathbb{R}^2, \mathcal{B}(\mathbb{R}^2)\right): \qquad \mathbb{P}_Z \ll \underline{m} = m \otimes m.$$

La derivata di Radon-Nikodym

$$\frac{d\mathbb{P}_Z}{d\underline{m}} = f_Z$$

si dice funzione di densità congiunta di $Z = (X, Y)$.

Osservazione: Ricordiamo che f_Z essendo una derivata di Radeon-Nykodim deve essere

$$f_Z \text{ misurabile}, \qquad f_Z \geq 0.$$

$$\forall\, C \in \mathcal{B}(\mathbb{R}^2) \qquad \mathbb{P}_Z(C) = \mathbb{P}(Z \in C) = \int_C f_Z \, d\underline{m}.$$

e in particolare

$$\begin{aligned}\mathbb{P}_Z(\mathbb{R}^2) = 1 &= \int_{\mathbb{R}^2} f_Z \, d\underline{m} \\ &= \int_{-\infty}^{+\infty} \left(\int_{-\infty}^{+\infty} f_Z(x,y)\, dx \right) dy \\ &= \int_{-\infty}^{+\infty} \left(\int_{-\infty}^{+\infty} f_Z(x,y)\, dy \right) dx.\end{aligned}$$

Proposizione 3.2.2. Sia $Z = (x, y)$ un vettore aleatorio assolutamente continuo.
Allora le componenti X e Y sono variabili aleatorie assolutamente continue (diciamo che sono congiuntamente assolutamente continue) e le loro densità, dette marginali, si ricavano dalla densità congiunta:

$$\forall x \in \mathbb{R} \qquad f_X(x) = \int_{-\infty}^{+\infty} f_{(x,y)}(x,y)\, dy$$

$$\forall y \in \mathbb{R} \qquad f_Y(y) = \int_{-\infty}^{+\infty} f_{(x,y)}(x,y)\, dx$$

Dimostrazione. Sia $A \in \mathcal{B}(\mathbb{R})$.

$$\begin{aligned}\mathbb{P}_X(A) = \mathbb{P}(x \in A) = \mathbb{P}(x \in A,\, y \in \mathbb{R}) &= \mathbb{P}\big((x,y) \in A \times \mathbb{R}\big) \\ &= \underbrace{\mathbb{P}_Z(A \times \mathbb{R})}_{\substack{Z \text{ è assolutamente continua} \\ \mathbb{P}_Z \ll \underline{m} \text{ e } f_Z = \frac{d\mathbb{P}_Z}{d\underline{m}}}} = \int_{A\times\mathbb{R}} f_Z \, d\underline{m} \\ &= \int_{\mathbb{R}^2} \underbrace{\mathbb{1}_A(x) f_Z(x,y)}_{\substack{\geq 0 \text{ misurabile} \\ \text{integrabile}}} d\underline{m}(x,y) \\ &\overset{\text{Fubini-Tonelli}}{=} \int_A \underbrace{\left(\int_{-\infty}^{+\infty} f_Z(x,y)\, dy \right)}_{\text{poniamo } f_X(x)} dx = \int_A f_X \, dm.\end{aligned}$$

dal momento che

$$\int_A (\cdots)\, dx \qquad \text{corrisponde a} \qquad \int_{\mathbb{R}} \mathbb{1}_A(x)(\cdots)\, dx.$$

Ho trovato una funzione

$$\underbrace{\text{misurabile e } \geq 0}_{\text{Tonelli}} \qquad \underbrace{(\text{integrabile})}_{\text{Fubini}}$$

$$f_X(x) = \int_{-\infty}^{+\infty} f_Z(x,y)\, dy.$$

tale che

$$\forall A \in \mathcal{B}(\mathbb{R}) \qquad \mathbb{P}_X(A) = \int_A f_X \, dm \qquad \Rightarrow \qquad \mathbb{P}_X \ll m$$

e

$$f_X = \frac{d\mathbb{P}_X}{dm} \quad \text{q.o.}$$

ovvero X è assolutamente continua e f_X è la densità di X.
Analogo per Y. □

Osservazione:
Se X e Y sono variabili aleatorie assolutamente continue non posso dire che (X,Y) è assolutamente continuo.
Quindi non ha senso pensare di poter ricavare f_Z da f_X e f_Y a meno di ipotesi più forti.

Esempio 3.2.3. Si considerino due variabili aleatorie X e Y aventi densità congiunta

$$f_{(X,Y)}(x,y) = 2e^{-(x+2y)}\, \mathbb{1}_D(x,y),$$

con

$$D = (0,+\infty) \times (0,+\infty).$$

a) Calcolare $\mathbb{P}(X > 1, Y < 1)$.

b) Calcolare $\mathbb{P}(X < Y)$.

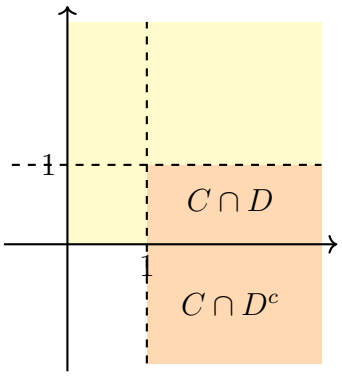
c) Ricavare le leggi marginali di X e Y.

Soluzione
a)

$$\mathbb{P}(X > 1, Y < 1) = \mathbb{P}\big((x,y) \in C\big) = \int_C f_{(X,Y)}(x,y)\, dx\, dy = *$$

dove

$$C = \big\{(x,y) \in \mathbb{R}^2 : x > 1,\ y < 1\big\} \in \mathcal{B}(\mathbb{R}^2).$$



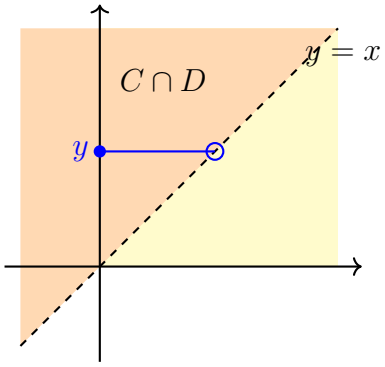
$$
\begin{aligned}
* &= \int_{C\cap D} 2e^{-(x+2y)}\,dx\,dy \\
&= \int_0^1 \left(\int_1^{+\infty} 2e^{-(x+2y)}\,dx \right) dy \\
&= \int_0^1 2e^{-2y} \underbrace{\left(\int_1^{+\infty} e^{-x}\,dx \right)}_{\substack{S_T(1)=e^{-1} \\ T\sim \mathrm{Exp}(1)}} dy \\
&= e^{-1} \int_0^1 2e^{-2y}\,dy \\
&= e^{-1}(1-e^{-2}).
\end{aligned}
$$

b)

$$\mathbb{P}(X<Y) = \mathbb{P}\big((x,y)\in C\big) = \int_C f_{(X,Y)}(x,y)\,dx\,dy = *$$

dove

$$C = \big\{(x,y)\in\mathbb{R}^2 : x<y\big\}.$$



$$
\begin{aligned}
* &= \int_{C\cap D} 2e^{-(x+2y)}\,dx\,dy \\
&= \int_0^{+\infty} \left(\int_0^y 2e^{-(x+2y)}\,dx \right) dy \\
&= \int_0^{+\infty} 2e^{-2y} \underbrace{\left(\int_0^y e^{-x}\,dx \right)}_{F_T(y)=1-e^{-y}} dy \\
&= \int_0^{+\infty} 2e^{-2y}\,dy - \int_0^{+\infty} 2e^{-3y}\,dy \\
&= 1 - \frac{2}{3} \underbrace{\int_0^{+\infty} 3e^{-3y}\,dy}_{\substack{1 \\ V\sim \mathrm{Exp}(3)}} \\
&= 1 - \frac{2}{3} = \frac{1}{3}.
\end{aligned}
$$

In alternativa avremmo potuto anche calcolare l'integrale ricordandoci del rapporto tra media e funzione di sopravvivenza di V.

$$
2\int_0^{+\infty} e^{-3y}\,dy = 2\int_0^{+\infty} S_V(y)\,dy = 2\mathbb{E}[V] = \frac{2}{3}
$$

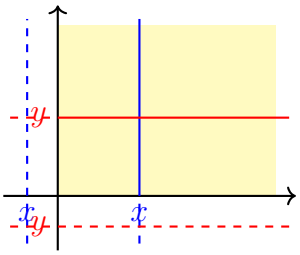
c)

$$
\forall x \in \mathbb{R} \qquad f_X(x) = \int_{-\infty}^{+\infty} f_{(X,Y)}(x,y)\,dy
$$

$$
\text{se } x \le 0 \qquad f_X(x) = 0
$$

$$
\begin{aligned}
\text{se } x > 0 \qquad f_X(x) &= \int_0^{+\infty} 2e^{-(x+2y)}\,dy \\
&= e^{-x} \underbrace{\int_0^{+\infty} 2e^{-2y}\,dy}_{\substack{1 \\ U\sim \mathrm{Exp}(2)}} = e^{-x}
\end{aligned}
$$

$$
\Rightarrow \qquad f_X(x) = e^{-x}\mathbb{1}_{(0,+\infty)}(x) \qquad \Rightarrow \qquad X \sim \mathrm{Exp}(1)
$$



$$\forall y \in \mathbb{R} \qquad f_Y(y) = \int_{-\infty}^{+\infty} f_{(X,Y)}(x,y)\,dx$$

$$\text{se } y \le 0 \qquad f_Y(y) = 0$$

$$\text{se } y > 0 \qquad f_Y(y) = \int_0^{+\infty} 2e^{-(x+2y)}\,dx = 2e^{-2y} \underbrace{\int_0^{+\infty} e^{-x}\,dx}_{\substack{1 \\ T\sim \text{Exp}(1)}}$$

$$= 2e^{-2y}$$

$$\Rightarrow \qquad f_Y(y) = 2e^{-2y}\mathbb{1}_{(0,+\infty)}(y) \qquad \Rightarrow \qquad Y \sim \text{Exp}(2)$$

3.3 Variabili aleatorie indipendenti

Ricoridamo che una famiglia di σ-algebre $(\mathcal{A}_i)_{i\in I}$ si dice indipendente se, per ogni scelta finita di indici distinti

$$i_1, \dots, i_n \in I$$

e per ogni

$$A_{i_k} \in \mathcal{A}_{i_k},$$

vale

$$\mathbb{P}\left(\bigcap_{k=1}^{n} A_{i_k}\right) = \prod_{k=1}^{n} \mathbb{P}(A_{i_k}).$$

Definizione 3.3.1. Diciamo che le variabili aleatorie $(X_i)_{i\in I}$ sono indipendenti, se sono indipendenti le σ-algebre

$$\big(\sigma(X_i)\big)_{i\in I}$$

dove

$$\sigma(X_i) = \left\{X_i^{-1}(A) : A \in \mathcal{B}(\mathbb{R})\right\}.$$

Esempio 3.3.2. Consideriamo uno schema di Bernoulli (binomiale)

$$X \sim B(n,p).$$

$$X = \sum_{i=1}^{n} Y_i \qquad \text{con } Y_i \sim b(p).$$

Osserviamo che

$$Y_i = \mathbb{1}_{A_i} \qquad \text{con } A_i = \text{ho successo alla prova } i\text{-esima}.$$

$$\sigma(Y_i) = \left\{Y_i^{-1}(A) : A \in \mathcal{B}(\mathbb{R})\right\} = \{\Omega, \emptyset, A_i, A_i^c\} = \sigma(A_i).$$

$$(A_i)_{i=1,\dots,n} \text{ sono indipendenti} \quad \Rightarrow \quad \text{sono indipendenti le}$$

$$\big(\sigma(A_i)\big)_{i=1,\dots,n} = \big(\sigma(Y_i)\big)_{i=1,\dots,n} \quad \Rightarrow \quad \text{sono indipendenti le}$$

$$(Y_i)_{i=1,\dots,n}.$$

Ogni volta che avremo un set di variabili aleatorie con stessa densità e indipendenti scriveremo

$$Y_i \underset{\text{iid}}{\sim} b(p) \qquad \text{iid} = \text{indipendenti e identicamente distribuite.}$$

Osservazione: Siano

$$Z = (X, Y).$$

osserviamo che

$$X \perp\!\!\!\perp Y \quad \text{(indipendenti)} \iff \sigma(X) \perp\!\!\!\perp \sigma(Y)$$

$$\iff \left\{X^{-1}(A) : A \in \mathcal{B}(\mathbb{R})\right\} \perp\!\!\!\perp \left\{Y^{-1}(B) : B \in \mathcal{B}(\mathbb{R})\right\}$$

$$\iff \forall A, B \in \mathcal{B}(\mathbb{R}) \qquad X^{-1}(A) \perp\!\!\!\perp Y^{-1}(B)$$

$$\iff \forall A, B \in \mathcal{B}(\mathbb{R}) \qquad \mathbb{P}\left(X^{-1}(A) \cap Y^{-1}(B)\right) = \mathbb{P}\left(X^{-1}(A)\right)\mathbb{P}\left(Y^{-1}(B)\right)$$

$$\iff \forall A, B \in \mathcal{B}(\mathbb{R}) \qquad \underbrace{\mathbb{P}(X \in A, Y \in B)}_{\substack{\mathbb{P}\left((X,Y)\in A\times B\right) \\ = \mathbb{P}_Z(A\times B)}} = \underbrace{\mathbb{P}(X \in A)}_{\mathbb{P}_X(A)} \cdot \underbrace{\mathbb{P}(Y \in B)}_{\mathbb{P}_Y(B)}$$

$$\iff \forall A, B \in \mathcal{B}(\mathbb{R}) \qquad \mathbb{P}_Z(A \times B) = \mathbb{P}_X(A) \cdot \mathbb{P}_Y(B)$$

$$\iff \mathbb{P}_Z = \mathbb{P}_X \otimes \mathbb{P}_Y.$$

essendo la misura prodotto l'unica che fattorizza le misure.

Proposizione 3.3.3. Sia $Z = (X, Y)$ un vettore aleatorio. Allora

$$X \perp\!\!\!\perp Y \iff F_Z(x, y) = F_X(x) \cdot F_Y(y) \qquad \forall x, y \in \mathbb{R}.$$

Dimostrazione. Segue da

$$\begin{aligned} F_Z(x, y) &= \mathbb{P}(X \le x, Y \le y) \\ &= \mathbb{P}\left(Z \in \underbrace{(-\infty, x]}_{A} \times \underbrace{(-\infty, y]}_{B}\right) \\ &= \mathbb{P}_Z\left(\underbrace{(-\infty, x] \times (-\infty, y]}_{A\times B}\right). \end{aligned}$$

$$F_X(x) = \mathbb{P}(X \le x) = \mathbb{P}_X\left(\underbrace{(-\infty, x]}_{A}\right)$$

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}_Y\left(\underbrace{(-\infty, y]}_{B}\right).$$

□

Proposizione 3.3.4. 1) Sia $Z = (X, Y)$ un vettore aleatorio discreto, con densità congiunta

$$p_Z = p_{(X,Y)}$$

e marginali p_X e p_Y.

$$X \perp\!\!\!\perp Y \iff p_{(X,Y)}(x_i, y_j) = p_X(x_i)\, p_Y(y_j) \qquad \forall x_i \in X(\Omega), \quad \forall y_j \in Y(\Omega).$$

2a) Sia $Z = (X, Y)$ un vettore aleatorio assolutamente continuo, con densità congiunta

$$f_Z = f_{(X,Y)}$$

e marginali f_X e f_Y.
Supponiamo che valga

$$f_{(X,Y)}(x, y) = f_X(x) \cdot f_Y(y) \qquad \text{per } \underline{m}\text{-q.o. } (x, y) \in \mathbb{R}^2.$$

$$\Rightarrow \qquad X \perp\!\!\!\perp Y.$$

2b) Siano X, Y variabili aleatorie assolutamente continue, con densità f_X e f_Y rispettivamente,

$$X \perp\!\!\!\perp Y.$$

Allora $Z = (X, Y)$ è assolutamente continuo con densità

$$f_Z = f_{(X,Y)} = f_X(x) \cdot f_Y(y)$$

Dimostrazione. **1)**

$$\begin{aligned} p_{(X,Y)}(x_i, y_j) &= \mathbb{P}(X = x_i, Y = y_j) \\ &= \mathbb{P}\left((X, Y) \in \{x_i\} \times \{y_j\}\right) \\ &= \mathbb{P}_Z\left(\underbrace{\{x_i\}}_{A} \times \underbrace{\{y_j\}}_{B}\right). \end{aligned}$$

$$p_X(x_i) = \mathbb{P}(X = x_i) = \mathbb{P}(X \in \{x_i\}) = \mathbb{P}_X\left(\underbrace{\{x_i\}}_{A}\right)$$

$$p_Y(y_j) = \mathbb{P}(Y = y_j) = \mathbb{P}(Y \in \{y_j\}) = \mathbb{P}_Y\left(\underbrace{\{y_j\}}_{B}\right).$$

L'implicazione $\Leftarrow$ è immediata. Facciamo l'implicazione $\Rightarrow$. Siano $A, B \in \mathcal{B}(\mathbb{R})$

$$\mathbb{P}_Z(A \times B) = \sum_{(x_i,y_i)\in A\times B} \mathbb{P}_Z(\{x_i, y_i\}) = \sum_{(x_i,y_i)\in A\times B} p_Z(x_i, y_i) = \sum_{(x_i,y_i)\in A\times B} p_X(x_i) \cdot p_Y(y_i) =$$

$$= \left(\sum_{x_i\in A} p_X(x_i)\right) \cdot \left(\sum_{y_i\in B} p_Y(y_i)\right) = \mathbb{P}_X(x_i) \cdot \mathbb{P}(y_i)$$

2)

$$\forall A, B \in \mathcal{B}(\mathbb{R})$$

$$\begin{aligned} \mathbb{P}_X(A) \cdot \mathbb{P}_Y(B) &= \int_A f_X \, dm \cdot \int_B f_Y \, dm \\ &\overset{\text{Tonelli}}{=} \int_{A\times B} (f_X \cdot f_Y) \, d\underline{m}, \qquad \underline{m} = m \otimes m. \end{aligned} \tag{$\star$}$$

2a)
Per ipotesi

$$f_Z = f_X \cdot f_Y \qquad \underline{m}\text{-q.o.}$$

$$\begin{aligned} \mathbb{P}_X(A) \cdot \mathbb{P}_Y(B) &\overset{\star}{=} \int_{A\times B} (f_X \cdot f_Y) \, d\underline{m} \\ &= \int_{A\times B} f_Z \, d\underline{m} \\ &= \mathbb{P}_Z(A \times B). \end{aligned}$$

$$\Rightarrow \qquad \mathbb{P}_Z = \mathbb{P}_X \otimes \mathbb{P}_Y \qquad \Rightarrow \qquad X \perp\!\!\!\perp Y.$$

2b)
Per ipotesi

$$X \perp\!\!\!\perp Y \qquad \Rightarrow \qquad \mathbb{P}_Z = \mathbb{P}_X \otimes \mathbb{P}_Y.$$

Definiamo su

$$\left(\mathbb{R}^2, \mathcal{B}(\mathbb{R}^2)\right)$$

una misura μ come

$$\mu(C) = \int_C (f_X \cdot f_Y) \, d\underline{m} \qquad \forall C \in \mathcal{B}(\mathbb{R}^2).$$

Ben definita perchè

$$f_X \cdot f_Y \geq 0 \qquad \text{misurabile.}$$

$$\Rightarrow \qquad \mu \ll \underline{m} \qquad \text{con} \qquad \frac{d\mu}{d\underline{m}} = f_X \cdot f_Y \qquad \underline{m}\text{-q.o.}$$

Consideriamo

$$C = A \times B \qquad \text{con } A, B \in \mathcal{B}(\mathbb{R}) \qquad \Rightarrow$$

$$\mu(A \times B) = \int_{A\times B} (f_X \cdot f_Y) \, d\underline{m} \overset{\star}{=} \mathbb{P}_X(A) \cdot \mathbb{P}_Y(B).$$

$$\Rightarrow \qquad \mu = \mathbb{P}_X \otimes \mathbb{P}_Y = \mathbb{P}_Z \qquad \text{per ipotesi}$$

$$\Rightarrow \qquad \mathbb{P}_Z \ll \underline{m} \qquad (\Rightarrow Z = (X,Y) \text{ è assolutamente continuo})$$

e

$$f_Z := \frac{d\mathbb{P}_Z}{d\underline{m}} = f_X \cdot f_Y \qquad \underline{m}\text{-q.o.}$$

□

Osservazione: Sia $Z = (X,Y)$ vettore assolutamente continuo tale che

$$f_Z(x,y) = h(x) \cdot g(y) \qquad \underline{m}\text{-q.o.} \Rightarrow \qquad X \perp\!\!\!\perp Y.$$

Infatti

$$\begin{aligned}
f_X(x) &= \int_{-\infty}^{+\infty} f_Z(x,y)\,dy = \int_{-\infty}^{+\infty} h(x)\cdot g(y)\,dy \\
&= \left(\underbrace{\int_{-\infty}^{+\infty} g(y)\,dy}_{c}\right)\cdot h(x) = c\cdot h(x). \\
f_Y(y) &= \int_{-\infty}^{+\infty} f_Z(x,y)\,dx = \int_{-\infty}^{+\infty} h(x)\cdot g(y)\,dx \\
&= \left(\underbrace{\int_{-\infty}^{+\infty} h(x)\,dx}_{c'}\right)\cdot g(y) = c'\cdot g(y). \\
f_X(x)\cdot f_Y(y) &= \big(c\cdot h(x)\big)\big(c'\cdot g(y)\big) \\
&= \left(\int_{-\infty}^{+\infty} g(y)\,dy\right)\left(\int_{-\infty}^{+\infty} h(x)\,dx\right)\cdot h(x)\cdot g(y) \\
&\overset{\text{Fubini}}{=} \underbrace{\int_{\mathbb{R}^2} \underbrace{h(x)\cdot g(y)}_{f_Z(x,y)\ \text{q.o.}}\,dx\,dy}_{c\cdot c'=1}\cdot \underbrace{h(x)\cdot g(y)}_{f_Z(x,y)\ \text{q.o.}} \\
&= f_Z(x,y) \qquad \underline{m}\text{-q.o.} \Rightarrow \qquad X \perp\!\!\!\perp Y
\end{aligned}$$

Proposizione 3.3.5. Siano $X \perp\!\!\!\perp Y$ e $h, g : \mathbb{R} \to \mathbb{R}$ misurabili.
Allora

$$h(X) \perp\!\!\!\perp g(Y).$$

Dimostrazione. Siano

$$A, B \in \mathcal{B}(\mathbb{R}).$$

$$\begin{aligned}\mathbb{P}\big(h(X)\in A, g(Y)\in B\big) &= \mathbb{P}\left(X\in \underbrace{h^{-1}(A)}_{\in\mathcal{B}(\mathbb{R})}, Y\in \underbrace{g^{-1}(B)}_{\in\mathcal{B}(\mathbb{R})}\right)\\ &= \mathbb{P}\left(X\in h^{-1}(A)\right)\cdot\mathbb{P}\left(Y\in g^{-1}(B)\right)\\ &= \mathbb{P}\big(h(X)\in A\big)\cdot\mathbb{P}\big(g(Y)\in B\big)\\ &\Rightarrow h(X)\perp\!\!\!\perp g(Y).\end{aligned}$$

□

Esempio 3.3.6.

$$X\perp\!\!\!\perp Y \qquad\Rightarrow\qquad X^2\perp\!\!\!\perp e^{-Y}.$$

Si può generalizzare facilmente generalizzare ad un numero finito n di variabili aleatorie.

Proposizione 3.3.7. Siano

$$X_1,\dots,X_n\perp\!\!\!\perp Y_1,\dots,Y_n.$$

Siano

$$h:\mathbb{R}^n\to\mathbb{R} \qquad \text{e} \qquad g:\mathbb{R}^n\to\mathbb{R}$$

misurabili.

$$\Rightarrow \qquad h(X_1,\dots,X_n)\perp\!\!\!\perp g(Y_1,\dots,Y_n).$$

Esempio 3.3.8. Siano X_i indipendenti.

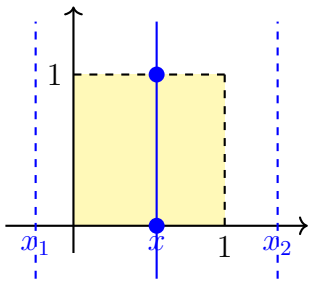
$$X_1X_2-X_3^2\perp\!\!\!\perp X_4+X_5^3-e^{X_6}\cdot X_7^2.$$

Esempio 3.3.9. *Siano X e Y due variabili aleatorie con funzione di densità congiunta*

$$f_{(X,Y)}(x,y)=4xy\,\mathbb{1}_D(x,y),$$

dove $D=(0,1)\times(0,1)$.
Determinare le leggi marginali e dire se X e Y sono indipendenti.

Soluzione



- $$f_X(x) = \int_{-\infty}^{+\infty} f_{(X,Y)}(x,y)\,dy$$

  se $x \leq 0$ oppure $x \geq 1$

  $$f_X(x) = 0.$$

  se $x \in (0,1)$

  $$f_X(x) = \int_0^1 4xy\,dy = 4x \cdot \frac{y^2}{2}\Big|_0^1 = 2x.$$

  $$\Rightarrow f_X(x) = 2x\,\mathbb{1}_{(0,1)}(x).$$

- per simmetria

  $$f_Y(y) = 2y\,\mathbb{1}_{(0,1)}(y).$$

$$\Rightarrow f_X(x) \cdot f_Y(y) = 4xy\,\mathbb{1}_{(0,1)\times(0,1)}(x,y) = f_{(X,Y)}(x,y) \qquad \forall (x,y) \in \mathbb{R}.$$

Avremmo potuto osservare che osservare che, per simmetria,

$$f_{(X,Y)}(x,y) = h(x) \cdot g(y) \qquad \text{con}$$

$$h(x) = g(x) = 2x\,\mathbb{1}_{(0,1)}(x) \Rightarrow X \perp Y \quad \text{e inoltre}$$

$$f_X(x) = f_Y(x) = 2x\,\mathbb{1}_{(0,1)}(x)$$

Esempio 3.3.10. *Siano X e Y due variabili aleatorie con funzione di densità congiunta*

$$f_{(X,Y)}(x,y) = kxy\,\mathbb{1}_D(x,y),$$

dove

$$D = \{(x,y) \in \mathbb{R}^2 : 0 < x \leq y < 1\}$$

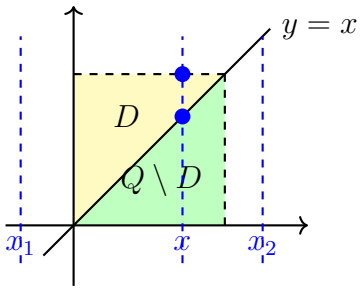
e $k \in \mathbb{R}$.

a) *Calcolare k.*
b) *Dire se X e Y sono indipendenti.*

soluzione

a)

- $f_{(X,Y)}$ è misurabile
- $f_{(X,Y)} \geq 0$ se $k \geq 0$



- $$1 = \int_{\mathbb{R}^2} f_{(X,Y)}\, d\underline{m}$$

$$= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f_{(X,Y)}(x,y)\, dx\, dy = \int_D kxy\, dx\, dy$$

$$= \int_0^1 \left(\int_0^y kxy\, dx \right) dy = \int_0^1 ky \cdot \frac{y^2}{2}\, dy =$$

$$= \frac{k}{2} \int_0^1 y^3\, dy = \frac{k}{2} \cdot \frac{1}{4} = \frac{k}{8} \Rightarrow \boxed{k = 8}$$

b)

- $$f_X(x) = \int_{-\infty}^{+\infty} f_{(X,Y)}(x,y)\, dy$$

se $x \leq 0$ oppure $x \geq 1$

$$f_X(x) = 0$$

se $0 < x < 1$

$$f_X(x) = \int_x^1 8xy\, dy = 8x \cdot \frac{y^2}{2}\Big|_x^1 =$$

$$= 4x - 4x^3 = 4x(1 - x^2)$$

$$\Rightarrow f_X(x) = 4x(1 - x^2)\, \mathbb{1}_{(0,1)}(x)$$

- $$f_Y(y) = \int_{-\infty}^{+\infty} f_{(X,Y)}(x,y)\, dy$$

se $y \leq 0$ oppure $y \geq 1$

$$f_Y(y) = 0$$

se $0 < y < 1$

$$f_Y(y) = \int_0^y 8xy\,dx = 8y \cdot \frac{y^2}{2} = 4y^3$$

$$\Rightarrow f_Y(y) = 4y^3\,\mathbb{1}_{(0,1)}(y)$$

- $$f_X(x) \cdot f_Y(y) = 4x(1-x^2)\,\mathbb{1}_{(0,1)}(x) \cdot 4y^3\,\mathbb{1}_{(0,1)}(y)$$

$$= 16xy^3(1-x^2)\,\mathbb{1}_Q(x,y)$$

$$\text{con } Q = (0,1) \times (0,1)$$

$$\neq f_{(X,Y)}(x,y)$$

$$= 8xy\,\mathbb{1}_D(x,y)$$

$$\Rightarrow X \not\perp\!\!\!\perp Y$$

Osservazione: Posso osservare che

$$f_X \cdot f_Y \neq 0 = f_{(X,Y)} \qquad \text{su } Q \setminus D \quad (q.o.)$$

ma

$$\underline{m}(Q \setminus D) > 0$$

$$\Rightarrow X \not\perp\!\!\!\perp Y$$

Esempio 3.3.11. *Siano X e Y variabili aleatorie discrete, a valori in $\mathbb{N}$, con densità congiunta*

$$p_{(X,Y)}(n,m) = c \cdot \frac{\nu^n \mu^m}{n!m!} \cdot \alpha^{nm}$$

dove $\nu, \mu > 0$, $0 < \alpha \leq 1$, e c è la costante di normalizzazione.

a) *Calcolare le densità marginali di X e Y.*
b) *Calcolare le probabilità condizionate $\mathbb{P}(X = n \mid Y = m)$.*
c) *Provare che, se $\alpha = 1$, le variabili aleatorie X e Y sono indipendenti.*

Soluzione

a)

$$\forall n \in \mathbb{N} \qquad p_X(n) = \sum_{m \in \mathbb{N}} p_{(X,Y)}(n,m) =$$

$$= \sum_{m=0}^{\infty} c \cdot \frac{\nu^n \mu^m}{n! \cdot m!} \alpha^{nm} = c \frac{\nu^n}{n!} \sum_{m=0}^{\infty} \frac{(\mu \alpha^n)^m}{m!}$$

$$= c \cdot \frac{\nu^n}{n!} e^{\mu \alpha^n}$$

Per simmetria

$$\forall m \in \mathbb{N} \qquad p_Y(m) = c \cdot \frac{\mu^m}{m!} e^{\nu \alpha^m}$$

b)

$$\mathbb{P}(X = n \mid Y = m) = \frac{\mathbb{P}(X = n, Y = m)}{\mathbb{P}(Y = m)} = \frac{p_{(X,Y)}(n, m)}{p_Y(m)}$$

$$= \frac{c \cdot \frac{\nu^n \mu^m}{n! \cdot m!} \alpha^{nm}}{c \frac{\mu^m}{m!} e^{\nu \alpha^m}}$$

$$= \frac{\nu^n}{n!} \alpha^{nm} e^{-\nu \alpha^m} = \frac{(\nu \alpha^m)^n}{n!} e^{-\nu \alpha^m}$$

c) se $\alpha = 1$

$$p_{(X,Y)}(n, m) = c \frac{\nu^n \mu^m}{n!\, m!} = c \left(\frac{\nu^n}{n!} \right) \left(\frac{\mu^m}{m!} \right)$$

$$p_X(n) = c e^{\mu} \frac{\nu^n}{n!}$$

$$p_Y(m) = c e^{\nu} \frac{\mu^m}{m!}$$

$$X \perp\!\!\!\perp Y \Leftrightarrow p_{(X,Y)}(n, m) = p_X(n) \cdot p_Y(m) \Leftrightarrow$$

$$\Leftrightarrow c \frac{\nu^n}{n!} \cdot \frac{\mu^m}{m!} = c e^{\mu} \frac{\nu^n}{n!} \cdot c e^{\nu} \frac{\mu^m}{m!}$$

$$c = c^2 e^{\mu + \nu}$$

$$(c \neq 0) \Rightarrow 1 = c e^{\mu + \nu} \Rightarrow \boxed{c = e^{-(\nu + \mu)}}$$

$$\Rightarrow p_{(X,Y)}(n, m) = e^{-(\nu + \mu)} \frac{\nu^n}{n!} \frac{\mu^m}{m!}$$

$$p_X(n) = c e^{\mu} \frac{\nu^n}{n!} = e^{-(\nu + \mu)} e^{\mu} \frac{\nu^n}{n!} = e^{-\nu} \frac{\nu^n}{n!}$$

analogamente

$$p_Y(m) = e^{-\mu} \frac{\mu^m}{m!}$$

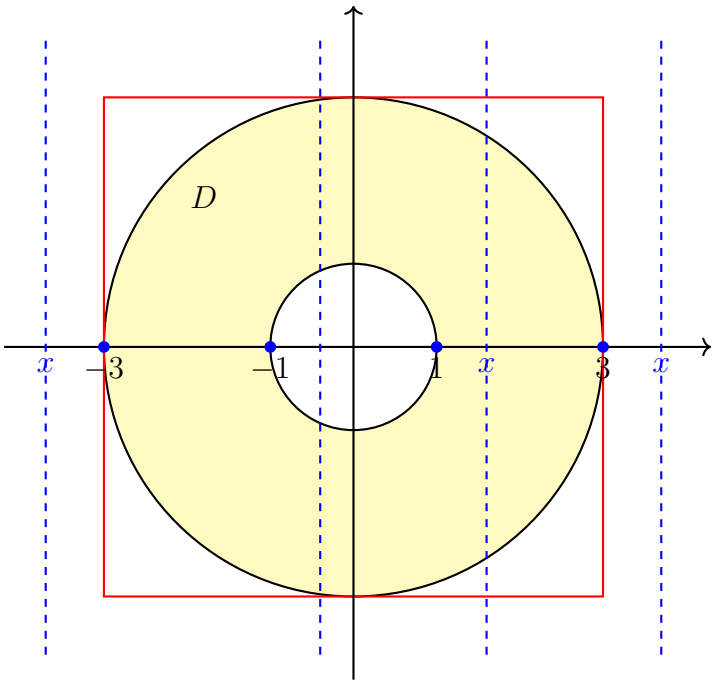
$$\Rightarrow \boxed{X \sim P(\nu) \quad \perp\!\!\!\perp \quad Y \sim P(\mu)}$$

Esempio 3.3.12. *Sia (X, Y) un vettore aleatorio distribuito uniformemente sull'insieme*

$$D = \{(x, y) \in \mathbb{R}^2 : 1 \leq x^2 + y^2 \leq 9\}.$$

a) *Scrivere esplicitamente la densità congiunta.*
b) *Determinare le densità marginali.*
c) *X e Y sono indipendenti? Sono scorrelate?*

Soluzione



a)

$$f_{(X,Y)}(x, y) = k\, \mathbb{1}_D(x, y)$$

$$= \frac{1}{\text{area}\, D}\, \mathbb{1}_D(x, y) = \frac{1}{8\pi}\, \mathbb{1}_D(x, y)$$

$$\text{area}\, D = \pi R^2 - \pi r^2 = 8\pi$$

b)

$$f_X(x) = \int_{-\infty}^{+\infty} f_{(X,Y)}(x, y)\, dy \qquad \forall x \in \mathbb{R}$$

- se $x < -3$ oppure $x > 3$

$$f_X(x) = 0$$

- se $-3 \leq x < -1$ oppure $1 < x \leq 3$

$$f_X(x) = \int_{-\sqrt{9-x^2}}^{+\sqrt{9-x^2}} \frac{1}{8\pi}\, dy = \frac{1}{8\pi}\left[\sqrt{9-x^2} + \sqrt{9-x^2}\right] = \frac{1}{4\pi}\sqrt{9-x^2}$$

- se $-1 \leq x \leq 1$

$$f_X(x) = \int_{-\sqrt{9-x^2}}^{-\sqrt{1-x^2}} \frac{1}{8\pi}\, dy + \int_{\sqrt{1-x^2}}^{\sqrt{9-x^2}} \frac{1}{8\pi}\, dy =$$

$$= \frac{1}{8\pi}\left[-\sqrt{1-x^2} + \sqrt{9-x^2}\right] + \frac{1}{8\pi}\left[\sqrt{9-x^2} - \sqrt{1-x^2}\right]$$

$$= \frac{1}{4\pi}\left[\sqrt{9-x^2} - \sqrt{1-x^2}\right]$$

$$\Rightarrow f_X(x) = \frac{1}{4\pi}\left[\sqrt{9-x^2} - \sqrt{1-x^2}\right] \mathbb{1}_{[-1,1]}(x) + \frac{1}{4\pi}\sqrt{9-x^2}\, \mathbb{1}_{[-3,-1)\cup(1,3]}(x,y)$$

Per simmetria possiamo porre

$$f_Y(x) = f_X(x) \forall x \in \mathbb{R}$$

c)

$$f_X(x) \cdot f_Y(y) \neq \frac{1}{8\pi}\mathbb{1}_D(x,y) = f_{(X,Y)}(x,y) \Rightarrow X \not\perp\!\!\!\perp Y$$

Esempio 3.3.13. *Ugo e Zoe si danno appuntamento davanti ad un locale, concordando di aspettarsi fuori per non più di 10 minuti (dopodiché il primo arrivato inizia ad entrare nel locale).*
Si supponga che Ugo e Zoe arrivino, in maniera indipendente l'uno dall'altra, in un istante distribuito uniformemente tra le 21:00 e le 22:00.
Con quale probabilità entrano insieme nel locale?

Soluzione

Ugo arriva alle 21 e U minuti

$$U \sim U((0,60))$$

Zoe arriva alle 21 e Z minuti

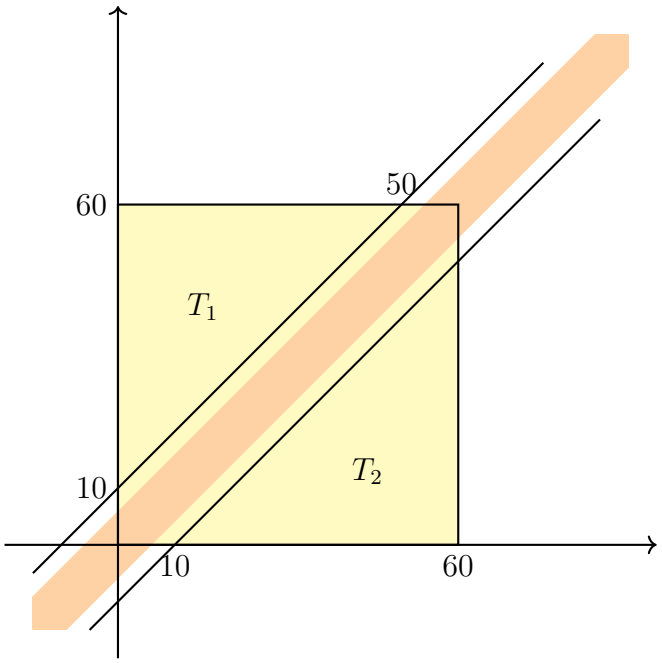
$$Z \sim U((0,60))$$

$$U \perp Z$$

$$f_U(u) = \frac{1}{60}\mathbb{1}_{(0,60)}(u)$$

$$f_Z(z) = \frac{1}{60}\mathbb{1}_{(0,60)}(z)$$

$$\Rightarrow f_{(U,Z)}(u,z) = f_U(u) \cdot f_Z(z) = \frac{1}{3600}\mathbb{1}_{(0,60)\times(0,60)}(u,z)$$



$$\mathbb{P}(\text{entrare insieme}) = \mathbb{P}\big(|U - Z| < 10\big) = \mathbb{P}\big((U, Z) \in C\big)$$

con

$$C = \big\{(u, z) \in \mathbb{R}^2 : |u - z| < 10\big\}$$

$$= \big\{(u, z) \in \mathbb{R}^2 : u - 10 < z < u + 10\big\}$$

$$\mathbb{P}\big((U, Z) \in C\big) = \int_C f_{(U,Z)}(u, z)\, du\, dz = \int_{C \cap Q} \frac{1}{3600}\, du\, dz$$

$$= \frac{1}{3600} \operatorname{area}(C \cap Q) = \frac{1}{3600} (\operatorname{area} Q - \operatorname{area} T_1 - \operatorname{area} T_2)$$

$$= \frac{1}{3600} \left(3600 - \frac{2500}{2} - \frac{2500}{2}\right) = \frac{1100}{3600} = \boxed{\frac{11}{36}}$$

3.4 Valori attesi

Definizione 3.4.1. Sia $Z = (X, Y)$ un vettore aleatorio e sia

$$g : \mathbb{R}^2 \to \mathbb{R}$$

misurabile.
Si dice valore atteso della variabile aletoria

$$g \circ Z = g(Z) = g(X, Y)$$

la quantità seguente (se ben definita)

$$\mathbb{E}\left[\underbrace{g(X,Y)}_{g(Z)}\right] = \int_\Omega \underbrace{g(X,Y)}_{g(Z)}\, d\mathbb{P} = \int_{\mathbb{R}^2} g\, d\mathbb{P}_Z =$$

$$= \int_{\mathbb{R}^2} g(x,y)\, d\mathbb{P}_Z(x,y) = \begin{cases} \displaystyle\sum_{(x_i,y_j)\in Z(\Omega)} g(x_i,y_j)\, p_Z(x_i,y_j) & \text{se } Z \text{ discreta} \\ \displaystyle\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty} g(x,y) f_Z(x,y)\, dx\, dy & \text{se } Z \text{ assoluamente continua} \end{cases}$$

Diciamo che $g(x,y)$ ammette momento finito di ordine 1
se

$$g(x,y) \in L^1(\Omega, \mathcal{F}, \mathbb{P})$$

ovvero

$$g \in L^1\big(\mathbb{R}^2, \mathcal{B}(\mathbb{R}^2), \mathbb{P}_Z\big).$$

Proposizione 3.4.2 (Disuguaglianza di Cauchy-Schwarz)**.** Siano $X, Y \in L^2(\Omega, \mathcal{F}, \mathbb{P})$

$$\Rightarrow XY \in L^1(\Omega, \mathcal{F}, \mathbb{P})$$

inoltre

$$|\mathbb{E}[XY]| \le \mathbb{E}[|XY|] \le \sqrt{\mathbb{E}[X^2]\cdot\mathbb{E}[Y^2]}$$

Osservazione: Possiamo riscrivere in forma più astratta la disuaguaglianza del modo seguente

$$|\langle X, Y\rangle \le \|XY\|_{L_1}| \le \|X\|_{L_2}\|Y\|_{L_2}$$

ovvero usando il prodotto scalare e la sua norma indotta di L_2.

3.5 Covarianza e correlazione

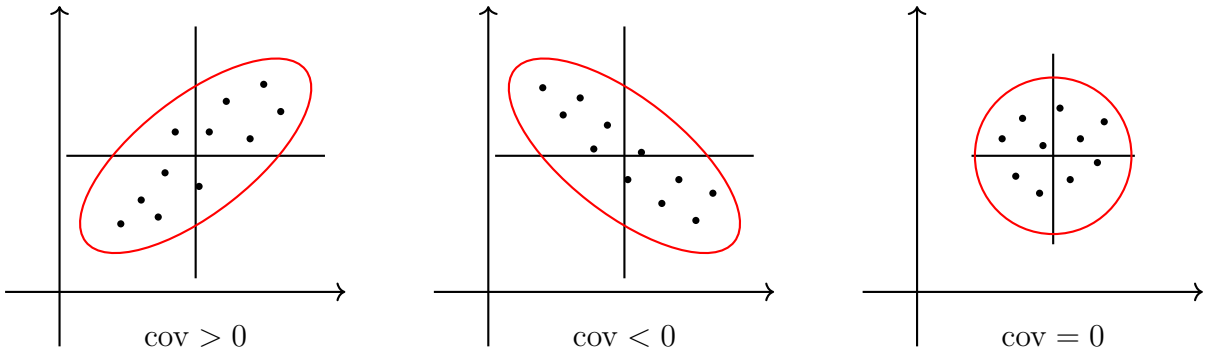
Sono indici numerici del legame che intercorre fra due variabili aleatorie.

Definizione 3.5.1 (Covarianza)**.** Siano $X, Y \in L^2$ (o $X, Y, XY \in L^1$). Si dice covarianza tra X e Y la quantità

$$\mathrm{Cov}(X,Y) = \mathbb{E}\left[(X - \mathbb{E}[X])\,(Y - \mathbb{E}[Y])\right].$$

Osservazione:

- se $\mathrm{cov}(X,Y) > 0$ diciamo che X e Y sono positivamente correlate
- se $\mathrm{cov}(X,Y) < 0$ diciamo che X e Y sono negativamente correlate
- se $\mathrm{cov}(X,Y) = 0$ diciamo che X e Y sono scorrelate o non correlate



Le figure ci aiutano a capire a livello intutivo il significato pratico del segno della covarianza. Quando questo è positivo aumentando la X aumenta anche la Y e se diminuisce la X diminuisce anche la Y. Quando è negativo accade il viceversa ovvero se la X aumenta la Y tende a diminuire mentre se la X diminuisce la Y tende ad aumentare. Nel caso di covarianza nulla non c'è una relazione predominante tra le due. È importante precisare che il comporatmento descritto avviene in media probabilistica e quindi potrebbero esserci singoli casi in cui X e Y sembrano scorrelate anche se la covarianza è non nulla.

Osservazione: Possiamo interpretare la varianza in modo più astratto. Immaginiamo una variabile aleatoria X come un "vettore" di infinite coordinate date da $X(\omega) \quad \forall \omega \in \Omega$. Il prodotto scalare in $L_2(\Omega, \mathcal{F}, \mathbb{P})$ allora di venta l'analogo di un prodotto scalare in $\mathbb{R}^n$, ovvero sto sommando i prodotti delle corrispettive coordinate di X e Y.Nel caso della covarianza facciamo il prodotto scalare di $X - \mathbb{E}[X]$ e $Y - \mathbb{E}[Y]$, ovvero possiamo immaginare di "sommare" su tutti gli $\omega \in \Omega$ il prodotto di quanto X si distacca dalla sua media in ω per quanto si distacca dalla sua media Y in ω. Siamo più che altro interessati al segno del prodotto scalare: se questo è positivo vuol dire che X, Y assumono valori sopra o sotto la media in maniera concorde, o per lo meno la "quantità" di punti di Ω in cui questo accade supera la "quantità" di punti dove non accade. Se il prodotto scalare è negativo succede essattamente il contrario ovvero la "quantità" di punti in cui assumono valori sopra o sotto la media in maniera discorde supera la "quantità" di punti in cui questo avviene in maniera concorde. Nel caso di prodotto scalare nullo non c'è una prevalenza di uno dei due comportamenti e quindi non si possono individuare tendenze globali.

Proposizione 3.5.2. Siano $X, Y \in L^2(\Omega, \mathcal{F}, \mathbb{P})$ due variabili aleatorie reali. Allora

$$\mathrm{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

Dimostrazione. Per definizione,

$$\mathrm{Cov}(X, Y) = \mathbb{E}\left[(X - \mu_X)\,(Y - \mu_Y)\right],$$

dove

$$\mu_X = \mathbb{E}[X], \qquad \mu_Y = \mathbb{E}[Y].$$

Sviluppando il prodotto,

$$\begin{aligned}\mathrm{Cov}(X,Y) &= \mathbb{E}\left[XY - X\mu_Y - \mu_X Y + \mu_X\mu_Y\right] \\ &= \mathbb{E}[XY] - \mathbb{E}[X]\mu_Y - \mu_X\mathbb{E}[Y] + \mu_X\mu_Y \\ &= \mathbb{E}[XY] - \mu_X\mu_Y - \mu_X\mu_Y + \mu_X\mu_Y \\ &= \mathbb{E}[XY] - \mu_X\mu_Y \\ &= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].\end{aligned}$$

□

Proposizione 3.5.3. Siano $X, Y \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ e

$$X \perp\!\!\!\perp Y.$$

Allora

$$XY \in L^1 \qquad \text{e} \qquad \mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y].$$

$$(\text{ovvero } \operatorname{cov}(X,Y) = 0 \text{ cioè } X, Y \text{ scorrelate})$$

Soluzione. Sia

$$g(x,y) = |xy|.$$

Sia

$$Z = (X,Y).$$

$$\underbrace{\mathbb{E}[|XY|]}_{\mathbb{E}[g(X,Y)]} = \int_\Omega \underbrace{|XY|}_{g(X,Y)}\, d\mathbb{P} = \int_{\mathbb{R}^2} \underbrace{|xy|}_{g(x,y)}\, d\mathbb{P}_Z(x,y)$$

$$= \int_{\mathbb{R}^2} |xy|\, d(\mathbb{P}_X \otimes \mathbb{P}_Y)(x,y).$$

Dal momento che

$$g(x,y) \geq 0 \quad \text{misurabile in } \left(\mathbb{R}^2, \mathcal{B}(\mathbb{R}^2)\right).$$

applico Tonelli

$$= \left(\int_{\mathbb{R}} |x|\, d\mathbb{P}_X(x)\right)\left(\int_{\mathbb{R}} |y|\, d\mathbb{P}_Y(y)\right) = \int_\Omega |X|\, d\mathbb{P} \cdot \int_\Omega |Y|\, d\mathbb{P}$$

$$= \mathbb{E}[|X|] \cdot \mathbb{E}[|Y|].$$

$$\Rightarrow g(x,y) = |xy| \in L^1(\Omega, \mathcal{F}, \mathbb{P})$$

$$\Leftrightarrow h(X,Y) = XY \in L^1(\Omega, \mathcal{F}, \mathbb{P}) \Leftrightarrow h \in L^1\left(\mathbb{R}^2, \mathcal{B}(\mathbb{R}^2), \mathbb{P}_Z\right).$$

Allora

$$\mathbb{E}[XY] = \cdots = \mathbb{E}[X]\mathbb{E}[Y].$$

facendo gli stessi passaggi di prima da applicando Fubini al posto di Tonelli. □

Osservazione:

$$X \perp\!\!\!\perp Y \quad \Rightarrow \quad \operatorname{cov}(X,Y) = 0,$$

ma in generale non vale il viceversa.

Esempio 3.5.4.

$$X \sim U((-1,1)) \qquad Y = X^2$$

$$X \not\perp\!\!\!\perp Y$$

$$\operatorname{cov}(x,y) = \mathbb{E}[xy] - \mathbb{E}[x]\mathbb{E}[y]$$

$$\mathbb{E}[X] = \frac{a+b}{2} = 0$$

- $$\mathbb{E}[Y] = \mathbb{E}[X^2] = \operatorname{var}(X) = \frac{(b-a)^2}{12} = \frac{1}{3}$$
- $$\mathbb{E}[XY] = \mathbb{E}[X^3] = \int_{-\infty}^{+\infty} x^3 f_X(x)\,dx = \int_{-1}^{1} x^3 \cdot \frac{1}{2}\,dx = 0$$

$$\Rightarrow \operatorname{cov}(x,y) = 0$$

Proposizione 3.5.5 (Proprietà della covarianza)**.** Siano $X, Y, Z, X_1, X_2, Y_1, Y_2 \in L^2(\Omega, \mathcal{F}, \mathbb{P})$ e siano $a, b, c, a_1, a_2, b_1, b_2, c_1, c_2 \in \mathbb{R}$. Allora valgono le seguenti proprietà:

1. $$\operatorname{cov}(X,X) = \operatorname{var}(X).$$
2. $$\operatorname{cov}(X,Y) = \operatorname{cov}(Y,X).$$
3. $$\operatorname{cov}(aX + bY + c, Z) = a\,\operatorname{cov}(X,Z) + b\,\operatorname{cov}(Y,Z).$$
4. $$\begin{aligned}&\operatorname{cov}(a_1X_1 + b_1Y_1 + c_1,\ a_2X_2 + b_2Y_2 + c_2)\\ &= a_1a_2\operatorname{cov}(X_1,X_2) + a_1b_2\operatorname{cov}(X_1,Y_2) + b_1a_2\operatorname{cov}(Y_1,X_2) + b_1b_2\operatorname{cov}(Y_1,Y_2).\end{aligned}$$

   Quindi la covarianza è bilineare.
5. $$\operatorname{var}(aX + bY + c) = a^2\operatorname{var}(X) + 2ab\,\operatorname{cov}(X,Y) + b^2\operatorname{var}(Y).$$
6. Se $X \perp\!\!\!\perp Y$ o X, Y sono scorrelate,
   $$\operatorname{var}(aX + bY + c) = a^2\operatorname{var}(X) + b^2\operatorname{var}(Y).$$

In particolare, se $X \perp\!\!\!\perp Y$ (o scorrelate),

$$\operatorname{var}(X+Y) = \operatorname{var}(X) + \operatorname{var}(Y),$$

$$\operatorname{var}(X-Y) = \operatorname{var}(X) + \operatorname{var}(Y).$$

Altrimenti,

$$\operatorname{var}(X+Y) = \operatorname{var}(X) + \operatorname{var}(Y) + 2\operatorname{cov}(X,Y),$$
$$\operatorname{var}(X-Y) = \operatorname{var}(X) + \operatorname{var}(Y) - 2\operatorname{cov}(X,Y).$$

Dimostrazione. Per la prima proprietà,

$$\operatorname{cov}(X,X) = \mathbb{E}\left[(X-\mathbb{E}[X])(X-\mathbb{E}[X])\right] = \mathbb{E}\left[(X-\mathbb{E}[X])^2\right] = \operatorname{var}(X).$$

Per la seconda proprietà,

$$\begin{aligned}\operatorname{cov}(X,Y) &= \mathbb{E}\left[(X-\mathbb{E}[X])(Y-\mathbb{E}[Y])\right] \\ &= \mathbb{E}\left[(Y-\mathbb{E}[Y])(X-\mathbb{E}[X])\right] \\ &= \operatorname{cov}(Y,X).\end{aligned}$$

Per la terza proprietà,

$$\begin{aligned}\operatorname{cov}(aX+bY+c,Z) &= \mathbb{E}\left[(aX+bY+c-\mathbb{E}[aX+bY+c])(Z-\mathbb{E}[Z])\right] \\ &= \mathbb{E}\left[(aX+bY+c-a\mathbb{E}[X]-b\mathbb{E}[Y]-c)\,(Z-\mathbb{E}[Z])\right] \\ &= \mathbb{E}\left[(a(X-\mathbb{E}[X])+b(Y-\mathbb{E}[Y]))\,(Z-\mathbb{E}[Z])\right] \\ &= a\mathbb{E}\left[(X-\mathbb{E}[X])(Z-\mathbb{E}[Z])\right] + b\mathbb{E}\left[(Y-\mathbb{E}[Y])(Z-\mathbb{E}[Z])\right] \\ &= a\,\operatorname{cov}(X,Z) + b\,\operatorname{cov}(Y,Z).\end{aligned}$$

Considerando le proprietà 2) e 3), otteniamo

$$\begin{aligned}&\operatorname{cov}(a_1X_1+b_1Y_1+c_1,\, a_2X_2+b_2Y_2+c_2) \\ &= a_1a_2\operatorname{cov}(X_1,X_2) + a_1b_2\operatorname{cov}(X_1,Y_2) + b_1a_2\operatorname{cov}(Y_1,X_2) + b_1b_2\operatorname{cov}(Y_1,Y_2).\end{aligned}$$

Quindi la covarianza è bilineare.
Per la quinta proprietà,

$$\begin{aligned}\operatorname{var}(aX+bY+c) &= \operatorname{cov}(aX+bY+c, aX+bY+c) \\ &= a^2\operatorname{cov}(X,X) + ab\operatorname{cov}(X,Y) + ab\operatorname{cov}(Y,X) + b^2\operatorname{cov}(Y,Y) \\ &= a^2\operatorname{var}(X) + 2ab\,\operatorname{cov}(X,Y) + b^2\operatorname{var}(Y).\end{aligned}$$

Se $X \perp\!\!\!\perp Y$ o X, Y sono scorrelate, allora

$$\operatorname{cov}(X,Y) = 0,$$

e dunque

$$\operatorname{var}(aX+bY+c) = a^2\operatorname{var}(X) + b^2\operatorname{var}(Y).$$

□

Osservazione: In particolare,

$$\operatorname{var}(X+Y) = \operatorname{var}(X) + \operatorname{var}(Y),$$

e

$$\operatorname{var}(X-Y) = \operatorname{var}(X) + \operatorname{var}(Y).$$

Altrimenti,

$$\mathrm{var}(X+Y) = \mathrm{var}(X) + \mathrm{var}(Y) + 2\,\mathrm{cov}(X,Y),$$

e

$$\mathrm{var}(X-Y) = \mathrm{var}(X) + \mathrm{var}(Y) - 2\,\mathrm{cov}(X,Y).$$

Esempio 3.5.6.

$$X \sim B(n,p) \qquad X = \sum_{i=1}^{n} Y_i \qquad Y_i \sim b(p) \quad \text{iid}$$

$$\mathbb{E}[X] = \mathbb{E}\left[\sum_{i=1}^{n} Y_i\right] = \sum_{i=1}^{n} \mathbb{E}[Y_i] = \sum_{i=1}^{n} p = np$$

$$\mathrm{var}(X) = \mathrm{var}\left(\sum_{i=1}^{n} Y_i\right) \overset{\text{indip}}{=} \sum_{i=1}^{n} \mathrm{var}(Y_i) = \sum_{i=1}^{n} p(1-p) = np(1-p)$$

Definizione 3.5.7. Sia

$$\underline{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_N \end{pmatrix}$$

un vettore aleatorio a valori in $\mathbb{R}^N$.

- Si dice vettore delle medie (media) di $\underline{X}$ il vettore

$$\underline{\mu} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_N \end{pmatrix} \qquad \text{dove } \mu_i = \mathbb{E}[X_i] \qquad \forall i = 1 \dots N.$$

- Si dice matrice di varianza e covarianza di $\underline{X}$ la matrice

$$C = (C_{ij})_{i,j=1\dots N} \qquad \text{dove } C_{ij} = \mathrm{cov}(X_i, X_j)$$

$$\forall i,j = 1 \dots N \qquad \text{e in particolare} \qquad C_{ii} = \mathrm{var}(X_i) \qquad \forall i = 1 \dots N.$$

Proposizione 3.5.8. La matrice di varianza e covarianza di un vettore aleatorio $\underline{X}$ è una matrice simmetrica e semidefinita positiva.

Dimostrazione.

$$C_{ij} = \mathrm{cov}(X_i, X_j) = \mathrm{cov}(X_j, X_i) = C_{ji} \qquad \Rightarrow \text{ ok.}$$

Sia

$$\underline{a} \in \mathbb{R}^N.$$

$$\begin{aligned}
\underline{a}^T C \underline{a} &= \sum_{i,j=1}^{N} a_i a_j C_{ij} \\
&= \sum_{i=1}^{N} a_i^2 C_{ii} + 2 \sum_{i<j} a_i a_j C_{ij} \\
&= \sum_{i=1}^{N} a_i^2 \operatorname{var}(X_i) + \sum_{i<j} a_i a_j \operatorname{cov}(X_i, X_j) \\
&= \operatorname{var}\left(\sum_{i=1}^{N} a_i X_i \right) \geq 0 \qquad \Rightarrow \text{ ok.}
\end{aligned}$$

□

Definizione 3.5.9. Chiamiamo coefficiente di correlazione lineare (correlazione) tra X e Y la quantità (quando ben definita)

$$\rho(X,Y) = \frac{\operatorname{cov}(X,Y)}{\sqrt{\operatorname{var}(X)\operatorname{var}(Y)}}.$$

Osservazione:

$$\rho(X,Y) = \frac{\operatorname{cov}(X,Y)}{\sqrt{\operatorname{var}(X)} \cdot \sqrt{\operatorname{var}(Y)}} = \frac{\operatorname{cov}(X,Y)}{\sigma_X \cdot \sigma_Y} = \frac{\langle X - \mathbb{E}[X], Y - \mathbb{E}[Y] \rangle_{L^2}}{\|X - \mathbb{E}[X]\|_{L^2} \cdot \|Y - \mathbb{E}[Y]\|_{L^2}} = \cos\theta$$

ovvero la correlazione è il coseno dell' "angolo" tra i due vettori e misura quindi in modo adimensionato e senza scala la stessa proprietà misurata dalla covarianza. La correlazione però ci dà maggiori informazioni rispetto al semplice segno. È infatti indipendente da riscalamenti delle variabili aleatorie e quindi possiamo usare il suo valore numerico oltre al segno per misurare l'andamento comune delle due variabili aleatorie.

Proposizione 3.5.10 (Proprietà di $\rho(X,Y)$)**.**

1. $a, b > 0$

$$\rho(aX, bY) = \rho(X,Y)$$

(ρ è un n° puro che non si fa condizionare dai cambi di scala)

2.
$$-1 \leq \rho(X,Y) \leq 1$$

3.
$$\rho(X,Y) = \pm 1 \iff Y = aX + b \quad \text{q.o.} \qquad a, b \in \mathbb{R}, \quad a \neq 0$$

Dimostrazione. 1.

$$\rho(aX, bY) = \frac{\operatorname{cov}(aX, bY)}{\sqrt{\operatorname{var}(aX)\operatorname{var}(bY)}} = \frac{ab \operatorname{cov}(X,Y)}{\sqrt{a^2 \operatorname{var}(X)\, b^2 \operatorname{var}(Y)}}$$

$$= \frac{ab\,\operatorname{cov}(X,Y)}{ab\sqrt{\operatorname{var}(X)\operatorname{var}(Y)}} = \rho(X,Y)$$

2.
$$|\rho(X,Y)| = \frac{|\operatorname{cov}(X,Y)|}{\sqrt{\operatorname{var}(X)\operatorname{var}(Y)}} = \frac{|\mathbb{E}\left[(X-\mathbb{E}[X])(Y-\mathbb{E}[Y])\right]|}{\sqrt{\mathbb{E}\left[(X-\mathbb{E}[X])^2\right]\mathbb{E}\left[(Y-\mathbb{E}[Y])^2\right]}}$$

$$= \frac{|\langle X-\mathbb{E}[X],\, Y-\mathbb{E}[Y]\rangle|}{\|X-\mathbb{E}[X]\|_{L^2}\cdot\|Y-\mathbb{E}[Y]\|_{L^2}}$$

$$\leq \frac{\|(X-\mathbb{E}[X])(Y-\mathbb{E}[Y])\|_{L^1}}{\|X-\mathbb{E}[X]\|_{L^2}\cdot\|Y-\mathbb{E}[Y]\|_{L^2}} \leq 1 \qquad \text{per Cauchy-Schwarz}$$

3. Sia $y = ax + b$.

$$\begin{aligned}
\rho(x,y) &= \frac{\operatorname{cov}(x,y)}{\sqrt{\operatorname{var}(x)\operatorname{var}(y)}} \\
&= \frac{\operatorname{cov}(x, ax+b)}{\sqrt{\operatorname{var}(x)\cdot\operatorname{var}(ax+b)}} \\
&= \frac{a\operatorname{var}(x)}{\sqrt{\operatorname{var}(x)\cdot a^2\operatorname{var}(x)}} \\
&= \frac{a\operatorname{var}(x)}{|a|\operatorname{var}(x)} = \frac{a}{|a|} = \operatorname{sign}(a) \\
&= \begin{cases} +1 & \text{se } a > 0, \\ -1 & \text{se } a < 0. \end{cases}
\end{aligned}$$

Sia $\rho(x,y) = \pm 1$, denotiamo con σ_x^2, σ_y^2 le varianze di X e Y rispettivamente e con σ_x e σ_y le deviazioni standard.

$$\begin{aligned}
\operatorname{var}\left(\frac{X}{\sigma_x} \mp \frac{Y}{\sigma_y}\right) &= \frac{1}{\sigma_x^2}\operatorname{var}(x) + \frac{1}{\sigma_y^2}\operatorname{var}(y) \mp 2\frac{1}{\sigma_x}\frac{1}{\sigma_y}\operatorname{cov}(x,y) \\
&= 2(1 \mp \rho(x,y)) = 0.
\end{aligned}$$

$$\Rightarrow \frac{X}{\sigma_x} \mp \frac{Y}{\sigma_y} = c \quad \text{q.o.}$$

$$\Rightarrow Y = \pm\frac{\sigma_y}{\sigma_x}X \mp c\sigma_y$$

$$\Rightarrow y = ax + b \quad \text{q.o. con } a, b \in \mathbb{R}, \quad a > 0 \ (a < 0).$$

□

Esempio 3.5.11.

$$X \sim B\left(4, \frac{1}{4}\right) \qquad Y \sim U([0,2]) \qquad \operatorname{cov}(x,y) = \frac{1}{4}$$

$\rho(x, y)$?

$$\begin{aligned}\rho(x, y) &= \frac{\operatorname{cov}(x, y)}{\sqrt{\operatorname{var}(x)\operatorname{var}(y)}} \\ &= \frac{\frac{1}{4}}{\sqrt{\frac{3}{4} \cdot \frac{1}{3}}} = \frac{\frac{1}{4}}{\frac{1}{2}} = \frac{1}{2}\end{aligned}$$

2) $\mathbb{E}[2x - 3y^2 + 1]$?

$$\begin{aligned}\mathbb{E}[Y^2] &= \operatorname{var}(Y) + \mathbb{E}[Y]^2 \\ \mathbb{E}[2X - 3Y^2 + 1] &= 2\mathbb{E}[X] - 3\mathbb{E}[Y^2] + 1 \\ &= 2 \cdot 1 - 3\left(\frac{1}{3} + 1\right) + 1 = -1\end{aligned}$$

3) $\operatorname{var}(2x - y + 3)$?

$$\begin{aligned}\operatorname{var}(2x - y + 3) &= \operatorname{var}(2x - y) \\ &= 4\operatorname{var}(x) + \operatorname{var}(y) - 4\operatorname{cov}(x, y) \\ &= 4 \cdot \frac{3}{4} + \frac{1}{3} - 4 \cdot \frac{1}{4} = \frac{7}{3}\end{aligned}$$

4) $\operatorname{cov}(2x - y, 2x + 2y)$?

$$\begin{aligned}\operatorname{cov}(2x - y, 2x + 2y) &= 4\operatorname{cov}(x, x) + 4\operatorname{cov}(x, y) - 2\operatorname{cov}(y, x) - 2\operatorname{cov}(y, y) \\ &= 4\operatorname{var}(x) - 2\operatorname{var}(y) + 2\operatorname{cov}(x, y) \\ &= 4 \cdot \frac{3}{4} - 2 \cdot \frac{1}{3} + 2 \cdot \frac{1}{4} = \frac{17}{6} > 0\end{aligned}$$

Sono positivamente correlate

Capitolo 4

Trasformazioni di variabili e vettori aleatori

4.1 Trasformazioni di variabili aleatorie

Sia X variabile aleatoria reale e sia $g : \mathbb{R} \to \mathbb{R}$ misurabile.
Allora $Y = g(X) = g \circ X$ è una variabile aleatoria e possiamo calcolare la legge:

$$\begin{aligned} \forall A \in \mathcal{B}(\mathbb{R}) \qquad \mathbb{P}_Y(A) &= \mathbb{P}(Y^{-1}(A)) = \mathbb{P}(Y \in A) = \mathbb{P}(g(X) \in A) \\ &= \mathbb{P}(X \in g^{-1}(A)) = \mathbb{P}\left(X^{-1}(g^{-1}(A))\right) = \mathbb{P}_X(g^{-1}(A)) \end{aligned} \tag{$*$}$$

Osservazione: Nel corso di metodi abbiamo già incontrato variabili aleatorie del tipo $g \circ X$. In quel contesto però non ci siamo interrogati su quale fosse la legge (misura immagine) di $Y = g \circ X$ ma solo di calcolare

$$\mathbb{E}[g(X)] = \int_\Omega g \circ X \, d\mathbb{P} = \int_{\mathbb{R}} g \, d\mathbb{P}_X$$

ovvero abbiamo integrato g sull'immagine di X attraverso la sua misura immagine. Qui invece ci stiamo preoccupando di definire la misura immagine di Y che è una misura sull'immagine di g e sulla quale quindi non ha senso integrare g stessa.

4.1.1 Caso discreto

Se X è una variabile aleatoria discreta allora lo è anche $Y = g(X)$. Infatti $Y(\Omega) = g(X(\Omega))$ e $\forall y \in Y(\Omega)$

$$\begin{aligned} p_Y(y) = \mathbb{P}(Y = y) = \mathbb{P}_Y\left(\overbrace{\{y\}}^{A}\right) &\overset{(*)}{=} \mathbb{P}_X\left(\overbrace{g^{-1}(\{y\})}^{B}\right) \\ = \mathbb{P}\left(X \in \underbrace{g^{-1}(\{y\})}_{B}\right) &= \sum_{x \in g^{-1}(\{y\}) \cap X(\Omega)} p_X(x) \end{aligned}$$

Esempio 4.1.1. Sia $X \sim U(\{-2, -1, 0, 1\})$ e sia $Y = X^2 = g(x)$ con $g(x) = x^2$.

$$X(\Omega) = \{-2, -1, 0, 1\} \quad \Rightarrow \quad Y(\Omega) = g(X(\Omega)) = \{0, 1, 4\}$$

Ricordiamo che $p_X(x) = \frac{1}{4} \quad \forall x \in X(\Omega)$.

$$p_Y(0) = \sum_{x \in g^{-1}(\{0\})} p_X(x) = p_X(0) = \frac{1}{4}$$

$$p_Y(1) = \sum_{x \in g^{-1}(\{1\})} p_X(x) = p_X(-1) + p_X(1) = \frac{1}{4} + \frac{1}{4} = \frac{1}{2}$$

$$p_Y(4) = \sum_{x \in g^{-1}(\{4\})} p_X(x) = p_X(-2) + \underbrace{\cancel{p_X(2)}}_{2 \notin X(\Omega)} = p_X(-2) = \frac{1}{4}$$

4.1.2 Caso assolutamente continuo

Sia X variabile aleatoria assolutamente continua, $g : \mathbb{R} \to \mathbb{R}$ misurabile. $Y = g(X)$.

$$\forall y \in \mathbb{R} \qquad F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}_Y\left(\overbrace{(-\infty, y]}^{A}\right) \overset{(*)}{=} \mathbb{P}_X\left(g^{-1}((-\infty, y])\right)$$

$$= \mathbb{P}\left(X \in \overbrace{g^{-1}((-\infty, y])}^{B}\right) = \int_{\underbrace{g^{-1}((-\infty, y])}_{B}} f_X \, dm$$

A questo punto possiamo ottenere la densità $f_Y(y)$ semplicemente derivando $F_Y(y)$ ovvero

$$f_Y(y) = \frac{dF_y(y)}{dy}$$

Chiamiamo questo modo di ottenere la densità metodo della funzione di ripartizione. Un altro metodo di calcolo della densità è dato dalla seguente proposizione.

Proposizione 4.1.2. Sia X variabile aleatoria assolutamente continua con densità f_X. Sia $g : \mathbb{R} \to \mathbb{R}$ tale che $g \in C^1$, $g' \neq 0$ ($\Rightarrow g$ strettamente monotona e quindi invertibile) tale che $g^{-1} \in C^1$. Allora $Y = g(X)$ è una variabile aleatoria assolutamente continua con densità:

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right| \mathbb{1}_{g(\mathbb{R})}(y)$$

Dimostrazione. Facciamo la dimostrazione nel caso in cui f_X continua $\Rightarrow F_X$ è derivabile

1) $g' > 0$ (g strettamente crescente)

   Sia $y \in g(\mathbb{R})$.

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(g(X) \leq y) = \mathbb{P}(X \leq g^{-1}(y))$$
$$= F_X(g^{-1}(y)) = \mathbb{P}\left(X \in (-\infty, g^{-1}(y)]\right)$$
$$= \int_{\underbrace{(-\infty, g^{-1}(y)]}_{g^{-1}((-\infty, y])}} f_X \, dm$$

   F_X è derivabile $\Rightarrow F_Y$ è derivabile $\Rightarrow Y$ è assolutamente continua

$$f_Y(y) = \frac{d}{dy}F_Y(y) = \frac{d}{dy}F_X(g^{-1}(y))$$
$$= f_X(g^{-1}(y)) \cdot \underbrace{\frac{d}{dy}g^{-1}(y)}_{>0}$$

2) $g' < 0$ (g strettamente decrescente)

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(g(X) \leq y) = \mathbb{P}(X \geq g^{-1}(y))$$
$$= 1 - F_X(g^{-1}(y))$$

$$f_Y(y) = \frac{d}{dy}F_Y(y) = \frac{d}{dy}\left(1 - F_X(g^{-1}(y))\right)$$
$$= -f_X(g^{-1}(y)) \cdot \underbrace{\frac{d}{dy}g^{-1}(y)}_{<0}$$

$$\Downarrow$$

$$f_Y(y) = f_X(g^{-1}(y)) \left|\frac{d}{dy}g^{-1}(y)\right| \mathbb{1}_{g(\mathbb{R})}(y)$$

□

Definizione 4.1.3. Una funzione $g : A \to \mathbb{R}$ si dice a tratti di classe C^1 e invertibile (strettamente monotona) se esiste una partizione quasi certa di A ovvero esistono $I_1, \ldots, I_n$ aperti tale che $I_i \cap I_j = \varnothing$ se $i \neq j$ ed esiste I_0 tale che $m(I_0) = 0$ per cui

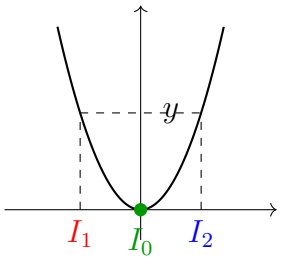
$$A = I_1 \cup \ldots \cup I_n \cup I_0$$

tale che $\forall i = 1, \ldots, n$, $g_i = g|_{I_i}$ è di classe C^1 e strettamente monotona (quindi invertibile).

Corollario 4.1.4. Sia X variabile aleatoria assolutamente continua con densità f_X. Sia $A \in \mathcal{B}(\mathbb{R})$ tale che $\mathbb{P}(X \in A) = 1$. Sia $g : A \to \mathbb{R}$ a tratti di classe C^1 e invertibile. Supponiamo inoltre che $\forall i = 1, \ldots, n$, g_i^{-1} sia di classe C^1. Allora $Y = g(X)$ è assolutamente continua con densità:

$$f_Y(y) = \sum_{i=1}^{n} f_X\left(g_i^{-1}(y)\right) \left|\frac{d}{dy}g_i^{-1}(y)\right| \mathbb{1}_{I_i}(y)$$

Esempio 4.1.5. Siano $X \sim \mathcal{N}(0,1)$, $g : \mathbb{R} \to \mathbb{R}$ tale che $g(x) = x^2$, $Y = g(X) = X^2$. Determiniamo la legge di Y.



Essendo $X \sim \mathcal{N}(0,1)$ questa è concentrata su $A = \mathbb{R}$. Possiamo partizionare $A = I_0 \cup I_1 \cup I_2$ con

$$I_0 = \{0\} \quad \text{e} \quad m(I_0) = 0 \qquad I_1 = (-\infty, 0) \qquad I_2 = (0, +\infty) \qquad g(I_1) = g(I_2) = (0, +\infty)$$

Allora

$$\begin{aligned} g_1(x) = g|_{I_1}(x) = x^2 \Rightarrow g_1^{-1}(y) = -\sqrt{y} \Rightarrow \frac{d}{dy} g_1^{-1}(y) = -\frac{1}{2\sqrt{y}} \\ g_2(x) = g|_{I_2}(x) = x^2 \Rightarrow g_2^{-1}(y) = +\sqrt{y} \Rightarrow \frac{d}{dy} g_2^{-1}(y) = +\frac{1}{2\sqrt{y}} \end{aligned} \qquad \text{se } y > 0$$

La formula generale è

$$f_Y(y) = \sum_{i=1}^{2} f_X(g_i^{-1}(y)) \left| \frac{d}{dy} g_i^{-1}(y) \right| \mathbb{1}_{g(I_i)}(y)$$

Nel nostro caso

- Se $y \leq 0$:
$$f_Y(y) = 0$$
- Se $y > 0$:
$$\begin{aligned} f_Y(y) &= f_X(-\sqrt{y}) \cdot \left| -\frac{1}{2\sqrt{y}} \right| + f_X(+\sqrt{y}) \cdot \left| +\frac{1}{2\sqrt{y}} \right| \\ &= \frac{1}{2\sqrt{y}} \left[f_X(\sqrt{y}) + f_X(-\sqrt{y}) \right] \end{aligned}$$

Calcoliamola anche con il metodo della funzione di ripartizione.

$$\forall y \in \mathbb{R} F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(X^2 \leq y)$$

- Se $y \leq 0$:
$$F_Y(y) = 0$$
- Se $y > 0$:
$$\begin{aligned} F_Y(y) &= \mathbb{P}(X^2 \leq y) = \mathbb{P}(-\sqrt{y} \leq X \leq \sqrt{y}) \\ &= F_X(\sqrt{y}) - F_X(-\sqrt{y}) \end{aligned}$$

Dal momento che F_X risulta derivabile quasi ovunque (X è assolutamente continua) possiamo sfruttarla per calcolare la derivata di F_Y.

- Se $y \leq 0$:
$$f_Y(y) = 0$$
- Se $y > 0$:
$$f_Y(y) = \frac{d}{dy} F_Y(y) = \frac{d}{dy} \left[F_X(\sqrt{y}) - F_X(-\sqrt{y}) \right]$$
$$= f_X(\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} - f_X(-\sqrt{y}) \cdot \left(-\frac{1}{2\sqrt{y}} \right)$$
$$= \frac{1}{2\sqrt{y}} \left[f_X(\sqrt{y}) + f_X(-\sqrt{y}) \right]$$

Possiamo caratterizzare ancora oltre il risultato.Usiamo il fatto che $X \sim \mathcal{N}(0,1)$

$$\Rightarrow f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2} \qquad \forall x \in \mathbb{R}$$

- Se $y \leq 0$:
$$f_Y(y) = 0$$
- Se $y > 0$:
$$f_Y(y) = \frac{1}{2\sqrt{y}} \left[\frac{1}{\sqrt{2\pi}} e^{-y/2} + \frac{1}{\sqrt{2\pi}} e^{-y/2} \right]$$
$$= \frac{1}{\sqrt{2\pi}} \cdot \frac{1}{\sqrt{y}} e^{-y/2}$$

$$\Rightarrow f_Y(y) = \frac{1}{\sqrt{2\pi}} y^{\frac{1}{2}-1} e^{-\frac{1}{2}y} \mathbb{1}_{(0,+\infty)}(y)$$

$$\Rightarrow Y \sim \Gamma\left(\frac{1}{2}, \frac{1}{2}\right)$$

Dal momento che la costante è univocamente determinata dal fatto che l'integrale debba sommare a uno

$$\frac{1}{\sqrt{2\pi}} = \frac{\lambda^\alpha}{\Gamma(\alpha)} = \frac{\left(\frac{1}{2}\right)^{1/2}}{\Gamma\left(\frac{1}{2}\right)} = \frac{1}{\sqrt{2}\,\Gamma\left(\frac{1}{2}\right)}$$

$$\Rightarrow \Gamma\left(\frac{1}{2}\right) = \sqrt{\pi} \qquad \Rightarrow \qquad \Gamma\left(\frac{3}{2}\right) = \frac{1}{2}\Gamma\left(\frac{1}{2}\right) = \frac{\sqrt{\pi}}{2}$$

$$\Rightarrow \ldots \text{ posso conoscere } \Gamma\left(\frac{n}{2}\right) \quad \forall n \in \mathbb{N}^*$$

Dal momento che il caso n pari è già noto (è il caso intero).
Quando una variabile aleatoria ha legge $\Gamma\left(\frac{1}{2}, \frac{1}{2}\right)$ diciamo anche che ha legge Chi-quadro ad 1 grado di libertà e scriviamo

$$Y \sim \chi^2(1).$$

Esempio 4.1.6. Sia $X \sim \mathcal{N}(0,1)$ e sia $g : \mathbb{R} \to \mathbb{R}$, $x \mapsto \sigma x + \mu$. Chiamiamo $Y = g \circ X = \sigma X + \mu$. Troviamo la densità $f_Y(y)$ con il metodo della funzione di ripartizione.

$$F_Y(y) = \mathbb{P}(Y < y) = \mathbb{P}(\sigma X + \mu < y) = \mathbb{P}(\sigma X < y - \mu)$$

- Se $\sigma > 0$:

$$\begin{aligned} F_Y(y) &= \mathbb{P}\left(X < \frac{y-\mu}{\sigma}\right) = F_X\left(\frac{y-\mu}{\sigma}\right) \\ &= \int_{-\infty}^{\frac{y-\mu}{\sigma}} e^{-\frac{x^2}{2}} \cdot \frac{1}{\sqrt{2\pi}}\, dx \end{aligned}$$

$$\Rightarrow \frac{dF_Y(y)}{dy} = \frac{1}{\sigma} \cdot \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{(y-\mu)^2}{2\sigma^2}} = f_Y(y)$$

- Se $\sigma < 0$:

$$\begin{aligned} F_Y(y) &= \mathbb{P}(-\sigma X > \mu - y) = \mathbb{P}\left(X > \frac{\mu - y}{-\sigma}\right) \\ &= \mathbb{P}\left(X > \frac{y-\mu}{\sigma}\right) \\ &= 1 - F_X\left(\frac{y-\mu}{\sigma}\right) \\ &= 1 - \int_{-\infty}^{\frac{y-\mu}{\sigma}} \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{x^2}{2}}\, dx \end{aligned}$$

$$\Rightarrow f_Y(y) = -\frac{1}{\sigma} \cdot \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{(y-\mu)^2}{2\sigma^2}}$$

Mettendo assieme i due casi

$$\begin{aligned} f_Y(y) &= \frac{1}{|\sigma|} \cdot \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{(y-\mu)^2}{2\sigma^2}} \\ &= \frac{1}{\sqrt{\sigma^2}} \cdot \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{(y-\mu)^2}{2\sigma^2}} \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{(y-\mu)^2}{2\sigma^2}} \qquad \forall y \in \mathbb{R} \end{aligned}$$

$$\Rightarrow Y \sim \mathcal{N}(\mu, \sigma)$$

Usiamo anche il metodo della derivata con $A = \mathbb{R}$, $g(x) = \sigma x + \mu$ è di classe C^1 invertibile ($g' \neq 0$) con inversa di classe C^1,

$$g^{-1}(y) = \frac{y-\mu}{\sigma} \quad \Rightarrow \quad \frac{d}{dy} g^{-1}(y) = \frac{1}{\sigma}$$

$$g(\mathbb{R}) = \mathbb{R}$$

$$\Rightarrow \quad f_Y(y) = f_X(g^{-1}(y)) \cdot \left| \frac{d}{dy} g^{-1}(y) \right|$$

$$= f_X\left(\frac{y-\mu}{\sigma}\right) \cdot \frac{1}{|\sigma|}$$

$$\Rightarrow f_Y(y) = \frac{1}{|\sigma|} f_X\left(\frac{y-\mu}{\sigma}\right) \qquad \forall y \in \mathbb{R}$$

Noi abbiamo $X \sim \mathcal{N}(0,1)$.

$$f_Y(y) = \frac{1}{\sqrt{\sigma^2}} \cdot \frac{1}{\sqrt{2\pi}} e^{-\left(\frac{y-\mu}{\sigma}\right)^2/2}$$

$$= \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y-\mu)^2}{2\sigma^2}} \qquad \forall y \in \mathbb{R}$$

4.2 Trasformazioni di vettori aleatori

In questa sezione $Z = (X, Y)$ è un vettore aleatorio e $h : \mathbb{R}^2 \to \mathbb{R}, g : \mathbb{R}^2 \to \mathbb{R}^2$ funzioni misurabili. Fissiamo inoltre

$$T = h(Z) = h \circ Z = h(X, Y)$$

$$W = (U, V) = g \circ Z = g(Z) = g(X, Y)$$

4.2.1 Caso discreto

Sia $Z = (X, Y)$ vettore aleatorio discreto.

a) $T = h \circ Z$ è una variabile aleatoria discreta con

$$T(\Omega) = h(Z(\Omega))$$

$\forall t \in T(\Omega)$

$$\begin{aligned} p_T(t) &= \mathbb{P}(T = t) = \mathbb{P}_T(\{t\}) \\ &= \mathbb{P}_Z\left(h^{-1}(\{t\})\right) = \mathbb{P}\left(Z \in h^{-1}(\{t\})\right) \\ &= \sum_{z \in h^{-1}(\{t\})} p_Z(z) \end{aligned}$$

con $z = (x, y)$.

b) $W = (U, V) = g \circ Z$ è un vettore aleatorio discreto

con

$$W(\Omega) = g(Z(\Omega))$$

$\forall w \in W(\Omega)$, con $w = (u, v)$

$$\begin{aligned} p_W(w) &= \mathbb{P}(W = w) = \mathbb{P}_W(\{w\}) \\ &= \mathbb{P}_Z\left(g^{-1}(\{w\})\right) = \mathbb{P}\left(Z \in g^{-1}(\{w\})\right) \\ &= \sum_{z \in g^{-1}(\{w\})} p_Z(z) \end{aligned}$$

Merita di essere riportato per la sua utilità il seguente caso. Sia $Z = (X, Y)$, $h : \mathbb{R}^2 \to \mathbb{R}$ misurabile.

$$h(z) = h(x, y) = x + y \qquad \forall z = (x, y) \in \mathbb{R}^2$$

$$T = h(Z) = h(X, Y) = X + Y$$

Supponiamo che $X(\Omega) = Y(\Omega) = \mathbb{N} \Rightarrow T(\Omega) = \mathbb{N}$.
$\forall t \in \mathbb{N}$

$$\begin{aligned} p_T(t) &= \sum_{z \in h^{-1}(\{t\})} p_Z(z) \\ &= \sum_{\substack{(x,y) \in \mathbb{R}^2 \\ x+y=t}} p_Z(x, y) \\ &= \sum_{x \in \mathbb{R}} p_Z(x, t-x) = \sum_{x=0}^{t} p_Z(x, t-x) \end{aligned}$$

Posso fare il calcolo diretto:

$$\begin{aligned} p_T(t) &= \mathbb{P}(T = t) = \mathbb{P}(X + Y = t) \\ &= \sum_{x \in \mathbb{N}} \mathbb{P}(X + Y = t, X = x) \\ &= \sum_{x \in \mathbb{N}} \mathbb{P}(X = x, Y = t - x) \\ &= \sum_{x \in \mathbb{N}} p_Z(x, t-x) = \sum_{x=0}^{t} p_Z(x, t-x) \end{aligned}$$

Dove abbiamo usato la formula della probabilità totale con la partizione dell'evento certo

$$\{(X = x) : x \in \mathbb{N}\}.$$

Allora per simmetria

$$\boxed{p_{X+Y}(t) = \mathbb{P}(X + Y = t) = \sum_{x=0}^{t} p_Z(x, t-x) = \sum_{y=0}^{t} p_Z(t-y, y)} \qquad \forall t \in \mathbb{N}$$

Se $X \perp\!\!\!\perp Y$

$$p_Z(x, y) = p_X(x) \cdot p_Y(y)$$

$$\begin{aligned} \Rightarrow \quad p_{X+Y}(t) &= \sum_{x=0}^{t} p_X(x) p_Y(t-x) \\ &= \sum_{y=0}^{t} p_X(t-y) \cdot p_Y(y) \\ &= (p_X * p_Y)(t) \end{aligned}$$

Abbiamo quindi ottenuto che se $X + Y$ sono discrete a valori naturali e indipendenti la densità della somma è la convoluzione delle densità degli addendi.

Esempio 4.2.1. Sia $X \perp\!\!\!\perp Y$ con $X \sim P(\lambda)$, $Y \sim P(\mu)$, $\lambda, \mu > 0$.
Determiniamo la legge di $T = X + Y$.

$$T(\Omega) = \mathbb{N} \qquad \forall k \in \mathbb{N}$$

$$\begin{aligned} p_T(k) = p_{X+Y}(k) &= (p_X * p_Y)(k) \\ &= \sum_{i=0}^{k} p_X(i) p_Y(k-i) \\ &= \sum_{i=0}^{k} \left(e^{-\lambda}\frac{\lambda^i}{i!}\right)\left(e^{-\mu}\frac{\mu^{k-i}}{(k-i)!}\right) \\ &= \frac{e^{-(\lambda+\mu)}}{k!}\sum_{i=0}^{k}\binom{k}{i}\lambda^i\mu^{k-i} \\ &= \frac{e^{-(\lambda+\mu)}}{k!}(\lambda+\mu)^k \end{aligned}$$

$$\Rightarrow T(\Omega) = \mathbb{N} \quad \text{e} \quad \forall k \in \mathbb{N} \qquad p_T(k) = e^{-(\lambda+\mu)} \cdot \frac{(\lambda+\mu)^k}{k!}$$

$$\Rightarrow T = X + Y \sim P(\lambda + \mu)$$

In questo caso X, Y potrebbero rappresentare il numero di clienti serviti in un'ora da due sportelli di un ufficio postale e $X + Y$ potrebbe rappresentare il numero di clienti serviti in un'ora dall'intero ufficio postale.

Osservazione: Seguendo i passi dell'esempio precedenti si possono ottenere le seguenti proprietà

1)
$$X \sim P(\lambda) \perp\!\!\!\perp Y \sim P(\mu) \quad \Rightarrow \quad X + Y \sim P(\lambda + \mu)$$

2)
$$X \sim B(n, p) \perp\!\!\!\perp Y \sim B(m, p) \quad \Rightarrow \quad X + Y \sim B(n + m, p)$$

3)
$$X \sim G(p) \perp\!\!\!\perp Y \sim G(p) \quad \Rightarrow \quad X + Y \sim \text{Pascal}(2, p)$$

4)
$$X \sim \text{Pascal}(r, p) \perp\!\!\!\perp Y \sim \text{Pascal}(s, p)$$
$$\Rightarrow \quad X + Y \sim \text{Pascal}(r + s, p)$$

4.2.2 Caso assolutamente continuo

Iniziamo con il caso di trasformazioni $g : \mathbb{R}^2 \to \mathbb{R}^2$ misurabile.

Definizione 4.2.2. Sia $A \subseteq \mathbb{R}^2$ aperto, sia $g : A \to \mathbb{R}^2$.Diciamo che g è un C^1-diffeomorfismo da A in $g(A)$ se g è di classe C^1, è invertibile con determinante Jacobiano non nullo e g^{-1} è di classe C^1.

Teorema 4.2.3. Sia $Z = (X, Y)$ un vettore aleatorio assolutamente continuo con densità f_Z. Sia $B \in \mathcal{B}(\mathbb{R}^2)$ tale che $\mathbb{P}(Z \in B) = 1$ (la legge di Z è concentrata su B). Sia $g : B \to \mathbb{R}^2$ e supponiamo che esista una partizione quasi certa $\{A_1, \dots, A_n\}$ tale che $g_i := g|_{A_i}$ sia un C^1-diffeomorfismo da A_i a $g(A_i)$ $\forall i = 1, \dots, n$.
Sia $W = (U, V) = g(Z) = g(X, Y)$. Allora W è un vettore aleatorio assolutamente continuo con densità

$$f_W(w) = \sum_{i=1}^{n} f_Z\left(g_i^{-1}(w)\right) \left|\det J_{g_i^{-1}}(w)\right| \mathbb{1}_{g(A_i)}(w) \qquad \forall w \in \mathbb{R}^2$$

Osservazione: Chiamiamo il metodo introdotto dal precedente teorema "metodo dello Jacobiano".

Trasformazioni lineari

Sia $Z = \begin{pmatrix} X \\ Y \end{pmatrix}$ un vettore aleatorio assolutamente continuo con densità f_Z.

Sia $g : \mathbb{R}^2 \to \mathbb{R}^2$ tale che $\forall \underline{z} = \begin{pmatrix} x \\ y \end{pmatrix} \in \mathbb{R}^2$

$$g(\underline{z}) = A\underline{z} + \underline{b} \qquad \text{con } A \in \mathbb{R}^{2,2}, \quad \underline{b} \in \mathbb{R}^2, \quad \det A \neq 0$$

Notiamo che g è un C^1-diffeomorfismo da $\mathbb{R}^2$ in $\mathbb{R}^2$.
Sia

$$W = \begin{pmatrix} U \\ V \end{pmatrix} = g(Z) = g\begin{pmatrix} X \\ Y \end{pmatrix} = AZ + \underline{b}$$

Per il teorema W è un vettore aleatorio assolutamente continuo con densità

$$f_W(\underline{w}) = f_Z(g^{-1}(\underline{w})) \left|\det J_{g^{-1}}(\underline{w})\right| \mathbb{1}_{g(\mathbb{R}^2)}(\underline{w})$$

Nello specifico

$$g(\underline{z}) = A\underline{z} + \underline{b} = \underline{w} \quad \Rightarrow \quad g^{-1}(\underline{w}) = A^{-1}(\underline{w} - \underline{b})$$

$$\det J_{g^{-1}}(\underline{w}) = \det A^{-1} = \frac{1}{\det A}$$

Ovvero $\forall \underline{w} \in \mathbb{R}^2$

$$f_W(\underline{w}) = f_Z\left(A^{-1}(\underline{w} - \underline{b})\right) \cdot \left|\frac{1}{\det A}\right|$$

$$= \frac{1}{|\det A|} \cdot f_Z\left(A^{-1}(\underline{w} - \underline{b})\right)$$

Osservazione: Nel caso reale si ha, se $Y = aX + b$, $a, b \in \mathbb{R}$, $a \neq 0$,

$$f_Y(y) = \frac{1}{|a|} f_X\left(\frac{y-b}{a}\right) \qquad \forall y \in \mathbb{R}$$

ovvero ritroviamo quanto già detto per le trasfromazioni di variabili aleatorie.

Esempio 4.2.4. Sia $X, Y \underset{\text{iid}}{\sim} \mathcal{N}(0,1)$, sia $Z = \begin{pmatrix} X \\ Y \end{pmatrix}$.
Sia $g : \mathbb{R}^2 \to \mathbb{R}^2$ tale che $\forall (x,y) \in \mathbb{R}^2$

$$g(x,y) = \begin{pmatrix} x+y \\ x-y \end{pmatrix}$$

Sia

$$W = \begin{pmatrix} U \\ V \end{pmatrix} = g(X,Y) = \begin{pmatrix} X+Y \\ X-Y \end{pmatrix} = A \begin{pmatrix} X \\ Y \end{pmatrix} + \underline{b}$$

con

$$\underline{b} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \qquad A = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}$$

$$\Rightarrow \det A = -2 \quad \Rightarrow \quad A^{-1} = -\frac{1}{2}\begin{pmatrix} -1 & -1 \\ -1 & 1 \end{pmatrix} = \begin{pmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & -\frac{1}{2} \end{pmatrix}$$

$$\Rightarrow \quad A^{-1}(\underline{w} - \underline{b}) = A^{-1}\underline{w}$$
$$= \begin{pmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & -\frac{1}{2} \end{pmatrix} \begin{pmatrix} u \\ v \end{pmatrix}$$
$$= \begin{pmatrix} \frac{1}{2}(u+v) \\ \frac{1}{2}(u-v) \end{pmatrix}$$

$$f_W(u,v) = \frac{1}{|-2|} \cdot f_Z\left(\frac{u+v}{2}, \frac{u-v}{2}\right)$$

$X, Y \underset{\text{iid}}{\sim} \mathcal{N}(0,1)$

$$\Rightarrow \quad f_Z(x,y) = f_X(x) \cdot f_Y(y)$$
$$= \left(\frac{1}{\sqrt{2\pi}} e^{-x^2/2}\right)\left(\frac{1}{\sqrt{2\pi}} e^{-y^2/2}\right)$$
$$= \frac{1}{2\pi} e^{-\frac{1}{2}(x^2+y^2)}$$

$$\Rightarrow \quad f_W(u,v) = \frac{1}{2} \cdot \frac{1}{2\pi} \exp\left\{-\frac{1}{2}\left[\left(\frac{u+v}{2}\right)^2 + \left(\frac{u-v}{2}\right)^2\right]\right\}$$
$$= \frac{1}{4\pi} \exp\left\{-\frac{1}{2}\left(\frac{u^2}{4} + \frac{v^2}{4} + \frac{1}{2}uv + \frac{u^2}{4} + \frac{v^2}{4} - \frac{1}{2}uv\right)\right\}$$
$$= \frac{1}{4\pi} \exp\left(-\frac{u^2+v^2}{4}\right)$$

$\forall (u,v) \in \mathbb{R}^2$

$$f_W(u,v) = \frac{1}{4\pi} e^{-\frac{u^2+v^2}{4}}$$
$$= \underbrace{\left(\frac{1}{\sqrt{4\pi}} e^{-\frac{u^2}{4}}\right)}_{f_U(u)} \underbrace{\left(\frac{1}{\sqrt{4\pi}} e^{-\frac{v^2}{4}}\right)}_{f_V(v)}$$

per simmetria

$$\Rightarrow U, V \underset{\text{iid}}{\sim} \mathcal{N}(0,2)$$

Passiamo al caso di trasformazioni del tipo $h : \mathbb{R}^2 \to \mathbb{R}$ misurabile.
Sia $Z = (X,Y)$ vettore aleatorio assolutamente continuo e sia $T = h(Z) = h(X,Y)$.
Vogliamo determinare la legge di T.Abbiamo 2 alternative:

1) Metodo della funzione di ripartizione:$\forall t \in \mathbb{R}$

$$F_T(t) = \mathbb{P}(T \le t) = \mathbb{P}(h(X,Y) \le t) = \mathbb{P}_T((-\infty, t])$$
$$= \mathbb{P}_Z\left(h^{-1}((-\infty,t])\right) = \mathbb{P}\left(Z \in \underbrace{h^{-1}((-\infty,t])}_{C}\right)$$
$$= \int_{\underbrace{h^{-1}((-\infty,t])}_{C}} f_Z \, d\underline{m}$$

Da qui otteniamo

$$f_T(t) = \frac{dF_T(t)}{dt}$$

2) Sia $g : \mathbb{R}^2 \to \mathbb{R}^2$ C^1-diffeomorfismo dato da

$$g(x,y) = \big(h(x,y), \ell(x,y)\big)$$

con $l(x,y) = x$ oppure $l(x,y) = y$ (o qualsiasi altra funzione che renda g un C^1-diffeomorfismo ma conviene avere espressioni facili). Sia $W = (T,V)$ con $T = h(X,Y)$ e $V = \ell(X,Y)$. Possiamo pensare di usare il metodo dello Jacobiano su W ottenendo f_W. A questo punto

$$f_T(t) = \int_{-\infty}^{+\infty} f_W(t,v)\, dv$$

Massimi e minimi

Sia $Z = (X,Y)$. Vogliamo calcolare la legge di

$$U = \min(X,Y)$$
$$V = \max(X,Y)$$

a) $V = \max(X,Y)$
$\forall v \in \mathbb{R}$

$$F_V(v) = \mathbb{P}(V \le v) = \mathbb{P}(\max(X,Y) \le v)$$
$$= \mathbb{P}(X \le v, Y \le v) = F_Z(v,v)$$
$$\overset{X \perp\!\!\!\perp Y}{=} \mathbb{P}(X \le v)\mathbb{P}(Y \le v) = F_X(v) \cdot F_Y(v)$$

b) $U = \min(X, Y)$

$\forall u \in \mathbb{R}$

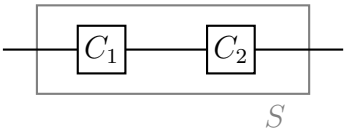
$$\begin{aligned} F_U(u) &= \mathbb{P}(U \leq u) = \mathbb{P}(\min(X, Y) \leq u) \\ &= 1 - \mathbb{P}(\min(X, Y) > u) \\ &= 1 - \mathbb{P}(X > u, Y > u) \\ &\overset{X \perp\!\!\!\perp Y}{=} 1 - \mathbb{P}(X > u)\mathbb{P}(Y > u) = 1 - S_X(u) \cdot S_Y(u) \\ &= 1 - (1 - F_X(u))(1 - F_Y(u)) \end{aligned}$$

In particolare

$$S_U(u) \overset{X \perp\!\!\!\perp Y}{=} S_X(u) \cdot S_Y(u)$$

Una diretta applicazione di questi concetti è lo studio dell'affidabilità di sistemi. Siano T_i = Tempo di vita dei componenti C_i di un sistema e T_S = Tempo di vita del sistema S.
Consideriamo $i = 1, 2$.

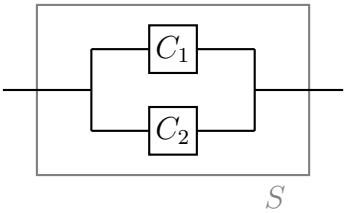
1) **Serie**



$$T_S = \min(T_1, T_2)$$

$$T_1 \perp\!\!\!\perp T_2 \quad \Rightarrow \quad S_{T_S}(t) = S_{T_1}(t) \cdot S_{T_2}(t)$$

2) **Parallelo**



$$T_S = \max(T_1, T_2)$$

$$T_1 \perp\!\!\!\perp T_2 \quad \Rightarrow \quad F_{T_S}(t) = F_{T_1}(t) \cdot F_{T_2}(t)$$

Esempio 4.2.5. Siano $X \sim \text{Exp}(\lambda) \perp\!\!\!\perp Y \sim \text{Exp}(\mu)$,$U = \min(X, Y)$. Determiniamo la legge di U.

- Se $t \leq 0$

$$F_U(t) = 0, \qquad S_U(t) = 1$$

- Se $t > 0$

$$S_U(t) = S_X(t)S_Y(t) = e^{-\lambda t} \cdot e^{-\mu t}$$

$$\Rightarrow S_U(t) = e^{-(\lambda+\mu)t}, \qquad F_U(t) = 1 - e^{-(\lambda+\mu)t}$$

$$\Rightarrow U = \min(X, Y) \sim \text{Exp}(\lambda + \mu)$$

Somma di variabili aleatorie

Proposizione 4.2.6. Sia $Z = (X, Y)$ assolutamente continua e sia $h : \mathbb{R}^2 \to \mathbb{R}$ tale che $\forall (x, y) \in \mathbb{R}^2$, $h(x, y) = x + y$. Sia $T = h(Z) = h(X, Y)$.
Allora T è una v.a. assolutamente continua con densità

$$f_T(t) = \int_{-\infty}^{+\infty} f_Z(x, t - x)\, dx = \int_{-\infty}^{+\infty} f_Z(t - y, y)\, dy.$$

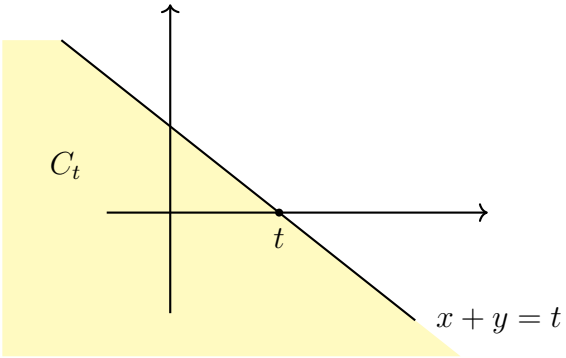
Se $X \perp\!\!\!\perp Y$, allora

$$\begin{aligned} f_T(t) = f_{X+Y}(t) &= \int_{-\infty}^{+\infty} f_X(x) f_Y(t - x)\, dx \\ &= \int_{-\infty}^{+\infty} f_X(t - y) f_Y(y)\, dy \\ &= (f_X * f_Y)(t). \end{aligned}$$

Dimostrazione (1). Per ogni $t \in \mathbb{R}$,

$$F_T(t) = \mathbb{P}(T \leq t) = \mathbb{P}(X + Y \leq t) = \mathbb{P}\big((X, Y) \in C_t\big),$$

dove $C_t = \{(x, y) \in \mathbb{R}^2 : x + y \leq t\}$.



Pertanto,

$$\begin{aligned} F_T(t) &= \int_{C_t} f_Z(x, y)\, dx\, dy \\ &= \int_{-\infty}^{+\infty} \left(\int_{-\infty}^{t-x} f_Z(x, y)\, dy \right) dx. \end{aligned}$$

Ponendo $x + y = u$, da cui $y = u - x$, si ottiene usando Tonelli

$$\begin{aligned} F_T(t) &= \int_{-\infty}^{+\infty} \left(\int_{-\infty}^{t} f_Z(x, u - x)\, du \right) dx \\ &= \int_{-\infty}^{t} \left(\int_{-\infty}^{+\infty} f_Z(x, u - x)\, dx \right) du \\ &= \int_{-\infty}^{t} f_T(u)\, du. \end{aligned}$$

Ho trovato una funzione non negativa e misurabile

$$f_T(u) = \int_{-\infty}^{+\infty} f_Z(x, u-x)\,dx$$

tale che, per ogni $t \in \mathbb{R}$,

$$F_T(t) = \int_{-\infty}^{t} f_T(u)\,du = \int_{(-\infty,t]} f_T\,dm = \mathbb{P}_T((-\infty,t]).$$

Le semirette del tipo $(-\infty, t]$ generano i boreliani, quindi

$$\forall B \in \mathcal{B}(\mathbb{R}), \qquad \mathbb{P}_T(B) = \int_B f_T\,dm,$$

ovvero $\mathbb{P}_T \ll m$, con

$$\frac{d\mathbb{P}_T}{dm} = f_T \quad \text{q.o.}$$

Cioè T è a.c. con densità f_T. □

Dimostrazione. Costruiamo un C^1-diffeomorfismo. Sia $g : \mathbb{R}^2 \to \mathbb{R}^2$ tale che $g(x,y) = (x, x+y)$. Si ha

$$g(\underline{z}) = A\underline{z} + \underline{b}, \qquad A = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix}, \qquad \underline{b} = \underline{0},$$

con $\underline{z} = \begin{pmatrix} x \\ y \end{pmatrix}$.
g è un C^1-diffeomorfismo da $\mathbb{R}^2$ in $\mathbb{R}^2$ perché è una trasformazione lineare e, detto $W = (U, T)$ con $U = X$ e $T = X + Y$, si ha

$$f_W(\underline{w}) = \frac{1}{|\det A|} f_Z(A^{-1}\underline{w}).$$

Nel nostro caso,

$$A = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix} \implies \det A = 1, \qquad A^{-1} = \begin{pmatrix} 1 & 0 \\ -1 & 1 \end{pmatrix}.$$

Pertanto,

$$A^{-1}\underline{w} = \begin{pmatrix} 1 & 0 \\ -1 & 1 \end{pmatrix} \begin{pmatrix} u \\ t \end{pmatrix} = \begin{pmatrix} u \\ t-u \end{pmatrix}, \qquad \forall\, \underline{w} = \begin{pmatrix} u \\ t \end{pmatrix} \in \mathbb{R}^2.$$

Quindi,

$$f_W(\underline{w}) = f_W(u,t) = f_Z(A^{-1}\underline{w}) = f_Z(u, t-u).$$

Per ogni $t \in \mathbb{R}$,

$$f_T(t) = \int_{-\infty}^{+\infty} f_W(u,t)\,du = \int_{-\infty}^{+\infty} f_Z(u, t-u)\,du.$$

□

Esempio 4.2.7. Siano $X, Y \overset{\text{iid}}{\sim} \text{Exp}(\lambda)$ e $T = X + Y$. Troviamo la legge di T.

Per ogni $t \in \mathbb{R}$,

$$\begin{aligned} f_T(t) = f_{X+Y}(t) = (f_X * f_Y)(t) &= \int_{-\infty}^{+\infty} f_{(X,Y)}(x, t-x)\,dx \\ &= \int_{-\infty}^{+\infty} f_X(x) \cdot f_Y(t-x)\,dx \\ &= \int_{-\infty}^{+\infty} \left(\lambda e^{-\lambda x} \mathbb{1}_{(0,+\infty)}(x)\right) \cdot \left(\lambda e^{-\lambda(t-x)} \mathbb{1}_{(0,+\infty)}(t-x)\right)\,dx. \end{aligned}$$

Se $t \leq 0$, si ha $f_T(t) = 0$. Se invece $t > 0$,

$$\begin{aligned} f_T(t) &= \int_0^t \lambda^2 e^{-\lambda t}\,dx \\ &= \lambda^2 t e^{-\lambda t}. \end{aligned}$$

Pertanto,

$$f_T(t) = \frac{\lambda^2}{\Gamma(2)} t^{2-1} e^{-\lambda t} \mathbb{1}_{(0,+\infty)}(t) \quad \Longrightarrow \quad T \sim \Gamma(2, \lambda).$$

Se X è il tempo di servizio del primo cliente in coda a uno sportello, con $X \sim \text{Exp}(\lambda)$ e Y è il tempo di servizio del secondo cliente in coda a uno sportello, con $Y \sim \text{Exp}(\lambda)$.
$T = X + Y$ è il tempo necessario per servire due clienti in coda, con $T \sim \Gamma(2, \lambda)$ (Erlang).

4.3 Variabile aleatoria Beta

Consideriamo $A = (0, +\infty) \times (0, +\infty)$, per cui $\mathbb{P}((X, Y) \in A) = 1$.
Sia $g : A \to \mathbb{R}^2$ tale che

$$g(x, y) = \left(x + y, \frac{x}{x+y}\right).$$

Si ha

$$\begin{aligned} \det J_g(x, y) &= \begin{vmatrix} 1 & 1 \\ \dfrac{x+y-x}{(x+y)^2} & -\dfrac{x}{(x+y)^2} \end{vmatrix} \\ &= -\frac{x+y}{(x+y)^2} = -\frac{1}{x+y} \neq 0 \qquad \text{su } A. \end{aligned}$$

Inoltre,

$$g : \begin{cases} s = x + y, \\ t = \dfrac{x}{x+y} \end{cases} \quad \Longrightarrow \quad \begin{cases} s = x + y, \\ t = \dfrac{x}{s} \end{cases} \quad \Longrightarrow \quad g^{-1} : \begin{cases} x = st, \\ y = s - st = s(1-t). \end{cases}$$

Quindi,

$$\begin{aligned} \det J_{g^{-1}}(s, t) &= \begin{vmatrix} t & s \\ 1-t & -s \end{vmatrix} \\ &= -st - s + st = -s \neq 0. \end{aligned}$$

g è un C^1-diffeomorfismo da A in $g(A)$. Essendo g invertibile,

$$\begin{aligned} g(A) &= (g^{-1})^{-1}(A) \\ &= \left\{(s,t) \in \mathbb{R}^2 : g^{-1}(s,t) \in A\right\} \\ &= \left\{(s,t) \in \mathbb{R}^2 : (st, s(1-t)) \in A\right\} \\ &= \left\{(s,t) \in \mathbb{R}^2 : st > 0,\ s(1-t) > 0\right\} \\ &= \left\{(s,t) \in \mathbb{R}^2 : s > 0,\ 0 < t < 1\right\} \\ &= (0, +\infty) \times (0,1). \end{aligned}$$

La densità congiunta di (S,T) è

$$\begin{aligned} f_{(S,T)}(s,t) &= f_{(X,Y)}\big(g^{-1}(s,t)\big)\, |\det J_{g^{-1}}(s,t)|\, \mathbb{1}_{g(A)}(s,t) \\ &= f_{(X,Y)}(st, s(1-t))|-s|\, \mathbb{1}_{(0,+\infty)\times(0,1)}(s,t) \\ &= f_X(st) \cdot f_Y(s(1-t)) \cdot s \cdot \mathbb{1}_{(0,+\infty)\times(0,1)}(s,t). \end{aligned}$$

Ricordando che

$$f_X(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} \mathbb{1}_{(0,+\infty)}(x),$$

$$f_Y(y) = \frac{\lambda^\beta}{\Gamma(\beta)} y^{\beta-1} e^{-\lambda y} \mathbb{1}_{(0,+\infty)}(y),$$

si ottiene

$$\begin{aligned} f_{(S,T)}(s,t) &= \left[\frac{\lambda^\alpha}{\Gamma(\alpha)} s^{\alpha-1} t^{\alpha-1} e^{-\lambda st}\right] \\ &\quad \cdot \left[\frac{\lambda^\beta}{\Gamma(\beta)} s^{\beta-1} (1-t)^{\beta-1} e^{-\lambda s(1-t)}\right] \\ &\quad \cdot s\, \mathbb{1}_{(0,+\infty)\times(0,1)}(s,t) \\ &= \frac{\lambda^{\alpha+\beta}}{\Gamma(\alpha)\Gamma(\beta)} s^{\alpha+\beta-1} t^{\alpha-1} (1-t)^{\beta-1} e^{-\lambda s} \mathbb{1}_{(0,+\infty)\times(0,1)}(s,t). \\ &= f_{(S,T)}(s,t) = \frac{\lambda^{\alpha+\beta}}{\Gamma(\alpha)\Gamma(\beta)} \left(s^{\alpha+\beta-1} e^{-\lambda s} \mathbb{1}_{(0,+\infty)}(s)\right) \left(t^{\alpha-1}(1-t)^{\beta-1} \mathbb{1}_{(0,1)}(t)\right). \end{aligned}$$

Deduciamo che:

1. $S \perp\!\!\!\perp T$.
2. $f_S(s) = c_1 s^{\alpha+\beta-1} e^{-\lambda s} \mathbb{1}_{(0,+\infty)}(s)$.
3. $f_T(t) = c_2 t^{\alpha-1}(1-t)^{\beta-1} \mathbb{1}_{(0,1)}(t)$.
4. $c_1 c_2 = \dfrac{\lambda^{\alpha+\beta}}{\Gamma(\alpha)\Gamma(\beta)}$.

Dal punto 2) segue che

$$S = X + Y \sim \Gamma(\alpha+\beta, \lambda),$$

inoltre

$$c_1 = \frac{\lambda^{\alpha+\beta}}{\Gamma(\alpha+\beta)}.$$

Dal punto 4) otteniamo

$$\frac{\lambda^{\alpha+\beta}}{\Gamma(\alpha+\beta)} \cdot c_2 = \frac{\lambda^{\alpha+\beta}}{\Gamma(\alpha)\Gamma(\beta)} \implies c_2 = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}.$$

Quindi, dal punto 3),

$$f_T(t) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} t^{\alpha-1}(1-t)^{\beta-1}\mathbb{1}_{(0,1)}(t).$$

Diciamo che la v.a. T ha legge Beta di parametri $\alpha, \beta > 0$ e indichiamo

$$T \sim \text{Beta}(\alpha, \beta).$$

Definizione 4.3.1. La *funzione Beta* è una funzione

$$B : (0, +\infty) \times (0, +\infty) \to (0, +\infty)$$

definita da

$$(\alpha, \beta) \longmapsto B(\alpha, \beta) = \int_0^1 t^{\alpha-1}(1-t)^{\beta-1}\, dt = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}.$$

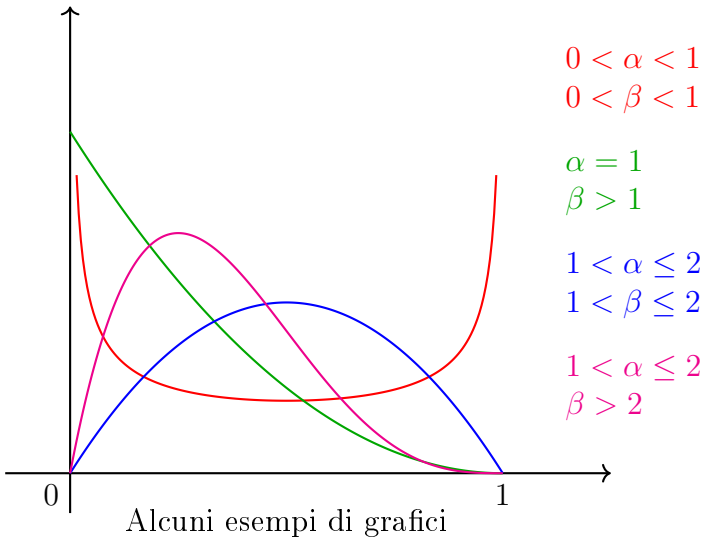
Quindi possiamo scrivere

$$f_T(t) = \frac{1}{B(\alpha, \beta)} t^{\alpha-1}(1-t)^{\beta-1}\mathbb{1}_{(0,1)}(t).$$

La v.a. Beta assume valori in $(0, 1)$ e quindi viene utilizzata per modellizzare proporzioni o probabilità. Viene usata in statistica Bayesiana.
Se consideriamo $\alpha = \beta = 1$, allora $T \sim \text{Beta}(1, 1)$ e

$$\begin{aligned} f_T(t) &= \frac{\Gamma(2)}{\Gamma(1)\Gamma(1)} t^{1-1}(1-t)^{1-1}\mathbb{1}_{(0,1)}(t) \\ &= \mathbb{1}_{(0,1)}(t). \end{aligned}$$

Quindi $T \sim U(0, 1)$.



Alcuni esempi di grafici

Calcoliamo media e varianza:

$$\begin{aligned}
\mathbb{E}[T] &= \int_{-\infty}^{+\infty} t f_T(t)\,dt \\
&= \int_0^1 t \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} t^{\alpha-1}(1-t)^{\beta-1}\,dt \\
&= \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \cdot \frac{\Gamma(\alpha+1)\Gamma(\beta)}{\Gamma(\alpha+1+\beta)} \int_0^1 \frac{\Gamma(\alpha+1+\beta)}{\Gamma(\alpha+1)\Gamma(\beta)} t^{\alpha}(1-t)^{\beta-1}\,dt \\
&= \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \cdot \frac{\Gamma(\alpha+1)\Gamma(\beta)}{\Gamma(\alpha+\beta+1)} \\
&= \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \cdot \frac{\alpha\Gamma(\alpha)\Gamma(\beta)}{(\alpha+\beta)\Gamma(\alpha+\beta)} \\
&= \frac{\alpha}{\alpha+\beta}.
\end{aligned}$$

$$\begin{aligned}
\mathbb{E}[T^2] &= \int_{-\infty}^{+\infty} t^2 f_T(t)\,dt \\
&= \int_0^1 \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} t^{\alpha+1}(1-t)^{\beta-1}\,dt \\
&= \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \cdot \frac{\Gamma(\alpha+2)\Gamma(\beta)}{\Gamma(\alpha+2+\beta)} \underbrace{\int_0^1 \frac{\Gamma(\alpha+2+\beta)}{\Gamma(\alpha+2)\Gamma(\beta)} t^{\alpha+1}(1-t)^{\beta-1}\,dt}_{\text{Beta}(\alpha+2,\beta)} \\
&= \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \cdot \frac{\Gamma(\beta)(\alpha+1)\Gamma(\alpha+1)}{(\alpha+\beta+1)\Gamma(\alpha+\beta+1)} \\
&= \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)} \cdot \frac{(\alpha+1)\alpha\Gamma(\alpha)}{(\alpha+\beta+1)(\alpha+\beta)\Gamma(\alpha+\beta)} \\
&= \frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)}.
\end{aligned}$$

Quindi,

$$\begin{aligned}
\text{Var}(T) &= \mathbb{E}[T^2] - \mathbb{E}[T]^2 \\
&= \frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)} - \frac{\alpha^2}{(\alpha+\beta)^2} \\
&= \frac{\beta\alpha}{(\alpha+\beta)^2(\alpha+\beta+1)}.
\end{aligned}$$

Capitolo 5

Funzioni Caratteristiche

Tutta la teoria dell'integrazione secondo Lebesgue si può ripetere per funzioni a valori complessi. Sia $f : (\mathcal{X}, \mathcal{A}, \mu) \to \mathbb{C}$, con $f = \operatorname{Re} f + i \operatorname{Im} f$. Allora

$$\int_{\mathcal{X}} f \, d\mu = \int_{\mathcal{X}} \operatorname{Re} f \, d\mu + i \int_{\mathcal{X}} \operatorname{Im} f \, d\mu.$$

Se X è una variabile aleatoria a valori in $\mathbb{C}$, allora $X = \operatorname{Re} X + i \operatorname{Im} X$ e

$$\begin{aligned} \mathbb{E}[X] &= \int_{\Omega} X \, d\mathbb{P} \\ &= \int_{\Omega} \operatorname{Re} X \, d\mathbb{P} + i \int_{\Omega} \operatorname{Im} X \, d\mathbb{P} \\ &= \mathbb{E}[\operatorname{Re} X] + i\mathbb{E}[\operatorname{Im} X], \end{aligned}$$

quando questi oggetti sono ben definiti.

Definizione 5.0.1. Sia μ una misura finita su $(\mathbb{R}^N, \mathcal{B}(\mathbb{R}^N))$. Diciamo *trasformata di Fourier di* μ e indichiamo con $\widehat{\mu}$ la funzione

$$\widehat{\mu} : \mathbb{R}^N \to \mathbb{C}$$

tale che, per ogni $\underline{t} = \begin{pmatrix} t_1 \\ \vdots \\ t_N \end{pmatrix} \in \mathbb{R}^N$,

$$\begin{aligned} \widehat{\mu}(\underline{t}) &= \int_{\mathbb{R}^N} e^{i\underline{t}^T \underline{x}} \, d\mu(\underline{x}) \\ &= \int_{\mathbb{R}^N} \cos(\underline{t}^T \underline{x}) \, d\mu(\underline{x}) + i \int_{\mathbb{R}^N} \operatorname{sen}(\underline{t}^T \underline{x}) \, d\mu(\underline{x}), \end{aligned}$$

dove

$$\underline{t}^T \underline{x} = \sum_{j=1}^{n} t_j x_j, \qquad \underline{t} = \begin{pmatrix} t_1 \\ \vdots \\ t_N \end{pmatrix}, \qquad \underline{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_N \end{pmatrix}.$$

Osservazione: $\widehat{\mu}(\underline{t})$ è ben definita per ogni $\underline{t} \in \mathbb{R}^N$, perché sto integrando funzioni limitate rispetto a una misura μ finita.

Definizione 5.0.2. Sia $\underline{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_N \end{pmatrix}$ un vettore aleatorio a valori in $\mathbb{R}^N$.

Chiamiamo *funzione caratteristica* di $\underline{X}$ la trasformata di Fourier della sua legge, e la indichiamo con $\Phi_{\underline{X}}$:

$$\Phi_{\underline{X}} : \mathbb{R}^N \to \mathbb{C},$$

tale che, per ogni $\underline{t} \in \mathbb{R}^N$,

$$\begin{aligned}\Phi_{\underline{X}}(\underline{t}) = \widehat{\mathbb{P}}_{\underline{X}}(\underline{t}) &= \int_{\mathbb{R}^N} e^{i\underline{t}^T \underline{x}}\, d\mathbb{P}_{\underline{X}}(\underline{x}) \\ &= \int_{\Omega} e^{i\underline{t}^T \underline{X}}\, d\mathbb{P} = \mathbb{E}\left[e^{i\underline{t}^T \underline{X}}\right],\end{aligned}$$

finito per ogni $\underline{t} \in \mathbb{R}$.

Osservazione: $\Phi_{\underline{X}}(\underline{t})$ è ben definita per ogni $\underline{t} \in \mathbb{R}^N$, qualsiasi sia la legge di $\underline{X}$. Si noti che

$$\begin{aligned}\Phi_{\underline{X}}(\underline{t}) &= \mathbb{E}\left[e^{i\underline{t}^T \underline{X}}\right] \\ &= \mathbb{E}\left[\cos\left(\underline{t}^T \underline{X}\right)\right] + i\mathbb{E}\left[\operatorname{sen}\left(\underline{t}^T \underline{X}\right)\right].\end{aligned}$$

La funzione caratteristica $\Phi_{\underline{X}}$ caratterizza la legge di $\underline{X}$.

Teorema 5.0.3.

1. Siano μ_1 e μ_2 misure finite su $(\mathbb{R}^N, \mathcal{B}(\mathbb{R}^N))$. Allora

$$\mu_1 = \mu_2 \iff \widehat{\mu}_1 = \widehat{\mu}_2 \qquad \left(\forall\, \underline{t} \in \mathbb{R}^N,\ \widehat{\mu}_1(\underline{t}) = \widehat{\mu}_2(\underline{t})\right).$$

2. Siano $\underline{X}$ e $\underline{Y}$ vettori aleatori a valori in $\mathbb{R}^N$. Allora

$$\underline{X} \sim \underline{Y} \quad (\mathbb{P}_{\underline{X}} = \mathbb{P}_{\underline{Y}}) \iff \Phi_{\underline{X}} = \Phi_{\underline{Y}} \quad (\widehat{\mathbb{P}}_{\underline{X}} = \widehat{\mathbb{P}}_{\underline{Y}}).$$

Teorema 5.0.4. Se $\Phi_{\underline{X}}$ è integrabile, ossia

$$\Phi_{\underline{X}} \in L^1\left(\mathbb{R}^N, \mathcal{B}(\mathbb{R}^N), \underline{m}\right),$$

allora $\underline{X}$ è un vettore aleatorio assolutamente continuo e

$$f_{\underline{X}}(\underline{x}) = \frac{1}{(2\pi)^N} \int_{\mathbb{R}^N} e^{-i\underline{t}^T \underline{x}} \Phi_{\underline{X}}(\underline{t})\, d\underline{t}, \qquad \forall\, \underline{x} \in \mathbb{R}^N.$$

Osservazione: Si noti che, se $\underline{X}$ è assolutamente continuo,

$$\Phi_{\underline{X}}(\underline{t}) = \int_{\mathbb{R}^N} e^{i\underline{t}^T \underline{x}}\, d\mathbb{P}_{\underline{X}}(\underline{x}) = \int_{\mathbb{R}^N} e^{i\underline{t}^T \underline{x}} f_{\underline{X}}(\underline{x})\, d\underline{x}.$$

Un'altra funzione che caratterizza la legge è la *funzione generatrice dei momenti*:

$$M_{\underline{X}}(\underline{t}) = \mathbb{E}\left[e^{\underline{t}^T \underline{X}}\right],$$

che però non è sempre definita per ogni $\underline{t} \in \mathbb{R}^N$.

5.1 Proprietà delle funzioni caratteristiche

Proposizione 5.1.1. Sia $\underline{X}$ un vettore aleatorio a valori in $\mathbb{R}^N$, definito su uno spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$, e sia $\Phi_{\underline{X}}$ la sua funzione caratteristica. Allora

$$\Phi_{\underline{X}}(\underline{0}) = 1,$$

e $\Phi_{\underline{X}}$ è limitata e (uniformemente) continua.

Dimostrazione. Innanzitutto,

$$\Phi_{\underline{X}}(\underline{0}) = \mathbb{E}\left[e^{i\underline{0}^T \underline{X}}\right] = \mathbb{E}[1] = 1.$$

Inoltre, per ogni $\underline{t} \in \mathbb{R}^N$,

$$\begin{aligned}\left|\Phi_{\underline{X}}(\underline{t})\right| &= \left|\mathbb{E}\left[e^{i\underline{t}^T \underline{X}}\right]\right| \\ &\leq \mathbb{E}\left[\left|e^{i\underline{t}^T \underline{X}}\right|\right] = \mathbb{E}[1] = 1.\end{aligned}$$

Infatti, anche nel caso complesso vale

$$\left|\int_{\mathcal{X}} f \, d\mu\right| \leq \int_{\mathcal{X}} |f| \, d\mu.$$

Sia $(\underline{t}_n)_{n\geq 1}$ una successione in $\mathbb{R}^N$ tale che $\underline{t}_n \to \underline{t}$, con $\underline{t} \in \mathbb{R}^N$. Consideriamo le funzioni

$$f_n(\underline{x}) = e^{i\underline{t}_n^T \underline{x}}, \qquad f(\underline{x}) = e^{i\underline{t}^T \underline{x}}, \qquad \forall\, \underline{x} \in \mathbb{R}^N.$$

Si ha che $f_n \to f$ puntualmente, f_n e f sono funzioni misurabili e, inoltre,

$$|f_n(\underline{x})| = \left|e^{i\underline{t}_n^T \underline{x}}\right| = 1 \in L^1\left(\mathbb{R}^N, \mathcal{B}(\mathbb{R}^N), \mathbb{P}_{\underline{X}}\right).$$

Possiamo quindi utilizzare il teorema di convergenza dominata:

$$\begin{aligned}\Phi_{\underline{X}}(\underline{t}_n) &= \mathbb{E}\left[e^{i\underline{t}_n^T \underline{X}}\right] \\ &= \int_{\Omega} e^{i\underline{t}_n^T \underline{X}} \, d\mathbb{P} \\ &= \int_{\mathbb{R}^N} e^{i\underline{t}_n^T \underline{x}} \, d\mathbb{P}_{\underline{X}}(\underline{x}) \\ &= \int_{\mathbb{R}^N} f_n(\underline{x}) \, d\mathbb{P}_{\underline{X}}(\underline{x}) \\ &\xrightarrow[n\to\infty]{} \int_{\mathbb{R}^N} f(\underline{x}) \, d\mathbb{P}_{\underline{X}}(\underline{x}) \\ &= \int_{\mathbb{R}^N} e^{i\underline{t}^T \underline{x}} \, d\mathbb{P}_{\underline{X}}(\underline{x}) \\ &= \int_{\Omega} e^{i\underline{t}^T \underline{X}} \, d\mathbb{P} \\ &= \mathbb{E}\left[e^{i\underline{t}^T \underline{X}}\right] \\ &= \Phi_{\underline{X}}(\underline{t}).\end{aligned}$$

Quindi $\Phi_{\underline{X}}$ è continua. □

Proposizione 5.1.2. Sia $\underline{X}$ un vettore aleatorio a valori in $\mathbb{R}^N$, definito su uno spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$, e sia $\Phi_{\underline{X}}$ la sua funzione caratteristica. Allora, per ogni $\underline{t} \in \mathbb{R}^N$,

$$\Phi_{-\underline{X}}(\underline{t}) = \overline{\Phi_{\underline{X}}(\underline{t})}.$$

Dimostrazione. Infatti,

$$\begin{aligned}\Phi_{-\underline{X}}(\underline{t}) &= \mathbb{E}\left[e^{i\underline{t}^T(-\underline{X})}\right] = \mathbb{E}\left[e^{-i\underline{t}^T\underline{X}}\right] \\ &= \mathbb{E}\left[\overline{e^{i\underline{t}^T\underline{X}}}\right] = \overline{\mathbb{E}\left[e^{i\underline{t}^T\underline{X}}\right]} \\ &= \overline{\Phi_{\underline{X}}(\underline{t})},\end{aligned}$$

dove si è utilizzata la scomposizione in parte reale e immaginaria. □

Osservazione: Diciamo che $\underline{X}$ è *simmetrico* se $\underline{X} \sim -\underline{X}$. In questo caso,

$$\Phi_{-\underline{X}}(\underline{t}) = \overline{\Phi_{\underline{X}}(\underline{t})}.$$

Poiché $\underline{X} \sim -\underline{X}$ implica $\Phi_{-\underline{X}}(\underline{t}) = \Phi_{\underline{X}}(\underline{t})$, si ha

$$\Phi_{\underline{X}}(\underline{t}) \in \mathbb{R}.$$

Come caso particolare, se $X \sim \mathcal{N}(0,1)$, allora anche $-X \sim \mathcal{N}(0,1)$. Vedremo che $\Phi_X(t) \in \mathbb{R}$.

Proposizione 5.1.3. Siano $\underline{X}$ e $\underline{Y}$ due vettori aleatori a valori in $\mathbb{R}^N$, definiti sullo stesso spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$. Se $\underline{X} \perp\!\!\!\perp \underline{Y}$, allora

$$\Phi_{\underline{X}+\underline{Y}}(\underline{t}) = \Phi_{\underline{X}}(\underline{t}) \cdot \Phi_{\underline{Y}}(\underline{t}), \qquad \forall\, \underline{t} \in \mathbb{R}^N.$$

Dimostrazione. Infatti,

$$\begin{aligned}\Phi_{\underline{X}+\underline{Y}}(\underline{t}) &= \mathbb{E}\left[e^{i\underline{t}^T(\underline{X}+\underline{Y})}\right] \\ &= \mathbb{E}\left[e^{i\underline{t}^T\underline{X}} \cdot e^{i\underline{t}^T\underline{Y}}\right] \\ &= \mathbb{E}\left[e^{i\underline{t}^T\underline{X}}\right] \cdot \mathbb{E}\left[e^{i\underline{t}^T\underline{Y}}\right] \\ &= \Phi_{\underline{X}}(\underline{t}) \cdot \Phi_{\underline{Y}}(\underline{t}).\end{aligned}$$

La fattorizzazione del valore atteso segue dall'indipendenza delle variabili aleatorie $e^{i\underline{t}^T\underline{X}}$ ed $e^{i\underline{t}^T\underline{Y}}$, conseguenza dell'indipendenza di $\underline{X}$ e $\underline{Y}$. □

In realtà vale di più.

Proposizione 5.1.4. Sia

$$\underline{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_N \end{pmatrix}$$

un vettore aleatorio a valori in $\mathbb{R}^N$, definito su uno spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$. Le sue

componenti sono indipendenti se e solo se, per ogni $\underline{t} = \begin{pmatrix} t_1 \\ \vdots \\ t_N \end{pmatrix} \in \mathbb{R}^N$,

$$\Phi_{\underline{X}}(\underline{t}) = \prod_{j=1}^{N} \Phi_{X_j}(t_j).$$

Dimostrazione. Supponiamo che le componenti siano indipendenti. Allora

$$\begin{aligned}
\Phi_{\underline{X}}(\underline{t}) &= \mathbb{E}\left[e^{i\underline{t}^T \underline{X}}\right] = \mathbb{E}\left[e^{i\sum_{j=1}^{N} t_j X_j}\right] \\
&= \mathbb{E}\left[\prod_{j=1}^{N} e^{it_j X_j}\right] = \prod_{j=1}^{N} \mathbb{E}\left[e^{it_j X_j}\right] \\
&= \prod_{j=1}^{N} \Phi_{X_j}(t_j),
\end{aligned}$$

poiché le variabili aleatorie $e^{it_j X_j}$ sono indipendenti.
Viceversa, supponiamo che

$$\Phi_{\underline{X}}(\underline{t}) = \prod_{j=1}^{N} \Phi_{X_j}(t_j), \qquad \forall\, \underline{t} \in \mathbb{R}^N.$$

Da una parte,

$$\begin{aligned}
\Phi_{\underline{X}}(\underline{t}) &= \mathbb{E}\left[e^{i\underline{t}^T \underline{X}}\right] \\
&= \int_{\mathbb{R}^N} e^{i\underline{t}^T \underline{x}}\, d\mathbb{P}_{\underline{X}}(\underline{x}) \\
&= \widehat{\mathbb{P}}_{\underline{X}}(\underline{t}).
\end{aligned}$$

Dall'altra,

$$\begin{aligned}
\prod_{j=1}^{N} \Phi_{X_j}(t_j) &= \prod_{j=1}^{N} \mathbb{E}\left[e^{it_j X_j}\right] \\
&= \prod_{j=1}^{N} \int_{\mathbb{R}} e^{it_j x_j}\, d\mathbb{P}_{X_j}(x_j) \\
&= \int_{\mathbb{R}^N} \left(\prod_{j=1}^{N} e^{it_j x_j}\right) d\mathbb{P}_{X_1}(x_1) \cdots d\mathbb{P}_{X_N}(x_N) \\
&= \int_{\mathbb{R}^N} e^{i\underline{t}^T \underline{x}}\, d\left(\mathbb{P}_{X_1} \otimes \cdots \otimes \mathbb{P}_{X_N}\right)(\underline{x}) \\
&= \widehat{\mathbb{P}_{X_1} \otimes \cdots \otimes \mathbb{P}_{X_N}}(\underline{t}),
\end{aligned}$$

dove si è utilizzato il teorema di Fubini.
Quindi abbiamo

$$\widehat{\mathbb{P}}_{\underline{X}} = \widehat{\mathbb{P}_{X_1} \otimes \cdots \otimes \mathbb{P}_{X_N}} \iff \mathbb{P}_{\underline{X}} = \mathbb{P}_{X_1} \otimes \cdots \otimes \mathbb{P}_{X_N}$$

se e solo se le componenti sono indipendenti. □

Proposizione 5.1.5. Sia $\underline{X}$ un vettore aleatorio a valori in $\mathbb{R}^N$ e sia $\underline{Y} = A\underline{X} + \underline{b}$, dove $\underline{b} \in \mathbb{R}^k$ e $A \in M_{k\times N}(\mathbb{R})$. Allora $\underline{Y}$ è un vettore aleatorio a valori in $\mathbb{R}^k$ e

$$\Phi_{\underline{Y}}(\underline{t}) = \Phi_{A\underline{X}+\underline{b}}(\underline{t}) = e^{i\underline{t}^T b}\Phi_{\underline{X}}(A^T\underline{t}), \qquad \forall\, \underline{t} \in \mathbb{R}^k.$$

Nel caso reale, se X è una variabile aleatoria reale e $Y = aX + b$, con $a, b \in \mathbb{R}$, si ha

$$\Phi_Y(t) = \Phi_{aX+b}(t) = e^{itb}\Phi_X(at), \qquad \forall\, t \in \mathbb{R}.$$

Dimostrazione. Infatti,

$$\begin{aligned}
\Phi_{\underline{Y}}(\underline{t}) &= \mathbb{E}\left[e^{i\underline{t}^T\underline{Y}}\right] = \mathbb{E}\left[e^{i\underline{t}^T(A\underline{X}+\underline{b})}\right] \\
&= \mathbb{E}\left[e^{i\underline{t}^T A\underline{X}} \cdot e^{i\underline{t}^T\underline{b}}\right] \\
&= e^{i\underline{t}^T\underline{b}}\mathbb{E}\left[e^{i(\underline{t}^T A)\underline{X}}\right] \\
&= e^{i\underline{t}^T\underline{b}}\mathbb{E}\left[e^{i(A^T\underline{t})^T\underline{X}}\right] \\
&= e^{i\underline{t}^T\underline{b}}\Phi_{\underline{X}}(A^T\underline{t}).
\end{aligned}$$

□

Teorema 5.1.6. Sia

$$\underline{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_N \end{pmatrix}$$

un vettore aleatorio a valori in $\mathbb{R}^N$. Supponiamo che esista $n \geq 1$ tale che, per ogni $j = 1, \ldots, N$,

$$X_j \in L^n(\Omega, \mathcal{F}, \mathbb{P}),$$

ossia tutte le componenti del vettore ammettono momenti finiti fino all'ordine n.
Allora $\Phi_{\underline{X}}$ è di classe C^n. Inoltre, per ogni $j_1, \ldots, j_k \in \{1, \ldots, N\}$, con $k \leq n$, e per ogni $\underline{t} = \begin{pmatrix} t_1 \\ \vdots \\ t_N \end{pmatrix} \in \mathbb{R}^N$,

$$\frac{\partial^k}{\partial t_{j_1} \cdots \partial t_{j_k}}\Phi_{\underline{X}}(\underline{t}) = i^k\mathbb{E}\left[X_{j_1} \cdots X_{j_k} e^{i\underline{t}^T\underline{X}}\right].$$

Se valutiamo in $\underline{t} = \underline{0}$, otteniamo

$$\frac{\partial^k}{\partial t_{j_1} \cdots \partial t_{j_k}}\Phi_{\underline{X}}(\underline{0}) = i^k\mathbb{E}\left[X_{j_1} \cdots X_{j_k}\right].$$

Nel caso reale, sia X una variabile aleatoria reale. Se $X \in L^n(\Omega, \mathcal{F}, \mathbb{P})$, allora Φ_X è di classe C^n e, per ogni $k \leq n$,

$$\Phi_X^{(k)}(t) = \frac{d^k}{dt^k}\Phi_X(t) = i^k\mathbb{E}\left[X^k e^{itX}\right]. \qquad (*)$$

In particolare,

$$\Phi_X^{(k)}(0) = i^k\mathbb{E}[X^k].$$

Osservazione: Se X è una variabile aleatoria reale, allora

$$\begin{aligned}\Phi_X(0) &= 1,\\ \Phi'_X(0) &= i\mathbb{E}[X],\\ \Phi''_X(0) &= -\mathbb{E}[X^2].\end{aligned}$$

ovvero possiamo ottenere media e varianza. Se $\underline{X} = (X_1, X_2)$ è un vettore aleatorio, allora

$$\begin{aligned}\frac{\partial}{\partial t_1}\Phi_{\underline{X}}(\underline{0}) &= i\mathbb{E}[X_1],\\ \frac{\partial}{\partial t_2}\Phi_{\underline{X}}(\underline{0}) &= i\mathbb{E}[X_2].\end{aligned}$$

ovvero il gradiente della funzione caratteristica valutato in zero è i volte il vettore delle medie. Inoltre,

$$\begin{aligned}\frac{\partial^2}{\partial t_1^2}\Phi_{\underline{X}}(\underline{0}) &= -\mathbb{E}[X_1^2],\\ \frac{\partial^2}{\partial t_2^2}\Phi_{\underline{X}}(\underline{0}) &= -\mathbb{E}[X_2^2],\\ \frac{\partial^2}{\partial t_1 \partial t_2}\Phi_{\underline{X}}(\underline{0}) &= -\mathbb{E}[X_1 X_2].\end{aligned}$$

ovvero possiamo ottenere la matrice di varianza e covarianza a meno di costanti.
Per il viceversa vale un risultato parziale: sia X una variabile aleatoria reale e supponiamo che Φ_X sia di classe C^n, con n pari. Allora

$$X \in L^n(\Omega, \mathcal{F}, \mathbb{P})$$

e vale $(*)$.
Se Φ_X è di classe C^∞, allora $X \in L^\infty$ e tutto funziona.

Proposizione 5.1.7. Sia $\underline{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_N \end{pmatrix}$ un vettore aleatorio a valori in $\mathbb{R}^N$. Allora, per ogni $j = 1, \dots, N$,

$$\Phi_{X_j}(t) = \Phi_{\underline{X}}(t\underline{e}_j), \qquad \forall t \in \mathbb{R},$$

dove $\underline{e}_j$ è il vettore j-esimo della base canonica di $\mathbb{R}^N$, ossia

$$\underline{e}_j = \begin{pmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{pmatrix}.$$

Dimostrazione.

$$\Phi_{X_j}(t) = \mathbb{E}\left[e^{itX_j}\right] = \mathbb{E}\left[e^{it\underline{e}_j^T \underline{X}}\right] = \mathbb{E}\left[e^{i(t\underline{e}_j)^T \underline{X}}\right] = \Phi_{\underline{X}}(t\underline{e}_j).$$

□

Capitolo 6

Condizionamento

6.1 Condizionamento di variabili aleatorie discrete

Siano X, Y variabili aleatorie discrete. Sappiamo che si verifica l'evento $(Y = y)$. Vogliamo studiare come è influenzata la legge di X.

Definizione 6.1.1. Si dice **densità discreta di X condizionata all'evento** $(Y = y)$ la funzione tale che per ogni $x \in X(\Omega)$

$$p_{X|Y=y}(x) = p_{X|Y}(x \mid y) = \mathbb{P}(X = x \mid Y = y) = \frac{\mathbb{P}(X = x, Y = y)}{\mathbb{P}(Y = y)} = \frac{p_{(X,Y)}(x, y)}{p_Y(y)},$$

per ogni $y \in Y(\Omega)$ tale che $p_Y(y) \neq 0$. Se $p_Y(y) = 0$, $p_{X|Y=y}(x)$ si definisce in maniera arbitraria; tipicamente si pone pari a zero.

Osservazione: Se $p_Y(y) \neq 0$, $p_{X|Y=y}(x)$ è una densità discreta:

- $0 \leq p_{X|Y=y}(x) \leq 1$ per costruzione;
- $$\sum_{x \in X(\Omega)} p_{X|Y=y}(x) = \frac{\displaystyle\sum_{x \in X(\Omega)} p_{(X,Y)}(x, y)}{p_Y(y)} = 1.$$

Definizione 6.1.2. Si definisce **legge di X condizionata all'evento** $(Y = y)$ e si indica con $\mathbb{P}_{X|Y=y}$ la legge discreta concentrata su $X(\Omega)$ indotta da $p_{X|Y=y}$ tale che per ogni $B \in \mathcal{B}(\mathbb{R})$,

$$\begin{aligned}\mathbb{P}_{X|Y=y}(B) &= \sum_{x \in B \cap X(\Omega)} p_{X|Y=y}(x) \\ &= \sum_{x \in B \cap X(\Omega)} \mathbb{P}(X = x \mid Y = y) \\ &= \mathbb{P}(X \in B \mid Y = y).\end{aligned}$$

Osservazione: Posso calcolare il valore atteso rispetto a $\mathbb{P}_{X|Y=y}$:

$$\mathbb{E}[X \mid Y = y] := \int_{\mathbb{R}} x \, d\mathbb{P}_{X|Y=y}(x) = \sum_{x \in X(\Omega)} x \, p_{X|Y=y}(x).$$

Questo è ben definito se

$$\sum_{x \in X(\Omega)} |x| \, p_{X|Y=y}(x) < +\infty.$$

In tal caso, $\mathbb{E}[X \mid Y = y]$ viene detto **attesa di X condizionata all'evento** $(Y = y)$.

Osservazione: Osserviamo che $\mathbb{E}[X \mid Y = y] = h(y)$, con h misurabile.
Possiamo quindi considerare la variabile aleatoria $h \circ Y = h(Y)$ denotata con $\mathbb{E}[X \mid Y]$ e chiamata **attesa di X condizionata a Y**. Nel caso in cui $\mathbb{E}[X \mid Y = y]$ è ben definita $\quad \forall y : \mathbb{P}(Y = y) \neq 0$, abbiamo definito $\mathbb{E}[X \mid Y]$ ovunque tranne sugli eventi del tipo $(Y = y)$ tali che $\mathbb{P}(Y = y) = 0$ allora è definita $\mathbb{P}$-q.o.

Esempio 6.1.3. Siano $X \sim P(\lambda)$ e $Y \sim P(\mu)$ indipendenti, e sia $Z = X + Y \sim P(\lambda + \mu)$.
Supponiamo che si verifichi l'evento $(Z = n)$. Calcoliamo la legge di X condizionata a $Z = n$.
Per ogni $k \in \mathbb{N} = X(\Omega)$, calcoliamo $p_{X|Z=n}(k)$:

$$\begin{aligned} p_{X|Z=n}(k) &= \frac{p_{(X,Z)}(k,n)}{p_Z(n)} = \frac{\mathbb{P}(Z = n, X = k)}{\mathbb{P}(Z = n)} \\ &= \frac{\mathbb{P}(X = k, Y = n - k)}{\mathbb{P}(Z = n)} \\ &= \frac{\mathbb{P}(X = k)\mathbb{P}(Y = n - k)}{\mathbb{P}(Z = n)}. \end{aligned}$$

Per ogni $k > n$ si ha $p_{X|Z=n}(k) = 0$, mentre per ogni $k \leq n$:

$$\begin{aligned} p_{X|Z=n}(k) &= \frac{\left(e^{-\lambda}\frac{\lambda^k}{k!}\right)\left(e^{-\mu}\frac{\mu^{n-k}}{(n-k)!}\right)}{e^{-(\lambda+\mu)}\frac{(\lambda+\mu)^n}{n!}} \\ &= \frac{n!}{k!(n-k)!}\frac{\lambda^k\mu^{n-k}}{(\lambda+\mu)^n} \\ &= \binom{n}{k}\left(\frac{\lambda}{\lambda+\mu}\right)^k\left(1 - \frac{\lambda}{\lambda+\mu}\right)^{n-k}. \end{aligned}$$

Dunque, per ogni $k = 0, \ldots, n$,

$$p_{X|Z=n}(k) = \binom{n}{k} p^k (1-p)^{n-k}, \qquad p = \frac{\lambda}{\lambda+\mu}.$$

Abbiamo quindi che $X|Z = n \sim B(n, p)$. In questi casi possiamo anche scrivere $X \sim B(Z, p)$, dove Z è una variabile e $p = \dfrac{\lambda}{\lambda+\mu}$.

Possiamo calcolare $\mathbb{E}[X \mid Z = n]$:

$$\mathbb{E}[X \mid Z = n] = np = n\frac{\lambda}{\lambda + \mu} = h(n),$$

da cui

$$h(Z) = \mathbb{E}[X \mid Z] = Z\frac{\lambda}{\lambda + \mu}.$$

Quest'esempio potrebbe modellizzare la seguente situazione. Consideriamo un ufficio con due sportelli e definiamo:

- X: numero di persone servite in un'ora dal primo sportello dell'ufficio;
- Y: numero di persone servite in un'ora dal secondo sportello dell'ufficio.

Supponiamo che $X \sim P(\lambda)$ e $Y \sim P(\mu)$ siano indipendenti. Allora

$$Z = X + Y \sim P(\lambda + \mu),$$

dove Z rappresenta il numero di persone servite in un'ora dall'intero ufficio.
Se sappiamo che $Z = n$, per ciascuna delle n persone abbiamo:

- se è stata servita dal primo sportello, si ha un successo;
- se è stata servita dal secondo sportello, si ha un insuccesso.

Di conseguenza, X rappresenta il numero di successi nelle n prove. Ha quindi senso dire che

$$X \mid_{Z=n} \sim B(n, p).$$

Il parametro

$$p = \frac{\lambda}{\lambda + \mu}$$

rappresenta la proporzione di persone servite dal primo sportello (in media), e si ha

$$p = \frac{\mathbb{E}[X]}{\mathbb{E}[Z]}.$$

Pertanto,

$$\mathbb{E}[X \mid Z = n] = np = n\frac{\lambda}{\lambda + \mu}.$$

6.1.1 Proprietà caratterizzanti dell'attesa condizionata $\mathbb{E}[X|Y]$ nel caso discreto

Teorema 6.1.4. Siano X e Y variabili aleatorie (non necessariamente discrete). X è misurabile rispetto alla σ-algebra $\sigma(Y)$ se e solo se esiste una funzione

$$h : (\mathbb{R}, \mathcal{B}(\mathbb{R})) \longrightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$$

misurabile tale che $X = h(Y)$.

Dimostrazione. Dimostriamo solo "$\Leftarrow$".
Per ogni $B \in \mathcal{B}(\mathbb{R})$ dobbiamo provare che $X^{-1}(B) \in \sigma(Y)$.
Ma

$$\sigma(Y) = \left\{Y^{-1}(A) : A \in \mathcal{B}(\mathbb{R})\right\}.$$

Allora, poiché $X = h(Y)$,

$$X^{-1}(B) = Y^{-1}\left(h^{-1}(B)\right) = Y^{-1}(A) \in \sigma(Y),$$

dove $A = h^{-1}(B) \in \mathcal{B}(\mathbb{R})$, essendo h misurabile. □

Osservazione: Nel nostro caso, X e Y sono variabili aleatorie discrete e

$$\mathbb{E}[X \mid Y] = h(Y), \qquad \text{con } h \text{ misurabile.}$$

Di conseguenza,

$$\mathbb{E}[X \mid Y] \text{ è } \sigma(Y)\text{-misurabile.}$$

Questo è un fatto molto importante a livello probabilistico. Infatti, ci dice che $Z = \mathbb{E}[X \mid Y]$ non può distinguere e misurare eventi che Y non può distinguere e misurare. Capiamo nel dettaglio perché.
Innanzitutto, notiamo che quando misuriamo l'evento $A = \{Y \in B\}$, ovvero calcoliamo

$$\mathbb{P}(A) = \mathbb{P}(Y \in B) = \mathbb{P}\big(Y^{-1}(B)\big) = \mathbb{P}_Y(B),$$

stiamo di fatto misurando un evento contenuto in

$$\sigma(Y) = \left\{A \in \mathcal{P}(\Omega) : \exists B \in \mathcal{B}(\mathbb{R}) \text{ tale che } A = Y^{-1}(B)\right\}.$$

Ovvero, attraverso Y possiamo misurare solo eventi contenuti nella sua σ-algebra generata.
Ora, dire che Z è $\sigma(Y)$-misurabile equivale a dire che $\sigma(Z) \subseteq \sigma(Y)$. Infatti,

$$\begin{aligned} A \in \sigma(Z) &\implies \exists B \in \mathcal{B}(\mathbb{R}) : A = Z^{-1}(B) \\ &= (h \circ Y)^{-1}(B) = Y^{-1}\big(h^{-1}(B)\big) \\ &\implies A \in \sigma(Y), \end{aligned}$$

essendo $h^{-1}(B) \in \mathcal{B}(\mathbb{R})$ perché h è misurabile.
Per quanto detto prima, questo vuol dire che posso misurare attraverso Z al massimo gli stessi eventi che posso misurare attraverso Y.
In particolare, se Y non distingue due eventi $\omega_1, \omega_2 \in \Omega$, ovvero se

$$Y(\omega_1) = Y(\omega_2) \iff \omega_1, \omega_2 \in Y^{-1}(B),$$

nemmeno Z riesce a farlo.
In più, e questa è la cosa più sorprendente, per misurare eventi attraverso $Z = \mathbb{E}[X \mid Y]$ abbiamo bisogno solo di conoscere come misurarli tramite Y e non tramite X.

Teorema 6.1.5. Siano X e Y variabili aleatorie discrete, con $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$. Allora, per ogni $A \in \sigma(Y)$,

$$\int_A \mathbb{E}[X \mid Y]\, d\mathbb{P} = \int_A X\, d\mathbb{P}.$$

Dimostrazione. Sia $A \in \sigma(Y)$, cioè $A = Y^{-1}(B)$ per qualche $B \in \mathcal{B}(\mathbb{R})$.
Ricordando che $\mathbb{E}[X \mid Y] = h(Y)$, si ha

$$\begin{aligned}\int_A \mathbb{E}[X \mid Y]\, d\mathbb{P} &= \int_{Y^{-1}(B)} h(Y)\, d\mathbb{P} \\ &= \int_\Omega h(Y)\, \mathbb{1}_{Y^{-1}(B)}\, d\mathbb{P} \\ &= \int_\Omega h(Y)\, \mathbb{1}_B(Y)\, d\mathbb{P}.\end{aligned}$$

Infatti,

$$\omega \in Y^{-1}(B) \iff Y(\omega) \in B,$$

quindi

$$\mathbb{1}_{Y^{-1}(B)}(\omega) = \mathbb{1}_B(Y(\omega)).$$

Ponendo $g(Y) = h(Y)\mathbb{1}_B(Y)$, stiamo calcolando $\mathbb{E}[g(Y)] = \mathbb{E}[h(Y)\mathbb{1}_B(Y)]$. Pertanto,

$$\begin{aligned}\int_\Omega h(Y)\, \mathbb{1}_B(Y)\, d\mathbb{P} &= \int_{\mathbb{R}} h(y)\, \mathbb{1}_B(y)\, d\mathbb{P}_Y(y) \\ &= \int_B h(y)\, d\mathbb{P}_Y(y) \\ &= \sum_{y \in B \cap Y(\Omega)} h(y)\, p_Y(y) \\ &= \sum_{y \in B \cap Y(\Omega)} \left(\sum_{x \in X(\Omega)} x\, p_{X|Y=y}(x) \right) p_Y(y) \\ &= \sum_{y \in B \cap Y(\Omega)} \sum_{x \in X(\Omega)} x\, \frac{p_{(X,Y)}(x,y)}{p_Y(y)}\, p_Y(y) \\ &= \sum_{(x,y) \in X(\Omega) \times Y(\Omega)} x\, \mathbb{1}_B(y)\, p_{(X,Y)}(x,y).\end{aligned}$$

Poiché (X, Y) è un vettore discreto, possiamo esprimere la somma come un integrale rispetto alla sua legge congiunta. In particolare, stiamo calcolando $\mathbb{E}[\ell(X,Y)]$, dove

$$\ell(x,y) = x\, \mathbb{1}_B(y).$$

Dunque,

$$\begin{aligned}\sum_{(x,y) \in X(\Omega) \times Y(\Omega)} x\, \mathbb{1}_B(y)\, p_{(X,Y)}(x,y) &= \int_{\mathbb{R}^2} x\, \mathbb{1}_B(y)\, d\mathbb{P}_{(X,Y)}(x,y) \\ &= \int_\Omega X\, \mathbb{1}_B(Y)\, d\mathbb{P} \\ &= \int_\Omega X\, \mathbb{1}_{Y^{-1}(B)}\, d\mathbb{P} \\ &= \int_{Y^{-1}(B)} X\, d\mathbb{P} \\ &= \int_A X\, d\mathbb{P}.\end{aligned}$$

□

Osservazione: Si vede che, se $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$, tutti i conti sono leciti. Inoltre,

$$\mathbb{E}[X \mid Y] \in L^1(\Omega, \mathcal{F}, \mathbb{P}).$$

6.2 Attesa condizionata rispetto ad una σ-algebra

Nel caso di variabili aleatorie non discrete (ad esempio assolutamente continue) non possiamo costruire la densità di X condizionata ad un evento $Y = y$ o a Y come nel caso discreto perché potrebbe accadere che $\mathbb{P}(Y = y) = 0 \quad \forall y \in \mathbb{R}$ (si pensi al caso assolutamente continuo). Siamo quindi costretti a dare una costruzione più teorica e complessa per il caso generale che per il caso discreto ricada in quanto già definito e per il caso assolutamente continuo definisca un concetto intuitivamente analogo ma formalmente rigoroso. Partiamo dalla seguente definizione.

Definizione 6.2.1. Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e sia $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ (va bene anche $X \geq 0$).
Sia $\mathcal{G} \subseteq \mathcal{F}$ una sotto-σ-algebra di $\mathcal{F}$ (ovvero una σ-algebra contenuta in $\mathcal{F}$).
Si definisce **attesa di X condizionata alla σ-algebra $\mathcal{G}$** una variabile aleatoria, denotata con $\mathbb{E}[X \mid \mathcal{G}]$, tale che:

1. $\mathbb{E}[X \mid \mathcal{G}]$ è $\mathcal{G}$-misurabile;
2. Per ogni $A \in \mathcal{G}$,
$$\int_A X \, d\mathbb{P} = \int_A \mathbb{E}[X \mid \mathcal{G}] \, d\mathbb{P},$$
ovvero
$$\mathbb{E}[X \mathbb{1}_A] = \mathbb{E}\big[\mathbb{E}[X \mid \mathcal{G}] \mathbb{1}_A\big].$$

Teorema 6.2.2. Se $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ (anche se $X \geq 0$), una variabile aleatoria che soddisfi le condizioni 1) e 2) della definizione di attesa condizionata esiste ed è unica q.o. in $(\Omega, \mathcal{G}, \mathbb{P}|_{\mathcal{G}})$,, quindi tranne per $A \in \mathcal{G}$ con $\mathbb{P}(A) = 0$.

Dimostrazione. Sia $X \geq 0$ e $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$.
Definiamo, per ogni $A \in \mathcal{G}$,
$$Q(A) = \int_A X \, d\mathbb{P}.$$
Osserviamo che:

- Q è una misura su $(\Omega, \mathcal{G})$;
- $Q \ll \mathbb{P}|_{\mathcal{G}}$;
- Q è una misura finita, infatti
$$Q(\Omega) = \int_\Omega X \, d\mathbb{P} = \mathbb{E}[X] < +\infty.$$

Possiamo quindi applicare il teorema di Radon-Nikodym: esiste ed è unica q.o. in $(\Omega, \mathcal{G}, \mathbb{P}|_{\mathcal{G}})$ una variabile aleatoria $\widehat{X}$ che sia $\mathcal{G}$-misurabile e tale che

$$Q(A) = \int_A \widehat{X}\, d\mathbb{P}, \qquad \forall A \in \mathcal{G},$$

e

$$\widehat{X} = \frac{dQ}{d\mathbb{P}|_{\mathcal{G}}} \quad \Longrightarrow \quad \widehat{X} = \mathbb{E}[X \mid \mathcal{G}].$$

Se $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$, allora

$$X = X^+ - X^-,$$

con $X^+, X^- \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ e $X^+, X^- \geq 0$.
Quindi esistono e sono uniche q.o. $\mathbb{E}[X^+ \mid \mathcal{G}]$ e $\mathbb{E}[X^- \mid \mathcal{G}]$.
Se $A \in \mathcal{G}$,

$$\begin{aligned}\int_A X\, d\mathbb{P} &= \int_A X^+\, d\mathbb{P} - \int_A X^-\, d\mathbb{P} \\ &= \int_A \mathbb{E}[X^+ \mid \mathcal{G}]\, d\mathbb{P} - \int_A \mathbb{E}[X^- \mid \mathcal{G}]\, d\mathbb{P} \\ &= \int_A \big(\mathbb{E}[X^+ \mid \mathcal{G}] - \mathbb{E}[X^- \mid \mathcal{G}]\big)\, d\mathbb{P}.\end{aligned}$$

Unicità. Supponiamo che $\widehat{X}_1$ e $\widehat{X}_2$ soddisfino le condizioni 1) e 2).
$\widehat{X}_1$ e $\widehat{X}_2$ sono $\mathcal{G}$-misurabili e, per ogni $A \in \mathcal{G}$,

$$\int_A \widehat{X}_1\, d\mathbb{P} = \int_A X\, d\mathbb{P} = \int_A \widehat{X}_2\, d\mathbb{P} \quad \Longrightarrow \quad \widehat{X}_1 = \widehat{X}_2 \quad \text{q.o.}$$

in $(\Omega, \mathcal{G}, \mathbb{P}|_{\mathcal{G}})$.
Pertanto,

$$\mathbb{E}[X \mid \mathcal{G}] = \mathbb{E}[X^+ \mid \mathcal{G}] - \mathbb{E}[X^- \mid \mathcal{G}] \qquad \text{q.o.}$$

□

Definizione 6.2.3. Sia Y una variabile aleatoria. Si definisce **attesa di X condizionata a Y** la variabile aleatoria

$$\mathbb{E}[X \mid Y] := \mathbb{E}[X \mid \sigma(Y)].$$

Poiché $\mathbb{E}[X \mid Y]$ è $\sigma(Y)$-misurabile, esiste una funzione misurabile $h : \mathbb{R} \to \mathbb{R}$ tale che

$$\mathbb{E}[X \mid Y] = h(Y).$$

Definizione 6.2.4. Si definisce

$$\mathbb{E}[X \mid Y = y] := h(y),$$

che viene detta **attesa di X condizionata all'evento** $(Y = y)$.

Teorema 6.2.5. Sia (X, Y) un vettore aleatorio assolutamente continuo e sia $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$.

Allora

$$h(y) = \mathbb{E}[X \mid Y = y] = \int_{\mathbb{R}} x\, f_{X|Y=y}(x)\, dx,$$

dove

$$f_{X|Y=y}(x) = \begin{cases} \dfrac{f_{(X,Y)}(x,y)}{f_Y(y)} & \text{se } f_Y(y) \neq 0, \\ 0 & \text{se } f_Y(y) = 0 \quad \text{(valore arbitrario).} \end{cases}$$

Osservazione:

1. $f_{X|Y=y}$ è una funzione di densità ed è detta **densità di X condizionata a $(Y = y)$**, se $f_Y(y) \neq 0$.

   Infatti:

   - $f_{X|Y=y} \geq 0$;
   - $f_{X|Y=y}$ è misurabile;
   - $$\int_{\mathbb{R}} f_{X|Y=y}(x)\, dx = \frac{1}{f_Y(y)} \underbrace{\int_{\mathbb{R}} f_{(X,Y)}(x,y)\, dx}_{f_Y(y)} = 1.$$

   Quindi $f_{X|Y=y}$ è una derivata di Radon-Nikodym e genera una misura di probabilità assolutamente continua rispetto a m, indicata con $\mathbb{P}_{X|Y=y}$ e detta **legge di X condizionata a Y**:

   $$\mathbb{P}_{X|Y=y} \ll m, \qquad f_{X|Y=y} = \frac{d\mathbb{P}_{X|Y=y}}{dm}.$$

   In particolare, per ogni $B \in \mathcal{B}(\mathbb{R})$,

   $$\mathbb{P}_{X|Y=y}(B) = \int_B f_{X|Y=y}(x)\, dx.$$

2. Si ha

   $$f_{(X,Y)}(x,y) = f_{X|Y=y}(x) \cdot f_Y(y) \qquad \text{q.o.}$$

   Possiamo quindi ottenere la densità congiunta.

3. Il punto precedente, insieme al fatto che

   $$X \perp\!\!\!\perp Y \iff f_{(X,Y)} = f_X \cdot f_Y \qquad \text{q.o.},$$

   fornisce un criterio di indipendenza:

   $$X \perp\!\!\!\perp Y \iff f_{X|Y=y}(x) = f_X(x) \quad \text{q.o.}, \qquad \forall y : \ f_Y(y) \neq 0.$$

4. Possiamo ripetere quanto detto per variabili aleatorie discrete, miste, a valori in $\mathbb{R}^N$, ...

5. Per ricavare $\mathbb{E}[X \mid Y]$:

   - Calcolo $f_{X|Y=y}$;
   - Calcolo
     $$h(y) = \mathbb{E}[X \mid Y = y] = \int_{\mathbb{R}} x\, f_{X|Y=y}(x)\, dx;$$

- Ottengo
$$h(Y) = \mathbb{E}[X \mid Y].$$

Esempio 6.2.6. Siano $X, Y \overset{\text{iid}}{\sim} \text{Exp}(\lambda)$ e sia $Z = X + Y$, da cui $Z \sim \Gamma(2, \lambda)$.
Determiniamo la legge di X condizionata all'evento $(Z = z)$.
Notiamo che, essendo $X \perp\!\!\!\perp Y$,
$$f_{(X,Y)}(x, y) = f_X(x) \cdot f_Y(y).$$
Inoltre,
$$f_{(X,Z)}(x, z) = f_{(X,Y)}(x, z - x) = f_X(x) f_Y(z - x).$$
Poiché $Z \sim \Gamma(2, \lambda)$, si ha $\mathbb{P}(Z > 0) = 1$ e, quindi, per ogni $z \leq 0$, $f_Z(z) = 0$.
Consideriamo soltanto $z > 0$:
$$\begin{aligned} f_{X|Z=z}(x) &= \frac{f_{(X,Z)}(x, z)}{f_Z(z)} = \frac{f_X(x) f_Y(z - x)}{f_Z(z)} \\ &= \frac{\left(\lambda e^{-\lambda x} \mathbb{1}_{(0,+\infty)}(x)\right) \left(\lambda e^{-\lambda(z-x)} \mathbb{1}_{(0,+\infty)}(z - x)\right)}{\frac{\lambda^2}{\Gamma(2)} z^{2-1} e^{-\lambda z}} \\ &= \frac{1}{z} \mathbb{1}_{(0,+\infty)}(x) \cdot \mathbb{1}_{(0,+\infty)}(z - x) \\ &= \frac{1}{z} \mathbb{1}_{(0,z)}(x). \end{aligned}$$
Dunque, per ogni $z > 0$,
$$f_{X|Z=z}(x) = \frac{1}{z} \mathbb{1}_{(0,z)}(x),$$
da cui
$$X \mid_{Z=z} \sim U(0, z), \qquad \text{ovvero} \qquad X \sim U(0, Z).$$
Possiamo calcolare l'attesa condizionata:
$$\mathbb{E}[X \mid Z = z] = \frac{z}{2} = h(z), \qquad \forall z > 0.$$
Pertanto,
$$\mathbb{E}[X \mid Z] = h(Z) = \frac{Z}{2}.$$
Consideriamo un ufficio postale e definiamo:

- X: tempo di servizio del primo cliente;
- Y: tempo di servizio del secondo cliente.

Supponiamo che $X, Y \overset{\text{iid}}{\sim} \text{Exp}(\lambda)$ e sia Z il tempo necessario per servire i due clienti, con $Z \sim \Gamma(2, \lambda)$.

Supponiamo che si verifichi l'evento $(Z = z)$, con $z = 20$ minuti. Allora

$$X \mid_{Z=z} \sim U(0, z),$$

da cui

$$\mathbb{E}[X \mid Z = z] = \frac{z}{2} = 10 \text{ minuti}.$$

Di conseguenza,

$$\mathbb{E}[X \mid Z] = \mathbb{E}[X \mid \sigma(Z)] = \frac{Z}{2} = h(Z).$$

Casi particolari di $\mathbb{E}[X \mid \mathcal{G}]$

1. **Caso $\mathcal{G} = \{\varnothing, \Omega\}$ (nessuna informazione).**

   Osservazione: Se $\mathcal{G} = \{\varnothing, \Omega\}$, una variabile aleatoria U è $\mathcal{G}$-misurabile se e solo se $U = c$, con c costante.

   La proprietà vale anche $\mathcal{G}$-q.o., ovvero tranne su un insieme $A \in \mathcal{G}$ tale che $\mathbb{P}(A) = 0$. L'unico insieme di questo tipo è $\varnothing$, quindi la proprietà vale sempre.

   Sia $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$. Poiché $\mathbb{E}[X \mid \mathcal{G}]$ è $\mathcal{G}$-misurabile, si ha

   $$\mathbb{E}[X \mid \mathcal{G}] = c.$$

   Determiniamo c attraverso la seconda proprietà dell'attesa condizionata, ovvero

   $$\int_A X \, d\mathbb{P} = \int_A \mathbb{E}[X \mid \mathcal{G}] \, d\mathbb{P}, \qquad \forall A \in \mathcal{G}.$$

   Se $A = \varnothing$, l'uguaglianza è verificata. Se invece $A = \Omega$, si ha

   $$\int_\Omega X \, d\mathbb{P} = \mathbb{E}[X]$$

   e

   $$\int_\Omega \mathbb{E}[X \mid \mathcal{G}] \, d\mathbb{P} = \int_\Omega c \, d\mathbb{P} = c \, \mathbb{P}(\Omega) = c.$$

   Pertanto,

   $$\boxed{\mathbb{E}[X \mid \mathcal{G}] = \mathbb{E}[X].}$$

2. **Caso $\mathcal{G} = \mathcal{F}$ (ho tutte le informazioni possibili).**

   Per ogni $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$,

   $$\boxed{\mathbb{E}[X \mid \mathcal{G}] = X \qquad \text{q.o.}}$$

3. **Caso $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ e X $\mathcal{G}$-misurabile (ho tutte le informazioni su X).**

   In questo caso,

   $$\boxed{\mathbb{E}[X \mid \mathcal{G}] = X \qquad \text{q.o.}}$$

4. **Caso $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ e X indipendente da $\mathcal{G}$.**

   Supponiamo che
   $$\sigma(X) \perp\!\!\!\perp \mathcal{G},$$
   ovvero che non abbiamo nessuna informazione su X.

   Questo significa che, per ogni $A \in \sigma(X)$ e $B \in \mathcal{G}$, gli eventi A e B sono indipendenti, cioè
   $$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

   Equivalentemente, per ogni variabile aleatoria Y $\mathcal{G}$-misurabile, con $\sigma(Y) \subseteq \mathcal{G}$, si ha
   $$\sigma(X) \perp\!\!\!\perp \sigma(Y), \qquad \text{ovvero} \qquad X \perp\!\!\!\perp Y.$$

   Verifichiamo le proprietà dell'attesa condizionata.

   Per ogni $A \in \mathcal{G}$, la variabile $\mathbb{1}_A$ è $\mathcal{G}$-misurabile e, per l'indipendenza, $\mathbb{1}_A \perp\!\!\!\perp X$. Pertanto,
   $$\begin{aligned}\int_A X \, d\mathbb{P} &= \int_\Omega X \mathbb{1}_A \, d\mathbb{P} \\ &= \mathbb{E}[X\mathbb{1}_A] \\ &= \mathbb{E}[X]\mathbb{E}[\mathbb{1}_A] \\ &= \mathbb{E}[X]\mathbb{P}(A) \\ &= \int_A \mathbb{E}[X] \, d\mathbb{P}.\end{aligned}$$

   Inoltre, $\mathbb{E}[X]$ è costante e quindi $\mathcal{G}$-misurabile.

   Per l'unicità dell'attesa condizionata,
   $$\boxed{\mathbb{E}[X \mid \mathcal{G}] = \mathbb{E}[X] \qquad \text{q.o.}}$$

   Osservazione: Se $\mathcal{G} = \sigma(Y)$ e $Y \perp\!\!\!\perp X$, ovvero $\sigma(Y) \perp\!\!\!\perp \sigma(X)$, allora
   $$\mathbb{E}[X \mid Y] = \mathbb{E}[X] \qquad \text{q.o.}$$

   In particolare, dove possibile,
   $$\mathbb{E}[X \mid Y = y] = \mathbb{E}[X] \qquad \text{q.o.}$$

Il viceversa dell'ultima proprietà non vale, come mostra il seguente controesempio.

Esempio 6.2.7. Sia
$$X \sim U(\{-2, -1, 1, 2\}), \qquad Y = X^2.$$
Allora
$$Y \sim U(\{1, 4\}).$$
Per ogni $k = 1, 4$,
$$X \mid_{Y=k} \sim U(\{-\sqrt{k}, \sqrt{k}\}).$$
In particolare, si ha anche
$$X \sim U(\{-\sqrt{Y}, \sqrt{Y}\}).$$
Di conseguenza,
$$\mathbb{E}[X \mid Y = k] = 0 = \mathbb{E}[X], \qquad \forall k = 1, 4.$$

Pertanto,

$$\boxed{\mathbb{E}[X \mid Y] = 0 = \mathbb{E}[X],}$$

ma

$$X \not\perp\!\!\!\perp Y.$$

6.2.1 Proprietà dell'attesa condizionata rispetto ad una σ-algebra

Supponiamo che tutte le variabile aleatorie utilizzate in questa sezione siano in L^1.

Proposizione 6.2.8 (Linearità)**.** Siano $X, Y \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ e $a, b, c \in \mathbb{R}$. Allora

$$\mathbb{E}[aX + bY + c \mid \mathcal{G}] = a\mathbb{E}[X \mid \mathcal{G}] + b\mathbb{E}[Y \mid \mathcal{G}] + c \qquad \text{q.o.}$$

Dimostrazione. La $\mathcal{G}$-misurabilità è verificata.
Per ogni $A \in \mathcal{G}$, si ha

$$\begin{aligned}
\int_A \mathbb{E}[aX + bY + c \mid \mathcal{G}]\, d\mathbb{P} &= \int_A (aX + bY + c)\, d\mathbb{P} \\
&= a\int_A X\, d\mathbb{P} + b\int_A Y\, d\mathbb{P} + c\int_A d\mathbb{P} \\
&= a\int_A \mathbb{E}[X \mid \mathcal{G}]\, d\mathbb{P} + b\int_A \mathbb{E}[Y \mid \mathcal{G}]\, d\mathbb{P} + c\int_A d\mathbb{P} \\
&= \int_A (a\mathbb{E}[X \mid \mathcal{G}] + b\mathbb{E}[Y \mid \mathcal{G}] + c)\, d\mathbb{P}.
\end{aligned}$$

Per l'unicità dell'attesa condizionata si ha la tesi. □

Proposizione 6.2.9 (Monotonia)**.** Se $X \leq Y$ q.o., allora

$$\mathbb{E}[X \mid \mathcal{G}] \leq \mathbb{E}[Y \mid \mathcal{G}] \qquad \text{q.o.}$$

Dimostrazione. Per ipotesi, $Y - X \geq 0$ q.o. Per il teorema di Radon-Nikodym,

$$\mathbb{E}[Y - X \mid \mathcal{G}] \geq 0 \qquad \text{q.o.}$$

Per la linearità dell'attesa condizionata,

$$0 \leq \mathbb{E}[Y - X \mid \mathcal{G}] = \mathbb{E}[Y \mid \mathcal{G}] - \mathbb{E}[X \mid \mathcal{G}] \qquad \text{q.o.},$$

da cui la tesi. □

Teorema 6.2.10 (Teorema di convergenza monotona)**.** Sia $(X_n)_{n\geq 1}$ una successione di variabili aleatorie non negative e non decrescente. Allora

$$\lim_n \mathbb{E}[X_n \mid \mathcal{G}] = \mathbb{E}\left[\lim_n X_n \mid \mathcal{G}\right] \qquad \text{q.o.}$$

Dimostrazione. Poiché

$$0 \leq X_n \leq X_{n+1},$$

per la monotonia dell'attesa condizionata si ha

$$0 \leq \mathbb{E}[X_n \mid \mathcal{G}] \leq \mathbb{E}[X_{n+1} \mid \mathcal{G}].$$

Esistono quindi entrambi i limiti

$$\lim_n X_n \qquad \text{e} \qquad \lim_n \mathbb{E}[X_n \mid \mathcal{G}].$$

Verifichiamo le due proprietà dell'attesa condizionata.
La $\mathcal{G}$-misurabilità è verificata.
Per ogni $A \in \mathcal{G}$, si ha

$$\begin{aligned}\int_A \mathbb{E}\left[\lim_n X_n \mid \mathcal{G}\right] d\mathbb{P} &= \int_A \lim_n X_n \, d\mathbb{P} \\ &= \lim_n \int_A X_n \, d\mathbb{P} \\ &= \lim_n \int_A \mathbb{E}[X_n \mid \mathcal{G}] \, d\mathbb{P} \\ &= \int_A \lim_n \mathbb{E}[X_n \mid \mathcal{G}] \, d\mathbb{P}.\end{aligned}$$

Per l'unicità dell'attesa condizionata si ha la tesi. □

Lemma 6.2.11 (Lemma di Fatou)**.** Sia $(X_n)_{n\geq 1}$ una successione di variabili aleatorie non negative. Allora

$$\mathbb{E}\left[\liminf_n X_n \mid \mathcal{G}\right] \leq \liminf_n \mathbb{E}[X_n \mid \mathcal{G}] \qquad \text{q.o.}$$

Osservazione: Per il teorema di convergenza monotona e il lemma di Fatou non è necessario che $X_n \in L^1$.

Teorema 6.2.12 (Teorema di convergenza dominata)**.** Sia $(X_n)_{n\geq 1}$ una successione di variabili aleatorie convergente q.o. a una variabile aleatoria X. Supponiamo che, per ogni $n \geq 1$,

$$|X_n| \leq Y,$$

con $Y \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ e $Y \geq 0$.
Allora

$$\lim_n \mathbb{E}[X_n \mid \mathcal{G}] = \mathbb{E}\left[\lim_n X_n \mid \mathcal{G}\right] \qquad \text{q.o.}$$

Proposizione 6.2.13 (Tower property (assorbimento, proiettività))**.** Siano $\Theta \subseteq \mathcal{G} \subseteq \mathcal{F}$ tre σ-algebre. Allora

$$\mathbb{E}\big[\mathbb{E}[X \mid \mathcal{G}] \mid \Theta\big] = \mathbb{E}[X \mid \Theta] \qquad \text{q.o.}$$

Dimostrazione. La Θ-misurabilità è verificata.
Per ogni $A \in \Theta$, essendo $\Theta \subseteq \mathcal{G}$, si ha

$$\begin{aligned}\int_A \mathbb{E}[X \mid \Theta]\, d\mathbb{P} &= \int_A X\, d\mathbb{P} \\ &= \int_A \mathbb{E}[X \mid \mathcal{G}]\, d\mathbb{P} \\ &= \int_A Y\, d\mathbb{P} \\ &= \int_A \mathbb{E}[Y \mid \Theta]\, d\mathbb{P} \\ &= \int_A \mathbb{E}\big[\mathbb{E}[X \mid \mathcal{G}] \mid \Theta\big]\, d\mathbb{P},\end{aligned}$$

dove $Y = \mathbb{E}[X \mid \mathcal{G}]$ è $\mathcal{G}$-misurabile.
Per l'unicità dell'attesa condizionata si ha la tesi. □

Osservazione: Se $\Theta = \{\Omega, \varnothing\}$ è la σ-algebra banale, la Tower property diventa

$$\mathbb{E}\big[\mathbb{E}[X \mid \mathcal{G}]\big] = \mathbb{E}[X].$$

In realtà, questa proprietà segue anche dalla definizione di attesa condizionata, poiché

$$\forall A \in \mathcal{G}, \qquad \mathbb{E}[X \mathbb{1}_A] = \mathbb{E}\big[\mathbb{E}[X \mid \mathcal{G}] \mathbb{1}_A\big].$$

Nel caso in cui $A = \Omega$, si ottiene

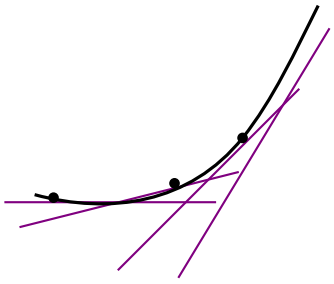
$$\mathbb{E}[X] = \mathbb{E}\big[\mathbb{E}[X \mid \mathcal{G}]\big].$$

Teorema 6.2.14 (Disuguaglianza di Jensen)**.** Sia $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ e sia ψ una funzione convessa tale che $\psi(X) \in L^1(\Omega, \mathcal{F}, \mathbb{P})$.
La proprietà funziona anche se $X \geq 0$ e ψ è convessa con $\psi(X) \geq 0$.
Allora

$$\psi\left(\mathbb{E}[X \mid \mathcal{G}]\right) \leq \mathbb{E}[\psi(X) \mid \mathcal{G}] \qquad \text{q.o.}$$

Dimostrazione. La funzione ψ è convessa se e solo se si appoggia sulle rette, ovvero esistono $a_n, b_n \in \mathbb{R}$, per ogni $n \geq 1$, tali che

$$\psi(x) = \sup_n (a_n x + b_n) = \sup_n L_n(x), \qquad \forall x \in \mathbb{R}.$$



Si noti che

$$L_n(X) = a_n X + b_n \leq \psi(X).$$

Le rette vengono mantenute dall'attesa condizionata. Infatti, per la monotonia,

$$\mathbb{E}[L_n(X) \mid \mathcal{G}] \leq \mathbb{E}[\psi(X) \mid \mathcal{G}] \qquad \text{q.o.}$$

Inoltre, per la linearità,

$$\mathbb{E}[L_n(X) \mid \mathcal{G}] = L_n\left(\mathbb{E}[X \mid \mathcal{G}]\right) \qquad \text{q.o.}$$

Pertanto, per la convessità di ψ, la linearità e la monotonia dell'attesa condizionata, si ha

$$\begin{aligned}\psi\left(\mathbb{E}[X \mid \mathcal{G}]\right) &= \sup_n L_n\left(\mathbb{E}[X \mid \mathcal{G}]\right) \\ &= \sup_n \mathbb{E}[L_n(X) \mid \mathcal{G}] \\ &\leq \sup_n \mathbb{E}[\psi(X) \mid \mathcal{G}] \\ &= \mathbb{E}[\psi(X) \mid \mathcal{G}] \qquad \text{q.o.},\end{aligned}$$

da cui la tesi. □

Proposizione 6.2.15 (Contrattività in L^p)**.** Sia $X \in L^p(\Omega, \mathcal{F}, \mathbb{P})$, con $p \geq 1$. Allora

$$\mathbb{E}[X \mid \mathcal{G}] \in L^p(\Omega, \mathcal{G}, \mathbb{P}|_{\mathcal{G}})$$

e inoltre

$$\|\mathbb{E}[X \mid \mathcal{G}]\|_{L^p(\Omega,\mathcal{G},\mathbb{P}|_{\mathcal{G}})} \leq \|X\|_{L^p(\Omega,\mathcal{F},\mathbb{P})}.$$

La funzione

$$\begin{aligned}\mathbb{E}[\cdot \mid \mathcal{G}] : L^p(\Omega, \mathcal{F}, \mathbb{P}) &\longrightarrow L^p(\Omega, \mathcal{G}, \mathbb{P}|_{\mathcal{G}}) \\ X &\longmapsto \mathbb{E}[X \mid \mathcal{G}]\end{aligned}$$

è una **contrazione (in senso lato)**.

Dimostrazione. Sia $\psi(x) = |x|^p$, con $p \geq 1$, una funzione convessa.
Poiché $X \in L^p(\Omega, \mathcal{F}, \mathbb{P})$, si ha

$$\psi(X) = |X|^p \in L^1(\Omega, \mathcal{F}, \mathbb{P}).$$

Per la disuguaglianza di Jensen,

$$|\mathbb{E}[X \mid \mathcal{G}]|^p \leq \mathbb{E}[|X|^p \mid \mathcal{G}] \qquad \text{q.o.}$$

Pertanto,

$$\begin{aligned}\mathbb{E}\left[|\mathbb{E}[X \mid \mathcal{G}]|^p\right] &\leq \mathbb{E}\left[\mathbb{E}[|X|^p \mid \mathcal{G}]\right] \\ &= \mathbb{E}[|X|^p] < +\infty,\end{aligned}$$

dove abbiamo applicato la Tower property e utilizzato l'ipotesi $X \in L^p$.
Di conseguenza,

$$\mathbb{E}[X \mid \mathcal{G}] \in L^p(\Omega, \mathcal{G}, \mathbb{P}|_{\mathcal{G}})$$

e inoltre

$$\|\mathbb{E}[X \mid \mathcal{G}]\|_{L^p(\Omega,\mathcal{G},\mathbb{P}|_{\mathcal{G}})} \leq \|X\|_{L^p(\Omega,\mathcal{F},\mathbb{P})}.$$

□

Proposizione 6.2.16 (Contrattività in L^∞)**.** Sia $X \in L^\infty(\Omega, \mathcal{F}, \mathbb{P})$. Allora

$$\mathbb{E}[X \mid \mathcal{G}] \in L^\infty(\Omega, \mathcal{G}, \mathbb{P}|_{\mathcal{G}})$$

e inoltre

$$\|\mathbb{E}[X \mid \mathcal{G}]\|_{L^\infty(\Omega,\mathcal{G},\mathbb{P}|_\mathcal{G})} \leq \|X\|_{L^\infty(\Omega,\mathcal{F},\mathbb{P})}.$$

La funzione

$$\begin{aligned}\mathbb{E}[\cdot \mid \mathcal{G}] : L^\infty(\Omega,\mathcal{F},\mathbb{P}) &\longrightarrow L^\infty(\Omega,\mathcal{G},\mathbb{P}|_\mathcal{G}) \\ X &\longmapsto \mathbb{E}[X \mid \mathcal{G}]\end{aligned}$$

è una **contrazione (in senso lato)**.

Dimostrazione. Poiché $X \in L^\infty(\Omega,\mathcal{F},\mathbb{P})$, si ha

$$|X| \leq \|X\|_{L^\infty(\Omega,\mathcal{F},\mathbb{P})} \qquad \text{q.o.}$$

Sia $\psi(x) = |x|$, una funzione convessa. Per la disuguaglianza di Jensen e la monotonia dell'attesa condizionata,

$$\begin{aligned}|\mathbb{E}[X \mid \mathcal{G}]| &\leq \mathbb{E}[|X| \mid \mathcal{G}] \\ &\leq \mathbb{E}\left[\|X\|_{L^\infty(\Omega,\mathcal{F},\mathbb{P})} \mid \mathcal{G}\right] \\ &= \|X\|_{L^\infty(\Omega,\mathcal{F},\mathbb{P})} \qquad \text{q.o.},\end{aligned}$$

essendo $\|X\|_{L^\infty(\Omega,\mathcal{F},\mathbb{P})}$ una costante e quindi $\mathcal{G}$-misurabile.
Pertanto,

$$\mathbb{E}[X \mid \mathcal{G}] \in L^\infty(\Omega,\mathcal{G},\mathbb{P}|_\mathcal{G})$$

e inoltre

$$\|\mathbb{E}[X \mid \mathcal{G}]\|_{L^\infty(\Omega,\mathcal{G},\mathbb{P}|_\mathcal{G})} \leq \|X\|_{L^\infty(\Omega,\mathcal{F},\mathbb{P})}.$$

□

Proposizione 6.2.17 (Proprietà di estrazione)**.** Siano $X, Y, XY \in L^1(\Omega,\mathcal{F},\mathbb{P})$ e sia Y una variabile aleatoria $\mathcal{G}$-misurabile. Allora

$$\mathbb{E}[XY \mid \mathcal{G}] = Y\mathbb{E}[X \mid \mathcal{G}] \qquad \text{q.o.}$$

Dimostrazione. Non dimostriamo la proprietà nel caso generale, ma consideriamo il caso particolare $Y = \mathbb{1}_B$, con $B \in \mathcal{G}$, e proviamo che

$$\mathbb{E}[X\mathbb{1}_B \mid \mathcal{G}] = \mathbb{E}[X \mid \mathcal{G}]\mathbb{1}_B \qquad \text{q.o.}$$

La $\mathcal{G}$-misurabilità è verificata.
Sia $A \in \mathcal{G}$. Per definizione di attesa condizionata,

$$\begin{aligned}\int_A \mathbb{E}[X\mathbb{1}_B \mid \mathcal{G}]\, d\mathbb{P} &= \int_A X\mathbb{1}_B\, d\mathbb{P} \\ &= \int_{A\cap B} X\, d\mathbb{P} \\ &= \int_{A\cap B} \mathbb{E}[X \mid \mathcal{G}]\, d\mathbb{P} \\ &= \int_A \mathbb{E}[X \mid \mathcal{G}]\mathbb{1}_B\, d\mathbb{P}.\end{aligned}$$

La tesi segue quindi dall'unicità dell'attesa condizionata. □

Abbiamo dunque che

$$\mathbb{E}[XY \mid \mathcal{G}] = Y\mathbb{E}[X \mid \mathcal{G}] \qquad \text{q.o.}$$

Applicando la Tower property,

$$\mathbb{E}\big[\mathbb{E}[XY \mid \mathcal{G}]\big] = \mathbb{E}\big[Y\mathbb{E}[X \mid \mathcal{G}]\big].$$

Poiché

$$\mathbb{E}\big[\mathbb{E}[XY \mid \mathcal{G}]\big] = \mathbb{E}[XY],$$

si ottiene

$$\mathbb{E}[XY] = \mathbb{E}[\widehat{X}Y], \qquad \widehat{X} = \mathbb{E}[X \mid \mathcal{G}].$$

Osservazione: Se $Y = \mathbb{1}_B$, con $B \in \mathcal{G}$, si ha

$$\mathbb{E}[X\mathbb{1}_B] = \mathbb{E}[\widehat{X}\mathbb{1}_B],$$

cioè

$$\int_B X \, d\mathbb{P} = \int_B \widehat{X} \, d\mathbb{P}.$$

Si ottiene quindi la definizione di $\widehat{X} = \mathbb{E}[X \mid \mathcal{G}]$.
Poiché l'attesa condizionata è unica, si ottiene la seguente caratterizzazione.

Proposizione 6.2.18 (Caratterizzazione dell'attesa condizionata)**.** Sia $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$. Allora

$$\widehat{X} = \mathbb{E}[X \mid \mathcal{G}]$$

è, q.o., l'unica variabile aleatoria $\mathcal{G}$-misurabile tale che, per ogni variabile aleatoria Y $\mathcal{G}$-misurabile, con

$$Y \in L^1(\Omega, \mathcal{F}, \mathbb{P}), \qquad XY \in L^1(\Omega, \mathcal{F}, \mathbb{P}),$$

sia soddisfatta l'uguaglianza

$$\mathbb{E}[\widehat{X}Y] = \mathbb{E}[XY].$$

Proposizione 6.2.19 (Proiezione ortogonale)**.** Sia $\mathcal{G} \subseteq \mathcal{F}$ una sotto-σ-algebra. Se $X \in L^2(\Omega, \mathcal{F}, \mathbb{P})$, allora

$$\widehat{X} = \mathbb{E}[X \mid \mathcal{G}] \in L^2(\Omega, \mathcal{G}, \mathbb{P}|_{\mathcal{G}})$$

è la proiezione ortogonale di X sul sottospazio chiuso $L^2(\Omega, \mathcal{G}, \mathbb{P}|_{\mathcal{G}})$.
In particolare, vale

$$\boxed{\|X - \widehat{X}\|_{L^2} \leq \|X - Z\|_{L^2}} \qquad \forall Z \in L^2(\Omega, \mathcal{G}, \mathbb{P}|_{\mathcal{G}}).$$

Dimostrazione. Noitiamo innanzitutto che $\widehat{X} \in L^2(\Omega, \mathcal{G}, \mathbb{P}|_{\mathcal{G}})$ per la contrattività.
Per la caratterizzazione del valore atteso condizionato, per ogni $Y \in L^2(\Omega, \mathcal{G}, \mathbb{P}|_{\mathcal{G}})$ si ha

$$\mathbb{E}[XY] = \mathbb{E}[\widehat{X}Y].$$

Poiché il prodotto scalare in L^2 è definito da

$$\langle X, Y \rangle = \mathbb{E}[XY],$$

segue che

$$\langle X, Y\rangle = \langle \widehat{X}, Y\rangle \iff \langle X - \widehat{X}, Y\rangle = 0.$$

Pertanto $X - \widehat{X}$ è ortogonale a ogni elemento di $L^2(\Omega, \mathcal{G}, \mathbb{P}|_{\mathcal{G}})$, dunque $\widehat{X}$ è la proiezione ortogonale di X su tale sottospazio.
Inoltre, per ogni $Z \in L^2(\Omega, \mathcal{G}, \mathbb{P}|_{\mathcal{G}})$, essendo $\widehat{X} - Z$ un elemento del sottospazio, per il teorema di Pitagora si ottiene

$$\begin{aligned}\|X - Z\|_{L^2}^2 &= \|(X - \widehat{X}) + (\widehat{X} - Z)\|_{L^2}^2 \\ &= \|X - \widehat{X}\|_{L^2}^2 + \|\widehat{X} - Z\|_{L^2}^2 \\ &\geq \|X - \widehat{X}\|_{L^2}^2.\end{aligned}$$

Da cui

$$\boxed{\|X - \widehat{X}\|_{L^2} \leq \|X - Z\|_{L^2}.}$$

□

Osservazione: Per la proprietà del valore atteso condizionato,

$$\mathbb{E}[\widehat{X}] = \mathbb{E}[X] \implies \mathbb{E}[X - \widehat{X}] = 0.$$

Di conseguenza,

$$\mathrm{Var}(X - \widehat{X}) = \mathbb{E}[(X - \widehat{X})^2] = \|X - \widehat{X}\|_{L^2}^2.$$

Pertanto, per ogni $Z \in L^2(\Omega, \mathcal{G}, \mathbb{P}|_{\mathcal{G}})$ tale che $\mathbb{E}[Z] = \mathbb{E}[X]$, si ha

$$\boxed{\mathrm{Var}(X - \widehat{X}) \leq \mathrm{Var}(X - Z).}$$

Quindi

$$\widehat{X} = \mathbb{E}[X \mid \mathcal{G}]$$

fornisce la **migliore stima non distorta** della variabile aleatoria X, note le informazioni contenute in $\mathcal{G}$, nel senso che minimizza la varianza dell'errore di stima tra tutte le variabili aleatorie $\mathcal{G}$-misurabili e non distorte.
Essendo $\widehat{X}$ una variabile aleatoria, essa rappresenta uno **stimatore** di X.

Esempio 6.2.20. Trasmettiamo un segnale aleatorio X. In ricezione si ottiene un segnale $Y = X + W$, dove W è il rumore.
Vedo il segnale in ricezione, quindi le mie informazioni sono contenute in $\mathcal{G} = \sigma(Y)$. Il modo migliore per stimare X è usare

$$\widehat{X} = \mathbb{E}[X \mid Y] = h(Y).$$

All'atto pratico, io ricevo un segnale y, quindi la miglior stima del segnale trasmesso è

$$h(y) = \mathbb{E}[X \mid Y = y].$$

6.3 Varianza condizionata

Definizione 6.3.1. Sia $X \in L^2(\Omega, \mathcal{F}, \mathbb{P})$ e sia Y una variabile aleatoria.

1) Definiamo la **varianza di X condizionata all'evento** $(Y = y)$ come la varianza fatta rispetto alla legge $\mathbb{P}_{X|Y=y}$:

$$\mathrm{Var}(X \mid Y = y) = \mathbb{E}\left[(X - \mathbb{E}[X \mid Y = y])^2 \mid Y = y\right] = g(y).$$

2) Definiamo la **varianza di X condizionata alla variabile aleatoria Y** come la composizione di g con Y:

$$\mathrm{Var}(X \mid Y) = g(Y) = \mathbb{E}\left[\left(X - \underbrace{\mathbb{E}[X \mid Y]}_{\mathbb{E}[X|\sigma(Y)]}\right)^2 \,\middle|\, \underbrace{Y}_{\sigma(Y)}\right].$$

3) Definiamo la **varianza di X condizionata a $\mathcal{G} \subseteq \mathcal{F}$** come

$$\mathrm{Var}(X \mid \mathcal{G}) = \mathbb{E}\left[(X - \mathbb{E}[X \mid \mathcal{G}])^2 \mid \mathcal{G}\right].$$

È una variabile aleatoria $\mathcal{G}$-misurabile.

Proposizione 6.3.2. Sia $X \in L^2(\Omega, \mathcal{F}, \mathbb{P})$ e sia $\mathcal{G} \subseteq \mathcal{F}$ una sotto-σ-algebra. Vale le seguente proprietà:

$$\boxed{\mathrm{Var}(X) = \mathrm{Var}\big(\mathbb{E}[X \mid \mathcal{G}]\big) + \mathbb{E}\big[\mathrm{Var}(X \mid \mathcal{G})\big]}$$

Dimostrazione. Poniamo $\widehat{X} = \mathbb{E}[X \mid \mathcal{G}]$. Si ha

$$\begin{aligned}
\mathrm{Var}(X) &= \mathbb{E}\left[(X - \mathbb{E}[X])^2\right] \\
&= \mathbb{E}\left[\Big((X - \widehat{X}) + (\widehat{X} - \mathbb{E}[X])\Big)^2\right] \\
&= \mathbb{E}\left[(X - \widehat{X})^2\right] + \mathbb{E}\left[(\widehat{X} - \mathbb{E}[X])^2\right] \\
&\quad + 2\mathbb{E}\left[(X - \widehat{X})(\widehat{X} - \mathbb{E}[X])\right].
\end{aligned}$$

Per la proprietà della proiezione ortogonale, l'ultimo termine è nullo, poiché

$$\mathbb{E}\left[(X - \widehat{X})(\widehat{X} - \mathbb{E}[X])\right] = \left\langle X - \widehat{X}, \widehat{X} - \mathbb{E}[X] \right\rangle = 0,$$

essendo $\widehat{X} - \mathbb{E}[X] \in L^2(\Omega, \mathcal{G}, \mathbb{P}|_{\mathcal{G}})$.
Consideriamo quindi i due termini rimanenti. Ricordiamo che $\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X|\mathcal{G}]]$. Allora

1)
$$\begin{aligned}
\mathbb{E}\left[(X - \widehat{X})^2\right] &= \mathbb{E}\left[\mathbb{E}\left[(X - \widehat{X})^2 \mid \mathcal{G}\right]\right] \\
&= \mathbb{E}\left[\underbrace{\mathbb{E}\left[(X - \mathbb{E}[X \mid \mathcal{G}])^2 \mid \mathcal{G}\right]}_{\mathrm{Var}(X|\mathcal{G})}\right] \\
&= \mathbb{E}\left[\mathrm{Var}(X \mid \mathcal{G})\right].
\end{aligned}$$

2) $\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X \mid \mathcal{G}]] = \mathbb{E}[\widehat{X}]$. Pertanto,

$$\begin{aligned}
\mathbb{E}\left[(\widehat{X} - \mathbb{E}[X])^2\right] &= \mathbb{E}\left[(\widehat{X} - \mathbb{E}[\widehat{X}])^2\right] \\
&= \mathrm{Var}(\widehat{X}) \\
&= \mathrm{Var}(\mathbb{E}[X \mid \mathcal{G}]).
\end{aligned}$$

Mettendo tutto insieme, si ottiene la tesi. □

Esempio 6.3.3. Sia $Z \sim \Gamma(2, \lambda)$ e sia $X \sim U([0, Z])$, cioè

$$X \mid_{Z=z} \sim U((0, z)).$$

Si ha

$$\mathbb{E}[X \mid Z = z] = \frac{z}{2} \quad \Longrightarrow \quad \mathbb{E}[X \mid Z] = \frac{Z}{2},$$

e

$$\mathrm{Var}(X \mid Z = z) = \frac{z^2}{12} \quad \Longrightarrow \quad \mathrm{Var}(X \mid Z) = \frac{Z^2}{12}.$$

Per la proprietà del valore atteso condizionato,

$$\begin{aligned}
\mathbb{E}[X] &= \mathbb{E}\left[\mathbb{E}[X \mid Z]\right] \\
&= \mathbb{E}\left[\frac{Z}{2}\right] \\
&= \frac{1}{2}\mathbb{E}[Z] \\
&= \frac{1}{2} \cdot \frac{2}{\lambda} \\
&= \boxed{\frac{1}{\lambda}}.
\end{aligned}$$

Inoltre, per la formula della varianza totale,

$$\begin{aligned}
\mathrm{Var}(X) &= \mathbb{E}\left[\mathrm{Var}(X \mid Z)\right] + \mathrm{Var}\left(\mathbb{E}[X \mid Z]\right) \\
&= \mathbb{E}\left[\frac{Z^2}{12}\right] + \mathrm{Var}\left(\frac{Z}{2}\right) \\
&= \cdots \\
&= \boxed{\frac{1}{\lambda^2}}.
\end{aligned}$$

Capitolo 7

Convergenza di sucessioni di variabili aleatorie

7.1 Convergenza q.c., $\mathbb{P}$ e in L^p

Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità (completo).

Definizione 7.1.1. Diciamo che una successione di variabili aleatorie $(X_n)_{n\geq 1}$ converge **quasi ovunque** alla variabile aleatoria X, oppure converge **quasi certamente**, o **con probabilità 1**, se

$$\mathbb{P}\left(\{\omega \in \Omega : X_n(\omega) \to X(\omega)\}\right) = \mathbb{P}\left((X_n \to X)\right) = 1,$$

o equivalentemente

$$\mathbb{P}\left(\{\omega \in \Omega : X_n(\omega) \nrightarrow X(\omega)\}\right) = \mathbb{P}\left((X_n \nrightarrow X)\right) = 0.$$

Indichiamo

$$X_n \xrightarrow{\text{q.o.}} X, \qquad X_n \xrightarrow{\text{q.c.}} X.$$

Definizione 7.1.2. Diciamo che una successione di variabili aleatorie $(X_n)_{n\geq 1}$ converge **in probabilità** (**in misura**) alla variabile aleatoria X se, per ogni $\varepsilon > 0$,

$$\mathbb{P}(|X_n - X| > \varepsilon) \xrightarrow[n\to\infty]{} 0,$$

ossia

$$\mathbb{P}\left(\{\omega \in \Omega : |X_n(\omega) - X(\omega)| > \varepsilon\}\right) \xrightarrow[n\to\infty]{} 0.$$

Indichiamo

$$X_n \xrightarrow{\mathbb{P}} X.$$

Definizione 7.1.3. Diciamo che una successione di variabili aleatorie $(X_n)_{n\geq 1}$ converge **in norma** L^p alla variabile aleatoria X (**in** L^p o **in media di ordine** p) se $X_n, X \in L^p(\Omega, \mathcal{F}, \mathbb{P})$ per ogni $n \geq 1$ e

$$\|X_n - X\|_{L^p(\Omega,\mathcal{F},\mathbb{P})} \longrightarrow 0.$$

Denotiamo

$$X_n \xrightarrow{L^p} X.$$

Osservazione: Osserviamo che

$$X_n \xrightarrow{L^p} X \iff \mathbb{E}\left[|X_n - X|^p\right] \longrightarrow 0.$$

Nel caso $p = 2$ parliamo di **convergenza in media quadratica**. Nel caso $p = 1$ parliamo di **convergenza in media**.

Teorema 7.1.4. Valgono le seguenti proprietà:

1) Siano $p \geq q \geq 1$. Allora
$$X_n \xrightarrow{L^p} X \implies X_n \xrightarrow{L^q} X.$$

2) Se $X_n \xrightarrow{L^1} X$, allora
$$\mathbb{E}[X_n] \longrightarrow \mathbb{E}[X].$$

3) Se $X_n \xrightarrow{L^p} X$, allora
$$\mathbb{E}[|X_n|^p] \longrightarrow \mathbb{E}[|X|^p] \qquad \forall p \geq 1.$$

4) Si ha
$$X_n \xrightarrow{L^2} a \iff \begin{cases} \mathbb{E}[X_n] \longrightarrow a, \\ \mathrm{Var}(X_n) \longrightarrow 0. \end{cases}$$

Dimostrazione. 1) Per ipotesi $p \geq q \geq 1$, e sappiamo già che $L^p \subseteq L^q$.

Se $X \in L^p$, allora $X \in L^q$. Si ha

$$\begin{aligned} +\infty > \mathbb{E}[|X|^p] &= \mathbb{E}\left[(|X|^q)^{p/q}\right] \\ &= \mathbb{E}\left[\psi(|X|^q)\right] \\ &\geq \psi\left(\mathbb{E}[|X|^q]\right) \\ &= \left(\mathbb{E}[|X|^q]\right)^{p/q}, \end{aligned}$$

dove $\psi(x) = x^{p/q}$, per $x > 0$, è convessa poiché $p/q \geq 1$.

Per applicare la **disuguaglianza di Jensen**, consideriamo le variabili aleatorie coinvolte:

$$X \in L^p \subseteq L^q \implies |X|^q \in L^1,$$

e inoltre

$$\psi(|X|^q) = |X|^p \in L^1,$$

essendo $X \in L^p$ per ipotesi. Pertanto, entrambe le variabili aleatorie sono in L^1 e possiamo applicare Jensen.

Equivalentemente, possiamo utilizzare la versione della disuguaglianza di Jensen per variabili aleatorie non negative, osservando che

$$|X|^q \geq 0, \qquad \psi(|X|^q) = |X|^p \geq 0.$$

In questo modo otteniamo gli stessi conti.

Quindi

$$+\infty > \underbrace{\mathbb{E}[|X|^p]^{1/p}}_{\|X\|_{L^p}} \geq \mathbb{E}[|X|^q]^{1/q} = \|X\|_{L^q},$$

da cui

$$\|X\|_{L^q} \leq \|X\|_{L^p} < +\infty.$$

Ora consideriamo $X_n, X \in L^p$, quindi $X_n, X \in L^q$.

Per ipotesi,

$$X_n \xrightarrow{L^p} X \implies \|X_n - X\|_{L^p} \longrightarrow 0.$$

Pertanto,

$$\|X_n - X\|_{L^q} \leq \|X_n - X\|_{L^p} \longrightarrow 0 \implies X_n \xrightarrow{L^q} X.$$

2) Se $X_n \xrightarrow{L^1} X$, allora

$$\mathbb{E}[|X_n - X|] \longrightarrow 0.$$

Inoltre,

$$\begin{aligned} |\mathbb{E}[X_n] - \mathbb{E}[X]| &= |\mathbb{E}[X_n - X]| \\ &\leq \mathbb{E}[|X_n - X|] \longrightarrow 0. \end{aligned}$$

Quindi

$$\mathbb{E}[X_n] \longrightarrow \mathbb{E}[X].$$

3) Se $X_n \xrightarrow{L^p} X$, allora

$$\mathbb{E}[|X_n - X|^p] = \|X_n - X\|_{L^p}^p \longrightarrow 0.$$

Vogliamo provare che

$$\underbrace{\mathbb{E}[|X_n|^p]}_{\|X_n\|_{L^p}^p} \longrightarrow \underbrace{\mathbb{E}[|X|^p]}_{\|X\|_{L^p}^p}.$$

Per la disuguaglianza triangolare inversa,

$$|\|X_n\|_{L^p} - \|X\|_{L^p}| \leq \|X_n - X\|_{L^p} \longrightarrow 0,$$

da cui segue la tesi.

4) Proviamo che

$$X_n \xrightarrow{L^2} a \iff \begin{cases} \mathbb{E}[X_n] \longrightarrow a, \\ \mathrm{Var}(X_n) \longrightarrow 0. \end{cases}$$

Si ha

$$X_n \xrightarrow{L^2} a \iff \mathbb{E}[(X_n - a)^2] \longrightarrow 0,$$

dove

$$\begin{aligned} \mathbb{E}[(X_n - a)^2] &= \mathrm{Var}(X_n - a) + \mathbb{E}[X_n - a]^2 \\ &= \mathrm{Var}(X_n) + (\mathbb{E}[X_n] - a)^2. \end{aligned}$$

Pertanto,

$$\begin{aligned} X_n \xrightarrow{L^2} a &\iff \mathrm{Var}(X_n) + (\mathbb{E}[X_n] - a)^2 \longrightarrow 0 \\ &\iff \begin{cases} \mathrm{Var}(X_n) \longrightarrow 0, \\ (\mathbb{E}[X_n] - a)^2 \longrightarrow 0. \end{cases} \end{aligned}$$

Quindi

$$\mathbb{E}[X_n] \longrightarrow a, \qquad \mathrm{Var}(X_n) \longrightarrow 0.$$

□

Osservazione: Se $X_n \xrightarrow{L^2} X$, allora, per la proprietà 1,

$$X_n \xrightarrow{L^2} X \implies X_n \xrightarrow{L^1} X.$$

Dalla proprietà 2 segue che

$$\mathbb{E}[X_n] \longrightarrow \mathbb{E}[X].$$

Inoltre, per la proprietà 3,

$$\mathbb{E}[X_n^2] \longrightarrow \mathbb{E}[X^2],$$

da cui

$$\mathrm{Var}(X_n) \longrightarrow \mathrm{Var}(X).$$

In generale non vale il viceversa.

Teorema 7.1.5. Si ha

$$X_n \xrightarrow{\mathbb{P}} X \iff \mathbb{E}\left[\frac{|X_n - X|}{|X_n - X| + 1}\right] \xrightarrow[n\to\infty]{} 0.$$

Dimostrazione. Supponiamo che $X = 0$, altrimenti si considera la successione $Y_n = X_n - X$, $n \geq 1$.
($\Rightarrow$) Supponiamo che $X_n \xrightarrow{\mathbb{P}} 0$, ovvero, per ogni $\varepsilon > 0$,

$$\mathbb{P}(|X_n - 0| > \varepsilon) = \mathbb{P}(|X_n| > \varepsilon) \xrightarrow[n\to\infty]{} 0.$$

Si ha

$$\begin{aligned} 0 \leq \frac{|X_n|}{|X_n|+1} &= \frac{|X_n|}{|X_n|+1}\mathbb{1}_{\{|X_n|>\varepsilon\}} + \frac{|X_n|}{|X_n|+1}\mathbb{1}_{\{|X_n|\leq\varepsilon\}} \\ &\leq \mathbb{1}_{\{|X_n|>\varepsilon\}} + \varepsilon\mathbb{1}_{\{|X_n|\leq\varepsilon\}}. \end{aligned}$$

Pertanto,

$$\begin{aligned} 0 \leq \mathbb{E}\left[\frac{|X_n|}{|X_n|+1}\right] &\leq \mathbb{E}\left[\mathbb{1}_{\{|X_n|>\varepsilon\}}\right] + \mathbb{E}\left[\varepsilon\mathbb{1}_{\{|X_n|\leq\varepsilon\}}\right] \\ &= \mathbb{P}(|X_n| > \varepsilon) + \varepsilon \underbrace{\mathbb{P}(|X_n| \leq \varepsilon)}_{\leq 1} \\ &\leq \mathbb{P}(|X_n| > \varepsilon) + \varepsilon. \end{aligned}$$

Per arbitrarietà di ε, esiste

$$\lim_{n\to\infty} \mathbb{E}\left[\frac{|X_n|}{|X_n|+1}\right] = 0.$$

($\Leftarrow$) Supponiamo che

$$\mathbb{E}\left[\frac{|X_n|}{|X_n|+1}\right] \longrightarrow 0.$$

Osserviamo che

$$\begin{aligned} \frac{|X_n|}{|X_n|+1} &= \frac{|X_n|}{|X_n|+1}\mathbb{1}_{\{|X_n|>\varepsilon\}} + \frac{|X_n|}{|X_n|+1}\mathbb{1}_{\{|X_n|\leq\varepsilon\}} \\ &\geq \frac{|X_n|}{|X_n|+1}\mathbb{1}_{\{|X_n|>\varepsilon\}} \\ &= f(|X_n|)\mathbb{1}_{\{|X_n|>\varepsilon\}}. \end{aligned} \tag{*}$$

Consideriamo la funzione $f(x) = \dfrac{x}{x+1}$, strettamente crescente, infatti

$$f'(x) = \frac{(x+1)-x}{(x+1)^2} = \frac{1}{(x+1)^2} > 0.$$

Quindi, se $|X_n| > \varepsilon$, allora $f(|X_n|) > f(\varepsilon)$. Di conseguenza, da $(*)$,

$$f(|X_n|)\mathbb{1}_{\{|X_n|>\varepsilon\}} \geq \frac{\varepsilon}{\varepsilon+1}\mathbb{1}_{\{|X_n|>\varepsilon\}} \geq 0.$$

Passando al valore atteso,

$$\begin{aligned} 0 &\leq \mathbb{E}\left[\frac{\varepsilon}{\varepsilon+1}\mathbb{1}_{\{|X_n|>\varepsilon\}}\right] \\ &= \frac{\varepsilon}{\varepsilon+1}\mathbb{P}(|X_n| > \varepsilon) \\ &\leq \mathbb{E}\left[\frac{|X_n|}{|X_n|+1}\right] \longrightarrow 0. \end{aligned}$$

Pertanto,

$$\lim_{n\to\infty} \mathbb{P}(|X_n| > \varepsilon) = 0 \implies X_n \xrightarrow{\mathbb{P}} 0.$$

□

Lemma 7.1.6 (Disuguaglianza di Markov)**.** Sia $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$, con $X \geq 0$ quasi ovunque. Allora, per ogni $\varepsilon > 0$,

$$\boxed{\mathbb{P}(X > \varepsilon) \leq \frac{\mathbb{E}[X]}{\varepsilon}}.$$

Dimostrazione. Sia

$$Y = \varepsilon\mathbb{1}_{\{X>\varepsilon\}}.$$

Allora $X \geq Y$ quasi ovunque, dunque

$$\begin{aligned} \mathbb{E}[X] &\geq \mathbb{E}[Y] \\ &= \mathbb{E}\left[\varepsilon\mathbb{1}_{\{X>\varepsilon\}}\right] \\ &= \varepsilon\mathbb{P}(X > \varepsilon). \end{aligned}$$

Pertanto,

$$\mathbb{P}(X > \varepsilon) \leq \frac{\mathbb{E}[X]}{\varepsilon}.$$

□

Teorema 7.1.7. Valgono le seguenti proprietà:

1) Se $X_n \xrightarrow{L^p} X$, con $p \geq 1$, allora
$$X_n \xrightarrow{\mathbb{P}} X.$$

2) Se $X_n \xrightarrow{\text{q.c.}} X$, allora
$$X_n \xrightarrow{\mathbb{P}} X.$$

Dimostrazione. 1) Se $X_n \xrightarrow{L^p} X$, allora, essendo $p \geq 1$,

$$X_n \xrightarrow{L^1} X.$$

Quindi

$$\|X_n - X\|_{L^1} = \mathbb{E}[|X_n - X|] \longrightarrow 0.$$

Dobbiamo provare che, per ogni $\varepsilon > 0$,

$$\mathbb{P}(|X_n - X| > \varepsilon) \longrightarrow 0.$$

Applicando la disuguaglianza di Markov alla variabile aleatoria $Z = |X_n - X|$, osservando che $Z \in L^1$ e $Z \geq 0$ quasi ovunque, otteniamo

$$\mathbb{P}(|X_n - X| > \varepsilon) \leq \frac{\mathbb{E}[|X_n - X|]}{\varepsilon} \longrightarrow 0.$$

2) Sia $X_n \xrightarrow{\text{q.c.}} X$. Allora

$$\underbrace{\frac{|X_n - X|}{|X_n - X| + 1}}_{Y_n} \xrightarrow{\text{q.c.}} 0 = Y.$$

Inoltre,

$$0 \leq Y_n = \frac{|X_n - X|}{|X_n - X| + 1} \leq 1,$$

dove $1 \in L^1(\Omega, \mathcal{F}, \mathbb{P})$.

Per il teorema di convergenza dominata otteniamo

$$\lim_{n\to\infty} \mathbb{E}[Y_n] = \mathbb{E}\left[\lim_{n\to\infty} Y_n\right],$$

ovvero

$$\lim_{n\to\infty} \mathbb{E}\left[\frac{|X_n - X|}{|X_n - X| + 1}\right] = 0.$$

Per il teorema precedente,

$$X_n \xrightarrow{\mathbb{P}} X.$$

□

In generale non valgono i viceversa. Facciamo alcuni controesempi.

Esempio 7.1.8. Sia $\Omega = [0,1]$, $\mathcal{F} = \mathcal{B}([0,1])$ e $\mathbb{P} = m_{[0,1]}$.
Mostriamo che

$$X_n \xrightarrow{\text{q.c.}} X \not\Rightarrow X_n \xrightarrow{L^p} X, \qquad \forall p \geq 1,$$

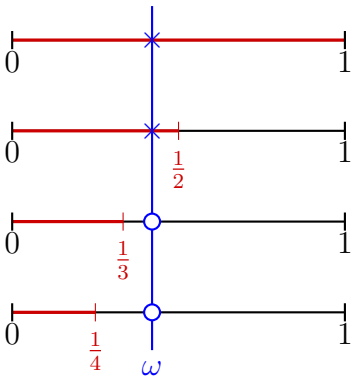
e che

$$X_n \xrightarrow{\mathbb{P}} X \not\Rightarrow X_n \xrightarrow{L^p} X.$$

Sia

$$X_n = 2^n \mathbb{1}_{(0,\frac{1}{n})}, \qquad \forall n \geq 1.$$

Rappresentiamo i primi termini della successione.



$$X_1 = 2\mathbb{1}_{(0,1)}$$
$$X_2 = 4\mathbb{1}_{(0,\frac{1}{2})}$$
$$X_3 = 8\mathbb{1}_{(0,\frac{1}{3})}$$
$$X_4 = 16\mathbb{1}_{(0,\frac{1}{4})}$$

Per ogni $\omega \in \Omega$ esiste $\overline{n}$ tale che, per ogni $n \geq \overline{n}$, si ha $X_n(\omega) = 0$. Pertanto $X_n(\omega) \to 0$, da cui

$$X_n \xrightarrow{\text{q.c.}} 0.$$

Anzi, è convergenza puntuale.
Inoltre, per il teorema precedente,

$$X_n \xrightarrow{\mathbb{P}} 0.$$

Proviamolo direttamente.
Dobbiamo provare che, per ogni $\varepsilon > 0$,

$$\mathbb{P}(|X_n| > \varepsilon) \xrightarrow[n\to\infty]{} 0.$$

Fissiamo $\varepsilon > 0$. Si ha

$$\begin{aligned}
\mathbb{P}(|X_n| > \varepsilon) &= \mathbb{P}\left(2^n \mathbb{1}_{(0,\frac{1}{n})} > \varepsilon\right) \\
&\leq \mathbb{P}(X_n = 2^n) \\
&= \mathbb{P}\left((0, \frac{1}{n})\right) \\
&= m\left((0, \frac{1}{n})\right) = \frac{1}{n} \xrightarrow[n\to\infty]{} 0.
\end{aligned}$$

Infatti, se $\varepsilon > 2^n$, si ha $\mathbb{P}(|X_n| > \varepsilon) = 0$, mentre se $\varepsilon < 2^n$, si ha $\mathbb{P}(|X_n| > \varepsilon) = \mathbb{P}(X_n = 2^n)$.
Infine,

$$X_n \xcancel{\xrightarrow{L^p}} 0, \qquad \forall p \geq 1,$$

ossia X_n non converge in L^p. Infatti,

$$\begin{aligned}
\mathbb{E}[|X_n|^p] &= \mathbb{E}\left[2^{np} \mathbb{1}_{(0,\frac{1}{n})}\right] \\
&= 2^{np} \mathbb{P}\left((0, \frac{1}{n})\right) \\
&= 2^{np} \cdot \frac{1}{n} \xrightarrow[n\to\infty]{} +\infty.
\end{aligned}$$

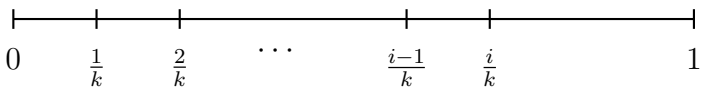
Esempio 7.1.9. Sia $\Omega = [0,1]$, $\mathcal{F} = \mathcal{B}([0,1])$ e $\mathbb{P} = m_{[0,1]}$.
Mostriamo che

$$X_n \xrightarrow{L^p} X \not\Rightarrow X_n \xrightarrow{\text{q.o.}} X,$$

e che

$$X_n \xrightarrow{\mathbb{P}} X \not\Rightarrow X_n \xrightarrow{\text{q.o.}} X.$$

Sia $k \geq 1$ e dividiamo $[0,1]$ in sottointervalli di ampiezza $\frac{1}{k}$.

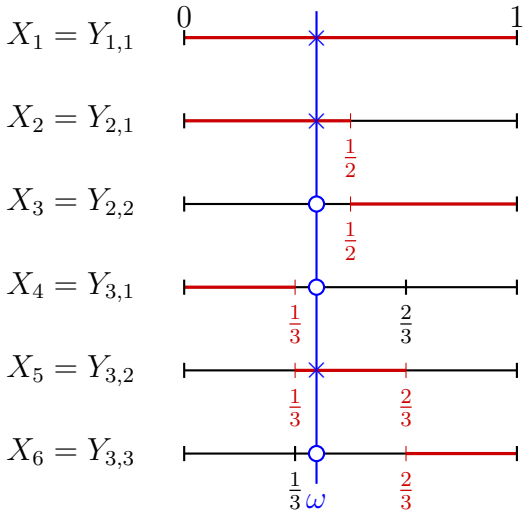


Per ogni $k \geq 1$ e per ogni $i = 1, \ldots, k$, poniamo

$$Y_{i,k} = \mathbb{1}_{(\frac{i-1}{k}, \frac{i}{k})}.$$

Poniamo

$$X_1 = Y_{1,1}, \quad X_2 = Y_{2,1}, \quad X_3 = Y_{2,2},$$
$$X_4 = Y_{3,1}, \quad X_5 = Y_{3,2}, \quad X_6 = Y_{3,3}.$$



Per ogni $n \geq 1$,

$$X_n = \mathbb{1}_{A_n}, \qquad m(A_n) = a_n \xrightarrow[n\to\infty]{} 0.$$

Si ha $X_n \xrightarrow{L^p} 0$. Infatti,

$$\begin{aligned}\mathbb{E}[|X_n|^p] &= \mathbb{E}[\mathbb{1}_{A_n}] \\ &= \mathbb{P}(A_n) \\ &= m(A_n) = a_n \xrightarrow[n\to\infty]{} 0.\end{aligned}$$

Di conseguenza,

$$X_n \xrightarrow{\mathbb{P}} 0.$$

Vediamolo direttamente.
Se $\varepsilon \geq 1$, allora

$$\mathbb{P}(|X_n| > \varepsilon) = 0.$$

Se $0 < \varepsilon < 1$, allora

$$\mathbb{P}(|X_n| > \varepsilon) = \mathbb{P}(X_n = 1) = \mathbb{P}(A_n) \xrightarrow[n\to\infty]{} 0.$$

Tuttavia,

$$X_n \not\xrightarrow{\text{q.c.}} 0,$$

quindi X_n non converge quasi certamente.
Infatti, per quasi ogni $\omega \in \Omega$, per ogni $k \geq 1$ esiste $i \in \{1, \dots, k\}$ tale che $Y_{k,i}(\omega) = 0$ ed esiste $j \in \{1, \dots, k\}$ tale che $Y_{k,j}(\omega) = 1$.
Pertanto,

$$\liminf_{n\to\infty} X_n(\omega) = 0 \neq 1 = \limsup_{n\to\infty} X_n(\omega).$$

Quindi non esiste $\lim_{n\to\infty} X_n(\omega)$, da cui

$$X_n \not\xrightarrow{\text{q.c.}} 0.$$

Valgono però i seguenti risultati più deboli.

Teorema 7.1.10. Se $X_n \xrightarrow{\mathbb{P}} X$, valgono le seguenti proprietà:

1) Se $|X_n| \leq Y$ quasi ovunque, per ogni $n \geq 1$, con $Y \in L^p$, $p \geq 1$, allora

$$X_n \xrightarrow{L^p} X.$$

2) Se $|X_n| \leq M \in \mathbb{R}_+$ quasi ovunque, per ogni $n \geq 1$, allora

$$X_n \xrightarrow{L^p} X \qquad \forall p \geq 1.$$

In questo caso la successione si dice **uniformemente limitata**.

Teorema 7.1.11. Se $X_n \xrightarrow{\mathbb{P}} X$, allora esiste una sottosuccessione (X_{n_k}) tale che

$$X_{n_k} \xrightarrow{\text{q.c.}} X.$$

Teorema 7.1.12 (Teorema di continuità)**.** Valgono le seguenti proprietà:

a) Se $X_n \xrightarrow{\text{q.c.}} X$ e f è continua, allora

$$f(X_n) \xrightarrow{\text{q.c.}} f(X).$$

b) Se $X_n \xrightarrow{\mathbb{P}} X$ e f è continua, allora

$$f(X_n) \xrightarrow{\mathbb{P}} f(X).$$

Osservazione: Come si posiziona la convergenza in L^∞?
Si ha

$$X_n \xrightarrow{L^\infty} X \iff \|X_n - X\|_{L^\infty} \xrightarrow[n\to\infty]{} 0,$$

come per la convergenza in L^p, con $p \geq 1$.

1) **La convergenza in L^∞ implica la convergenza in L^p**, per ogni $p \geq 1$:

$$X_n \xrightarrow{L^\infty} X \implies X_n \xrightarrow{L^p} X \qquad \forall p \geq 1.$$

Infatti, $L^\infty \subseteq L^p$ per ogni $p \geq 1$ e

$$\begin{aligned} \|X_n - X\|_{L^p} &= \mathbb{E}[|X_n - X|^p]^{1/p} \\ &\leq \mathbb{E}\left[\|X_n - X\|_{L^\infty}^p\right]^{1/p} \\ &= \|X_n - X\|_{L^\infty} \xrightarrow[n\to\infty]{} 0. \end{aligned}$$

La disuguaglianza segue dal fatto che, se $X_n, X \in L^\infty$, allora $X_n - X \in L^\infty$ e

$$|X_n - X| \leq \|X_n - X\|_{L^\infty} \qquad \text{q.o.},$$

dove la norma L^∞ è l'estremo superiore essenziale.

2) **La convergenza quasi ovunque non implica la convergenza in L^∞**:

$$X_n \xrightarrow{\text{q.o.}} X \not\Rightarrow X_n \xrightarrow{L^\infty} X.$$

Vale lo stesso controesempio visto prima:

$$X_n = 2^n \mathbb{1}_{(0,\frac{1}{n})}.$$

Si ha $X_n \xrightarrow{\text{q.o.}} 0$, però

$$\|X_n\|_{L^\infty} = 2^n \xrightarrow[n\to\infty]{} +\infty,$$

quindi

$$X_n \not\xrightarrow{L^\infty} 0.$$

Questo è coerente con il fatto che

$$X_n \xrightarrow{\text{q.o.}} X \not\Rightarrow X_n \xrightarrow{L^p} X.$$

3) **La convergenza in L^∞ implica la convergenza quasi ovunque**:

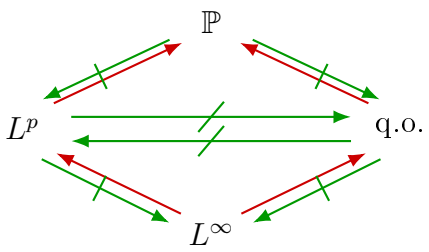
$$X_n \xrightarrow{L^\infty} X \implies X_n \xrightarrow{\text{q.o.}} X.$$

Infatti, $X_n, X \in L^\infty$ implica $X_n - X \in L^\infty$ e quindi, per quasi ogni $\omega \in \Omega$,

$$|X_n(\omega) - X(\omega)| \leq \|X_n - X\|_{L^\infty} \xrightarrow[n\to\infty]{} 0.$$

Pertanto,

$$X_n(\omega) \longrightarrow X(\omega) \implies X_n \xrightarrow{\text{q.o.}} X.$$



7.2 Legge dei grandi numeri

Teorema 7.2.1 (Disuguaglianza di Cebicev (Tchebjtcheff))**.** Sia $X \in L^2(\Omega, \mathcal{F}, \mathbb{P})$. Allora, per ogni $\varepsilon > 0$,

$$\boxed{\mathbb{P}\left(|X - \mathbb{E}[X]| > \varepsilon\right) \leq \frac{\mathrm{Var}(X)}{\varepsilon^2}}.$$

Dimostrazione. Sia $Y = (X - \mathbb{E}[X])^2 \geq 0$, con $Y \in L^1(\Omega, \mathcal{F}, \mathbb{P})$.
Possiamo usare la disuguaglianza di Markov:

$$\begin{aligned}
\mathbb{P}\left(|X - \mathbb{E}[X]| > \varepsilon\right) &= \mathbb{P}\left((X - \mathbb{E}[X])^2 > \varepsilon^2\right) \\
&= \mathbb{P}(Y > \varepsilon^2) \\
&\leq \frac{\mathbb{E}[Y]}{\varepsilon^2} \\
&= \frac{\mathbb{E}[(X - \mathbb{E}[X])^2]}{\varepsilon^2} \\
&= \frac{\mathrm{Var}(X)}{\varepsilon^2}.
\end{aligned}$$

□

Teorema 7.2.2 (Legge debole dei grandi numeri (LDGN))**.** Sia $(X_n)_{n \geq 1}$ una successione di variabili aleatorie indipendenti e identicamente distribuite (i.i.d.), con $X_n \in L^2(\Omega, \mathcal{F}, \mathbb{P})$, media μ e varianza σ^2.
Sia

$$\overline{X}_n = \frac{1}{n} \sum_{i=1}^{n} X_i$$

la **media campionaria**, per ogni $n \geq 1$.
Allora

$$\boxed{\overline{X}_n \xrightarrow{\mathbb{P}} \mu.}$$

Dimostrazione. Osserviamo che $\overline{X}_n \in L^2(\Omega, \mathcal{F}, \mathbb{P})$.
Calcoliamo il valore atteso della media campionaria:

$$\begin{aligned}
\mathbb{E}[\overline{X}_n] &= \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^{n} X_i\right] \\
&= \frac{1}{n} \sum_{i=1}^{n} \underbrace{\mathbb{E}[X_i]}_{\mu} \\
&\overset{\text{i.d.}}{=} \frac{1}{n} \cdot n\mu = \mu.
\end{aligned}$$

Analogamente, per la varianza si ha

$$\begin{aligned}\mathrm{Var}(\overline{X}_n) &= \mathrm{Var}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right)\\ &\overset{\text{indip.}}{=} \frac{1}{n^2}\sum_{i=1}^{n}\underbrace{\mathrm{Var}(X_i)}_{\sigma^2}\\ &\overset{\text{i.d.}}{=} \frac{1}{n^2}\cdot n\sigma^2 = \frac{\sigma^2}{n}.\end{aligned}$$

Per ogni $\varepsilon > 0$, applicando la disuguaglianza di Cebicev, otteniamo

$$\begin{aligned}\mathbb{P}(|\overline{X}_n - \mu| > \varepsilon) &= \mathbb{P}\left(|\overline{X}_n - \mathbb{E}[\overline{X}_n]| > \varepsilon\right)\\ &\leq \frac{\mathrm{Var}(\overline{X}_n)}{\varepsilon^2}\\ &= \frac{\sigma^2}{n\varepsilon^2} \xrightarrow[n\to\infty]{} 0.\end{aligned}$$

Pertanto,

$$\overline{X}_n \xrightarrow{\mathbb{P}} \mu.$$

□

Teorema 7.2.3 (Legge forte dei grandi numeri (LFGN) – Versione standard)**.** Sia $(X_n)_{n\geq 1}$ una successione di variabili aleatorie indipendenti e identicamente distribuite (i.i.d.), con $X_n \in L^2(\Omega, \mathcal{F}, \mathbb{P})$, media μ e varianza σ^2.
Sia

$$\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$$

la **media campionaria**, per ogni $n \geq 1$.
Allora

$$\boxed{\overline{X}_n \xrightarrow{\text{q.c.}} \mu \qquad \text{e} \qquad \overline{X}_n \xrightarrow{L^2} \mu.}$$

Dimostrazione della convergenza in L^2. Si ha

$$\overline{X}_n \xrightarrow{L^2} \mu \iff \begin{cases}\mathbb{E}[\overline{X}_n] \longrightarrow \mu,\\ \mathrm{Var}(X_n) \longrightarrow 0.\end{cases}$$

La tesi è ovvia poiché

$$\mathbb{E}[\overline{X}_n] = \mu \qquad \text{e} \qquad \mathrm{Var}(\overline{X}_n) = \frac{\sigma^2}{n}.$$

□

Teorema 7.2.4 (Legge forte dei grandi numeri di Kolmogorov)**.** Sia $(X_n)_{n\geq 1}$ una successione di variabili aleatorie indipendenti e identicamente distribuite (i.i.d.), con $X_n \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ e media μ.

Sia

$$\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$$

la **media campionaria**, per ogni $n \geq 1$.
Allora

$$\boxed{\overline{X}_n \xrightarrow{\text{q.c.}} \mu \qquad \text{e} \qquad \overline{X}_n \xrightarrow{L^1} \mu.}$$

Osservazione: I due teoremi mi dicono che la media campionaria converge quasi ovuqnue alla medie teorica. Quando nella realtà faccio un esperimento necessariamente sta accadendo un $\omega \in \Omega$ ma non saprò mai quale perché non posso fare infinite rilevazione. I teoremi però mi garantiscono che qualsiasi sia il mio ω si ha che

$$\overline{X}_n(\omega) \to \mu, \quad n \to \infty$$

e quindi continuando a campionare esperimenti aleatori indipendenti e identicamente distribuiti la media campionaria si avvicinerà alla media teorica.
Ad esempio se sto lanciando una moneta e ho ottenuto testa-testa-croce so che il mio evento elementare sta in sta in

$$\{\omega \in \Omega : \text{ i primi due lanci esce testa e al terzo esce croce}\}$$

ma non posso sapere quale di questi sia. So però che qualcunque questo sia la media campionaria tenderà a $1/2$.

7.2.1 Applicazione: Metodo Montecarlo

Sia $f \in L^1([0,1], \mathcal{B}, m)$. Vogliamo "calcolare" l'integrale

$$\int_0^1 f(x)\,dx.$$

Esistono due possibilità per "approssimare" l'integrale:

1) **Metodo deterministico**: approssimazione numerica.

2) **Metodo stocastico (Monte Carlo)**.

Consideriamo una successione di variabili aleatorie $U_n \sim U([0,1])$, i.i.d., e poniamo

$$X_n = f(U_n).$$

Le variabili aleatorie X_n sono i.i.d. e $X_n \in L^1(\Omega, \mathcal{F}, \mathbb{P})$.
Possiamo utilizzare la **legge forte dei grandi numeri di Kolmogorov**:

$$\overline{X}_n \longrightarrow \mu = \mathbb{E}[X_n] \qquad \text{q.c. (e in } L^1).$$

Calcoliamo il valore atteso:

$$\begin{aligned}\mu = \mathbb{E}[X_n] &= \mathbb{E}[f(U_n)] \\ &= \int_{-\infty}^{+\infty} f(x)\,d\mathbb{P}_{U_n}(x) \\ &= \int_{-\infty}^{+\infty} f(x) f_{U_n}(x)\,dx \\ &= \int_0^1 f(x)\,dx,\end{aligned}$$

dove

$$f_{U_n}(x) = \mathbb{1}_{[0,1]}(x).$$

Pertanto,

$$\boxed{\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i = \frac{1}{n}\sum_{i=1}^{n} f(U_i) \xrightarrow{\text{q.o.}} \mu = \int_0^1 f(x)\,dx.}$$

Se voglio approssimare l'integrale, genero una quantità n (grande) di numeri casuali distribuiti uniformemente su $[0,1]$, $x_1, \dots, x_n$. Quindi

$$\boxed{\frac{1}{n}\sum_{i=1}^{n} f(x_i) \simeq \int_0^1 f(x)\,dx.}$$

7.3 Convergenza in legge

Definizione 7.3.1. Sia $(\mu_n)_{n\geq 1}$ una successione di misure finite su $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ e sia μ una misura finita su $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$.
Diciamo che la successione $(\mu_n)_n$ **converge debolmente** a μ, e indichiamo

$$\mu_n \xrightarrow{w} \mu, \qquad \mu_n \rightharpoonup \mu,$$

se, per ogni $f \in C_b(\mathbb{R})$ (funzioni continue e limitate),

$$\boxed{\int_{\mathbb{R}} f\,d\mu_n \xrightarrow[n\to\infty]{} \int_{\mathbb{R}} f\,d\mu.}$$

Definizione 7.3.2. Sia $(X_n)_{n\geq 1}$ una successione di variabili aleatorie tale che, per ogni $n \geq 1$, X_n è definita su $(\Omega_n, \mathcal{F}_n, \mathbb{P}_n)$. Sia X una variabile aleatoria definita su $(\Omega, \mathcal{F}, \mathbb{P})$.
Diciamo che $(X_n)_{n\geq 1}$ **converge in legge (o in distribuzione)** alla variabile aleatoria X se la successione delle leggi $(\mathbb{P}_{X_n})_{n\geq 1}$ converge debolmente alla legge $\mathbb{P}_X$.
Denotiamo con

$$\boxed{X_n \xrightarrow{\mathcal{L}} X \qquad \left(X_n \xrightarrow{d} X\right).}$$

Quindi,

$$\begin{aligned}
X_n \xrightarrow{\mathcal{L}} X &\iff \mathbb{P}_{X_n} \to \mathbb{P}_X \\
&\iff \forall f \in C_b(\mathbb{R}), \quad \int_{\mathbb{R}} f\,d\mathbb{P}_{X_n} \xrightarrow[n\to\infty]{} \int_{\mathbb{R}} f\,d\mathbb{P}_X \\
&\iff \int_{\Omega_n} f(X_n)\,d\mathbb{P}_n \longrightarrow \int_{\Omega} f(X)\,d\mathbb{P} \\
&\iff \mathbb{E}_n[f(X_n)] \longrightarrow \mathbb{E}[f(X)].
\end{aligned}$$

Se X_n e X, per ogni $n \geq 1$, sono definite nello stesso spazio, la convergenza in legge è la più debole.

Teorema 7.3.3. Se X_n e X sono tutte definite sullo stesso spazio, allora

$$\boxed{X_n \xrightarrow{\mathbb{P}} X \implies X_n \xrightarrow{\mathcal{L}} X.}$$

Dimostrazione. Dobbiamo provare che, per ogni $f \in C_b(\mathbb{R})$,

$$\mathbb{E}[f(X_n)] \longrightarrow \mathbb{E}[f(X)].$$

Sappiamo che $X_n \xrightarrow{\mathbb{P}} X$.
Poiché f è continua,

$$f(X_n) \xrightarrow{\mathbb{P}} f(X).$$

Inoltre, f è limitata, quindi

$$|f(X_n)| \leq \|f\|_\infty \implies f(X_n) \xrightarrow{L^p} f(X) \qquad \forall p \geq 1.$$

Pertanto,

$$f(X_n) \xrightarrow{L^1} f(X) \implies \mathbb{E}[f(X_n)] \longrightarrow \mathbb{E}[f(X)].$$

□

Esempio 7.3.4 (Controesempio). Non vale il viceversa. Consideriamo

$$\Omega = \{0,1\}, \qquad \mathcal{F} = \mathcal{P}(\Omega), \qquad \mathbb{P}(\{0\}) = \mathbb{P}(\{1\}) = \frac{1}{2}.$$

Per ogni $n \geq 1$, siano

$$\begin{cases} X_n(0) = 0, \\ X_n(1) = 1, \end{cases} \qquad \text{e} \qquad \begin{cases} X(0) = 1, \\ X(1) = 0. \end{cases}$$

È banale osservare che

$$X_n \xrightarrow{\mathcal{L}} X,$$

perché $X_n, X \sim b\left(\frac{1}{2}\right)$.
Però, se $0 < \varepsilon < 1$,

$$\begin{aligned} \mathbb{P}(|X_n - X| > \varepsilon) &= \mathbb{P}\left(\{\omega \in \Omega : |X_n(\omega) - X(\omega)| > \varepsilon\}\right) \\ &= 1 \not\longrightarrow 0. \end{aligned}$$

Quindi

$$\boxed{X_n \xrightarrow{\mathbb{P}} X.}$$

Proposizione 7.3.5. Se $X_n \xrightarrow{L} X$ con $X = a$ q.o., allora $X_n \xrightarrow{P} X$.

Dimostrazione. Sia

$$f(x) = \frac{|x-a|}{|x-a|+1} \in C_b(\mathbb{R}).$$

Poiché $X_n \xrightarrow{L} X$, si ha

$$\mathbb{E}[f(X_n)] \xrightarrow[n\to\infty]{} \mathbb{E}[f(X)].$$

In particolare,

$$\begin{aligned}\mathbb{E}[f(X_n)] &= \mathbb{E}\left[\frac{|X_n - a|}{|X_n - a| + 1}\right] \\ &= \mathbb{E}\left[\frac{|X_n - X|}{|X_n - X| + 1}\right], \qquad X = a \text{ q.o.}\end{aligned}$$

mentre

$$\begin{aligned}\mathbb{E}[f(X)] &= \mathbb{E}\left[\frac{|X - a|}{|X - a| + 1}\right] \\ &= 0, \qquad X = a \text{ q.o.}\end{aligned}$$

Ovvero,

$$\mathbb{E}\left[\frac{|X_n - X|}{|X_n - X| + 1}\right] \longrightarrow 0 \quad \Longrightarrow \quad X_n \xrightarrow{P} X.$$

□

7.3.1 Criteri di convergenza in legge

Teorema 7.3.6 (Definizione alternativa)**.** Siano $(X_n)_{n\geq 1}$ e X variabili aleatorie, con $(F_{X_n})_{n\geq 1}$ e F_X funzioni di ripartizione. Allora

$$X_n \xrightarrow{L} X \quad \Longleftrightarrow \quad F_{X_n}(x) \xrightarrow[n\to\infty]{} F_X(x)$$

per ogni $x \in \mathbb{R}$ punto di continuità di F_X.

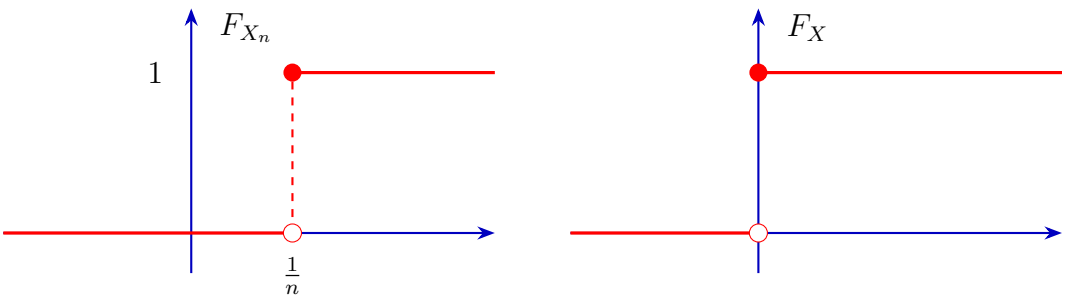
Non ci interessano i punti di discontinuità di F_X.

Esempio 7.3.7. Siano

$$X_n(\omega) = \frac{1}{n} \quad \forall \omega \in \Omega, \qquad X(\omega) = 0 \quad \forall \omega \in \Omega.$$

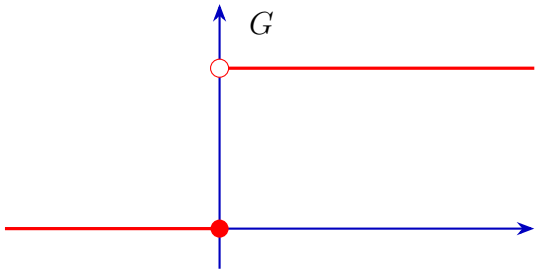
Banalmente, $X_n \to X$ q.o., in L^p, in probabilità e in legge.
Le funzioni di ripartizione sono

$$F_{X_n}(x) = \mathbb{1}_{[\frac{1}{n},+\infty)}(x), \qquad F_X(x) = \mathbb{1}_{[0,+\infty)}(x).$$



Si ha

$$\lim_{n\to\infty} F_{X_n}(x) = G(x) = \mathbb{1}_{(0,+\infty)}(x) \neq F_X(x).$$



Si ha $G(x) = F_X(x)$ tranne per $x = 0$, punto di discontinuità di F_X.

Osservazione: In generale, $X_n \xrightarrow{L} X$, ovvero $\mathbb{P}_{X_n} \longrightarrow \mathbb{P}_X$, non implica che

$$\mathbb{P}_{X_n}(B) \longrightarrow \mathbb{P}_X(B) \qquad \forall B \in \mathcal{B}(\mathbb{R}).$$

Il viceversa è vero. Infatti se

$$\mathbb{P}_{X_n}(B) \longrightarrow \mathbb{P}_X(B) \qquad \forall B \in \mathcal{B}(\mathbb{R}),$$

scelgo $B = (-\infty, x] \in \mathcal{B}(\mathbb{R})$ e ottengo, per ogni $x \in \mathbb{R}$,

$$\underbrace{\mathbb{P}_{X_n}((-\infty, x])}_{F_{X_n}(x)} \longrightarrow \underbrace{\mathbb{P}_X((-\infty, x])}_{F_X(x)}.$$

Quindi

$$X_n \xrightarrow{L} X \qquad (\text{e } \mathbb{P}_{X_n} \longrightarrow \mathbb{P}_X).$$

Teorema 7.3.8. a) Siano $(X_n)_{n\geq 1}$ e X variabili aleatorie discrete a valori in $\mathbb{N}$. Allora

$$X_n \xrightarrow{L} X \iff p_{X_n}(k) = \mathbb{P}(X_n = k) \xrightarrow[n\to\infty]{} \mathbb{P}(X = k) = p_X(k), \qquad \forall k \in \mathbb{N}.$$

b) Siano $(X_n)_{n\geq 1}$ e X variabili aleatorie assolutamente continue. Se

$$f_{X_n}(x) \xrightarrow[n\to\infty]{} f_X(x) \quad \text{q.o.},$$

allora $X_n \xrightarrow{L} X$.

Teorema 7.3.9 (Teorema di Paul Lévy)**.** Siano $(X_n)_{n\geq 1}$ variabili aleatorie con funzioni caratteristiche $(\Phi_{X_n})_{n\geq 1}$.

a) Se $X_n \xrightarrow{L} X$, con X variabile aleatoria avente funzione caratteristica Φ_X, allora

$$\Phi_{X_n}(t) \xrightarrow[n\to\infty]{} \Phi_X(t) \qquad \forall t \in \mathbb{R}.$$

b) Se

$$\Phi_{X_n}(t) \xrightarrow[n\to\infty]{} \varphi(t) \qquad \forall t \in \mathbb{R},$$

con φ continua in 0, allora esiste una variabile aleatoria reale X tale che $\Phi_X = \varphi$ e $X_n \xrightarrow{L} X$.

Osservazione: Se φ non è continua in 0, allora X_n non converge in legge. Infatti, supponendo per assurdo che $X_n \xrightarrow{L} X$, per il punto a) si avrebbe

$$\Phi_{X_n}(t) \longrightarrow \underbrace{\Phi_X(t)}_{\text{continua in } 0} \neq \varphi(t).$$

Assurdo!

7.3.2 Proprietà della convergenza in legge

Teorema 7.3.10 (Teorema di continuità)**.** Se $X_n \xrightarrow{L} X$ e f è continua, allora

$$f(X_n) \xrightarrow{L} f(X).$$

Dimostrazione. Per ogni $g \in C_b(\mathbb{R})$, si ha

$$\begin{aligned}\mathbb{E}[g(f(X_n))] &= \mathbb{E}[(g \circ f)(X_n)] \\ &\xrightarrow[n\to\infty]{} \mathbb{E}[(g \circ f)(X)] \\ &= \mathbb{E}[g(f(X))],\end{aligned}$$

poiché $g \circ f \in C_b(\mathbb{R})$ e $X_n \xrightarrow{L} X$.
Quindi

$$f(X_n) \xrightarrow{L} f(X).$$

□

Osservazione: Per la convergenza quasi ovunque, in L^p e in probabilità si ha

$$\left.\begin{aligned} X_n &\longrightarrow X \quad \text{q.o., } L^p, \mathbb{P}, \\ Y_n &\longrightarrow Y \quad \text{q.o., } L^p, \mathbb{P} \end{aligned}\right\} \Longrightarrow X_n + Y_n \longrightarrow X + Y \quad \text{q.o., } L^p, \mathbb{P}.$$

In generale, questa proprietà non vale per la convergenza in legge.

Esempio 7.3.11. Siano

$$X_n \sim \mathcal{N}(0,1), \qquad X \sim \mathcal{N}(0,1) \quad \Longrightarrow \quad X_n \xrightarrow{L} X,$$

e

$$Y_n \sim \mathcal{N}(0,1), \qquad Y = -X \sim \mathcal{N}(0,1) \quad \Longrightarrow \quad Y_n \xrightarrow{L} Y.$$

Se $X_n \perp Y_n$ per ogni $n \geq 1$, allora

$$X_n + Y_n \sim \mathcal{N}(0,2),$$

mentre $X + Y = 0$. Pertanto

$$X_n + Y_n \xcancel{\xrightarrow{L}} X + Y.$$

Proposizione 7.3.12. La convergenza in legge della somma è garantita nelle seguenti situazioni.

a) Se $X_n \to X$ e $Y_n \to Y$ quasi ovunque, in L^p o in probabilità, allora

$$X_n \xrightarrow{L} X, \qquad Y_n \xrightarrow{L} Y.$$

Inoltre,

$$X_n + Y_n \longrightarrow X + Y \quad \text{q.o., in } L^p \text{ o in } P,$$

e quindi

$$X_n + Y_n \xrightarrow{L} X + Y.$$

b) Se

$$X_n \xrightarrow{L} X, \qquad Y_n \xrightarrow{L} Y,$$

con

$$X_n \perp\!\!\!\perp Y_n \quad \forall n, \qquad X \perp\!\!\!\perp Y,$$

allora

$$X_n + Y_n \xrightarrow{L} X + Y.$$

Dimostrazione. Dimostriamo il punto b). Per l'indipendenza di X_n e Y_n, si ha

$$\Phi_{X_n+Y_n}(t) = \Phi_{X_n}(t) \cdot \Phi_{Y_n}(t).$$

Per il punto a) del teorema di Paul Lévy,

$$\Phi_{X_n}(t) \cdot \Phi_{Y_n}(t) \xrightarrow[n\to\infty]{} \Phi_X(t) \cdot \Phi_Y(t).$$

Poiché $X \perp Y$, si ha

$$\Phi_X(t) \cdot \Phi_Y(t) = \Phi_{X+Y}(t).$$

Quindi

$$\Phi_{X_n+Y_n}(t) \xrightarrow[n\to\infty]{} \Phi_{X+Y}(t).$$

Per il punto b) del teorema di Paul Lévy, segue

$$X_n + Y_n \xrightarrow{L} X + Y.$$

□

Teorema 7.3.13 (Teorema di Slutsky)**.** Se $X_n \xrightarrow{L} X$ e $Y_n \xrightarrow{L} a$ (equivalentemente, $Y_n \xrightarrow{P} a$), allora:

i) $X_n + Y_n \longrightarrow X + a$;

ii) $X_n Y_n \longrightarrow Xa$;

iii) $\dfrac{X_n}{Y_n} \longrightarrow \dfrac{X}{a}$, se ben definiti.

7.4 Teorema del limite centrale

Teorema 7.4.1. Sia $(X_n)_{n\geq 1}$ una successione di variabili aleatorie i.i.d., con $X_n \in L^2(\Omega, \mathcal{F}, \mathbb{P})$. Indichiamo con μ la media e con σ^2 la varianza.
Siano

$$S_n = \sum_{i=1}^{n} X_i \qquad \text{e} \qquad S_n^* = \frac{\sum_{i=1}^{n} X_i - n\mu}{\sqrt{n\sigma^2}}$$

la sua standardizzazione. Allora

$$S_n^* \xrightarrow{L} N \sim \mathcal{N}(0,1).$$

Dimostrazione. Bisogna provare che

$$S_n^* = \frac{\sum_{i=1}^{n} X_i - n\mu}{\sqrt{n\sigma^2}} \xrightarrow{L} N \sim \mathcal{N}(0,1),$$

con X_i i.i.d. e in L^2, tali che $\mathbb{E}[X_i] = \mu$ e $\mathrm{Var}(X_i) = \sigma^2$.
Consideriamo le standardizzazioni delle X_i:

$$Y_i = \frac{X_i - \mu}{\sigma}.$$

Allora

$$S_n^* = \frac{\sum_{i=1}^{n} \left(\dfrac{X_i - \mu}{\sigma}\right)}{\sqrt{n}} = \frac{1}{\sqrt{n}} \sum_{i=1}^{n} Y_i.$$

Le Y_i sono i.i.d. e in L^2, con

$$\mathbb{E}[Y_i] = 0, \qquad \mathrm{Var}(Y_i) = 1.$$

Denotiamo $\Phi = \Phi_{Y_i}$ e calcoliamo $\Phi_{S_n^*}$. Per ogni $t \in \mathbb{R}$,

$$\begin{aligned}
\Phi_{S_n^*}(t) &= \Phi_{\frac{1}{\sqrt{n}}\sum_{i=1}^{n} Y_i}(t) \\
&= \Phi_{\sum_{i=1}^{n} Y_i}\left(\frac{t}{\sqrt{n}}\right) \\
&= \prod_{i=1}^{n} \Phi_{Y_i}\left(\frac{t}{\sqrt{n}}\right) \\
&= \left[\Phi\left(\frac{t}{\sqrt{n}}\right)\right]^n.
\end{aligned}$$

Poiché $Y_1 \in L^2$, si ha $\Phi \in C^2$ e, per ogni $k \leq 2$,

$$\Phi^{(k)}(t) = i^k \mathbb{E}\left[Y_1^k e^{itY_1}\right].$$

In particolare,

$$\Phi^{(k)}(0) = i^k \mathbb{E}[Y_1^k].$$

Quindi

$$\begin{aligned}\Phi(0) &= 1,\\ \Phi'(0) &= i\mathbb{E}[Y_1] = 0,\\ \Phi''(0) &= i^2\mathbb{E}[Y_1^2] = -\operatorname{Var}(Y_1) = -1.\end{aligned}$$

Consideriamo lo sviluppo di Taylor in 0 di Φ fino al secondo ordine:

$$\begin{aligned}\Phi(t) &= \Phi(0) + \Phi'(0)t + \Phi''(0)\frac{t^2}{2} + o(t^2)\\ &= 1 - \frac{t^2}{2} + o(t^2), \qquad t \to 0.\end{aligned}$$

Fissiamo $t \in \mathbb{R}$. Quando $n \to \infty$, si ha $\frac{t}{\sqrt{n}} \to 0$, quindi

$$\Phi\left(\frac{t}{\sqrt{n}}\right) = 1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right), \qquad n \to \infty.$$

Pertanto,

$$\begin{aligned}\lim_{n\to\infty} \Phi_{S_n^*}(t) &= \lim_{n\to\infty} \left[\Phi\left(\frac{t}{\sqrt{n}}\right)\right]^n\\ &= \lim_{n\to\infty} \left(1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right)\right)^n\\ &= \lim_{n\to\infty} \exp\left[n \log\left(1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right)\right)\right]\\ &= \lim_{n\to\infty} \exp\left[n\left(-\frac{t^2}{2n} + o\left(\frac{1}{n}\right)\right)\right]\\ &= e^{-t^2/2} = \Phi_N(t),\end{aligned}$$

con $N \sim \mathcal{N}(0,1)$.
Per il teorema di Paul Lévy, si conclude che

$$S_n^* \xrightarrow{L} N.$$

□

Osservazione:

1) Dal Teorema del Limite Centrale si ha

$$S_n^* \xrightarrow{L} N \sim \mathcal{N}(0,1) \iff F_{S_n^*}(x) \xrightarrow[n\to\infty]{} F_N(x) \qquad \forall x \in \mathbb{R},$$

ovvero

$$\mathbb{P}(S_n^* \le x) \xrightarrow[n\to\infty]{} \mathbb{P}(N \le x) \qquad \forall x \in \mathbb{R}.$$

Cioè, se n è sufficientemente grande,

$$\boxed{\mathbb{P}(S_n^* \le x) \simeq \mathbb{P}(N \le x)}$$

(approssimazione gaussiana).

È importante distinguere la convergenza in legge

$$S_n^* \xrightarrow{L} N \sim \mathcal{N}(0,1)$$

dalle approssimazioni valide per n grande:

$$S_n^* \simeq \mathcal{N}(0,1), \qquad S_n \simeq \mathcal{N}(n\mu, n\sigma^2).$$

Tuttavia, non si ha

$$\boxed{S_n \nrightarrow \mathcal{N}(n\mu, n\sigma^2).}$$

perché i parametri della Gaussiana non sono fissi.

2) Poiché

$$S_n^* \xrightarrow{L} N \sim \mathcal{N}(0,1),$$

per il teorema di continuità si ottiene

$$\sigma S_n^* \xrightarrow{L} \sigma N \sim \mathcal{N}(0, \sigma^2).$$

Supponiamo $\sigma > 0$, dove σ è la deviazione standard. Allora

$$\begin{aligned} \sigma S_n^* &= \sigma \cdot \frac{S_n - n\mu}{\sigma\sqrt{n}} \\ &= \frac{n\left(\frac{1}{n}\sum_{i=1}^n X_i - \mu\right)}{\sqrt{n}} \\ &= \sqrt{n}(\overline{X}_n - \mu), \end{aligned}$$

Pertanto,

$$\boxed{\sqrt{n}(\overline{X}_n - \mu) \xrightarrow{L} \mathcal{N}(0, \sigma^2).}$$

La media campionaria $\overline{X}_n$ è quindi asintoticamente normale. Per n grande si ha l'approssimazione gaussiana

$$\boxed{\overline{X}_n \simeq \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).}$$

Tuttavia, non si ha

$$\boxed{\overline{X}_n \nrightarrow \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).}$$

perché i parametri della Gaussiana non sono costanti.

3) La LGN ci dice che

$$\overline{X}_n \longrightarrow \mu \qquad \text{q.o., in } L^2,\ \mathbb{P},\ L,$$

e quindi

$$|\overline{X}_n - \mu| \longrightarrow 0 \qquad \text{q.o., in } L^2,\ \mathbb{P},\ L,$$

Quanto veloce è questa convergenza? Esiste $\alpha > 0$ tale che

$$n^\alpha(\overline{X}_n - \mu) \longrightarrow Z \neq 0?$$

La risposta è data dal TLC: sì, se parliamo di convergenza in legge, con $\alpha = \frac{1}{2}$. La velocità di convergenza è dell'ordine di

$$\frac{1}{\sqrt{n}}.$$

4) La media campionaria $\overline{X}_n$ oscilla intorno alla media μ, ma le oscillazioni tendono a sparire al crescere di n:

$$\mathrm{Var}(\overline{X}_n) = \frac{\sigma^2}{n} \xrightarrow[n\to\infty]{} 0.$$

Se consideriamo $\sqrt{n}(\overline{X}_n - \mu)$, è come se guardassimo le oscillazioni con una lente di ingrandimento.

Al limite vediamo comunque le oscillazioni microscopiche come se fossero macroscopiche e scopriamo che hanno una distribuzione gaussiana.