# Appunti di Statistica

Carbone Davide [1]

A.A. 2026/2027

[1]Lezioni dei Prof. F. Pellerey e G. Mastrantonio

# Indice


**1 Vettori aleatori gaussiani** **2**

1.1 Ripasso di probabilità e notazioni . . . 2
1.1.1 Funzioni di massa, densità e parametri . . . 2
1.1.2 Normale univariata . . . 2
1.2 Vettori aleatori, valore atteso e covarianza . . . 3
1.2.1 Vettori e matrici aleatorie . . . 3
1.2.2 Prodotti tra matrici e vettori . . . 3
1.2.3 Matrice di varianza e covarianza . . . 3
1.2.4 Momenti di combinazioni lineari . . . 4
1.3 Cambi di variabile e metodo dello jacobiano . . . 5
1.4 Dalla normale standard alla normale multivariata . . . 6
1.4.1 Vettore gaussiano standard . . . 6
1.4.2 Caso generale e trasformazioni affini . . . 6
1.5 Densità e gaussiane degeneri . . . 7
1.5.1 Esercizi svolti . . . 8
1.6 Marginali, indipendenza e condizionamento . . . 9
1.6.1 Distribuzioni marginali . . . 9
1.6.2 Indipendenza tra blocchi . . . 10
1.6.3 Distribuzione condizionata . . . 10

**2 Stime puntuali** **13**

2.1 Introduzione alla statistica inferenziale . . . 13
2.2 Stime e stimatori puntuali . . . 16
2.3 Metodi per trovare stimatori . . . 16
2.3.1 Metodi dei momenti . . . 16
2.3.2 Metodo di massima verosomiglianza . . . 24
2.4 Metodi per valutare l'affidabilità di uno stimatore . . . 34

# Capitolo 1

# Vettori aleatori gaussiani

Questo capitolo rielabora le slide *Normale Multivariata* di Gianluca Mastrantonio (versione 1.1.0). Il testo in rosso contiene passaggi e precisazioni aggiunti rispetto alle slide.

## 1.1 Ripasso di probabilità e notazioni

### 1.1.1 Funzioni di massa, densità e parametri

In statistica si usa spesso la stessa lettera $f$ per la funzione di massa di probabilità (*pmf*) e per la densità (*pdf*). Se $X$ è discreta, $f_X(x)$ indica la probabilità $\mathbb{P}(X = x)$. Se $X$ è assolutamente continua, $f_X(x)$ indica il valore della sua densità nel punto $x$. Se la legge dipende da un parametro $\theta$, si può scrivere $f(x \mid \theta)$, $f(x;\theta)$ oppure $f_\theta(x)$. Quando la variabile o il parametro sono chiari dal contesto, si può usare semplicemente $f(x)$.
Spesso si specifica il supporto a parole e si scrive la formula della densità solo su quel supporto. Per esempio, per $X \sim G(\alpha, \beta)$ con parametro di tasso $\beta$, si ha

$$f_X(x;\alpha,\beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \qquad x > 0.$$

La densità vale zero fuori da $(0, +\infty)$. Se il secondo parametro è invece quello di scala $\theta$, la densità si scrive

$$f_X(x;\alpha,\theta) = \frac{\theta^{-\alpha}}{\Gamma(\alpha)} x^{\alpha-1} e^{-x/\theta}, \qquad x > 0.$$

Le due formule descrivono la stessa legge quando $\theta = 1/\beta$, con $\alpha, \beta, \theta > 0$.
La parametrizzazione va quindi letta insieme alla formula. Convenzioni diverse si incontrano anche per le leggi esponenziale e geometrica.

### 1.1.2 Normale univariata

**Definizione 1.1.1** (Normale standard)**.** Una variabile aleatoria $X \sim \mathcal{N}(0,1)$ ha densità

$$f_X(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right), \qquad x \in \mathbb{R}.$$

La sua media è 0, la sua varianza è 1 e la sua funzione caratteristica è

$$\varphi_X(t) = \exp\left(-\frac{t^2}{2}\right), \qquad t \in \mathbb{R}.$$

Se $Y = \mu + \sigma X$ con $\sigma \neq 0$, allora $Y \sim \mathcal{N}(\mu, \sigma^2)$ e

$$f_Y(y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y-\mu)^2}{2\sigma^2}\right), \qquad y \in \mathbb{R}.$$

Per linearità dell'attesa, $\mathbb{E}[Y] = \mu$, mentre $\operatorname{Var}(Y) = \sigma^2 \operatorname{Var}(X) = \sigma^2$. La funzione caratteristica diventa

$$\varphi_Y(t) = e^{it\mu}\varphi_X(\sigma t) = \exp\left(it\mu - \frac{\sigma^2 t^2}{2}\right).$$

Il segno di $\sigma$ è ininfluente per la legge di $Y$, che dipende da $\sigma$ tramite $\sigma^2$. Se $\sigma = 0$, $Y$ è costante e la legge è degenere. Indicheremo questa legge con $\mathcal{N}(\mu, 0)$.
Le trasformazioni affini preservano la normalità. Infatti, se $Z = a + bY$, allora

$$Z = (a + b\mu) + (b\sigma)X \quad \Longrightarrow \quad Z \sim \mathcal{N}(a + b\mu, b^2\sigma^2).$$

## 1.2 Vettori aleatori, valore atteso e covarianza

### 1.2.1 Vettori e matrici aleatorie

**Definizione 1.2.1.** Un **vettore aleatorio** $X = (X_1, \ldots, X_k)^\mathsf{T}$ è un vettore colonna le cui componenti sono variabili aleatorie. La sua legge è la legge congiunta di $X_1, \ldots, X_k$. Nei casi discreto e assolutamente continuo, la funzione di massa o di densità congiunta si indica con $f_X(x_1, \ldots, x_k)$. Una **matrice aleatoria** $W$ di dimensione $n \times m$ ha per elementi le variabili aleatorie $W_{ij}$.

L'attesa di un vettore o di una matrice si calcola elemento per elemento,

$$[\mathbb{E}[X]]_i = \mathbb{E}[X_i], \qquad [\mathbb{E}[W]]_{ij} = \mathbb{E}[W_{ij}].$$

Per calcolare $\mathbb{E}[X_i]$ basta la distribuzione marginale di $X_i$. L'attesa di una costante è la costante stessa e la linearità vale anche per vettori e matrici. Per esempio, se le dimensioni coincidono, $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$ e $\mathbb{E}[W + V] = \mathbb{E}[W] + \mathbb{E}[V]$.

### 1.2.2 Prodotti tra matrici e vettori

Siano $B \in \mathbb{R}^{q \times k}$ e $C \in \mathbb{R}^{k \times p}$. Indichiamo con $b_i^\mathsf{T}$ la riga $i$ di $B$ e con $c_j$ la colonna $j$ di $C$. La matrice $BC$ ha dimensione $q \times p$ e

$$[BC]_{ij} = b_i^\mathsf{T} c_j.$$

Il numero di colonne del primo fattore deve coincidere con il numero di righe del secondo. In generale il prodotto non è commutativo e la trasposizione inverte l'ordine dei fattori, $(BC)^\mathsf{T} = C^\mathsf{T} B^\mathsf{T}$.
Se $x \in \mathbb{R}^k$, la componente $i$ di $Bx$ è la combinazione lineare $b_i^\mathsf{T} x$. Per $u, x \in \mathbb{R}^k$, il prodotto $u^\mathsf{T} x = x^\mathsf{T} u$ è uno scalare, mentre $xx^\mathsf{T}$ è una matrice $k \times k$ con elemento $ij$ pari a $x_i x_j$.

### 1.2.3 Matrice di varianza e covarianza

Per due componenti con secondo momento finito, la covarianza è

$$\operatorname{Cov}(X_i, X_j) = \mathbb{E}\big[(X_i - \mathbb{E}[X_i])(X_j - \mathbb{E}[X_j])\big] = \mathbb{E}[X_i X_j] - \mathbb{E}[X_i]\mathbb{E}[X_j].$$

Per $i = j$ si ottiene la varianza di $X_i$.

**Definizione 1.2.2** (Matrice di covarianza)**.** La **matrice di varianza e covarianza** di $X$, indicata con $\mathrm{Var}(X)$ o $\mathrm{Cov}(X)$, è la matrice $k \times k$ con elemento $ij$ pari a $\mathrm{Cov}(X_i, X_j)$. Ponendo $\sigma_i^2 = \mathrm{Var}(X_i)$ e $\sigma_{ij} = \mathrm{Cov}(X_i, X_j)$ per $i \neq j$, si scrive

$$\mathrm{Var}(X) = \begin{pmatrix} \sigma_1^2 & \sigma_{12} & \cdots & \sigma_{1k} \\ \sigma_{21} & \sigma_2^2 & \cdots & \sigma_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{k1} & \sigma_{k2} & \cdots & \sigma_k^2 \end{pmatrix}.$$

Se $\mu = \mathbb{E}[X]$, il prodotto $(X-\mu)(X-\mu)^\mathsf{T}$ è una matrice aleatoria il cui elemento $ij$ è $(X_i-\mu_i)(X_j-\mu_j)$. Prendendone l'attesa si ricava la scrittura compatta

$$\mathrm{Var}(X) = \mathbb{E}\big[(X-\mu)(X-\mu)^\mathsf{T}\big] = \mathbb{E}[XX^\mathsf{T}] - \mu\mu^\mathsf{T}.$$

Invertendo l'ordine dei fattori si ottiene invece lo scalare $(X-\mu)^\mathsf{T}(X-\mu)$.

**Definizione 1.2.3** (Covarianza tra due vettori)**.** Siano $X \in \mathbb{R}^k$ e $Y \in \mathbb{R}^p$ vettori aleatori con medie $\mu_X$ e $\mu_Y$. La loro matrice di covarianza è la matrice $k \times p$

$$\mathrm{Cov}(X,Y) = \mathbb{E}\big[(X-\mu_X)(Y-\mu_Y)^\mathsf{T}\big], \qquad [\mathrm{Cov}(X,Y)]_{ij} = \mathrm{Cov}(X_i, Y_j).$$

La matrice $\mathrm{Cov}(X,Y)$ può anche essere rettangolare. Scambiando i vettori si ottiene $\mathrm{Cov}(Y,X) = \mathrm{Cov}(X,Y)^\mathsf{T}$. In particolare, $\mathrm{Var}(X) = \mathrm{Cov}(X,X)$. Se le componenti di $X$ sono indipendenti, le covarianze fuori diagonale sono nulle. In generale la diagonalità di $\mathrm{Var}(X)$ esprime l'incorrelazione a coppie, che è una proprietà più debole dell'indipendenza.

### 1.2.4 Momenti di combinazioni lineari

Sia $X$ un vettore aleatorio con media $\mu$ e matrice di covarianza $\Sigma$. Se $u, v \in \mathbb{R}^k$ sono costanti, allora $\mathbb{E}[u^\mathsf{T}X] = u^\mathsf{T}\mu$. Inoltre, usando il fatto che lo scalare $v^\mathsf{T}(X-\mu)$ coincide con il suo trasposto, otteniamo

$$\begin{aligned} \mathrm{Cov}(u^\mathsf{T}X, v^\mathsf{T}X) &= \mathbb{E}\big[u^\mathsf{T}(X-\mu)(X-\mu)^\mathsf{T}v\big] \\ &= u^\mathsf{T}\mathbb{E}\big[(X-\mu)(X-\mu)^\mathsf{T}\big]v = u^\mathsf{T}\Sigma v. \end{aligned}$$

In particolare, $\mathrm{Var}(u^\mathsf{T}X) = u^\mathsf{T}\Sigma u$.

**Proposizione 1.2.4** (Proprietà della matrice di covarianza)**.** La matrice di covarianza $\Sigma$ di un vettore aleatorio è simmetrica e semidefinita positiva.

*Dimostrazione.* La simmetria segue da $\mathrm{Cov}(X_i, X_j) = \mathrm{Cov}(X_j, X_i)$. Per ogni $u \in \mathbb{R}^k$ si ha $u^\mathsf{T}\Sigma u = \mathrm{Var}(u^\mathsf{T}X) \geq 0$, da cui la semidefinitezza positiva. □

Più combinazioni lineari si possono raccogliere in un vettore $Z = b + BX$, dove $B \in \mathbb{R}^{q \times k}$ e $b \in \mathbb{R}^q$. La componente $Z_i = b_i + [BX]_i$ ha media $b_i + [B\mu]_i$. Se $r_i^\mathsf{T}$ e $r_j^\mathsf{T}$ sono le righe $i$ e $j$ di $B$, allora $\mathrm{Cov}(Z_i, Z_j) = r_i^\mathsf{T}\Sigma r_j = [B\Sigma B^\mathsf{T}]_{ij}$.

**Proposizione 1.2.5** (Momenti di trasformazioni affini)**.** Per $Z = b + BX$ si ha

$$\mathbb{E}[Z] = b + B\mu, \qquad \mathrm{Var}(Z) = B\Sigma B^{\mathsf{T}}.$$

Inoltre, per $C \in \mathbb{R}^{p\times k}$ e $c \in \mathbb{R}^p$,

$$\mathrm{Cov}(b + BX, c + CX) = B\Sigma C^{\mathsf{T}}.$$

L'ultima identità si ricava centrando entrambi i vettori e calcolando

$$\mathbb{E}\big[B(X-\mu)(X-\mu)^{\mathsf{T}}C^{\mathsf{T}}\big] = B\Sigma C^{\mathsf{T}}.$$

## 1.3 Cambi di variabile e metodo dello jacobiano

Sia $X$ una variabile aleatoria assolutamente continua e sia $Y = g(X)$. Supponiamo che $g$ sia biunivoca, con inversa $h = g^{-1}$, e che entrambe siano di classe $C^1$. Allora

$$f_Y(y) = f_X\big(h(y)\big)\left|\frac{dh}{dy}(y)\right|.$$

Per esempio, se $Y = a + bX$ con $b \neq 0$, l'inversa è $h(y) = (y-a)/b$, da cui

$$f_Y(y) = f_X\left(\frac{y-a}{b}\right)\frac{1}{|b|}.$$

**Proposizione 1.3.1** (Metodo dello jacobiano)**.** Sia $X$ un vettore aleatorio di dimensione $k$ con densità $f_X$. Consideriamo $Y = g(X)$, dove $g\colon \mathbb{R}^k \to \mathbb{R}^k$ è biunivoca con inversa $h = g^{-1}$. Supponiamo che $g$ e $h$ siano di classe $C^1$. La matrice jacobiana di $h$ è la matrice $k \times k$ con elementi

$$[J_h(y)]_{ij} = \frac{\partial h_i}{\partial y_j}(y).$$

La densità di $Y$ è

$$f_Y(y) = f_X\big(h(y)\big)\,\big|\det J_h(y)\big|.$$

Per $k = 1$, il determinante coincide con la derivata dell'inversa e si ritrova la formula scalare. Per una trasformazione affine $Y = \mu + AX$, con $A$ quadrata e invertibile, si ha

$$h(y) = A^{-1}(y-\mu), \qquad J_h(y) = A^{-1}.$$

Poiché $\det(A^{-1}) = 1/\det(A)$, segue

$$f_Y(y) = \frac{f_X\big(A^{-1}(y-\mu)\big)}{|\det A|}. \tag{1.1}$$

La formula richiede una trasformazione invertibile tra spazi della stessa dimensione. Una matrice rettangolare può comunque produrre un vettore con densità. Per esempio, la proiezione di un vettore con densità su una parte delle sue coordinate ha la densità marginale corrispondente.

## 1.4 Dalla normale standard alla normale multivariata

### 1.4.1 Vettore gaussiano standard

Siano $X_1, \dots, X_k$ indipendenti e identicamente distribuite come $\mathcal{N}(0,1)$. La densità congiunta di $X = (X_1, \dots, X_k)^\mathsf{T}$ è il prodotto delle densità marginali,

$$f_X(x) = \prod_{i=1}^{k} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x_i^2}{2}\right) = (2\pi)^{-k/2} \exp\left(-\frac{x^\mathsf{T} x}{2}\right).$$

Infatti $x^\mathsf{T} x = \sum_{i=1}^{k} x_i^2$. Ogni componente ha media zero e varianza uno e, per indipendenza, le covarianze fuori diagonale sono nulle. Dunque $\mathbb{E}[X] = 0$ e $\mathrm{Var}(X) = I_k$.

**Definizione 1.4.1** (Normale multivariata standard)**.** Un vettore aleatorio assolutamente continuo $X$ in $\mathbb{R}^k$ si dice **gaussiano standard** se la sua densità è

$$f_X(x) = (2\pi)^{-k/2} \exp\left(-\frac{x^\mathsf{T} x}{2}\right), \qquad x \in \mathbb{R}^k.$$

Si scrive $X \sim \mathcal{N}_k(0, I_k)$, dove $I_k$ è la matrice identità di ordine $k$.

La funzione caratteristica si ottiene ancora per indipendenza,

$$\varphi_X(t) = \mathbb{E}\left[e^{it^\mathsf{T} X}\right] = \prod_{j=1}^{k} \varphi_{X_j}(t_j) = \exp\left(-\frac{t^\mathsf{T} t}{2}\right), \qquad t \in \mathbb{R}^k.$$

### 1.4.2 Caso generale e trasformazioni affini

**Definizione 1.4.2** (Normale multivariata)**.** Siano $X \sim \mathcal{N}_k(0, I_k)$, $\mu \in \mathbb{R}^n$ e $A \in \mathbb{R}^{n \times k}$. Il vettore

$$Y = \mu + AX$$

si dice **gaussiano** e si scrive $Y \sim \mathcal{N}_n(\mu, \Sigma)$, dove $\Sigma = AA^\mathsf{T}$. Quando la dimensione è chiara, si usa anche $\mathcal{N}(\mu, \Sigma)$.

Applicando le formule per i momenti delle trasformazioni affini, si trova

$$\mathbb{E}[Y] = \mu + A\mathbb{E}[X] = \mu, \qquad \mathrm{Var}(Y) = AI_kA^\mathsf{T} = \Sigma.$$

In termini di componenti,

$$Y_i = \mu_i + \sum_{h=1}^{k} a_{ih} X_h, \qquad \mathrm{Var}(Y_i) = \sum_{h=1}^{k} a_{ih}^2, \qquad \mathrm{Cov}(Y_i, Y_j) = \sum_{h=1}^{k} a_{ih} a_{jh}.$$

Poiché $\mathrm{Cov}(X_h, X_\ell) = 0$ per $h \neq \ell$, nel calcolo della covarianza contribuiscono solo i prodotti relativi alla stessa componente di $X$.
Per $t \in \mathbb{R}^n$ vale $t^\mathsf{T} AX = (A^\mathsf{T} t)^\mathsf{T} X$. Poiché $(A^\mathsf{T} t)^\mathsf{T}(A^\mathsf{T} t) = t^\mathsf{T} \Sigma t$, la funzione caratteristica di $Y$ è

$$\varphi_Y(t) = e^{it^\mathsf{T}\mu} \varphi_X(A^\mathsf{T} t) = \exp\left(it^\mathsf{T}\mu - \frac{1}{2} t^\mathsf{T} \Sigma t\right). \tag{1.2}$$

La funzione caratteristica determina la legge. Pertanto matrici $A$ diverse con lo stesso prodotto $AA^\mathsf{T}$ danno la stessa legge gaussiana a parità di $\mu$.

**Teorema 1.4.3** (Chiusura rispetto alle trasformazioni affini)**.** Se $Y \sim \mathcal{N}_n(\mu, \Sigma)$, $B \in \mathbb{R}^{q\times n}$ e $b \in \mathbb{R}^q$, allora

$$b + BY \sim \mathcal{N}_q\big(b + B\mu, B\Sigma B^{\mathsf{T}}\big).$$

*Dimostrazione.* Scrivendo $Y = \mu + AX$ con $X$ gaussiano standard, si ottiene $b + BY = (b + B\mu) + (BA)X$. Si tratta ancora di una trasformazione affine di $X$, con matrice di covarianza $(BA)(BA)^{\mathsf{T}} = B\Sigma B^{\mathsf{T}}$. □

## 1.5 Densità e gaussiane degeneri

**Proposizione 1.5.1** (Radice principale di una matrice di covarianza)**.** Sia $\Sigma$ una matrice simmetrica e semidefinita positiva di ordine $n$. Esiste una matrice $S$, simmetrica e semidefinita positiva, tale che

$$\Sigma = SS^{\mathsf{T}} = S^2.$$

La matrice $S$ si chiama **radice principale** di $\Sigma$. Se $\Sigma$ è invertibile, lo è anche $S$.

*Dimostrazione dell'esistenza.* Per il teorema spettrale, $\Sigma = Q\,\mathrm{diag}(\lambda_1, \dots, \lambda_n)Q^{\mathsf{T}}$, con $Q$ ortogonale e $\lambda_i \geq 0$. Basta porre

$$S = Q\,\mathrm{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_n})Q^{\mathsf{T}}.$$

Allora $S$ è simmetrica e semidefinita positiva e $S^2 = \Sigma$. Se tutti gli autovalori di $\Sigma$ sono positivi, anche quelli di $S$ lo sono. □

**Proposizione 1.5.2** (Densità di un vettore gaussiano)**.** Sia $Y \sim \mathcal{N}_n(\mu, \Sigma)$. Se $\Sigma$ è invertibile, $Y$ è assolutamente continuo e ha densità

$$f_Y(y) = \frac{1}{(2\pi)^{n/2}\sqrt{\det \Sigma}} \exp\left(-\frac{1}{2}(y-\mu)^{\mathsf{T}}\Sigma^{-1}(y-\mu)\right), \qquad y \in \mathbb{R}^n. \tag{1.3}$$

Se $\Sigma$ è singolare, la legge di $Y$ è degenere e non ammette densità su $\mathbb{R}^n$.

*Dimostrazione del caso invertibile.* Sia $S$ la radice principale di $\Sigma$. Per la chiusura rispetto alle trasformazioni affini, $U = S^{-1}(Y - \mu)$ è gaussiano con media zero e matrice di covarianza

$$S^{-1}\Sigma(S^{-1})^{\mathsf{T}} = S^{-1}SS^{\mathsf{T}}(S^{-1})^{\mathsf{T}} = I_n.$$

Dunque $U \sim \mathcal{N}_n(0, I_n)$. Applicando la formula (1.1) a $Y = \mu + SU$ si trova

$$f_Y(y) = \frac{1}{|\det S|}\,(2\pi)^{-n/2} \exp\left(-\frac{(S^{-1}(y-\mu))^{\mathsf{T}}(S^{-1}(y-\mu))}{2}\right).$$

Ora $(S^{-1})^{\mathsf{T}}S^{-1} = (SS^{\mathsf{T}})^{-1} = \Sigma^{-1}$ e $\det \Sigma = (\det S)^2$. Sostituendo queste due identità si ottiene la formula. □

*Dimostrazione del caso singolare.* Se $\Sigma$ è singolare, esiste $u \neq 0$ con $\Sigma u = 0$. La variabile $u^{\mathsf{T}}Y$ ha varianza $u^{\mathsf{T}}\Sigma u = 0$, quindi coincide quasi certamente con la sua media $u^{\mathsf{T}}\mu$. Il vettore $Y$ appartiene perciò con probabilità uno all'iperpiano

$$\big\{y \in \mathbb{R}^n : u^{\mathsf{T}}(y - \mu) = 0\big\}.$$

Questo insieme ha misura di Lebesgue nulla. Una legge con densità gli assegnerebbe probabilità zero. □

**Esempio 1.5.3** (Curve di livello di una normale bivariata). Sia $(X, Y)^\mathsf{T} \sim \mathcal{N}_2(\mu, \Sigma)$ con

$$\mu = \begin{pmatrix} 0 \\ 2 \end{pmatrix}, \qquad \Sigma = \begin{pmatrix} 1 & 0.8 \\ 0.8 & 1.2 \end{pmatrix}.$$

Le curve di livello della densità sono ellissi centrate in $(0, 2)$.

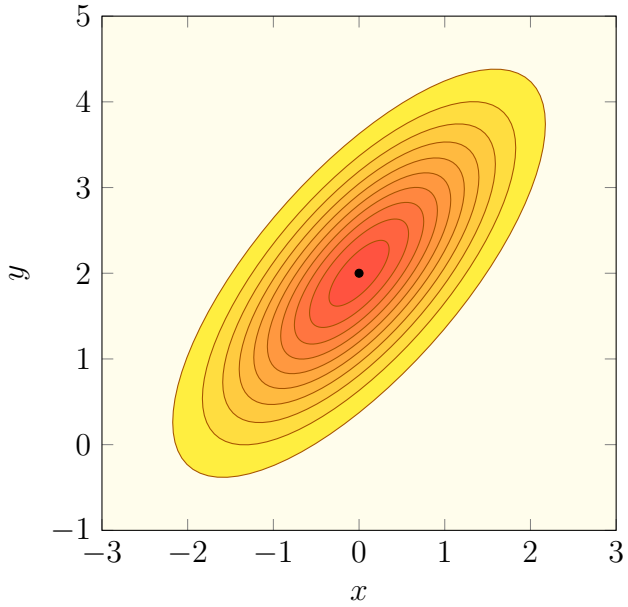



Figura 1.1: Curve di livello della densità bivariata per valori da 0.02 a 0.20, dal contorno più esterno a quello più interno.

### 1.5.1 Esercizi svolti

**Problema 1.5.4** (Legge di una trasformazione lineare).
Sia $X \sim \mathcal{N}_3(0, \Sigma)$ con

$$\Sigma = \begin{pmatrix} 2 & 1 & -1 \\ 1 & 2 & -1 \\ -1 & -1 & 1 \end{pmatrix}.$$

Determinare la legge di $Z = (X_1 - X_2, X_1 + X_3)^\mathsf{T}$.

*Soluzione.* Scriviamo $Z = BX$ con

$$B = \begin{pmatrix} 1 & -1 & 0 \\ 1 & 0 & 1 \end{pmatrix}.$$

Il vettore $Z$ è gaussiano, con media zero e matrice di covarianza

$$B\Sigma B^\mathsf{T} = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}.$$

Si ottiene la stessa matrice calcolando direttamente le due varianze e la covarianza delle componenti di $Z$. □

**Problema 1.5.5** (Esistenza e assoluta continuità)**.**
Si considerino i parametri $\mu = 0$ e

$$\Sigma = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}.$$

Esiste un vettore gaussiano $X \sim \mathcal{N}_2(\mu, \Sigma)$? La sua legge è assolutamente continua?

*Soluzione.* La matrice è simmetrica e $\det \Sigma = 2 \cdot 1 - 1^2 = 1$. Anche il minore principale iniziale di ordine uno, pari a 2, è positivo. Per il criterio di Sylvester, questi due controlli provano che $\Sigma$ è definita positiva. Il vettore gaussiano esiste. Si può costruire come $X = \mu + SU$, dove $S$ è la radice principale di $\Sigma$ e $U \sim \mathcal{N}_2(0, I_2)$. Poiché $\det \Sigma \neq 0$, la legge di $X$ è assolutamente continua. □

**Problema 1.5.6** (Parametri di una densità gaussiana)**.**
Sia $X$ un vettore aleatorio con densità

$$f_X(x) = \frac{1}{2\pi\sqrt{3}} \exp\left(-\frac{x_1^2 + x_1 x_2 + x_2^2}{3}\right), \qquad x \in \mathbb{R}^2.$$

Stabilire se $X$ ha legge gaussiana e, in caso affermativo, determinarne i parametri.

*Soluzione.* Confrontiamo la densità con la formula (1.3). L'esponente contiene solo termini di secondo grado, quindi deve essere $\mu = 0$. Sviluppando la forma quadratica $(x-\mu)^\mathsf{T}\Sigma^{-1}(x-\mu)$, il termine lineare è $-2x^\mathsf{T}\Sigma^{-1}\mu$. Si annulla per ogni $x$ solo se $\Sigma^{-1}\mu = 0$, da cui $\mu = 0$.
Poniamo $M = \Sigma^{-1}$. Poiché $M$ è simmetrica, il coefficiente di $x_1 x_2$ in $x^\mathsf{T} M x$ è $2M_{12}$. Confrontando con $\frac{2}{3}(x_1^2 + x_1 x_2 + x_2^2)$, si trova

$$M = \begin{pmatrix} 2/3 & 1/3 \\ 1/3 & 2/3 \end{pmatrix}, \qquad \Sigma = M^{-1} = \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix}.$$

Si ha $\det M = 1/3$, perciò $\det \Sigma = 3$, come richiesto dal fattore di normalizzazione. I minori principali iniziali di $\Sigma$ sono 2 e 3, entrambi positivi. La densità coincide quindi con quella di $\mathcal{N}_2(0, \Sigma)$. □

**Problema 1.5.7** (Una gaussiana degenere)**.**
Sia $X \sim \mathcal{N}_2(0, I_2)$ e poniamo

$$Y = AX, \qquad A = \begin{pmatrix} 1 & 1 \\ 2 & 2 \end{pmatrix}.$$

Determinare la natura del vettore $Y$.

*Soluzione.* Il vettore $Y$ è gaussiano con media zero e matrice di covarianza

$$AA^\mathsf{T} = \begin{pmatrix} 2 & 4 \\ 4 & 8 \end{pmatrix}.$$

Il determinante è zero, quindi la legge è degenere. Si può vedere direttamente dalle componenti $Y_1 = X_1 + X_2$ e $Y_2 = 2X_1 + 2X_2 = 2Y_1$. Il vettore è concentrato sulla retta $\{y \in \mathbb{R}^2 \colon y_2 = 2y_1\}$. Le due componenti hanno correlazione $4/\sqrt{2 \cdot 8} = 1$. □

## 1.6 Marginali, indipendenza e condizionamento

### 1.6.1 Distribuzioni marginali

La selezione di alcune coordinate è una trasformazione lineare. Pertanto un sottovettore di $X$ è gaussiano e i suoi parametri si ottengono scegliendo le componenti di $\mu$ e le righe e colonne corrispondenti di $\Sigma$.

**Proposizione 1.6.1** (Marginali univariate)**.** Se $X \sim \mathcal{N}_n(\mu, \Sigma)$, per ogni $i = 1, \dots, n$ si ha

$$X_i \sim \mathcal{N}(\mu_i, \sigma_i^2), \qquad \sigma_i^2 = \Sigma_{ii}.$$

*Dimostrazione.* Sia $e_i$ il vettore della base canonica con 1 in posizione $i$. Poiché $X_i = e_i^\mathsf{T} X$, per $s \in \mathbb{R}$ la sua funzione caratteristica si ottiene valutando la formula (1.2) in $se_i$,

$$\varphi_{X_i}(s) = \varphi_X(se_i) = \exp\left(is\mu_i - \frac{1}{2}s^2\sigma_i^2\right).$$

Questa è la funzione caratteristica della normale univariata con i parametri indicati. □

**Osservazione:** La normalità di tutte le marginali univariate, da sola, non garantisce che il vettore sia gaussiano. Per esempio, siano $U \sim \mathcal{N}(0,1)$ e $S$ indipendente da $U$, con $\mathbb{P}(S = 1) = \mathbb{P}(S = -1) = 1/2$. Per simmetria $SU \sim \mathcal{N}(0,1)$, ma la somma $U + SU$ è zero con probabilità $1/2$ e ha varianza positiva. Una normale con varianza positiva assegna probabilità zero a ogni singolo punto. Quindi $U + SU$ non è normale e, per la chiusura rispetto alle trasformazioni lineari, $(U, SU)^\mathsf{T}$ non è gaussiano.

### 1.6.2 Indipendenza tra blocchi

Ripartiamo le componenti di $X \sim \mathcal{N}_n(\mu, \Sigma)$ in due blocchi $X_A \in \mathbb{R}^{n_A}$ e $X_B \in \mathbb{R}^{n_B}$, con $n_A + n_B = n$. Nello stesso ordine scriviamo

$$X = \begin{pmatrix} X_A \\ X_B \end{pmatrix}, \qquad \mu = \begin{pmatrix} \mu_A \\ \mu_B \end{pmatrix}, \qquad \Sigma = \begin{pmatrix} \Sigma_A & \Sigma_{AB} \\ \Sigma_{AB}^\mathsf{T} & \Sigma_B \end{pmatrix}.$$

I blocchi diagonali sono $\Sigma_A = \mathrm{Var}(X_A)$ e $\Sigma_B = \mathrm{Var}(X_B)$, mentre $\Sigma_{AB} = \mathrm{Cov}(X_A, X_B)$.

**Proposizione 1.6.2** (Indipendenza e covarianza nulla)**.** Per un vettore congiuntamente gaussiano, $X_A$ e $X_B$ sono indipendenti se e solo se $\Sigma_{AB} = 0$.

*Dimostrazione.* Se $X_A$ e $X_B$ sono indipendenti, ogni covarianza tra le componenti dei due blocchi è nulla. Viceversa, supponiamo che $\Sigma_{AB} = 0$. Scrivendo $t = (t_A^\mathsf{T}, t_B^\mathsf{T})^\mathsf{T}$, la funzione caratteristica congiunta si fattorizza,

$$\begin{aligned} \varphi_X(t) &= \exp\left(i(t_A^\mathsf{T}\mu_A + t_B^\mathsf{T}\mu_B) - \tfrac{1}{2}(t_A^\mathsf{T}\Sigma_A t_A + t_B^\mathsf{T}\Sigma_B t_B)\right) \\ &= \exp\left(it_A^\mathsf{T}\mu_A - \tfrac{1}{2}t_A^\mathsf{T}\Sigma_A t_A\right)\exp\left(it_B^\mathsf{T}\mu_B - \tfrac{1}{2}t_B^\mathsf{T}\Sigma_B t_B\right) \\ &= \varphi_{X_A}(t_A)\,\varphi_{X_B}(t_B). \end{aligned}$$

La fattorizzazione nella funzione caratteristica delle marginali implica l'indipendenza. □

Il risultato si estende a più blocchi. In particolare, le componenti di un vettore gaussiano sono indipendenti se e solo se la sua matrice di covarianza è diagonale.

### 1.6.3 Distribuzione condizionata

**Proposizione 1.6.3** (Legge di un blocco condizionata all'altro)**.** Con la notazione a blocchi precedente, supponiamo che $\Sigma_B$ sia invertibile. La legge di $X_A$ condizionata a $X_B = x_B$ è

$$X_A \mid X_B = x_B \sim \mathcal{N}_{n_A}\big(\mu_{A|B}(x_B), \Sigma_{A|B}\big),$$

dove

$$\begin{aligned}\mu_{A|B}(x_B) &= \mu_A + \Sigma_{AB}\Sigma_B^{-1}(x_B - \mu_B),\\ \Sigma_{A|B} &= \Sigma_A - \Sigma_{AB}\Sigma_B^{-1}\Sigma_{AB}^{\mathsf{T}}.\end{aligned}$$

*Dimostrazione.* Poniamo $D = -\Sigma_{AB}\Sigma_B^{-1}$ e $Z = X_A + DX_B$. Si ha

$$\operatorname{Cov}(Z, X_B) = \Sigma_{AB} + D\Sigma_B = 0.$$

Il vettore $(Z^{\mathsf{T}}, X_B^{\mathsf{T}})^{\mathsf{T}}$ è congiuntamente gaussiano, essendo una trasformazione lineare di $X$. Per la proposizione precedente, $Z$ e $X_B$ sono indipendenti. Poiché $X_A = Z - DX_B$, la sua legge condizionata a $X_B = x_B$ è quella di $Z - Dx_B$. È dunque gaussiana e la sua media è

$$\mathbb{E}[Z] - Dx_B = \mu_A - D(x_B - \mu_B) = \mu_A + \Sigma_{AB}\Sigma_B^{-1}(x_B - \mu_B).$$

La covarianza condizionata è la covarianza di $Z$, in quanto $Dx_B$ è un termine costante. Sviluppando la covarianza della somma otteniamo

$$\begin{aligned}\operatorname{Var}(Z) &= \Sigma_A + D\Sigma_B D^{\mathsf{T}} + D\Sigma_{AB}^{\mathsf{T}} + \Sigma_{AB}D^{\mathsf{T}}\\ &= \Sigma_A + \Sigma_{AB}\Sigma_B^{-1}\Sigma_{AB}^{\mathsf{T}} - 2\Sigma_{AB}\Sigma_B^{-1}\Sigma_{AB}^{\mathsf{T}}\\ &= \Sigma_A - \Sigma_{AB}\Sigma_B^{-1}\Sigma_{AB}^{\mathsf{T}}.\end{aligned}$$

□

Le formule valgono per qualsiasi partizione delle coordinate, riordinando le componenti in modo da scrivere $X_A$ per primo. Il valore osservato $x_B$ compare nella media condizionata, mentre la covarianza condizionata dipende solo dai blocchi di $\Sigma$.

**Esempio 1.6.4** (Condizionamento di una normale bivariata).
Riprendiamo $(X, Y)^\intercal \sim \mathcal{N}_2(\mu, \Sigma)$, con

$$\mu = \begin{pmatrix} 0 \\ 2 \end{pmatrix}, \qquad \Sigma = \begin{pmatrix} 1 & 0.8 \\ 0.8 & 1.2 \end{pmatrix}.$$

Ponendo $X_A = X$ e $X_B = Y$ si ottiene

$$\mu_{X|Y}(y) = \frac{0.8}{1.2}(y-2) = \frac{2}{3}(y-2), \qquad \sigma^2_{X|Y} = 1 - \frac{0.8^2}{1.2} = \frac{7}{15}.$$

Le curve hanno dunque la stessa forma e si spostano al variare di $y$.

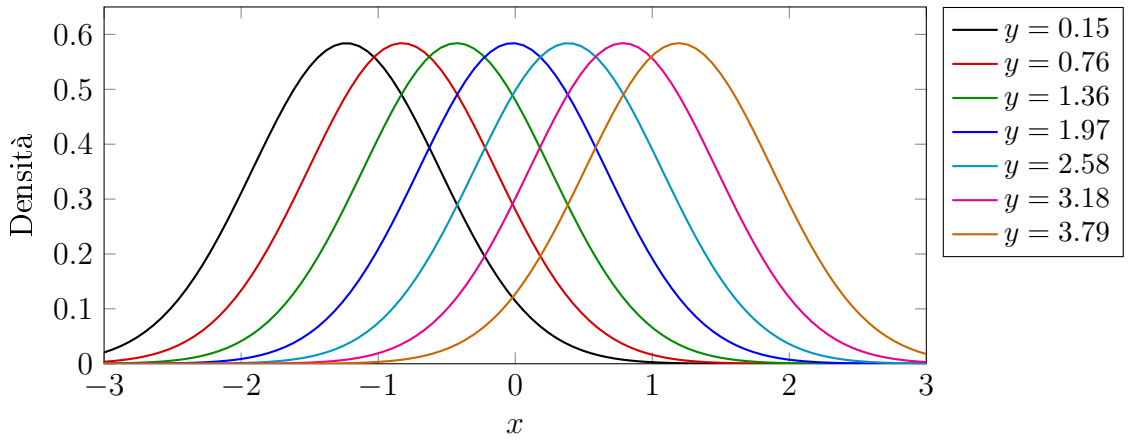



Figura 1.2: Densità di $X \mid Y = y$ per i diversi valori di $y$ mostrati nelle slide.

# Capitolo 2

# Stime puntuali

## 2.1 Introduzione alla statistica inferenziale

In questa parte del corso ci occuperemo di statistica inferenziale e solo marginalmente di statistica descrittiva.

**Definizione 2.1.1** (Statistica descrittiva)**.** La statistica descrittiva studia i criteri di rilevazione, classificazione, sintesi e rappresentazione dei dati raccolti su una popolazione o su un suo sottoinsieme ben specificato.

**Definizione 2.1.2** (Statistica inferenziale)**.** La statistica inferenziale comprende le procedure con cui si deducono le caratteristiche di una popolazione dall'osservazione di una parte di essa, detta **campione**, selezionata solitamente mediante un esperimento casuale.

Per studiare un fenomeno, come la temperatura nella città di Torino o l'efficacia di un nuovo farmaco, generalmente non è possibile osservare tutti i valori della popolazione. Consideriamo quindi un campione e usiamo le osservazioni per stimare la distribuzione della caratteristica di interesse o i suoi parametri. Altri problemi della statistica inferenziale riguardano la verifica di affermazioni sulle caratteristiche della popolazione e l'individuazione di relazioni tra caratteri diversi.
Supponiamo di studiare una caratteristica quantitativa degli individui di una popolazione e indichiamo con $F$ la sua distribuzione. Selezionando a caso un individuo, il valore osservato della caratteristica è una realizzazione di una variabile aleatoria $X$ con distribuzione $F$. La grandezza $X$ può anche essere multivariata, quando interessano congiuntamente più caratteri.

**Definizione 2.1.3** (Campione)**.** Un campione $\mathbf{X} = (X_1, \ldots, X_n)$ rappresenta una parte della popolazione, utilizzata per indagare determinate caratteristiche e attribuirle per estrapolazione alla popolazione di riferimento. Lo spazio dei possibili risultati di un esperimento è detto **spazio campionario**.

Distinguiamo tra campionamento da popolazioni finite e infinite. Una popolazione può anche essere soltanto potenzialmente infinita, come nel caso del numero di beni prodotti da un'azienda. Faremo questa distinzione quando sarà necessario.

**Definizione 2.1.4** (Campione casuale (o campione i.i.d.))**.** Sia $F_X$ una legge di probabilità. Un vettore $\mathbf{X} = (X_1, \ldots, X_n)$ si chiama **campione casuale** da $F_X$ di dimensione $n$ se le sue componenti sono indipendenti e provengono tutte da $F_X$.

A meno che non sia specificato diversamente, assumeremo sempre che i campioni siano i.i.d. Le componenti di $\mathbf{X}$ possono essere scalari o vettoriali, anche se in genere le indicheremo senza grassetto. La densità congiunta è

$$f_{\mathbf{X}}(\mathbf{x}) = \prod_{i=1}^{n} f_X(x_i).$$

La distribuzione $F_X$ o i suoi parametri sono generalmente sconosciuti. Possiamo assumere che $F_X$ appartenga a una famiglia nota e usare il campione per ricavare informazioni sui parametri. Per esempio, se $F_X$ è una $\mathcal{N}(\mu, \sigma^2)$, potremmo voler stimare $\mu$ e $\sigma^2$.

**Esempio 2.1.5.** Un macchinario per la produzione di pezzi elettronici ha una probabilità $p$, generalmente sconosciuta, di produrre un oggetto difettoso. Per il controllo di qualità raccogliamo $n$ pezzi e registriamo se ciascuno è difettoso ($X_i = 1$) oppure no ($X_i = 0$). Il vettore $(X_1, \ldots, X_n)$ è un campione da una Bern($p$).

**Esempio 2.1.6.** Per studiare il numero di figli delle famiglie italiane prendiamo $n$ famiglie scelte a caso e registriamo il numero di figli. Se assumiamo che questo numero si distribuisca come una Poisson con lo stesso parametro per ogni famiglia, otteniamo un campione casuale da una Poisson.

La distribuzione di Poisson nell'esempio è un'assunzione. La distribuzione effettiva potrebbe essere diversa e il parametro potrebbe dipendere dall'entrata mensile della famiglia, dallo stato sociale, dall'età o da altre caratteristiche. Durante il corso vedremo alcune tecniche per scegliere e verificare le assunzioni distributive, che in generale considereremo corrette.

**Definizione 2.1.7** (Statistica e distribuzione campionaria)**.** Una **statistica** è una funzione $T(X_1, X_2, \ldots, X_n)$ del campione $(X_1, \ldots, X_n)$. La sua distribuzione si chiama **distribuzione campionaria**.

**Osservazione:** Essendo funzioni di quantità aleatorie, le statistiche campionarie sono a loro volta grandezze casuali e hanno una propria distribuzione, media, varianza, ecc. Possono anche assumere valori vettoriali o matriciali.

Tra le statistiche più note troviamo:

- La **media campionaria**
$$\overline{X} = \sum_{i=1}^{n} \frac{X_i}{n}.$$
- La **varianza campionaria**
$$S^2 = \sum_{i=1}^{n} \frac{(X_i - \overline{X})^2}{n-1}.$$
Chiariremo il motivo per cui utilizziamo $n-1$ invece di $n$ introducendo la **distorsione**.

- La coppia $(\overline{X}, S^2)$, che è una statistica vettoriale.
- Il **range campionario**

$$R_n = \max(X_1, \dots, X_n) - \min(X_1, \dots, X_n).$$

- Il **vettore campionario ordinato**

$$(X_{(1)}, X_{(2)}, \dots, X_{(n)}) = \text{sort}(X_1, X_2, \dots, X_n),$$

  le cui componenti sono ordinate dal più piccolo al più grande:

$$X_{(1)} \leq X_{(2)} \leq \cdots \leq X_{(n)}.$$

- Il **conteggio dei valori minori o uguali a** $x$

$$C(x) = \sum_{i=1}^{n} I(X_i \leq x),$$

  dove $I(\cdot)$ vale 1 se l'argomento è vero e 0 altrimenti.

Definiamo la **funzione di ripartizione empirica** come la proporzione di osservazioni minori o uguali a $x$:

$$\boxed{\widehat{F}(x) = \frac{\displaystyle\sum_{i=1}^{n} I(X_i \leq x)}{n} = \frac{C(x)}{n}}$$

Essa approssima la funzione di ripartizione della popolazione. Infatti, se supponiamo che il campione $(X_1, \dots, X_n)$ sia i.i.d. con funzione di ripartizione $F$, per ogni $x \in \mathbb{R}$ definiamo

$$I_i^x := I(X_i \leq x) = \mathbb{1}_{\{X_i \leq x\}} = \begin{cases} 1 & \text{se } X_i(\omega) \leq x, \\ 0 & \text{se } X_i(\omega) > x. \end{cases}$$

Notiamo che, detto $p_x = \mathbb{P}(X_i \leq x)$, otteniamo $I_i^x \sim \text{Ber}(p_x)$.
Allora, per la LGN,

$$\widehat{F}_n(x) = \frac{\displaystyle\sum_{i=1}^{n} I_i^x}{n} \xrightarrow[n \to +\infty]{P} \mathbb{E}[I_i^x] = p_x = F(x).$$

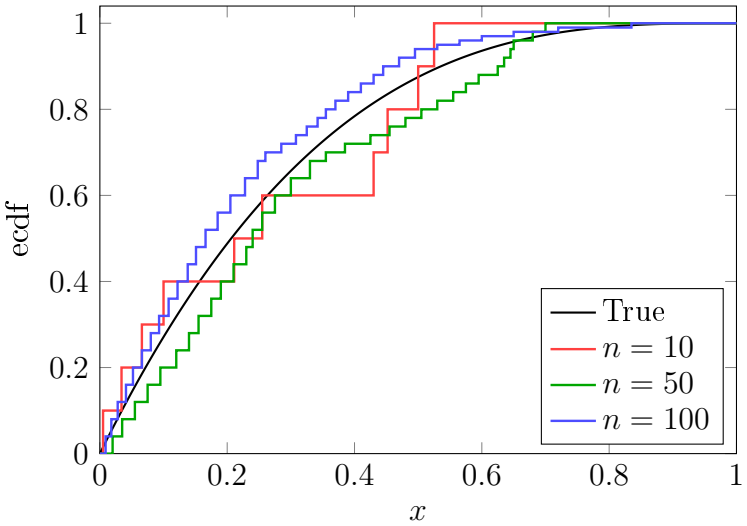



Figura 2.1: Alcuni esempi di funzioni di ripartizione empirica di una B(1, 3).

## 2.2 Stime e stimatori puntuali

Sia $X$ una variabile casuale la cui distribuzione $F(\cdot \mid \theta)$, dipendente da un parametro o vettore di parametri $\theta$, rappresenta la distribuzione di un dato carattere di una popolazione, e sia $\mathbf{X} = (X_1, \ldots, X_n)$ un campione casuale estratto da $X$.

**Definizione 2.2.1** (Stimatore puntuale (o stimatore) per un parametro $\theta$)**.** Chiamiamo **stimatore puntuale** una funzione $W(X_1, \ldots, X_n)$ del campione, utilizzata per stimare un parametro $\theta$ della distribuzione di $X$.

Uno stimatore è quindi una statistica utilizzata per fare stime, o inferenze, su $\theta$.

**Definizione 2.2.2** (Stima)**.** Una **stima** è il valore assunto dallo stimatore quando un campione è stato raccolto.

**Osservazione:** La media campionaria

$$W(X_1, \ldots, X_n) = \sum_{i=1}^{n} \frac{X_i}{n}$$

è uno stimatore, mentre

$$W(x_1, \ldots, x_n) = \sum_{i=1}^{n} \frac{x_i}{n}$$

è la stima.

Per effettuare inferenze su un parametro, dobbiamo individuare stimatori dotati di proprietà adeguate.

**Esempio 2.2.3.** Se i dati provengono da una distribuzione normale e vogliamo stimarne la media, possiamo considerare la media campionaria come candidato. Il minimo campionario, invece, potrebbe non essere altrettanto adeguato.

Per alcuni parametri disponiamo di candidati naturali. In altri casi, come per i parametri della distribuzione gamma, individuarli è meno immediato.
Ci occuperemo di due aspetti:

- **Metodi per trovare stimatori**: metodo dei momenti e di massima verosimiglianza;
- **Metodi per valutare la bontà di uno stimatore**.

## 2.3 Metodi per trovare stimatori

### 2.3.1 Metodi dei momenti

Il **metodo dei momenti** è uno dei primi metodi proposti per costruire stimatori. È ancora largamente utilizzato perché richiede soltanto la conoscenza dei momenti, sebbene altri metodi possano fornire stimatori migliori.

Ricordiamo che, per la legge dei grandi numeri, per variabili aleatorie i.i.d. con media $\mu$ e varianza finita, otteniamo

$$\frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{\mathbb{P}} \mu = \int x\, dF(x).$$

Simili risultati valgono anche per momenti di ordine maggiore. In generale, il momento di ordine $j$ è

$$\mu_j = \int x^j\, dF(x).$$

e possiamo dimostrare che $\frac{1}{n}\sum_{i=1}^{n} X_i^j \xrightarrow{\mathbb{P}} \mathbb{E}[X^j] = \mu_j$;
Infatti, se definiamo $Y = X^j$, il primo momento di $Y$ corrisponde al $j$-esimo momento di $X$, assumendo che la varianza di $Y$ sia finita.
Sia $\theta = (\theta_1, \dots, \theta_p)$. Poiché i momenti dipendono dai parametri, equipariamo il **momento campionario $j$-esimo** (anche detto **momento empirico**)

$$M_j = \frac{1}{n}\sum_{i=1}^{n} X_i^j$$

al momento $j$-esimo $\mu_j$ e costruiamo un sistema per stimare i $p$ parametri. Utilizziamo $p$ equazioni che dipendono dai parametri:

$$\begin{cases} \frac{1}{n}\sum_{i=1}^{n} X_i^1 = \mu_1, \\ \frac{1}{n}\sum_{i=1}^{n} X_i^2 = \mu_2, \\ \qquad\vdots \\ \frac{1}{n}\sum_{i=1}^{n} X_i^p = \mu_p. \end{cases}$$

I momenti campionari sono funzioni di $(X_1, \dots, X_n)$, mentre i momenti teorici sono funzioni di $\theta = (\theta_1, \dots, \theta_p)$.
Generalmente consideriamo i primi $p$ momenti, se dipendono da tutti i parametri, e risolviamo il sistema rispetto a questi ultimi. Le soluzioni ottenute sono gli **stimatori**.

**Esempio 2.3.1** (Normale). Supponiamo di avere un campione i.i.d. di dimensione $n$ da una normale $\mathcal{N}(\mu, \sigma^2)$. Usiamo il metodo dei momenti per determinare stimatori di $\mu$ e $\sigma^2$.
Sia $(X_1, \dots, X_n)$ il campione, con $X \sim \mathcal{N}(\mu, \sigma^2)$.
I momenti teorici sono

$$\begin{aligned} \mu_1 &= \mu, \\ \mu_2 &= \mathbb{E}[X^2] = \mathrm{Var}(X) + \mathbb{E}[X]^2 = \sigma^2 + \mu^2. \end{aligned}$$

I momenti campionari sono

$$M_1 = \frac{\sum_{i=1}^{n} X_i}{n}, \qquad M_2 = \frac{\sum_{i=1}^{n} X_i^2}{n}.$$

Equiparando i momenti campionari ai momenti teorici, otteniamo il sistema

$$\begin{cases} M_1 = \mu_1, \\ M_2 = \mu_2, \end{cases} \qquad \Longrightarrow \qquad \begin{cases} M_1 = \mu, \\ M_2 = \sigma^2 + \mu^2. \end{cases}$$

Risolvendo rispetto ai parametri:

$$\mu = M_1, \qquad \sigma^2 = M_2 - M_1^2.$$

Otteniamo quindi gli stimatori

$$\boxed{\widehat{\mu} = \frac{1}{n}\sum_{i=1}^{n} X_i}$$

e

$$\boxed{\widehat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n} X_i^2 - \left(\frac{1}{n}\sum_{i=1}^{n} X_i\right)^2}.$$

In particolare, $\widehat{\mu}$ è lo stimatore di $\mu$, mentre $\widehat{\sigma}^2$ è lo stimatore di $\sigma^2$.
Quest'ultimo coincide con la **varianza campionaria**

$$S_n^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X}_n)^2.$$

Infatti,

$$\begin{aligned} S_n^2 &= \frac{1}{n}\left[\sum_{i=1}^{n}\left(X_i^2 - 2X_i\overline{X} + \overline{X}^2\right)\right] \\ &= \frac{1}{n}\left[\sum_{i=1}^{n} X_i^2 - 2\overline{X}\sum_{i=1}^{n} X_i + n\overline{X}^2\right] \\ &= \frac{\sum_{i=1}^{n} X_i^2}{n} - 2\overline{X}\cdot\overline{X} + \frac{n}{n}\overline{X}^2 \\ &= \frac{\sum_{i=1}^{n} X_i^2}{n} - \overline{X}^2 \\ &= M_2 - (M_1)^2. \end{aligned}$$

Una formula alternativa per la varianza campionaria è

$$\boxed{S_n^2 = \frac{1}{2n^2}\sum_{j=1}^{n}\sum_{i=1}^{n}(X_i - X_j)^2.}$$

**Osservazione:** Notiamo che non utilizziamo l'ipotesi di normalità nel calcolo dei due stimatori di $\mu$ e $\sigma^2$ visti nel primo esempio. Per questa ragione, in generale, questi due stimatori (o la loro correzione che vedremo più avanti) vengono comunemente utilizzati per stimare media e varianza di una popolazione la cui distribuzione è sconosciuta.

**Esempio 2.3.2** (Esponenziale). Supponiamo di avere un campione i.i.d. di dimensione $n$ da una $\text{Exp}(\lambda)$, con $\mathbb{E}[X] = 1/\lambda$. Usiamo il metodo dei momenti per determinare lo stimatore di $\lambda$.
Equiparando il primo momento campionario al primo momento teorico, otteniamo

$$M_1 = \mu_1 \quad \Longrightarrow \quad \frac{\sum X_i}{n} = \frac{1}{\lambda}.$$

Risolvendo rispetto al parametro $\lambda$, otteniamo

$$\boxed{\widehat{\lambda} = \frac{1}{\frac{\sum X_i}{n}} = \frac{1}{\overline{X}_n}.}$$

**Esempio 2.3.3** (Gamma). Supponiamo di avere un campione i.i.d. di dimensione $n$ da una Gamma $G(a, b)$, con

$$\mathbb{E}[X] = \frac{a}{b}, \qquad \text{Var}(X) = \frac{a}{b^2}.$$

Usiamo il metodo dei momenti per determinare stimatori di $a$ e $b$.
Equiparando i primi due momenti campionari ai corrispondenti momenti teorici, otteniamo

$$\begin{cases} M_1 = \dfrac{\sum_{i=1}^n X_i}{n} = \mu_1, \\ M_2 = \dfrac{\sum_{i=1}^n X_i^2}{n} = \mu_2. \end{cases}$$

Poiché

$$\mu_2 = \mathbb{E}[X^2] = \text{Var}(X) + \mathbb{E}[X]^2,$$

otteniamo

$$\begin{cases} \dfrac{\sum_{i=1}^n X_i}{n} = \dfrac{a}{b}, \\ \dfrac{\sum_{i=1}^n X_i^2}{n} = \dfrac{a}{b^2} + \left(\dfrac{a}{b}\right)^2. \end{cases}$$

Consideriamo quindi il sistema

$$\begin{cases} \dfrac{\sum_{i=1}^n X_i}{n} = \dfrac{a}{b}, \\ \dfrac{\sum_{i=1}^n X_i^2}{n} = \dfrac{a}{b^2} - \left(\dfrac{a}{b}\right)^2. \end{cases}$$

Risolvendo rispetto ai parametri, otteniamo gli stimatori

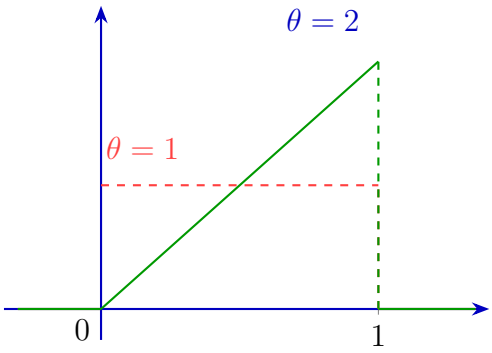
$$\boxed{\widehat{a} = \frac{M_1^2}{M_2 - M_1^2}, \qquad \widehat{b} = \frac{M_1}{M_2 - M_1^2}.}$$

**Esempio 2.3.4** (Power distribution). Supponiamo di avere un campione i.i.d. di dimensione $n$ da una variabile aleatoria $X$ con densità

$$f(x \mid \theta) = \begin{cases} \theta x^{\theta-1}, & \text{se } x \in [0,1], \\ 0, & \text{altrimenti,} \end{cases}$$

con $\theta \geq 1$. Usiamo il metodo dei momenti per stimare $\theta$.
Verifichiamo che

$$\int_0^1 f(x \mid \theta)\, dx = \left[x^\theta\right]_0^1 = 1.$$




Calcoliamo il primo momento teorico:

$$\begin{aligned} \mu_1 = \mu &= \int_0^1 x f(x \mid \theta)\, dx \\ &= \int_0^1 x\theta x^{\theta-1}\, dx \\ &= \left[\frac{x^{\theta+1}}{\theta+1} \cdot \theta\right]_0^1 \\ &= \frac{\theta}{\theta+1}. \end{aligned}$$

Equiparando il primo momento teorico al primo momento campionario,

$$\mu_1 = M_1, \qquad M_1 = \frac{\sum_{i=1}^n X_i}{n},$$

otteniamo

$$\frac{\theta}{\theta+1} = \frac{\sum_{i=1}^n X_i}{n}.$$

Risolvendo rispetto a $\theta$, otteniamo lo stimatore

$$\boxed{\widehat{\theta} = \frac{M_1}{1 - M_1}.}$$

Il metodo dei momenti non impone vincoli sui valori che può assumere lo stimatore. Esaminiamo questa proprietà nel seguente esempio.

**Esempio 2.3.5** (Binomiale). Supponiamo di avere un campione i.i.d. di dimensione $n$ da una $\text{Bin}(k, p)$. Usiamo il metodo dei momenti per determinare stimatori di $k$ e $p$.
I primi due momenti teorici sono

$$\begin{aligned}\mu_1 &= k \cdot p,\\ \mu_2 &= \sigma^2 + (\mu_1)^2 = kp(1-p) + (kp)^2.\end{aligned}$$

Equiparando i momenti campionari ai momenti teorici, otteniamo

$$\begin{cases} M_1 = \mu_1, \\ M_2 = \mu_2, \end{cases} \qquad \Longrightarrow \qquad \begin{cases} \dfrac{\sum_{i=1}^n X_i}{n} = k \cdot p, \\ \dfrac{\sum_{i=1}^n X_i^2}{n} = kp(1-p) + (kp)^2. \end{cases}$$

Risolvendo il sistema rispetto ai parametri, otteniamo gli stimatori

$$\boxed{\widehat{p} = \frac{\sum_{i=1}^n X_i}{n} \cdot \frac{1}{\widehat{k}}}$$

e

$$\boxed{\widehat{k} = \frac{M_1^2}{M_1 + M_1^2 - M_2}.}$$

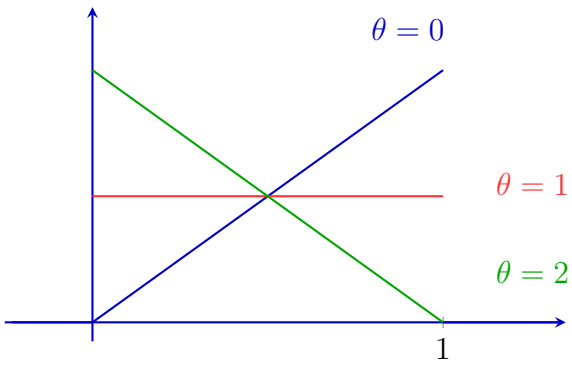
Osserviamo che $\widehat{k}$ difficilmente appartiene a $\mathbb{N}^+$.

**Osservazione:** Nell'esempio precedente non abbiamo alcuna garanzia che $\widehat{k}$ sia intero. Il metodo dei momenti può quindi risultare inappropriato. In altri casi, la stima può assumere un valore esterno all'insieme dei valori ammissibili del parametro.

**Esempio 2.3.6.** Supponiamo di avere un campione i.i.d. di dimensione $n$ da una variabile aleatoria $X$ con densità

$$f(x \mid \theta) = \begin{cases} \theta + 2(1-\theta)x, & \text{se } x \in [0,1], \\ 0, & \text{altrimenti}, \end{cases}$$

con $\theta \in [0, 2]$. Calcoliamo la stima di $\theta$ quando il campione $\mathbf{X}$ assume il valore $\mathbf{x} = (0.8, 0.9, 0.6, 0.5)$.



Stimiamo $\theta$ supponendo di osservare il campione. Calcoliamo il primo momento teorico:

$$\begin{aligned}\mu_1 &= \int_0^1 x\big(\theta + 2(1-\theta)x\big)\,dx \\ &= \int_0^1 \left[\theta x + 2(1-\theta)x^2\right]\,dx \\ &= \left[\frac{\theta x^2}{2} + \frac{2}{3}(1-\theta)x^3\right]_0^1 \\ &= \frac{\theta}{2} + \frac{2}{3}(1-\theta).\end{aligned}$$

Equiparando il primo momento campionario al primo momento teorico, otteniamo

$$M_1 = \mu_1 \quad \Longrightarrow \quad \frac{\sum_{i=1}^n X_i}{n} = \frac{\theta}{2} + \frac{2}{3}(1-\theta).$$

Risolvendo rispetto a $\theta$, otteniamo lo stimatore

$$\boxed{\widehat{\theta} = 4 - 6\frac{\sum_{i=1}^n X_i}{n}.}$$

Per il campione osservato $(0.8, 0.9, 0.6, 0.5)$ otteniamo

$$\overline{X}_4 = 0.7.$$

Pertanto, la stima è

$$\widehat{\theta} = 4 - 4.2 = -0.2,$$

che è un valore non assumibile dal parametro $\theta$.

### Varianza campionaria corretta

Abbiamo visto che un candidato naturale per stimare la varianza è

$$S^2 = \frac{\sum_{i=1}^n (X_i - \overline{X})^2}{n},$$

comunemente noto come **varianza campionaria**. Calcoliamo ora il valore atteso della varianza campionaria:

$$\mathbb{E}[S^2] = \mathbb{E}\left[\frac{\sum_{i=1}^n (X_i - \overline{X})^2}{n}\right].$$

Poniamo $Y_i = X_i - \overline{X}$, dove

$$\overline{X} = \frac{1}{n}\sum_{j=1}^n X_j, \qquad \mathbb{E}[X_i] = \mu, \qquad \mathrm{Var}(X_i) = \sigma^2.$$

Poiché $\mathbb{E}[\overline{X}] = \mu$, otteniamo

$$\mathbb{E}[Y_i] = \mathbb{E}[X_i] - \mathbb{E}[\overline{X}] = \mu - \mu = 0.$$

Pertanto,

$$\begin{aligned}\mathrm{Var}(Y_i) &= \mathbb{E}[Y_i^2] - \mathbb{E}[Y_i]^2 \\ &= \mathbb{E}[(X_i - \overline{X})^2] \\ &= \mathbb{E}[X_i^2 - 2X_i\overline{X} + \overline{X}^2] \\ &= \mathbb{E}[X_i^2] - 2\mathbb{E}[X_i\overline{X}] + \mathbb{E}[\overline{X}^2].\end{aligned}$$

Calcoliamo il termine misto $\mathbb{E}[X_i\overline{X}]$:

$$\begin{aligned}\mathbb{E}[X_i\overline{X}] &= \mathbb{E}\left[X_i\frac{1}{n}\sum_{j=1}^{n}X_j\right] \\ &= \frac{1}{n}\sum_{j=1}^{n}\mathbb{E}[X_iX_j] \\ &= \frac{1}{n}\left(\mathbb{E}[X_i^2] + \sum_{\substack{j=1\\j\neq i}}^{n}\mathbb{E}[X_iX_j]\right) \\ &= \frac{1}{n}\left(\mathbb{E}[X_i^2] + \sum_{\substack{j=1\\j\neq i}}^{n}\mathbb{E}[X_i]\mathbb{E}[X_j]\right) \\ &= \frac{1}{n}\left(\mathbb{E}[X_i^2] + (n-1)\mu^2\right) \\ &= \frac{1}{n}\left(\sigma^2 + \mu^2 + (n-1)\mu^2\right) \\ &= \frac{\sigma^2}{n} + \mu^2.\end{aligned}$$

D'altra parte, per l'indipendenza delle $X_i$,

$$\begin{aligned}\mathbb{E}[\overline{X}] &= \mu, \\ \mathrm{Var}(\overline{X}) &= \mathrm{Var}\left(\frac{1}{n}\sum_{j=1}^{n}X_j\right) \\ &= \frac{1}{n^2}\sum_{j=1}^{n}\mathrm{Var}(X_j) \\ &= \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.\end{aligned}$$

Quindi,

$$\begin{aligned}\mathbb{E}[\overline{X}^2] &= \mathrm{Var}(\overline{X}) + \mathbb{E}[\overline{X}]^2 \\ &= \frac{\sigma^2}{n} + \mu^2 \\ &= \mathbb{E}[X_i\overline{X}].\end{aligned}$$

Sostituendo nell'espressione iniziale, otteniamo

$$\begin{aligned}
\mathrm{Var}(Y_i) &= \mathbb{E}[X_i^2] - 2\mathbb{E}[X_i\overline{X}] + \mathbb{E}[\overline{X}^2] \\
&= \mathbb{E}[X_i^2] - 2\mathbb{E}[\overline{X}^2] + \mathbb{E}[\overline{X}^2] \\
&= \mathbb{E}[X_i^2] - \mathbb{E}[\overline{X}^2] \\
&= \mathrm{Var}(X_i) + \mathbb{E}[X_i]^2 - \left(\mathrm{Var}(\overline{X}) + \mathbb{E}[\overline{X}]^2\right) \\
&= \sigma^2 + \mu^2 - \left(\frac{\sigma^2}{n} + \mu^2\right) \\
&= \sigma^2 - \frac{\sigma^2}{n} \\
&= \frac{n-1}{n}\sigma^2.
\end{aligned}$$

Infine, poiché

$$S^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^2 = \frac{1}{n}\sum_{i=1}^{n} Y_i^2,$$

e $\mathbb{E}[Y_i] = 0$, otteniamo

$$\begin{aligned}
\mathbb{E}[S^2] &= \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}[Y_i^2] \\
&= \frac{1}{n}\sum_{i=1}^{n}\mathrm{Var}(Y_i) \\
&= \frac{1}{n}\sum_{i=1}^{n}\frac{n-1}{n}\sigma^2 \\
&= \boxed{\frac{n-1}{n}\sigma^2}.
\end{aligned}$$

Pertanto,

$$\boxed{\mathbb{E}[S^2] = \frac{n-1}{n}\,\mathrm{Var}[X].}$$

Per questa ragione (meglio giustificata più avanti) si preferisce utilizzare lo stimatore

$$\widetilde{S}^2 = \frac{\sum_{i=1}^{n}(X_i - \overline{X})^2}{n-1},$$

noto come **varianza campionaria corretta**, la cui media coincide con il parametro da stimare. Infatti,

$$\begin{aligned}
\mathbb{E}[\widetilde{S}^2] &= \frac{n}{n-1}\mathbb{E}[S^2] \\
&= \frac{n}{n-1}\cdot\frac{n-1}{n}\,\mathrm{Var}[X] \\
&= \mathrm{Var}[X].
\end{aligned}$$

### 2.3.2 Metodo di massima verosomiglianza

Introduciamo il concetto di **verosimiglianza**.

**Definizione 2.3.7** (Verosimiglianza)**.** Sia $f(\mathbf{x} \mid \theta)$ la densità congiunta (pmf o pdf) di un campione $\mathbf{X} = (X_1, \ldots, X_n)$. Allora, assumendo di aver osservato $\mathbf{X} = \mathbf{x}$, la funzione

$$L(\theta \mid \mathbf{x}) = f(\mathbf{x} \mid \theta) = f_\theta(x_1, x_2, \ldots, x_n)$$

è chiamata **funzione di verosimiglianza**.

**Osservazione:** Sottolineiamo due aspetti della verosimiglianza:

- La verosimiglianza, così come lo stimatore di massima verosimiglianza, non richiede dati i.i.d., né indipendenti, né identicamente distribuiti, ma soltanto la distribuzione congiunta.
- $f(\mathbf{x} \mid \theta)$ è funzione del campione, mentre la verosimiglianza è funzione di $\theta$. Ne segue che $L(\theta \mid \mathbf{x})$ non integra necessariamente a 1, come invece $f(\mathbf{x} \mid \theta)$ rispetto al campione, e non può quindi essere vista come una pdf o una pmf:

$$\int L(\theta \mid \mathbf{x})\, d\theta \neq 1.$$

Cerchiamo di interpretare la funzione di verosimiglianza assumendo che il campione $\mathbf{X}$ sia composto da variabili discrete e valutando la funzione di verosimiglianza usando due valori del parametro, $\theta_1$ e $\theta_2$, con $\theta \in \{\theta_1, \theta_2\}$.
Supponiamo di ottenere

$$L(\theta_1 \mid \mathbf{x}) = P_{\theta_1}(\mathbf{X} = \mathbf{x}) > P_{\theta_2}(\mathbf{X} = \mathbf{x}) = L(\theta_2 \mid \mathbf{x}),$$

ad esempio con valori rispettivamente pari a 0.87 e 0.32.
Questo indica che la verosimiglianza di $\theta_1$ è maggiore di quella di $\theta_2$ se e solo se la probabilità di osservare quel particolare campione da una distribuzione con parametro $\theta_1$, ossia $P_{\theta_1}(\mathbf{X} = \mathbf{x})$, è maggiore di quella con parametro $\theta_2$, ossia $P_{\theta_2}(\mathbf{X} = \mathbf{x})$.
La verosimiglianza consente quindi di confrontare i valori di $\theta$ rispetto al campione osservato. Poiché $\theta$ non è una variabile aleatoria, non gli assegniamo una probabilità.

**Esempio 2.3.8.** Sia $X \sim \text{Bern}(p)$, con $p \in \{0.2, 0.7\}$. Estraiamo un campione e osserviamo

$$\mathbf{x} = (1, 1, 1, 0, 0).$$

Valutiamo la funzione di verosimiglianza per i due possibili valori del parametro:

$$L(0.2 \mid \mathbf{x}) = (0.2)^3(0.8)^2 = 0.00512,$$
$$L(0.7 \mid \mathbf{x}) = (0.7)^3(0.3)^2 = 0.031.$$

Concludiamo che $p = 0.7$ è il valore più verosimile.
Consideriamo ora un altro campione

$$\mathbf{y} = (1, 0, 0, 0, 0).$$

In questo caso otteniamo

$$L(0.2 \mid \mathbf{y}) = (0.2)^1(0.8)^4 = 0.08192,$$
$$L(0.7 \mid \mathbf{y}) = (0.7)^1(0.3)^4 = 0.0057.$$

Per questo campione concludiamo che $p = 0.2$ è il valore più verosimile.

**Osservazione:**

- Distinguiamo la **verosimiglianza** dalla **densità congiunta** in base alla variabile considerata. Nella densità congiunta fissiamo il parametro e consideriamo il campione come variabile. Nella verosimiglianza fissiamo il campione osservato e confrontiamo i valori del parametro.

- $\theta$ non è una variabile aleatoria e quindi non è possibile assegnare una probabilità all'evento $\theta = c$, ma solo valutare quanto questo sia verosimile. Per questo motivo, il valore della verosimiglianza non è interpretabile da solo e si ragiona sempre sul rapporto o sul confronto tra valori. Ad esempio, se
$$\frac{L(\theta_1 \mid \mathbf{x})}{L(\theta_2 \mid \mathbf{x})} = \frac{P_{\theta_1}(\mathbf{X} = \mathbf{x})}{P_{\theta_2}(\mathbf{X} = \mathbf{x})} = 2,$$
concludiamo che $\theta_1$ è più verosimile di $\theta_2$. Possiamo anche dire che la sua verosimiglianza è doppia.

- Spesso lavoriamo con la **log-verosimiglianza**. Poiché il logaritmo è monotono crescente, esso preserva l'ordine tra i valori della verosimiglianza.

- Possiamo dare una simile interpretazione nel caso continuo, considerando un intorno piccolo di $\mathbf{x}$ del tipo
$$(\mathbf{x} - \varepsilon\mathbf{1}_n,\ \mathbf{x} + \varepsilon\mathbf{1}_n)$$
e considerando i rapporti
$$\frac{P_{\theta_1}(\mathbf{x} - \varepsilon\mathbf{1}_n < \mathbf{X} < \mathbf{x} + \varepsilon\mathbf{1}_n)}{P_{\theta_2}(\mathbf{x} - \varepsilon\mathbf{1}_n < \mathbf{X} < \mathbf{x} + \varepsilon\mathbf{1}_n)}$$
$$\approx \frac{(2\varepsilon)^n f(\mathbf{x} \mid \theta_1)}{(2\varepsilon)^n f(\mathbf{x} \mid \theta_2)} = \frac{f(\mathbf{x} \mid \theta_1)}{f(\mathbf{x} \mid \theta_2)} = \frac{L(\theta_1 \mid \mathbf{x})}{L(\theta_2 \mid \mathbf{x})}.$$

**Definizione 2.3.9** (Principio di verosimiglianza)**.** Se $\mathbf{x}$ e $\mathbf{y}$ sono due campioni per cui le funzioni di verosimiglianza sono proporzionali, ossia

$$L(\theta \mid \mathbf{x}) = C(\mathbf{x}, \mathbf{y})L(\theta \mid \mathbf{y}), \qquad \forall \theta \in \Theta,$$

dove $C(\mathbf{x}, \mathbf{y})$ è una costante che non dipende da $\theta$, allora l'inferenza su $\theta$ basata sui due campioni dovrebbe essere la stessa.

Valutiamo la verosimiglianza attraverso rapporti tra diversi valori di $\theta$. La costante $C(\mathbf{x}, \mathbf{y})$ si semplifica:

$$\frac{L(\theta_1 \mid \mathbf{x})}{L(\theta_2 \mid \mathbf{x})} = \frac{C(\mathbf{x}, \mathbf{y})L(\theta_1 \mid \mathbf{y})}{C(\mathbf{x}, \mathbf{y})L(\theta_2 \mid \mathbf{y})} = \frac{L(\theta_1 \mid \mathbf{y})}{L(\theta_2 \mid \mathbf{y})}.$$

Consideriamo come stima del parametro il valore che massimizza la verosimiglianza. Cerchiamo quindi una statistica, funzione dei dati, che individui il massimo della verosimiglianza o della log-verosimiglianza. Chiamiamo questa statistica **stimatore di massima verosimiglianza**.

**Definizione 2.3.10** (Stimatore di verosimiglianza)**.** Per ogni possibile campione $\mathbf{x}$ definiamo $\widehat{\theta}(\mathbf{x})$ (generalmente si scrive $\widehat{\theta}$) come un valore del parametro per cui $L(\theta \mid \mathbf{x})$ raggiunge il massimo come funzione di $\theta$, con $\mathbf{x}$ fissato.
Lo **stimatore di massima verosimiglianza (MLE)** del parametro $\theta$ basato su $\mathbf{X}$ è $\widehat{\theta}(\mathbf{X})$.

Assumiamo che il vettore dei parametri sia $\theta = (\theta_1, \ldots, \theta_p)$. In questo caso, se la funzione di verosimiglianza è differenziabile, allora possibili candidati sono i valori di $(\theta_1, \ldots, \theta_p)$ che soddisfano

$$\frac{\partial L(\theta \mid \mathbf{x})}{\partial \theta_i} = 0, \qquad i = 1, \ldots, k.$$

Questi valori sono soltanto candidati. Dobbiamo verificare che siano punti di massimo e considerare anche gli eventuali massimi sul bordo del dominio.

**Osservazione:** Notiamo che, per costruzione, lo stimatore di massima verosimiglianza appartiene sempre a $\Theta$, perché la densità congiunta è calcolata solo per valori del parametro in $\Theta$ e, quindi, non soffre del problema dello stimatore dei momenti.

**Esempio 2.3.11** (Esponenziale)**.** Assumiamo che $(X_1, \ldots, X_n)$ siano i.i.d. da una $\text{Exp}(\lambda)$ e di essere interessati a trovare lo stimatore di massima verosimiglianza di $\lambda$.
Sia $X \sim \text{Exp}(\lambda)$. Estraiamo un campione $\mathbf{x} = (10, 5, 3)$ da variabili i.i.d. e vogliamo stimare $\lambda$. La densità congiunta del campione è

$$\begin{aligned} f(\mathbf{x} \mid \lambda) &= f_X(x_1 \mid \lambda)\, f_X(x_2 \mid \lambda)\, f_X(x_3 \mid \lambda) \\ &= \lambda e^{-\lambda x_1} \cdot \lambda e^{-\lambda x_2} \cdot \lambda e^{-\lambda x_3} \\ &= \lambda^3 e^{-18\lambda} = L(\lambda \mid \mathbf{x}). \end{aligned}$$

Poiché $\lambda > 0$, con $\Theta = \mathbb{R}^+$, cerchiamo

$$\arg\max_{\lambda > 0} L(\lambda \mid \mathbf{x}),$$

oppure, applicando il logaritmo,

$$\arg\max_{\lambda > 0} \log L(\lambda \mid \mathbf{x}).$$

Otteniamo

$$\log L(\lambda \mid \mathbf{x}) = 3 \log \lambda - 18\lambda.$$

Derivando e imponendo la condizione necessaria per cercare il massimo,

$$\frac{\partial \log L(\lambda \mid \mathbf{x})}{\partial \lambda} = \frac{3}{\lambda} - 18 = 0,$$

da cui

$$\widehat{\lambda} = \frac{3}{18} = \frac{1}{6}.$$

Nel caso generale, con $\mathbf{X} = (X_1, \dots, X_n)$, ripetiamo i passaggi e otteniamo

$$f(\mathbf{X} \mid \lambda) = \lambda^n e^{-\lambda \sum_{i=1}^n X_i} = L(\lambda \mid \mathbf{X}).$$

La log-verosimiglianza è

$$\log L(\lambda \mid \mathbf{X}) = n \log \lambda - \lambda \sum_{i=1}^n X_i.$$

Derivando rispetto a $\lambda$,

$$\frac{\partial \log L(\lambda \mid \mathbf{X})}{\partial \lambda} = \frac{n}{\lambda} - \sum_{i=1}^n X_i.$$

Imponendo

$$\frac{n}{\lambda} - \sum_{i=1}^n X_i = 0,$$

ricaviamo lo stimatore di massima verosimiglianza:

$$\boxed{\widehat{\lambda} = \frac{1}{\frac{\sum_{i=1}^n X_i}{n}} = \frac{1}{\overline{X}_n}.}$$

**Esempio 2.3.12** (Normale). Assumiamo che $(X_1, \dots, X_n)$ siano i.i.d. da una $\mathcal{N}(\mu, 1)$ e di essere interessati a trovare lo stimatore di massima verosimiglianza di $\mu$, assumendo che $\Theta = \mathbb{R}$. Sia $\mathbf{X} = (X_1, \dots, X_n)$. La densità congiunta del campione è

$$\begin{aligned} f(\mathbf{x} \mid (\mu, 1)) &= \prod_{i=1}^n f(x_i \mid (\mu, 1)) \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi \cdot 1}} e^{-\frac{1}{2}\frac{(x_i-\mu)^2}{1}} \\ &= e^{-\frac{1}{2}\sum_{i=1}^n (x_i-\mu)^2} = L(\mu \mid \mathbf{x}). \end{aligned}$$

La log-verosimiglianza è

$$\log L(\mu \mid \mathbf{x}) = -\frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2.$$

Derivando rispetto a $\mu$ e imponendo la condizione necessaria per cercare il massimo,

$$\begin{aligned} \frac{\partial \log L(\mu \mid \mathbf{x})}{\partial \mu} &= (-1) \cdot (-1) \cdot 2 \cdot \frac{1}{2} \sum_{i=1}^n (x_i - \mu) \\ &= \sum_{i=1}^n x_i - n\mu = 0. \end{aligned}$$

Otteniamo quindi

$$\boxed{\widehat{\mu} = \frac{\sum_{i=1}^n X_i}{n}.}$$

**Esempio 2.3.13** (Power distribution). Supponiamo di avere un campione i.i.d. di dimensione $n$ da una variabile aleatoria $X$ con densità

$$f(x \mid \theta) = \begin{cases} \theta x^{\theta-1}, & \text{se } x \in [0,1], \\ 0, & \text{altrimenti,} \end{cases}$$

con $\theta \geq 1$. Usiamo il metodo della massima verosimiglianza per stimare $\theta$.
Supponiamo di avere $(X_1, \ldots, X_n)$ i.i.d. La densità congiunta è

$$\begin{aligned} f(\mathbf{x} \mid \theta) &= \prod_{i=1}^{n} f(x_i \mid \theta) \\ &= (\theta x_1^{\theta-1}) \cdots (\theta x_n^{\theta-1}) \\ &= \theta^n \left( \prod_{i=1}^{n} x_i \right)^{\theta-1} = L(\theta \mid \mathbf{x}). \end{aligned}$$

La log-verosimiglianza è

$$\log L(\theta \mid \mathbf{x}) = n \log \theta + (\theta - 1) \log \left( \prod_{i=1}^{n} x_i \right).$$

Derivando rispetto a $\theta$,

$$\frac{\partial \log L(\theta \mid \mathbf{x})}{\partial \theta} = \frac{n}{\theta} + \log \left( \prod_{i=1}^{n} x_i \right).$$

Ponendo la derivata uguale a zero, otteniamo

$$\boxed{\widehat{\theta} = -\frac{n}{\log \left( \prod_{i=1}^{n} X_i \right)}.}$$

Con il metodo dei momenti avevamo invece ottenuto

$$\boxed{\widehat{\theta} = \frac{M_1}{1 - M_1} = \frac{\sum_{i=1}^{n} X_i}{n - \sum_{i=1}^{n} X_i}.}$$

**Esempio 2.3.14** (Bernoulli). Assumiamo che $(X_1, \ldots, X_n)$ siano i.i.d. da una Bernoulli$(p)$ e di essere interessati a trovare lo stimatore di massima verosimiglianza di $p$, con $p \in [0,1]$.
La densità congiunta del campione è

$$f(\mathbf{x} \mid p) = \prod_{i=1}^{n} f(x_i \mid p),$$

dove

$$f(x_i \mid p) = p^{x_i}(1-p)^{1-x_i}.$$

Pertanto,

$$\begin{aligned} f(\mathbf{x} \mid p) &= \prod_{i=1}^{n} p^{x_i}(1-p)^{1-x_i} \\ &= p^{\sum_{i=1}^n x_i}(1-p)^{n-\sum_{i=1}^n x_i} \\ &= L(p \mid \mathbf{x}). \end{aligned}$$

Passando alla log-verosimiglianza,

$$\log L(p \mid \mathbf{x}) = \sum_{i=1}^{n} x_i \log p + \left(n - \sum_{i=1}^{n} x_i\right) \log(1-p).$$

Derivando rispetto a $p$,

$$\frac{\partial \log L(p \mid \mathbf{x})}{\partial p} = \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p}.$$

Poniamo la derivata uguale a zero:

$$\frac{\sum_{i=1}^n x_i}{p} = \frac{n - \sum_{i=1}^n x_i}{1-p}.$$

Da cui

$$\sum_{i=1}^{n} x_i - p\sum_{i=1}^{n} x_i = np - p\sum_{i=1}^{n} x_i.$$

Otteniamo quindi

$$\boxed{\widehat{p} = \frac{\sum_{i=1}^n X_i}{n}.}$$

**Esempio 2.3.15.** Assumiamo che $(X_1, \ldots, X_n)$ siano i.i.d. da $\mathcal{N}(\mu, \sigma^2)$. Troviamo gli stimatori di massima verosimiglianza di $\mu$ e $\sigma^2$.

$$\begin{aligned} f(\bar{x} \mid (\mu, \sigma^2)) &= \prod_{i=1}^{n} f(x_i \mid (\mu, \sigma^2)) \\ &= \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i-\mu)^2}{2\sigma^2}\right) \\ &= \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n \exp\left(-\frac{1}{2}\sum_{i=1}^{n} \frac{(x_i-\mu)^2}{\sigma^2}\right) \\ &= L((\mu, \sigma^2) \mid \bar{x}). \end{aligned}$$

Massimizziamo il logaritmo di $L((\mu, \sigma^2) \mid \bar{x})$.

$$\begin{aligned}
\log L((\mu,\sigma^2)\mid \bar{x}) &= \log\left(\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n\right) - \frac{1}{2}\sum_{i=1}^{n}\frac{(x_i-\mu)^2}{\sigma^2} \\
&= -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2 \\
&= g(\mu,\sigma^2).
\end{aligned}$$

$$\begin{aligned}
\frac{\partial g}{\partial \mu} &= \frac{1}{\sigma^2}\sum_{i=1}^{n}(x_i-\mu) = 0 \\
&\implies \sum_{i=1}^{n}(x_i-\mu) = 0 \\
&\iff \sum_{i=1}^{n} x_i = \mu n \\
&\implies \mu = \frac{\sum_{i=1}^{n} x_i}{n}. \\
&\implies \hat{\mu} = \frac{\sum_{i=1}^{n} X_i}{n} = \overline{X}.
\end{aligned}$$

$$\begin{aligned}
\frac{\partial g}{\partial \sigma^2} &= \frac{\partial}{\partial \sigma^2}\left(-\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2\right) \\
&= -\frac{n}{2\sigma^2} + \frac{1}{2}\cdot\frac{1}{\sigma^4}\sum_{i=1}^{n}(x_i-\mu)^2 = 0 \\
&\iff \frac{1}{2\sigma^2}\left(-n + \frac{1}{\sigma^2}\sum_{i=1}^{n}(x_i-\bar{x})^2\right) = 0 \\
&\iff \frac{1}{\sigma^2}\sum_{i=1}^{n}(x_i-\bar{x})^2 = n \\
&\iff \sigma^2 = \frac{\sum_{i=1}^{n}(x_i-\bar{x})^2}{n}. \\
&\implies \hat{\sigma}^2 = \frac{\sum_{i=1}^{n}(X_i-\overline{X})}{n}.
\end{aligned}$$

**Esempio 2.3.16.** Assumiamo che $(X_1,\dots,X_n)$ siano i.i.d. da $P(\lambda)$. Troviamo lo stimatore di verosimiglianza di $\lambda$.
Ricordiamo che

$$p(k\mid\lambda) = \frac{\lambda^k e^{-\lambda}}{k!}.$$

Allora

$$\begin{aligned} p(x_1, \dots, x_n \mid \lambda) &= \prod_{i=1}^{n} \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} \\ &= e^{-n\lambda} \prod_{i=1}^{n} \frac{\lambda^{x_i}}{x_i!} \\ &= L(\lambda \mid x_1, \dots, x_n). \end{aligned}$$

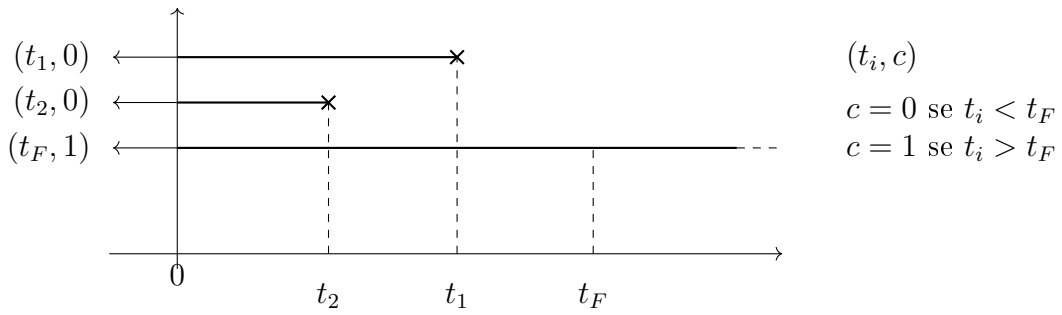
Massimizziamo il logaritmo di $L(\lambda \mid x_1, \dots, x_n)$:

$$\begin{aligned} &\frac{d}{d\lambda} \left( -n\lambda + \sum_{i=1}^{n} \log\left( \frac{\lambda^{x_i}}{x_i!} \right) \right) \\ &= \frac{d}{d\lambda} \left( -n\lambda + \sum_{i=1}^{n} x_i \log(\lambda) - \sum_{i=1}^{n} \log(x_i!) \right) \\ &= -n + \frac{1}{\lambda} \sum_{i=1}^{n} x_i = 0 \\ &\iff \lambda = \frac{\sum_{i=1}^{n} x_i}{n} = \bar{x}. \end{aligned}$$

Quindi

$$\boxed{\hat{\lambda} = \overline{X}.}$$

**Esempio 2.3.17** (Censoring). Supponiamo che $X$ rappresenti la popolazione dei tempi di vita di specifici componenti elettronici e che abbia distribuzione esponenziale di parametro $\lambda$.
In molte situazioni, anche quando il campione di componenti monitorati è di cardinalità finita $n$, non abbiamo la possibilità di osservare tutti gli $n$ tempi di vita, perché disponiamo di un tempo limitato $t_F$, al termine del quale non tutti i componenti potrebbero essersi guastati.
In questo caso, detto *right-censoring*, osserviamo coppie $(t_i, c)$, dove $c = 0$ se osserviamo $t_i$ e $c = 1$ altrimenti.
Stimiamo $\lambda$ con il metodo della massima verosimiglianza.




Consideriamo il campione

$$\big\{(t_i, c_i),\ i \in \{1, \dots, n\}\big\}.$$

La distribuzione congiunta di ciascuna osservazione è

$$f_i\big((t_i, c_i) \mid \lambda\big) = \big(\lambda e^{-\lambda t_i}\big)^{1-c_i} \cdot \big(e^{-\lambda t_F}\big)^{c_i}.$$

La distribuzione congiunta dell'intero campione, che coincide con la funzione di verosimiglianza, è

$$\begin{aligned} f\big((t,c) \mid \lambda\big) &= \prod_{j=1}^{n} \left(\lambda e^{-\lambda t_i}\right)^{1-c_i} \cdot \left(e^{-\lambda t_F}\right)^{c_i} \\ &= L\big(\lambda \mid (t,c)\big). \end{aligned}$$

Calcoliamo la log-verosimiglianza:

$$\begin{aligned} \log L\big(\lambda \mid (t,c)\big) &= \sum_{i=1}^{n} (1-c_i) \log\left(\lambda e^{-\lambda t_i}\right) + \sum_{i=1}^{n} c_i \log\left(e^{-\lambda t_F}\right) \\ &= \sum_{i=1}^{n} (1-c_i) \log \lambda + \sum_{i=1}^{n} (1-c_i)\lambda t_i + \sum_{i=1}^{n} c_i \lambda t_F. \end{aligned}$$

Derivando rispetto a $\lambda$, otteniamo

$$\frac{\partial \log L\big(\lambda \mid (t,c)\big)}{\partial \lambda} = \frac{\sum_{i=1}^{n}(1-c_i)}{\lambda} - \sum_{i=1}^{n}(1-c_i)t_i - \sum_{i=1}^{n} c_i t_F.$$

Poniamo la derivata uguale a zero e ricaviamo

$$\boxed{\widehat{\lambda} = \left[\frac{\sum_{i=1}^{n}(1-c_i)t_i + \sum_{i=1}^{n} c_i t_F}{\sum_{i=1}^{n}(1-c_i)}\right]^{-1}}.$$

**Proposizione 2.3.18** (Invarianza)**.** Se $\hat{\theta}$ è lo stimatore di massima verosimiglianza di $\theta$, allora, per ogni funzione $\tau(\theta)$, lo stimatore di massima verosimiglianza di $\tau(\theta)$ è $\tau(\hat{\theta})$.

Per la dimostrazione rimandiamo a Casella e Berger. Illustriamo il risultato mediante un esempio.

**Esempio 2.3.19.** Prendiamo un campione iid da una Poisson con parametro $\lambda$ e ricordiamo che la log-verosimiglianza è

$$\log L(\lambda \mid \mathbf{x}) = -n\lambda + \log(\lambda) \sum_{i=1}^{n} x_i - \sum_{i=1}^{n} \log(x_i!),$$

e che viene massimizzata con $\lambda = \bar{x}$.
Se utilizziamo il parametro $\eta = \tau(\lambda) = \log(\lambda)$, otteniamo la log-verosimiglianza

$$\log L(\eta \mid \mathbf{x}) = -n \exp(\eta) + \log(\exp(\eta)) \sum_{i=1}^{n} x_i - \sum_{i=1}^{n} \log(x_i!).$$

La verosimiglianza raggiunge il massimo quando $\exp(\eta) = \bar{x}$, condizione equivalente a $\lambda = \bar{x}$. Esprimendo il risultato in termini di $\eta$, otteniamo

$$\hat{\eta} = \log(\bar{x}),$$

e lo stimatore di massima verosimiglianza è

$$W(\mathbf{X}) = \log(\overline{X}),$$

come previsto dalla proposizione.

Il calcolo esplicito di uno stimatore di massima verosimiglianza può presentare difficoltà, come illustriamo nel seguente esempio.

**Esempio 2.3.20** (Gamma). Supponiamo di avere un campione iid di dimensione $n$ da una Gamma $G(a, b)$, con

$$\mathbb{E}(X) = \frac{a}{b}, \qquad \operatorname{var}(X) = \frac{a}{b^2}.$$

Cerchiamo gli stimatori di massima verosimiglianza di $a$ e $b$.
Notiamo che la log-verosimiglianza è data da

$$\log L(a, b \mid \mathbf{x}) = \sum_{i=1}^{n} \left(a \log(b) - \log(\Gamma(a)) + (a-1)\log(x_i) - b x_i\right).$$

Il calcolo della derivata prima richiede di derivare anche la funzione $\Gamma()$ rispetto al suo argomento.
Nei problemi più complessi può essere difficile ottenere una soluzione esplicita. Possiamo cercare il massimo numericamente usando R, Mathematica, Matlab o Python.

## 2.4 Metodi per valutare l'affidabilità di uno stimatore